

ÁLGEBRA LINEAR COMPUTACIONAL

Prof Nelson Antônio Borges Garcia
Professor Emérito - Instituto Militar de
Engenharia

Gen Bda Juraci Ferreira Galdino
Comandante do IME

Ano - 2023

Prefácio

Este texto foi elaborado com o intuito de dar uma formação básica em Álgebra Linear Computacional aos alunos de graduação e pós-graduação em Engenharia do IME. Ele é o resultado de uma compilação de notas de aulas de Álgebra Linear Computacional do curso de pós-graduação em Defesa do IME/EB, desde 2011.

Originalmente, esse curso foi ministrado pelo Gal Juraci Ferreira Galdino, atual Comandante do IME, tendo como professor Assistente o Cel Leonardo Oliveira de Araújo, Chefe de Informação Tecnológica, AGITEC.

Sem nenhuma pretensão de originalidade, esse texto é uma compilação de tópicos de Álgebra Linear dos livros de Cálculo do Apostol ([1] e [2]) e dos livros de Álgebra Linear

do Anton e Rores([4]) e Strang ([8]).

No segundo semestre de 2014, tive como alunos de pós-graduação pessoas importantes no meio acadêmico, entre elas: Professor Cláudio Abreu, Professor Laerte Vasconcelos, Maj Marcelo Vasconcelos, TC Bruno Madeira,... . O texto foi cuidadosamente editado em TEX pelo Professor Cláudio Abreu e enriquecido pela resolução dos exercícios propostos em MATLAB pelos alunos.

No ano de 2017, o texto foi minuciosamente revisado pelo Cel Marcelo de Araújo Oliveira, Chefe de Ensino e Pesquisa do IME.

Desde o ano de 2017, o curso de Álgebra Linear Computacional do curso de pós-graduação em Defesa do IME tem sido ministrado pelo Professor Leonardo Augusto Zão.

Agradecemos aos alunos do IME que fi-

zeram o uso deste texto durante todos esses anos e contribuíram no aprendizado em Álgebra Linear Computacional dando suas sugestões.

Conteúdo

1	Espaço Vetorial Euclidiano	8
1.1	Vetores - Introdução	8
1.2	Espaço Vetorial Euclidiano	9
1.3	Interpretação geométrica de $\mathbb{R}^n$ para $(n \leq 3)$	10
1.4	Produto Interno	12
1.5	Comprimento ou norma de um vetor	14
1.6	Ortogonalidade de Vetores	17
1.7	Projeções. Ângulo entre vetores em $\mathbb{R}^n$	18
1.8	Vetores de coordenadas unitárias	20
1.9	Norma vetorial em $\mathbb{R}^n$	21
1.10	Produto Interno Euclidiano em $\mathbb{C}^n$	23
2	Matrizes	31
2.1	Introdução	31
2.2	Operações com Matrizes	33
2.3	Propriedades das Operações com Matrizes	35
2.4	Matriz Transposta - Propriedades	35
2.5	Matriz Inversa	36
2.6	Cálculo da Matriz Inversa por operações Elementares	37
2.7	Particionamento de Matriz em blocos	40
2.8	Operações com matrizes particionadas	41
2.9	Norma de Matrizes	42
2.10	Erros nas operações com Matrizes	44
3	Resolução de Sistemas Lineares	53
3.1	Introdução	53

3.2	Método de Eliminação de Gauss	55
3.3	Pivoteamento Parcial	59
3.4	Decomposição LU	60
3.5	Cálculo da Inversa da Matriz A	63
3.6	Decomposição para Tipos Especiais de Matrizes	65
4	Espaços Vetoriais	77
4.1	Introdução	77
4.2	Subespaço Vetorial	79
4.3	Independência linear, subespaço gerado, base e dimensão	80
4.4	Soma e Interseção de Subespaços	83
4.5	Espaços Linha e Coluna de A	84
4.6	Espaço Nulo de A e Espaço nulo à esquerda de A	88
4.7	Resolução do sistema linear de m equações com n incógnitas	91
4.8	Inversa à Direita e à Esquerda de Matriz	95
5	Transformações Lineares	104
5.1	Introdução	104
5.2	Espaço Nulo e Imagem	106
5.3	Operações Algébricas em Transformações Lineares	110
5.4	Transformações Inversa à Direita e Inversa à Esquerda	112
5.5	Transformações Lineares Inversas	114
5.6	Representação Matricial das Transformações Lineares	119
5.7	Mudança de Base em Transformações Lineares	126
5.8	Isomorfismo entre Transformações Lineares	129
6	Subespaços Ortogonais. Projeções em subespaços ortogonais. Aplicações	144
6.1	Introdução	144
6.2	Subespaços Ortogonais	145
6.3	A matriz A e Subespaços Fundamentais	147
6.4	Projeção em Subespaços	149
6.5	Projeções e Aproximação pelos Mínimos Quadrados	151
6.6	Matrizes Ortogonais e ortogonalização de Gram-Schmidt	155

6.7 Fatoração QR	161
7 Determinantes	183
7.1 Função Determinante	183
7.2 Cálculo de Determinantes-Redução por Linhas	184
7.3 Cálculo de Determinantes - Expansão em Cofatores	187
7.4 Cálculo da inversa da matriz A usando Adjunta Clássica	188
7.5 Produto Vetorial de Vetores	189
8 Autovalores e Autovetores	196
8.1 Introdução	196
8.2 Autovalores e Autovetores	197
8.3 Traço de uma matriz	199
8.4 Diagonalização de uma Matriz	200
8.5 Polinômios e Matrizes	204
8.6 Potências de matrizes	206
9 Decomposição em Valores Singulares - SVD	212
9.1 Introdução	212
9.2 Desenvolvimento do cálculo da SVD	213
9.3 Aplicação da SVD no Método dos Mínimos Quadrados	220

Capítulo 1

Espaço Vetorial Euclidiano

1.1 Vetores - Introdução

Inicialmente, introduzimos o conceito de vetores, as operações algébricas, o produto interno e a norma vetorial em $\mathbf{R}^n$. Daremos também, a definição do produto interno entre vetores em $\mathbf{C}^n$, fazendo a extensão do espaço vetorial Euclidiano Real para o espaço vetorial Euclidiano Complexo.

Daremos aqui um enfoque teórico da Álgebra Linear no espaço Euclidiano, bem como aplicações em algumas áreas, exemplificadas com cálculos computacionais.

Com o surgimento dos computadores, foram criadas diversas bibliotecas em Álgebra Linear. Usando estas bibliotecas, podemos resolver diversos problemas práticos em Engenharia.

Entre as aplicações da Álgebra Linear podemos citar:

- Traçado de curvas e superfícies;
- Problemas de redes elétricas;
- Problemas em criptografia;
- Problemas de filtragem de sinais;
- Processamento digital de imagens;
- entre outros (ver Anton e Roes[4]).

Existem, essencialmente, três diferentes maneiras de introduzir a Álgebra Vetorial, (ver Apostol[2]):

- geometricamente: onde vetores são representados por segmentos de retas orientados ou flechas e as operações com estes são dadas por métodos geométricos;
- analiticamente: onde vetores e operações vetoriais são descritos em termos de números, chamados componentes;
- axiomaticamente: onde vetores e operações vetoriais têm conceitos indefinidos. Apenas, os vetores munidos das operações de adição e multiplicação de vetor por

escalar entre eles, satisfazem um certo conjunto de axiomas. Assim, tratamos os vetores como elementos de um conjunto abstrato.

1.2 Espaço Vetorial Euclidiano

Definição 1

Uma n-upla de números reais $(a_1, a_2, \dots, a_n)$, $(n \geq 1)$ é chamada de **um ponto n-dimensional** ou **vetor n-dimensional**. Os números $a_1, a_2, \dots, a_n$ são as coordenadas ou componentes do vetor. Denotamos por $\mathbf{R}^n$ o conjunto de vetores n-dimensionais, chamado de espaço vetorial n-dimensional munido das operações de adição de vetores e produto escalar por vetor dadas a seguir.

Obs.: Podemos estender este espaço vetorial aos números Complexos, onde tomamos $a_i \in \mathbf{C}^n$, $i = 1, 2, \dots, n$.

Para transformar $\mathbf{R}^n$ num sistema algébrico, introduzimos a igualdade de vetores e as duas operações: adição de vetores e multiplicação de escalar por vetor.

Definição 2

Dois vetores A e B em $\mathbf{R}^n$ são iguais quando suas componentes são iguais. Isto é, se $A = (a_1, a_2, \dots, a_n)$ e $B = (b_1, b_2, \dots, b_n)$, a equação vetorial $A = B$ significa:

$$a_1 = b_1, a_2 = b_2, \dots, a_n = b_n.$$

A soma $A + B$ é definida pela soma das componentes dos vetores A e B :

$$A + B = (a_1 + b_1, a_2 + b_2, \dots, a_n + b_n) \quad (1.1)$$

Se $\alpha \in \mathbf{R}$, definimos o produto escalar por vetor αA como:

$$\alpha A = (\alpha a_1, \alpha a_2, \dots, \alpha a_n) \quad (1.2)$$

Da definição 2, seguem as seguintes propriedades:

Propriedades

Sejam A , B e C vetores em $\mathbf{R}^n$.

1. $A + B = B + A$ (comutatividade);
2. $A + (B + C) = (A + B) + C$ (associatividade de vetores);
3. $\alpha(\beta A) = (\alpha\beta)A$, $\alpha, \beta \in \mathbf{R}$ (associatividade de escalares).
4. Além disso, são satisfeitas as leis distributivas:

$$\alpha(A + B) = \alpha A + \alpha B \quad \text{e}$$

$$(\alpha + \beta)A = \alpha A + \beta A, \quad \alpha, \beta \in \mathbf{R}.$$

O vetor $\mathbf{0}$ é chamado de vetor nulo, cujas componentes são nulas.

5. $A + \mathbf{0} = A$ (elemento neutro da adição).

O vetor $(-1)A$, também denotado por $-A$, chamado negativo de A . Daí, escrevemos:

$$A - B = A + (-B) \text{ (diferença entre } A \text{ e } B\text{)}.$$

Note que: $0A = \mathbf{0}$ e $1A = A$.

1.3 Interpretação geométrica de $\mathbf{R}^n$ para $(n \leq 3)$

Apesar das definições anteriores não estarem ligadas à geometria, vetores e operações vetoriais tem uma interpretação geométrica em espaços de dimensão $(n \leq 3)$. Por exemplo, em $\mathbf{R}^2$ (plano), um par de pontos A e B é chamado um vetor geométrico onde fixamos A como ponto inicial e B como ponto final ou extremidade, e denotamos pelo símbolo $\overrightarrow{AB}$ e visualizamos através da Figura 1.1:




Figura 1.1: *Vetor geométrico*

Vamos introduzir um sistema de coordenadas com origem O . Identificando o vetor $\overrightarrow{AB}$ em termos de suas componentes $B - A = (b_1 - a_1, b_2 - a_2)$, podemos facilmente interpretar a soma de dois vetores pela regra do paralelogramo. Assim, dados quatro pontos A, B, C e D , vértices de um paralelogramo, podemos escrever: $\overrightarrow{AB} \equiv \overrightarrow{CD}$ ($\overrightarrow{AB}$ e $\overrightarrow{CD}$ são vetores equivalentes) com $B - A = D - C \iff A + D = B + C$.

Supondo o ponto A na origem O , escrevemos: $D = B + C \iff \overrightarrow{OD} = \overrightarrow{OB} + \overrightarrow{OC}$ onde os vetores $\overrightarrow{OD}$, $\overrightarrow{OB}$ e $\overrightarrow{OC}$ são localizados na origem, conforme mostra Figura 1.2.




Figura 1.2: *Regra do Paralelogramo*

Para representar um ponto em $\mathbf{R}^n$ para $(n \leq 3)$, usaremos a letra maiúscula A , que irá representar o vetor geométrico $\overrightarrow{OA}$.

A Figura 1.3 a seguir, ilustra a interpretação geométrica da multiplicação de um escalar por vetor.




Figura 1.3: *Multiplicação de escalar por vetor*

Se $B = \alpha A$, o vetor geométrico $\overrightarrow{OB}$ tem comprimento $|\alpha|$ vezes o comprimento de $\overrightarrow{OA}$. Este vetor tem mesma direção de $\overrightarrow{OA}$ se α é positivo e direção oposta se α é negativo.

Definição 3

Dois vetores $\overrightarrow{OA}$ e $\overrightarrow{OB}$ em $\mathbf{R}^n$ têm a mesma direção se $\overrightarrow{OB} = \alpha \overrightarrow{OA}$ para algum escalar α positivo, e direção oposta se $\overrightarrow{OB} = \alpha \overrightarrow{OA}$ para algum escalar α negativo. Eles são chamados paralelos se $\overrightarrow{OB} = \alpha \overrightarrow{OA}$ para algum escalar α não nulo.

Exemplo

Sejam os pontos A , B , C e D representado na Figura 1.4, abaixo:




Figura 1.4: *Vetores Paralelos e Proporcionais*

De acordo com a Figura 1.4, temos: $|\overrightarrow{OA}| = A - O = (1, 2)$, $|\overrightarrow{BC}| = C - B = (2 - 1, 2 - 0) = (1, 2)$

Observe que as componentes de $\overrightarrow{OA}$ e $\overrightarrow{BC}$ são iguais e temos $\overrightarrow{OA} // \overrightarrow{BC}$.

Por outro lado, $|\overrightarrow{BD}| = D - B = (3/2 - 1, 1 - 0) = 1/2(1, 2)$, ou seja, $\overrightarrow{BD} = 1/2 \overrightarrow{OA}$.

1.4 Produto Interno

Introduzimos, agora, um tipo de multiplicação de vetores em $\mathbf{R}^n$ chamada de produto interno (produto escalar) em $\mathbf{R}^n$.

Definição 4

Sejam $A = (a_1, a_2, \dots, a_n)$ e $B = (b_1, b_2, \dots, b_n)$ dois vetores em $\mathbf{R}^n$, o produto interno de A e B , denotado por $A.B$, é definido por:

$$A.B = \sum_{k=1}^n a_k b_k \quad (1.3)$$

Exemplo

Sejam $A = (1, 2, 3)$ e $B = (-1, 2, -1)$ Temos que: $A.B = 1 \times (-1) + 2 \times 2 + 3 \times (-1) = 0$

Propriedades

$\forall A, B, C \in \mathbf{R}^n$ e $\forall \alpha \in \mathbf{R}$, valem as seguintes propriedades:

- a) $A.B = B.A$ (comutatividade)
- b) $A.(B + C) = (A.B) + (A.C)$ (distributividade)
- c) $\alpha(A.B) = (\alpha A).B$ (homogeneidade)
- d) $A.A > 0$ se $A \neq \mathbf{0}$ (positividade)
- e) $A.A = 0$ se $A = \mathbf{0}$

Daremos agora, um teorema que estabelece a desigualdade no produto interno de dois vetores:

Teorema 1.1 (Desigualdade de Cauchy Schwarz)

Se A e B são vetores em $\mathbf{R}^n$, temos:

$$(A.B)^2 \leq (A.A)(B.B) \quad (1.4)$$

Além do mais, a igualdade (1.4) é válida $\iff$ um vetor é múltiplo escalar do outro.

Prova

Daremos aqui uma prova baseada nas propriedades do produto interno. Se A ou B é um vetor nulo, a prova segue trivialmente. Assumamos que A e B são vetores não nulos. Seja C o vetor:

$$C = xA - yB, \text{ onde } x = B.B \text{ e } y = A.B$$

Pelas propriedades d) e e) temos que $C.C \geq 0$. Vamos expressar $C.C$ em termos de x e y .

$$C.C = (xA - yB).(xA - yB) = xA.(xA - yB) - yB.(xA - yB) = x^2(A.A) - 2xy(A.B) + y^2(B.B),$$

onde foram usadas as propriedades a), b) e c).

Usando as definições de x e y e a desigualdade $C.C \geq 0$, obtemos:

$$(B.B)^2(A.A) - 2(A.B)^2(B.B) + (A.B)^2(B.B) \geq 0$$

Por d), temos que $B.B > 0$, desde que $B \neq \mathbf{0}$. Dividindo a equação anterior por $(B.B)$, obtemos:

$$(B.B)(A.A) - (A.B)^2 \geq 0 \iff (A.B)^2 \leq (A.A)(B.B)$$

Além do mais, a igualdade vale quando $C = \mathbf{0}$, ou seja, $x A = y B$, isto é, quando A é múltiplo de B .

1.5 Comprimento ou norma de um vetor

Representamos um vetor geométrico $A = (a_1, a_2)$ no plano e localizado na origem conforme Figura 1.5.




Figura 1.5: *Comprimento de A em $\mathbf{R}^2$*

Do teorema de Pitágoras encontramos o comprimento de A pela fórmula:

$$comp(A) = \sqrt{a_1^2 + a_2^2}$$

Do mesmo modo, para o vetor geométrico $A = (a_1, a_2, a_3)$ no espaço e localizado na origem, conforme Figura 1.6,




Figura 1.6: *Comprimento de A em $\mathbf{R}^3$*

onde obtemos:

$$\text{comp}(A) = \sqrt{a_1^2 + a_2^2 + a_3^2}$$

Prosseguindo desta forma, introduzimos o conceito de comprimento de um vetor em $\mathbf{R}^n$.

Definição 5

Seja A um vetor em $\mathbf{R}^n$, o seu comprimento ou norma, denotado por $\|A\|$, é definido por:

$$\|A\| = (A.A)^{1/2} \quad (1.5)$$

De acordo com as propriedades fundamentais do produto interno, temos as seguintes propriedades para a norma:

Propriedades

Seja $A \in \mathbf{R}^n$ e seja $\alpha \in \mathbf{R}$, valem as seguintes propriedades:

- a) $\|A\| > 0$ se $A \neq \mathbf{0}$ (positividade)
- b) $\|A\| = 0$ se $A = \mathbf{0}$
- c) $\|\alpha A\| = |\alpha| \|A\|$ (homogeneidade)

Obs.: Agora, podemos escrever a desigualdade de Cauchy-Schwarz na forma:

$$|A.B| \leq \|A\| \|B\| \quad (1.6)$$

Teorema 1.2 (Desigualdade Triangular)

Se A e B são vetores em $\mathbf{R}^n$, temos:

$$\|A + B\| \leq \|A\| + \|B\| \quad (1.7)$$

Além do mais, a igualdade (1.7) é válida $\iff A = \mathbf{0}$ ou $B = \alpha A$ para algum $\alpha > 0$.

Prova

Reescrevemos a desigualdade triangular na forma equivalente:

$$\|A + B\|^2 \leq (\|A\| + \|B\|)^2$$

Desenvolvendo o lado esquerdo desta desigualdade, obtemos:

$$(\|A + B\|)^2 = (A + B).(A + B) = A.A + 2A.B + B.B = \|A\|^2 + 2A.B + \|B\|^2 \quad (1.8)$$

Por outro lado, obtemos:

$$(\|A\| + \|B\|)^2 = \|A\|^2 + 2\|A\|.\|B\| + \|B\|^2 \quad (1.9)$$

Comparando (1.8) e (1.9), vemos que a desigualdade $\|A + B\|^2 \leq (\|A\| + \|B\|)^2$ vale $\iff A.B \leq \|A\| \|B\|$

Ora, $A.B \leq |A.B| \leq \|A\| \|B\|$

Reciprocamente, se $\|A + B\|^2 \leq (\|A\| + \|B\|)^2$, então $A.B \leq \|A\| \|B\|$ vale para A e $-A$ e assim $(A.B)^2 \leq \|A\|^2 \|B\|^2$

Quando $\|A + B\| = \|A\| + \|B\|$, devemos ter: $A.B = \|A\| \|B\|$. Isto acontece quando $B = \alpha A$ para algum α .

Portanto,

$$A.B = \alpha \|A\|^2 \text{ e } \|A\| \|B\| = |\alpha| \|A\|^2.$$

Se $A \neq \mathbf{0} \implies \alpha = |\alpha| \geq 0$.

Se $B \neq \mathbf{0} \implies B = \alpha A$ com $\alpha > 0$.

1.6 Ortogonalidade de Vetores

Elevando ao quadrado ambos os lados da equação (1.7), obtemos:

$$\|A + B\|^2 \leq (\|A\| + \|B\|)^2 \quad (1.10)$$

que vale para quaisquer vetores A e B em $\mathbf{R}^n$. Vemos que a relação de Pitágoras vale somente quando $A.B = 0$. Assim, vamos definir a ortogonalidade de dois vetores em $\mathbf{R}^n$. Veja Figura 1.7.




Figura 1.7: *Desigualdade Triangular*

Definição 6

Dois vetores não nulos A e B em $\mathbf{R}^n$ são perpendiculares ou ortogonais, quando $A.B = 0$.

Desta forma, quando a igualdade na equação 1.10 ocorre para $A.B = 0$, temos a relação de Pitágoras em $\mathbf{R}^n$.

Veja a Figura 1.8.

Exemplo

Sejam $A = (a_1, a_2, \dots, a_n)$ e $B = (b_1, b_2, \dots, b_n) \in \mathbf{R}^n$ tais que: $a_j \neq 0$ para algum $j = k$ e $a_j = 0 \ \forall j \neq k, (j = 1, 2, \dots, n)$ e $b_l = 0$ para $l = k$ e $b_j \neq 0 \ \forall j \neq l, (j = 1, 2, \dots, n)$. Temos que: $A.B = 0 \times b_1 + 0 \times b_2 + \dots + a_k \times 0 \dots + 0 \times b_n = 0 + 0 + \dots + 0 \dots + 0 = 0$




Figura 1.8: *Relação de Pitágoras*

1.7 Projeções. Ângulo entre vetores em $\mathbf{R}^n$

Vamos dar uma interpretação geométrica do produto interno de dois vetores não nulos em $\mathbf{R}^2$. Para isto, consideramos o ângulo θ formado pelos vetores dados na Figura 1.9

Na Figura 1.9, temos dois vetores geométricos não nulos A e B fazendo um ângulo θ , $0 < \theta \leq \pi/2$. Na Figura 1.10, temos o mesmo vetor A , os vetores C e tB (perpendiculares) cuja soma é o vetor A . O vetor tB é chamado projeção de A ao longo de B . Na Figura 1.10, t é positivo, desde que $0 < \theta \leq \pi/2$.

Vamos usar o produto interno para expressar t em termos de A e B . Para isto, escrevemos $tB + C = A$ e efetuamos o produto interno desta igualdade por B , obtendo:

$$tB.B + C.B = A.B$$

Mas,

$$C.B = 0, \text{ uma vez que } C \perp B.$$

Portanto,

$$tB.B = A.B \text{ e assim,}$$

$$t = \frac{A.B}{B.B} = \frac{A.B}{\|B\|^2} \quad (1.11)$$

, onde $B \neq \mathbf{0}$




Figura 1.9: *Ângulo entre vetores*




Figura 1.10: *Projeção de A ao longo de B*

Por outro lado, temos que:

$$\cos(\theta) = \frac{\|tB\|}{\|A\|} = \frac{t\|B\|}{\|A\|}, t > 0 \quad (1.12)$$

Levando (1.11) em (1.12), obtemos:

$$\cos(\theta) = \frac{A.B}{\|B\|^2 \|A\|} = \frac{A.B}{\|A\| \|B\|} \quad (1.13)$$

ou ainda:

$$A.B = \|A\| \|B\| \cos(\theta) \quad (1.14)$$

Esta relação nos sugere uma maneira de definir ângulo em $\mathbf{R}^n$.

A desigualdade de Cauchy-Schwarz $|A.B| \leq \|A\| \|B\|$, agora pode ser escrita na forma de quociente:

$$\frac{|A.B|}{\|A\| \|B\|} \leq \frac{\|A\| \|B\|}{\|A\| \|B\|} = 1, \quad (1.15)$$

ou seja:

$$-1 \leq \frac{A.B}{\|A\| \|B\|} \leq 1, \quad (1.16)$$

para $0 \leq \theta \leq \pi$

Definição 7

Sejam A e B dois vetores em $\mathbf{R}^n$, com $B \neq \mathbf{0}$. O vetor tB , onde

$$t = \frac{A.B}{\|B\|^2} \quad (1.17)$$

é chamado a projeção de A ao longo de B . Se A e B são não nulos, o ângulo θ entre A e B é definido por:

$$\theta = \arccos\left(\frac{A.B}{\|A\| \|B\|}\right) \quad (1.18)$$

1.8 Vetores de coordenadas unitárias

Qualquer vetor (x_1, x_2) em $\mathbf{R}^2$ pode ser expresso na forma:

$$(x_1, x_2) = x_1(1, 0) + x_2(0, 1)$$

Os dois vetores $(1, 0)$ e $(0, 1)$ que multiplicam as componentes x_1 e x_2 são chamados de vetores coordenados unitários.

Introduzimos o conceito correspondente em $\mathbf{R}^n$.

Definição 8

Os n vetores $e_1 = (1, 0, 0, \dots, 0)$, $e_2 = (0, 1, 0, \dots, 0)$, ..., $e_n = (0, 0, 0, \dots, 1)$ são chamados vetores coordenados unitários, onde a k -ésima componente de e_k é igual a 1 e todas as outras são iguais à zero.

Obs.: Note que $e_k \cdot e_j = 0$ se $k \neq j$, ou seja, estes vetores são mutuamente ortogonais.

Ilustramos estes vetores em $\mathbf{R}^2$ e $\mathbf{R}^3$, nas Figuras 1.5 e 1.6:

A seguir, damos o seguinte teorema:

Teorema 1.3 (Vetores coordenadas unitárias)

Todo vetor $X = (x_1, x_2, \dots, x_n)$ em $\mathbf{R}^n$ pode ser escrito na forma:

$$X = x_1 e_1 + x_2 e_2 + \dots + x_n e_n = \sum_{k=1}^n x_k e_k \quad (1.19)$$

Além do mais, esta representação é única. Isto é, se $X = \sum_{k=1}^n x_k e_k$ e $Y = \sum_{k=1}^n y_k e_k$, então $x_k = y_k \ \forall k \ (k = 1, 2, \dots, n)$.

Prova

A primeira afirmação segue imediatamente da definição de adição entre vetores e multiplicação de vetor por escalar. A unicidade segue da definição de igualdade de vetores.

Um somatório do tipo $\sum c_i A_i$ é chamada uma combinação linear de vetores $A_1, A_2, \dots, A_n$. Assim, este teorema afirma que todo vetor pode ser escrito como combinação de vetores coordenados unitários. Descrevemos isto, dizendo que os vetores $e_1, e_2, \dots, e_n$ geram o espaço $\mathbf{R}^n$. Também, dizemos que estes vetores geram $\mathbf{R}^n$ unicamente, porque cada representação de um vetor como combinação linear de $e_1, e_2, \dots, e_n$ é única.

Frequentemente, em $\mathbf{R}^2$ os vetores e_1 e e_2 são representados pelas letras i e j , respectivamente, e em $\mathbf{R}^3$ os vetores e_1 , e_2 e e_3 são representados pelas letras i , j e k , respectivamente.

1.9 Norma vetorial em $\mathbf{R}^n$

Nesta seção, vamos generalizar o conceito de norma vetorial em $\mathbf{R}^n$.

Definição 9

Uma norma vetorial em $\mathbf{R}^n$ é uma função f de $\mathbf{R}^n$ em $\mathbf{R}$ que satisfaz as seguintes propriedades:

- i) $f(x) \geq 0$, $\forall x \in \mathbf{R}^n$ e $f(x) = 0 \iff x = 0$;
- ii) $f(x + y) \leq f(x) + f(y)$, $\forall x, y \in \mathbf{R}^n$;
- iii) $f(\alpha x) = |\alpha| f(x)$, $\forall \alpha \in \mathbf{R}$, $\forall x \in \mathbf{R}^n$.

A notação de barra dupla agora, indicará qualquer função norma, ou seja: $f(x) = \|x\|$, e quando necessário, usaremos um índice para especificar a mesma.

Uma classe importante de norma é a p -norma definida por:

$$\|x\|_p = (\|x_1\|^p + \|x_2\|^p + \dots + \|x_n\|^p)^{1/p}, \quad p \geq 1 \quad (1.20)$$

onde p caracteriza a norma para um dado p .

Entre elas, são mais importantes as normas:

$$\|x\|_1 = (\|x_1\| + \|x_2\| + \dots + \|x_n\|) \quad (1.21)$$

$$\|x\|_2 = (\|x_1\|^2 + \|x_2\|^2 + \dots + \|x_n\|^2)^{1/2} \quad (1.22)$$

$$\|x\|_\infty = \max_{1 \leq i \leq n} \|x_i\| \quad (1.23)$$

A norma 2, também chamada norma Euclidiana, é decorrente do produto interno de vetores, sendo a mais usada. Quando nos referimos a mesma, usaremos a notação $\|\cdot\|$ para efeito de simplificação. Um vetor unitário com respeito à norma $\|\cdot\|_p$ é um vetor x que satisfaz $\|x\|_p = 1$.

Propriedades da Norma Vetorial

1 - Um resultado clássico sobre p -normas é a desigualdade de Holder:

$$\|x^t y\| \leq \|x\|_p \|y\|_q, \quad \frac{1}{p} + \frac{1}{q} = 1 \quad (1.24)$$

Um caso mais importante disto é a desigualdade de Cauchy-Schwarz na norma Euclidiana:

$$\|x^t y\| \leq \|x\|_2 \|y\|_2 \quad (1.25)$$

2 - Todas as normas vetoriais em $\mathbf{R}^n$ são equivalentes, isto é, se $\|\cdot\|_\alpha$ e $\|\cdot\|_\beta$ são normas vetoriais em $\mathbf{R}^n$, então existem constantes positivas c_1 e c_2 tais que:

$$c_1 \|x\|_\alpha \leq \|x\|_\beta \leq c_2 \|x\|_\alpha \quad \forall x \in \mathbf{R}^n \quad (1.26)$$

Por exemplo, se $x \in \mathbf{R}^n$, então:

$$\|x\|_2 \leq \|x\|_1 \leq \sqrt{n} \|x\|_2 \quad (1.27)$$

$$\|x\|_\infty \leq \|x\|_2 \leq \sqrt{n} \|x\|_\infty \quad (1.28)$$

$$\|x\|_\infty \leq \|x\|_1 \leq n \|x\|_\infty \quad (1.29)$$

Exemplo

Seja o vetor

$$\mathbf{x} = \begin{bmatrix} 1 \\ -2 \\ 4 \\ -5 \end{bmatrix} \in \mathbf{R}^4$$

Temos:

$$\|x\|_1 = 12$$

$$\|x\|_2 = \sqrt{46}$$

$$\|x\|_\infty = 5$$

Observe que:

$$\sqrt{46} \leq 12 \leq \sqrt{4} \times \sqrt{46}$$

$$5 \leq \sqrt{46} \leq \sqrt{4} \times 5$$

$$5 \leq 12 \leq 4 \times 5$$

1.10 Produto Interno Euclidiano em $\mathbf{C}^n$

Definição 10

Se $x, y \in \mathbf{C}^n$, definimos o Produto Interno Euclidiano Complexo por:

$$(x, y)_C := \sum_{i=1}^n x_i \bar{y}_i \quad (1.30)$$

onde $\bar{y}_i$ é o complexo conjugado de y_i .

Neste caso, as propriedades para o Produto Interno Euclidiano Complexo ficam:

Propriedades

Se x, y e $z \in \mathbf{C}^n$ e α é um número complexo qualquer, então:

- a) $(x, y)_C = \overline{(y, x)_C}$;
- b) $((x + y), z)_C = (x, z)_C + (y, z)_C$;
- c) $\alpha(x, y)_C = (\alpha x, y)_C = (x, \bar{\alpha}y)_C$;
- d) $(x, x)_C \geq 0$ e $(x, x)_C = 0 \iff x = \mathbf{0}$.

A desigualdade de Cauchy-Schwarz, neste caso, fica:

$$|(x, y)_C|^2 \leq (x, x)_C (y, y)_C \quad (1.31)$$

Desde que o produto interno de um vetor por si mesmo é não negativo, podemos introduzir a norma de um vetor em $\mathbf{C}^n$ pela fórmula:

$$\|x\| = (x, x)_C^{1/2} \quad (1.32)$$

Todas as outras propriedades relacionadas com norma são também válidas em $\mathbf{C}^n$ e a ortogonalidade de vetores, no caso, é definida pela relação $(x, y)_C = 0$. Os conceitos de espaço gerado, dependência e independência linear, base são definidos para $\mathbf{C}^n$ exatamente como no caso real.

Exercícios Capítulo I

1 - Sejam $A = (1, 1, 1)$, $B = (0, 1, 1)$ e $C = (1, 1, 0)$ três vetores em $\mathbb{R}^3$ e seja $D = xA + yB + zC$, onde x , y e z são escalares.

- a) Determine as componentes de D ;
- b) Se $D = (0, 0, 0)$, mostre que $x = y = z = 0$;
- c) Encontre x, y, z tais que $D = (1, 2, 3)$.

2 - Dados os vetores $A = (2, -1, 1)$, $B = (1, 2, -1)$ e $C = (1, 1, -2)$ em $\mathbb{R}^3$. Encontre o vetor $D = xB + yC$ que é ortogonal à A e tem comprimento 1.

3 - Sejam dados dois vetores A e B em $\mathbb{R}^n$. Encontre dois vetores C e D em $\mathbb{R}^n$ satisfazendo as três condições seguintes: C é paralelo à A , D é ortogonal à A e $B = C + D$. Encontre C e D em $\mathbb{R}^3$, sendo dados $A = (1, 2, 3)$ e $B = (1, 1/2, 1/3)$.

4 - Dados os vetores $A = (\cos\theta, -\sin\theta)$ e $B = (\sin\theta, \cos\theta)$ em $\mathbb{R}^2$.

a) Mostre que A e B são vetores ortogonais e de comprimento 1. Faça uma figura ilustrando A e B quando $\theta = \pi/6$;

b) Encontre todos os vetores (x, y) em $\mathbb{R}^2$ tal que $(x, y) = xA + yB$. (Considere todas as possibilidades para θ).

5 - Três vetores A, B e C em $\mathbb{R}^3$ satisfazem as seguintes propriedades: $\|A\| = \|C\| = 5$, $\|B\| = 1$, $\|A - B + C\| = \|A + B + C\|$.

Se o ângulo entre A e B é $\pi/8$, encontre o ângulo entre B e C .

6 - Se θ é o ângulo entre dois vetores não nulos A e B em $\mathbb{R}^n$, prove que

$$\|A - B\|^2 = \|A\|^2 + \|B\|^2 - 2\|A\| \|B\| \cos\theta .$$

Quando interpretado geometricamente em $\mathbb{R}^2$, esta é a lei dos cossenos em trigonometria.

7 - Prove que para dois vetores A e B em $\mathbb{R}^n$ vale a identidade:

$$\|A + B\|^2 - \|A - B\|^2 = 4A \cdot B$$

e portanto, $A \cdot B = 0$, se e somente se, $\|A + B\| = \|A - B\|$. A interpretação geométrica deste resultado em $\mathbb{R}^2$ é a seguinte: "as diagonais de um paralelogramo são iguais, se e somente se, o paralelogramo é um retângulo".

8 - Suponha que, ao invés de se definir o produto interno de dois vetores $A = (a_1, a_2, \dots, a_n)$ e $B = (b_1, b_2, \dots, b_n) \in \mathbf{R}^n$ pela fórmula: $A \cdot B = \sum_{k=1}^n a_k b_k$, usou-se a seguinte definição:

$$A \cdot B = \sum_{k=1}^n |a_k b_k|$$

a) Quais das propriedades são válidas para esta definição, $\forall A, B, C \in \mathbf{R}^n$ e c escalar?

- i) $A \cdot B = B \cdot A$;
- ii) $A \cdot (B + C) = A \cdot B + A \cdot C$;
- iii) $c(A \cdot B) = (cA) \cdot B = A \cdot (cB)$;
- iv) $A \cdot A > 0$ se $A \neq \mathbf{0}$;
- v) $A \cdot A = 0$ se $A = \mathbf{0}$.

9 - Suponha que, ao invés de se definir a norma de um vetor $A = (a_1, a_2, \dots, a_n) \in \mathbf{R}^n$ pela fórmula: $(A \cdot A)^{1/2}$, usou-se a seguinte definição:

$$\|A\| = \sum_{k=1}^n |a_k|$$

a) Prove que esta definição satisfaz as seguintes propriedades:

- i) $\|A\| > 0$ se $A \neq \mathbf{0}$;
- ii) $\|A\| = 0$ se $A = \mathbf{0}$;
- iii) $\|cA\| = |c| \|A\|$;
- iv) $\|A + B\| \leq \|A\| + \|B\|$.

b) Use esta definição em $\mathbf{R}^2$ e descreva a figura formada pelo conjunto de todos os pontos (x, y) com norma igual a 1.

c) Verifique quais das quatro propriedades listadas no item a) são válidas ao se utilizar a seguinte definição de norma:

$$\|A\| = \left| \sum_{k=1}^n a_k \right|$$

Implementação dos Exercícios do Capítulo I em Matlab

```
1 %Exercicios Capitulo 1
2
3 % clear
4 %Exercicio 1 Letra c
5 %Ax=B
6 %A-1*A*x=A-1*B
7 %x=A-1*B
8
9 % A=[1 0 1; 1 1 1; 1 1 0]
10 % B=[1; 2; 3]
11 % A-1*B
12
13 %Exercicio 4 letra 2
14
15 % A=[cos(pi/6), -sin(pi/6)]
16 % B=[sin(pi/6), cos(pi/6)]
17 %
18 % dot(A,B)
19 %
20 % x=linspace(0,cos(pi/6),100);
21 % y=(cos(pi/6)/sin(pi/6))*x;
22 % plot(x,y)
23 % hold
24 % x2=linspace(-cos(pi/6),0,100);
25 % y2=(-sin(pi/6)/cos(pi/6))*x2;
26 % plot(x2,y2,'g')
27
28 %Exercicio 8 Exemplo de funcao com matlab
29
30 % A=[1 -2 3 4]
31 % B=[4 3 -2 1]
32 %
33 % produto=cap1ex8(A,B)
34
35 %Funcao utilizada
36
37 % function[produto]=cap1ex8(A,B)
38 % na=size(A');
39 % nb=size(B');
40 % if na~=nb
41 %     return
42 % end
43 % n=na(1);
44 % produto=0;
```

```
45 % for i=1:n
46 %     produto=produto+abs(A(i)*B(i));
47 % end
48 % end
```

Implementação de Exemplos do Capítulo I em Matlab

```
1 %Capitulo 1 Espaco Vetorial Euclidiano
2
3 % Representacao de Vetores em Matrizes
4
5 % disp('Vetor A na forma de matriz linha')
6 % A=[2 3]
7 %
8 % disp('Vetor B na forma de matriz coluna')
9 % B=[2
10 %    3]
11 % C=[2 3 4;5 6 7]
12 %
13 %
14 % disp('A transposto')
15 % A'
16 % disp('B transposto')
17 % B'
18 %
19 % disp('Soma de vetores')
20 % A+B'
21 % A'+B
22 % (A+B')'+A'+B
23 %
24 % disp('Multiplicacao por escalar')
25 % 2*A
26
27 %Exercício: Exemplifique as propriedades do Espaco Vetorial
    Euclidiano com
28 %vetores no  $R_4$ .
29
30 % clear
31 %
32 % A=[2 4 4 1]
33 % B=[1:4]
34 % C=[2:5]
35 % D(1:4)=1
36 % D(1:4)=0
37 %
38 % %Exemplo
39 % % A+B
40 % % B+A
41 %
42 %Produto Interno
43 % A
```

```

44 % B
45 % disp('Metodo 1')
46 % A(1)*B(1)+A(2)*B(2)+A(3)*B(3)+A(4)*B(4)
47 % disp('Metodo 2')
48 % Prod=0;
49 % for i=1:4
50 %     Prod=Prod+A(i)*B(i);
51 % end
52 % Prod
53 % % disp('Metodo 3')
54 % sum(A.*B)
55 % % %Funcao Pronta do Matlab
56 % % disp('Metodo 4')
57 % dot(A,B)
58 %
59 % Norma de um vetor
60 % disp('Metodo 1')
61 % N=sqrt(A(1)^2+A(2)^2+A(3)^2+A(4)^2)
62 % Funcao Pronta do Matlab
63 % disp('Metodo 2')
64 % norm(A)
65 %
66 % P-Norma
67 % disp('Norma 1')
68 % norm(A,1)
69 % disp('Norma 2')
70 % norm(A,2)
71 % disp('Norma 3')
72 % norm(A,3)
73 % disp('Norma Inf')
74 % norm(A,Inf)

```

Capítulo 2

Matrizes

2.1 Introdução

No capítulo 5, iremos definir aplicações lineares de um espaço vetorial $\mathbf{R}^n$ em outro espaço vetorial $\mathbf{R}^m$. Estas são chamadas transformações lineares. As matrizes aparecem de forma natural na representação destas transformações lineares. Podemos usar esta conexão com as transformações lineares para definir matrizes. Por enquanto, vamos tratar matrizes como classe de objetos matemáticos, onde definimos operações algébricas.

Definição 1

Sejam m e n dois inteiros positivos, e seja $I_{m,n}$ o conjunto de todos os pares de inteiros (i, j) tais que $1 \leq i \leq m$, $1 \leq j \leq n$. Qualquer função A cujo domínio é $I_{m,n}$ é chamada uma matriz $m \times n$. A função cujo valor é $A(i, j)$ é chamada o valor de entrada- ij ou elemento- ij ou coeficiente- ij da matriz A (também denotado por a_{ij}). Usualmente, representamos uma matriz retangular A com m linhas e n colunas por:

$$\mathbf{A} = \begin{bmatrix} a_{11} & a_{12} & \dots & a_{1n} \\ a_{21} & a_{22} & \dots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{m1} & a_{m2} & \dots & a_{mn} \end{bmatrix}$$

Os elementos a_{ij} podem pertencer a qualquer conjunto. Aqui, tomamos estes elementos pertencentes ao conjunto dos números reais ($\mathbf{R}$) ou ao conjunto dos números complexos ($\mathbf{C}$).

Muitas vezes, será conveniente representar as matrizes na forma compacta:

$$A = (a_{ij})_{i,j=1}^{m,n} \text{ ou } A = (a_{ij}) \quad (2.1)$$

Se $m = n$, a matriz A é dita quadrada de ordem n .

Matriz coluna é a matriz:

$$\begin{bmatrix} a_{1k} \\ a_{2k} \\ \vdots \\ a_{mk} \end{bmatrix}$$

para um dado inteiro positivo k . Também chamado de vetor coluna.

Matriz linha é a matriz:

$$\begin{bmatrix} a_{k1} & a_{k2} & \dots & a_{kn} \end{bmatrix}$$

para um dado inteiro positivo k . Também chamado de vetor linha.

Damos, a seguir, alguns tipos de matrizes encontradas em aplicações da engenharia.

Definição 2

A matriz transposta de A , denotada por A^t , é a matriz cujos coeficientes a_{ij} são os coeficientes a_{ji} de A , ou seja, as colunas da matriz A são as linhas da matriz A^t e vice-versa. Notamos por:

$$A^t(i, j) = A(j, i) \quad (2.2)$$

Quanto a forma, classificamos as seguintes matrizes quadradas A , $n \times n$:

-diagonal: se $a_{ij} = 0$ para $i \neq j$;

-triangular superior: se $a_{ij} = 0$ para $i > j$;

-triangular inferior: se $a_{ij} = 0$ para $i < j$;

-tridiagonal: se $a_{ij} = 0$ para $|i - j| > 1$;

-pentadiagonal: se $a_{ij} = 0$ para $|i - j| > 2$;

-identidade: é uma matriz diagonal onde $a_{ii} = 1$, denotada por I ;

-simétrica: é uma matriz quadrada com $a_{ij} = a_{ji}$, para $i, j = (1, 2, \dots, n)$, ou seja, $A = A^t$.

Definição 3

Duas matrizes A e B são iguais quando têm o mesmo número de linhas e o mesmo número de colunas e seus coeficientes são iguais.

$$A = B \iff a_{ij} = b_{ij} \quad \forall i, j \quad (2.3)$$

onde

$$A = (a_{i,j}) \text{ e } B = (b_{i,j}) \quad (2.4)$$

2.2 Operações com Matrizes

1 - Adição e Subtração

Sejam as matrizes A, B e C , $m \times n$. Diz-se que $C = A \pm B$ quando

$$c_{ij} = a_{ij} \pm b_{ij} \quad \forall i, j \quad i = 1, 2, \dots, m; \quad j = 1, 2, \dots, n \quad (2.5)$$

2 - Multiplicação por escalar

Sejam as matrizes A e D , $m \times n$, e seja o escalar α . Definimos o produto do escalar α pela matriz A como:

$$D = \alpha A \quad (2.6)$$

onde, $d_{ij} = \alpha a_{ij}$, $\forall i, j \quad i = 1, 2, \dots, m; \quad j = 1, 2, \dots, n$

2 - Multiplicação de matrizes

Sejam as matrizes A e B , $l \times m$ e $m \times n$, respectivamente. Define-se a matriz produto C , $l \times n$, obtida pela multiplicação das matrizes A e B e nota-se $C = AB$, cujos elementos são dados por:

$$c_{ij} = \sum_{k=1}^m a_{ik} b_{kj} \quad i = 1, 2, \dots, l; \quad j = 1, 2, \dots, n \quad (2.7)$$

Observe que c_{ij} é o produto interno entre a i -ésima linha da matriz A e a j -ésima coluna da matriz B .

Um caso especial de multiplicação de matriz ocorre quando a segunda matriz é um vetor coluna x , isto é, o produto matriz vetor Ax . Este produto é interpretado como combinação linear das componentes do vetor x . Assim, suponhamos que:

$$\mathbf{A} = \begin{bmatrix} a_1 & a_2 & \dots & a_n \end{bmatrix} \in \mathbf{R}^{m,n} \text{ com } a_i \in \mathbf{R}^n$$

e

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix}$$

Então,

$$Ax = a_1 x_1 + a_2 x_2 + \dots + a_n x_n \in \mathbf{R}^m$$

Exemplo

Sejam:

$$\mathbf{A} = \begin{bmatrix} 9 & 8 & 7 \\ 6 & 5 & 4 \end{bmatrix}$$

e

$$\mathbf{x} = \begin{bmatrix} 3 \\ 2 \\ 1 \end{bmatrix}$$

Calculando o produto Ax , obtemos:

$$\mathbf{Ax} = \begin{bmatrix} 50 \\ 32 \end{bmatrix}$$

Este mesmo produto pode ainda ser calculado por $x^t A^t$, onde x^t é o transposto do vetor coluna x e A^t é a matriz A transposta. Assim:

$$\mathbf{x}^t \mathbf{A}^t = \begin{bmatrix} 3 & 2 & 1 \end{bmatrix} \begin{bmatrix} 9 & 6 \\ 8 & 5 \\ 7 & 4 \end{bmatrix} = \begin{bmatrix} 50 & 32 \end{bmatrix}$$

Para multiplicação matricial, suponhamos que $A \in \mathbf{R}^{m,n}$ e

$$\mathbf{B} = \begin{bmatrix} b_1 & b_2 & \dots & b_p \end{bmatrix} \in \mathbf{R}^{n,p} \text{ com } b_i \in \mathbf{R}^n.$$

Então, a matriz produto AB pode ser tratada como anteriormente, aplicada p vezes:

$$\mathbf{AB} = \mathbf{A} \begin{bmatrix} b_1 & b_2 & \dots & b_p \end{bmatrix} = \begin{bmatrix} Ab_1 & Ab_2 & \dots & Ab_p \end{bmatrix} \in \mathbf{R}^{m,p}$$

Segundo esta formulação para produto de matrizes, podemos enunciar o seguinte teorema:

Teorema 2.1(Produto de matrizes)

Sejam

$$\mathbf{U} = \begin{bmatrix} u_1 & u_2 & \dots & u_n \end{bmatrix} \in \mathbf{R}^{m,n} \text{ com } u_i \in \mathbf{R}^m$$

e

$$\mathbf{V} = \begin{bmatrix} v_1 & v_2 & \dots & v_n \end{bmatrix} \in \mathbf{R}^{p,n} \text{ com } v_i \in \mathbf{R}^p.$$

Então,

$$UV^t = \sum_{i=1}^n u_i v_i^t \in \mathbf{R}^{m,p} \quad (2.8)$$

Este teorema nos permite escrever o produto interno Euclidiano para vetores $x, y \in \mathbf{R}^n$ na forma de produto matricial. Ou seja, considerando x e y como vetores coluna em $\mathbf{R}^n$, na forma matricial escrevemos:

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix} \text{ e } \mathbf{y} = \begin{bmatrix} y_1 \\ y_2 \\ \vdots \\ y_n \end{bmatrix}$$

e o produto interno Euclidiano de x e y pode ser escrito na forma:

$$\langle x, y \rangle := x^t y = \sum_{i=1}^n x_i y_i \quad (2.9)$$

2.3 Propriedades das Operações com Matrizes

Assumindo que A, B e C são matrizes com dimensões compatíveis, onde o produto por escalar pode ser definido e que $\lambda, \mu \in \mathbf{R}$, então:

- 1) $(\lambda\mu)A = \lambda(\mu A)$;
 - 2) $(\lambda + \mu)A = \lambda A + \mu A$;
 - 3) $\lambda(A + B) = \lambda A + \lambda B$;
 - 4) $A(BC) = (AB)C$;
 - 5) $A(B + C) = AB + AC$;
 - 6) $(A + B)C = AC + BC$;
 - 7) $\lambda(AB) = (\lambda A)B = A(\lambda B)$;
- e, em geral,
- 8) $AB \neq BA$.

2.4 Matriz Transposta - Propriedades

No início deste capítulo, definimos a matriz transposta de A e a denotamos por A^t . Para matrizes $A, n \times n$, definimos a matriz simétrica, onde os coeficientes $a_{ij} = a_{ji} \forall i, j = (1, 2, \dots, n)$. Ou seja, para matrizes simétricas têm-se $A = A^t$.

Propriedades

Assumindo que A e B são matrizes com dimensões compatíveis e λ é um escalar em $\mathbf{R}$, são válidos os seguintes resultados:

- 1) $(A^t)^t = A$;
- 2) $(A + B)^t = A^t + B^t$;
- 3) $(\lambda A)^t = \lambda A^t$;

$$4) (AB)^t = B^t A^t.$$

Obs.: Para a propriedade 4), basta que a matriz A seja $m \times p$ e que a matriz B seja $p \times n$, sendo possível definir o produto $C = AB$, onde C será uma matriz $m \times n$. Note que, o produto $B^t A^t$ dará uma matriz $C, m \times n$.

2.5 Matriz Inversa

Definimos no início deste capítulo a matriz identidade I , onde os coeficientes diagonais são iguais a 1 e os coeficientes extradiagonais são nulos. Geralmente, a denotamos por I quando não houver necessidade de especificar a dimensão da mesma, mas caso necessário, a denotamos por I_n .

Definição 4

Dada uma matriz A , $n \times n$, se pudermos encontrar uma matriz B de mesma dimensão tal que $AB = BA = I$, então dizemos que a matriz A é invertível e que a matriz B é a inversa da matriz A . Se não puder ser encontrada uma tal matriz B , então dizemos que a matriz A é não invertível ou singular.

Nota-se: Notamos por A^{-1} a inversa da matriz A .

Exemplos

1 - A matrix

$$\mathbf{B} = \begin{bmatrix} 3 & 5 \\ 1 & 2 \end{bmatrix}$$

é a inversa da matriz

$$\mathbf{A} = \begin{bmatrix} 2 & -5 \\ -1 & 3 \end{bmatrix}$$

pois, $AB = BA = I$.

2 - A matrix

$$\mathbf{A} = \begin{bmatrix} 1 & 4 & 0 \\ 2 & 5 & 0 \\ 3 & 6 & 0 \end{bmatrix}$$

é singular.

De fato, seja

$$\mathbf{B} = \begin{bmatrix} b_{11} & b_{12} & b_{13} \\ b_{21} & b_{22} & b_{23} \\ b_{31} & b_{32} & b_{33} \end{bmatrix}$$

uma matriz qualquer.

O produto da matriz B pela terceira coluna da matriz A nos dá o vetor coluna $\begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}$,

que deveria ser igual à $\begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix}$ caso a matriz A fosse invertível.

Propriedades

1 - Se B e C são matrizes, $n \times n$, ambas inversas da matriz A , $n \times n$, então $B = C$.

2 - Se A e B são matrizes, $n \times n$, invertíveis, então a matriz produto AB é invertível e:

$$(AB)^{-1} = B^{-1}A^{-1}.$$

3 - Se A é uma matriz, $n \times n$, invertível, então:

a) A^{-1} é invertível e $(A^{-1})^{-1} = A$;

b) A^n é invertível e $(A^n)^{-1} = (A^{-1})^n$, ($n = 1, 2, \dots$), onde definimos a potência da matriz A por:

$A^0 = I$ e $A^n = AA \dots A$, (n fatores);

c) Para qualquer escalar k não nulo, a matriz kA é invertível e:

$$(kA)^{-1} = \frac{1}{k}A^{-1};$$

d) A matriz A^t é também uma matriz invertível e $(A^t)^{-1} = (A^{-1})^t$.

De fato:

$$A^t(A^{-1})^t = (A^{-1}A)^t = I^t = I$$

$$(A^{-1})^t A^t = (AA^{-1})^t = I^t = I$$

2.6 Cálculo da Matriz Inversa por operações Elementares

Definição 5

Uma matriz elementar E é uma matriz $n \times n$ que pode ser obtida da matriz identidade I , $n \times n$, executando uma única operação elementar sobre as linhas da mesma.

São operações elementares em matrizes:

1 - Multiplicar uma linha da matriz por uma constante;

2 - Trocar duas linhas da matriz entre si;

3 - Somar um múltiplo de uma linha da matriz a uma outra linha da mesma.

Exemplo

As seguintes matrizes são elementares:

$$\mathbf{E}_1 = \begin{bmatrix} 0 & 1 \\ 1 & 0 \end{bmatrix}, \quad \mathbf{E}_2 = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 2 & 1 \end{bmatrix}, \quad \mathbf{E}_3 = \begin{bmatrix} 5 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

Proposição 2.1

Se a matriz elementar E , $m \times m$, resulta em efetuar uma certa operação sobre as linhas de I , $m \times m$, e se A é uma matriz, $m \times n$, então o produto EA é a matriz que resulta quando esta mesma operação sobre linhas é efetuada na matriz A .

Exemplo

Seja a matriz:

$$\mathbf{A} = \begin{bmatrix} 1 & 0 & 2 & 3 \\ 2 & -1 & 3 & 6 \\ 1 & 4 & 4 & 0 \end{bmatrix}$$

e seja a seguinte matriz elementar:

$$\mathbf{E} = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 3 & 0 & 1 \end{bmatrix}$$

Temos que,

$$\mathbf{EA} = \begin{bmatrix} 1 & 0 & 2 & 3 \\ 2 & -1 & 3 & 6 \\ 4 & 4 & 10 & 9 \end{bmatrix}$$

onde a terceira linha da matriz produto EA é igual a três vezes a primeira linha de A mais a terceira linha de A .

Proposição 2.2

Qualquer matriz elementar E , $n \times n$, é invertível e a sua inversa E^{-1} , é também uma matriz elementar. Daí, se a matriz A , $n \times n$, é invertível, então sua inversa A^{-1} , pode ser escrita como um produto de matrizes elementares.

Vamos utilizar este último resultado no cálculo da inversa de uma matriz A , $n \times n$, invertível.

Cálculo da inversa de matriz

Assim, de acordo com a **proposição 2.2**, caso exista A^{-1} , escrevemos:

$$A^{-1} = E_k E_{k-1} \dots E_2 E_1 \tag{2.10}$$

Escrevendo:

$$A^{-1}A = I$$

obtemos:

$$E_k E_{k-1} \dots E_2 E_1 A = I \implies A = E_1^{-1} E_2^{-1} \dots E_{k-1}^{-1} E_k^{-1} I \implies A = E_1^{-1} E_2^{-1} \dots E_{k-1}^{-1} E_k^{-1}$$

Desta forma, para se obter a inversa da matriz A , $n \times n$, basta multiplicá-la por matrizes elementares convenientes reduzindo-a a uma matriz identidade.

Exemplo

Seja calcular a inversa da matriz:

$$\mathbf{A} = \begin{bmatrix} 1 & 2 & 3 \\ 2 & 5 & 3 \\ 1 & 0 & 8 \end{bmatrix}$$

Inicialmente, colocamos esta matriz acoplada com a matriz identidade I :

$$\begin{bmatrix} 1 & 2 & 3 & 1 & 0 & 0 \\ 2 & 5 & 3 & 0 & 1 & 0 \\ 1 & 0 & 8 & 0 & 0 & 1 \end{bmatrix}$$

Multiplicamos esta matriz aumentada, sucessivamente, pelas matrizes elementares:

$$\mathbf{E}_1 = \begin{bmatrix} 1 & 0 & 0 \\ -2 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}, \quad \mathbf{E}_2 = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ -1 & 0 & 1 \end{bmatrix}$$

obtendo:

$$\begin{bmatrix} 1 & 2 & 3 & 1 & 0 & 0 \\ 0 & 1 & -3 & -2 & 1 & 0 \\ 0 & -2 & 5 & -1 & 0 & 1 \end{bmatrix}$$

Multiplicamos esta matriz aumentada, sucessivamente, pelas matrizes elementares:

$$\mathbf{E}_3 = \begin{bmatrix} 1 & -2 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}, \quad \mathbf{E}_4 = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 2 & 1 \end{bmatrix}$$

obtendo:

$$\begin{bmatrix} 1 & 0 & 9 & 5 & -2 & 0 \\ 0 & 1 & -3 & -2 & 1 & 0 \\ 0 & 0 & -1 & -5 & 2 & 1 \end{bmatrix}$$

Finalmente, multiplicamos esta matriz aumentada, sucessivamente, pelas matrizes elementares:

$$\mathbf{E}_5 = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & -1 \end{bmatrix}, \quad \mathbf{E}_6 = \begin{bmatrix} 1 & 0 & -9 \\ 0 & 1 & 0 \\ 0 & 0 & 1 \end{bmatrix}, \quad \mathbf{E}_7 = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 3 \\ 0 & 0 & 1 \end{bmatrix}$$

obtendo:

$$\begin{bmatrix} 1 & 0 & 0 & -40 & 16 & 9 \\ 0 & 1 & 0 & 13 & -5 & -3 \\ 0 & 0 & 1 & 5 & -2 & -1 \end{bmatrix}$$

Portanto, a matriz inversa é:

$$\mathbf{A}^{-1} = \begin{bmatrix} -40 & 16 & 9 \\ 13 & -5 & -3 \\ 5 & -2 & -1 \end{bmatrix}$$

2.7 Particionamento de Matriz em blocos

Vamos considerar a seguinte matriz genérica A , 3×4 ,

$$\mathbf{A} = \begin{bmatrix} a_{11} & a_{12} & a_{13} & a_{14} \\ a_{21} & a_{22} & a_{23} & a_{24} \\ a_{31} & a_{32} & a_{33} & a_{34} \end{bmatrix}$$

com $a_{ij} \in \mathbf{R}$, $i = 1, 2, 3$ e $j = 1, 2, 3, 4$.

Definindo-se

$$\mathbf{A}_{11} = \begin{bmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{bmatrix}, \quad \mathbf{A}_{12} = \begin{bmatrix} a_{13} & a_{14} \\ a_{23} & a_{24} \end{bmatrix}, \quad \mathbf{A}_{21} = \begin{bmatrix} a_{31} & a_{32} \end{bmatrix}, \quad \mathbf{A}_{22} = \begin{bmatrix} a_{33} & a_{34} \end{bmatrix}$$

Obtemos a matriz A na forma de matriz bloco:

$$\mathbf{A} = \begin{bmatrix} \mathbf{A}_{11} & \mathbf{A}_{12} \\ \mathbf{A}_{21} & \mathbf{A}_{22} \end{bmatrix}$$

Regras

- O índices das matrizes bloco indicam as suas posições na matriz original.
- O particionamento pode ser empregado para contemplar matrizes de quaisquer dimensões.
- Para uma mesma matriz existem várias maneiras de particionamento. A regra utilizada para particionamento é fazer com que as submatrizes que possuem o primeiro subíndice igual contenham a mesma quantidade de linhas e as que possuem o segundo subíndice igual contenham a mesma quantidade de colunas.

2.8 Operações com matrizes particionadas

Assumindo que,

$$\mathbf{A} = \begin{bmatrix} A_{11} & \dots & A_{1l} \\ \vdots & \ddots & \vdots \\ A_{k1} & \dots & A_{kl} \end{bmatrix} \text{ e } \mathbf{B} = \begin{bmatrix} B_{11} & \dots & B_{1l} \\ \vdots & \ddots & \vdots \\ B_{k1} & \dots & B_{kl} \end{bmatrix}$$

sendo as submatrizes A_{ij} de dimensões $\mu_i \times \lambda_j$ e B_{ij} de dimensões $\nu_i \times \beta_j$. Definimos:

Multiplicação por Escalar

$$\alpha \mathbf{A} = \begin{bmatrix} A_{11} & \dots & A_{1l} \\ \vdots & \ddots & \vdots \\ A_{k1} & \dots & A_{kl} \end{bmatrix} = \begin{bmatrix} \alpha A_{11} & \dots & \alpha A_{1l} \\ \vdots & \ddots & \vdots \\ \alpha A_{k1} & \dots & \alpha A_{kl} \end{bmatrix}$$

onde $\alpha \in \mathbf{R}$.

Adição de Matrizes

Assumindo $k = m$, $l = n$, $\mu_i = \nu_i$, e $\lambda_j = \beta_j$, temos que:

$$\mathbf{C} = \mathbf{A} + \mathbf{B} = \begin{bmatrix} C_{11} & \dots & C_{1l} \\ \vdots & \ddots & \vdots \\ C_{k1} & \dots & C_{kl} \end{bmatrix}$$

onde $C_{ij} = A_{ij} + B_{ij}$.

Transposição de Matriz

A transposta da matriz A é dada por:

$$\mathbf{A}^t = \begin{bmatrix} A_{11}^t & \dots & A_{1l}^t \\ \vdots & \ddots & \vdots \\ A_{k1}^t & \dots & A_{kl}^t \end{bmatrix}$$

Multiplicação de Matrizes

Assumindo que as dimensões das matrizes A e B são compatíveis para realizar o produto AB , ou seja, A , $r \times p$, e B , $p \times s$, e que $l = m$ e $\lambda_i = \nu_i$ (ou seja, o produto das submatrizes possa ser obtido, temos:

$$\mathbf{C} = \mathbf{AB} = \begin{bmatrix} C_{11} & \dots & C_{1l} \\ \vdots & \ddots & \vdots \\ C_{kl} & \dots & C_{kl} \end{bmatrix}$$

onde $C_{ij} = \sum_{s=1}^l A_{is} B_{sj}$.

O particionamento de matrizes em bloco é utilizado em alguns métodos envolvendo operações com matrizes em bloco como Decomposição em Valor Singular(SVD), que veremos no final deste curso.

2.9 Norma de Matrizes

A análise de algoritmos matriciais, frequentemente, requer o uso de normas matriciais. Por exemplo, a norma é utilizada em: estudo de sistemas lineares com matrizes "quase singulares", na verificação de matrizes "matrizes mal condicionadas", e assim por diante. Daí, a necessidade de se medir distâncias no espaço das matrizes, sendo que a norma matricial provê esta medida, ver Albrecht e Golub [1, 6].

Definição 6

Uma norma matricial para matrizes $A \in \mathbf{R}^{m \times n}$ é uma função f de $\mathbf{R}^{m \times n}$ em $\mathbf{R}$ que satisfaz as seguintes propriedades:

- i) $f(A) \geq 0$, $\forall A \in \mathbf{R}^{m \times n}$ e $f(A) = 0 \iff A = \mathbf{0}$;
- ii) $f(A + B) \leq f(A) + f(B)$, $\forall A, B \in \mathbf{R}^{m \times n}$;
- iii) $f(\alpha A) = |\alpha| f(A)$, $\forall \alpha \in \mathbf{R}$, $\forall A \in \mathbf{R}^{m \times n}$.

A notação de barra dupla agora, indicará qualquer função norma matricial, ou seja: $f(A) = \|A\|$, e quando necessário, usaremos um índice para especificar a mesma.

Para tratarmos as matrizes $A \in \mathbf{R}^{m \times n}$ como operadores lineares de $\mathbf{R}^m$ em $\mathbf{R}^n$ (falaremos em operadores lineares no capítulo sobre transformações lineares), à definição de norma matricial acrescentamos as seguintes condições relacionadas com a norma vetorial:

- iv) $\|Ax\| \leq \|A\| \|x\| \quad \forall A \in \mathbf{R}^{m \times n}, \forall x \in \mathbf{R}^n$;
- v) $\forall A \in \mathbf{R}^{m \times n}, \exists y \in \mathbf{R}^n$ tal que $\|Ay\| = \|A\| \|y\|$.

Definição 7

Uma norma matricial é dita consistente com uma norma vetorial quando,
 $\forall A \in \mathbf{R}^{m \times n}, \forall x \in \mathbf{R}^n$

$$\|Ax\| \leq \|A\| \|x\| \quad (2.11)$$

Definição 8

Uma norma matricial é dita subordinada a uma norma vetorial quando,
 $\forall A \in \mathbf{R}^{m \times n}, \exists y \in \mathbf{R}^n, y \neq \mathbf{0}$

$$\|Ay\| = \|A\| \|y\| \quad (2.12)$$

As normas mais frequentes em Álgebra Linear Numérica são:

i) A norma de Frobenius

$$\|A\|_F = \sqrt{\sum_{i=1}^m \sum_{j=1}^n |a_{ij}|^2} = |tr(AA^t)^{1/2}| \quad (2.13)$$

e ii) as p -normas:

$$\|A\|_p = \sup_{x \neq \mathbf{0}} \frac{\|Ax\|_p}{\|x\|_p} \quad (2.14)$$

Obs.: $\|A\|_p$ é a p -norma do maior vetor obtido aplicando A a um vetor de p -norma unitária:

$$\|A\|_p = \sup_{x \neq \mathbf{0}} \|A(\frac{x}{\|x\|_p})\|_p = \max_{\|x\|_p=1} \|Ax\|_p \quad (2.15)$$

Propriedades

As normas de Frobenius e p -normas (especialmente $p = 1, 2, \infty$) satisfazem certas desigualdades que são frequentemente usadas na análise de cálculos matriciais. Para $A \in \mathbf{R}^{m \times n}$, temos:

1)

$$\|A\|_2 \leq \|A\|_F \leq \sqrt{n} \|A\|_2 \quad (2.16)$$

onde

$$\|A\|_2 = \max_{1 \leq i \leq n} |\sqrt{\mu_i}|, \text{ sendo } \mu_i \text{ os autovalores de } A^t A$$

Esta norma é subordinada à norma vetorial Euclidiana $\|x\|_2 = \sqrt{\sum_{i=1}^n x_i^2}$. Ela é também conhecida como norma Espectral.

2)

$$\max_{i,j} |a_{ij}| \leq \|A\|_2 \leq \sqrt{mn} \max_{i,j} |a_{ij}| \quad (2.17)$$

Definimos, a norma do máximo por coluna:

$$\|A\|_1 = \max_{1 \leq j \leq n} \sum_{i=1}^m |a_{ij}| \quad (2.18)$$

subordinada à norma vetorial:

$$\|x\|_1 = \sum_{i=1}^n |x_i| \quad (2.19)$$

e, a norma do máximo por linha:

$$\|A\|_\infty = \max_{1 \leq i \leq m} \sum_{j=1}^n |a_{ij}| \quad (2.20)$$

subordinada à norma vetorial:

$$\|x\|_\infty = \max_{1 \leq i \leq m} |x_i| \quad (2.21)$$

3)

$$\frac{1}{\sqrt{n}} \|A\|_\infty \leq \|A\|_2 \leq \sqrt{m} \|A\|_\infty \quad (2.22)$$

4)

$$\frac{1}{\sqrt{m}} \|A\|_1 \leq \|A\|_\infty \leq \sqrt{n} \|A\|_1 \quad (2.23)$$

Obs.: A norma matricial de Frobenius é consistente, mas não subordinada à norma vetorial Euclidiana.

2.10 Erros nas operações com Matrizes

Inicialmente, consideramos a propagação do δx na solução x do sistema linear $Ax = b$ devido ao erro δb de b para $b \neq \mathbf{0}$. Em seguida, vamos analisar como perturbações em uma matriz A , $n \times n$, refletem no cálculo da inversa A^{-1} .

Admitindo que as normas usadas sejam consistentes, temos:

$$A(x + \delta x) = b + \delta b \implies A(\delta x) = \delta b \quad (2.24)$$

Portanto,

$$\|\delta x\| \leq \|A^{-1}\| \|\delta b\|, \text{ se } \det(A) \neq 0 \quad (2.25)$$

De

$$\|b\| = \|Ax\| \leq \|A\| \|x\|, \text{ segue-se que } \|x\| \geq \|b\| \|A\|^{-1} \quad (2.26)$$

Daí, de (2.25) e (2.26)

tiramos:

$$\frac{\|\delta x\|}{\|x\|} \leq \frac{\|A^{-1}\| \|\delta b\|}{\|b\| \|A\|^{-1}} \quad (2.27)$$

Acabamos de demonstrar o seguinte teorema:

Teorema 2.2

Seja o sistema linear $Ax = b$ com $\det(a) \neq 0, b \neq 0$. Se o vetor b tem o erro δb , então vale para o erro correspondente δx :

$$\frac{\|\delta x\|}{\|x\|} \leq K(A) \frac{\|\delta b\|}{\|b\|}, \text{ com } K(A) = \|A\| \|A^{-1}\| \quad (2.28)$$

Definição 9

O número

$$K(A) = \|A\| \|A^{-1}\| \quad (2.29)$$

é chamado de número de condição da matriz A . Em particular,

$$K_S(A) = \|A\|_2 \|A^{-1}\|_2 \quad (2.30)$$

é o número de condição espectral.

Se $K(A) \gg 1$, então o sistema linear $Ax = b$ é dito mal condicionado, isto é, pequenos erros de arredondamento na matriz A ou no vetor b , causam erros maiores na solução x deste sistema linear.

Exemplo

Vamos dar o seguinte exemplo apresentado em Albrecht [1]:

$$\begin{bmatrix} 10 & 7 & 8 & 7 \\ 7 & 5 & 6 & 5 \\ 8 & 6 & 10 & 9 \\ 7 & 5 & 9 & 10 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \end{bmatrix} = \begin{bmatrix} 32 \\ 23 \\ 33 \\ 31 \end{bmatrix}$$

Consideremos as duas aproximações abaixo para solução deste sistema linear:

1) $x_1 = 9.2, x_2 = -12.6, x_3 = 4.5, x_4 = -1.1$;

2) $x_1 = 1.82, x_2 = -0.36, x_3 = 1.35, x_4 = 0.79$.

Substituindo estas aproximações no lado direito do sistema linear, obtemos:

1) $b_1 = 32.1, b_2 = 22.9, b_3 = 33.1, b_4 = 30.9$;

2) $b_1 = 32.01, b_2 = 22.99, b_3 = 33.01, b_4 = 30.99$.

Acreditamos que estas duas aproximações são boas para a solução deste sistema linear, contudo estão longe da realidade, uma vez que a solução correta do problema é:

$$x_1 = x_2 = x_3 = x_4 = 1.0.$$

Calculando o número de condição da matriz A , obtemos:

$$K(A) = \|A\|_2 \|A^{-1}\|_2 = 30.29 \times 98.52 = 2984.17$$

Donde concluímos que o sistema linear é mal condicionado. Assim, pequenas variações no termo independente acarreta grandes variações na solução do sistema linear.

Seja, agora, E a matriz erro, $n \times n$, devido à pequenas perturbações nos coeficientes da matriz A , $n \times n$. Seja calcular a matriz inversa A^{-1} a partir da matriz $A + E$. Damos o seguinte lema:

Lema 2.1

Se $F \in \mathbf{R}^{n \times n}$ e $\|F\|_p \leq 1$, então $I - F$ é não singular e:

$$(I - F)^{-1} = \sum_{k=0}^{\infty} F^k \quad (2.31)$$

com

$$\|(I - F)^{-1}\|_p \leq \frac{1}{1 - \|F\|_p} \quad (2.32)$$

Prova

Suponhamos que $(I - F)$ seja singular. Segue-se que $(I - F)x = \mathbf{0}$ para algum vetor x não nulo. Então, $\|x\|_p = \|Fx\|_p \implies \|F\|_p \geq 1$, que é uma contradição. Assim, $(I - F)$ é não singular.

Consideremos, agora, a identidade:

$$\sum_{k=0}^N F^k(I - F) = I - F^{N+1} \quad (2.33)$$

Desde que $\|F\|_p \leq 1$ segue-se que, $\lim_{k \rightarrow \infty} F^k = 0$, porque $\|F^k\|_p \leq \|F\|_p^k$.

Assim,

$$\lim_{N \rightarrow \infty} \sum_{k=0}^N F^k(I - F) = I \quad (2.34)$$

e segue-se que:

$$(I - F)^{-1} = \lim_{N \rightarrow \infty} \sum_{k=0}^{\infty} F^k \quad (2.35)$$

Portanto, facilmente mostra-se que:

$$\|(I - F)^{-1}\|_p \leq \sum_{k=0}^{\infty} \|F\|_p^k = \frac{1}{1 - \|F\|_p} \quad (2.36)$$

Observe que

$$\|(I - F)^{-1} - I\|_p \leq \frac{\|F\|_p}{1 - \|F\|_p} \quad (2.37)$$

é uma consequência do **lema 2.1**. Assim, se $\varepsilon \ll 1$, $\vartheta(\varepsilon)$ perturbações em I induz $\vartheta(\varepsilon)$ perturbações na inversa. Passamos ao caso geral para qualquer matriz A , $n \times n$.

Teorema 2.3

Se A é uma matriz, $n \times n$, não singular e $r = \|A^{-1}E\|_p < 1$, então $A + E$ é não singular e

$$\|(A + E)^{-1} - A^{-1}\|_p \leq \frac{\|E\|_p \|A^{-1}\|_p^2}{1 - r} \quad (2.38)$$

Prova

Desde que a matriz A é não singular $A + E = A(I - F)$ onde $F = -A^{-1}E$ e sendo $\|F\|_p = r < 1$, segue-se do **lema 2.1** que $I - F$ é não singular e

$$\|(I - F)^{-1}\|_p \leq \frac{1}{1 - r}. \quad (2.39)$$

Agora, $(A + E)^{-1} = (I - F)^{-1}A^{-1}$ e então:

$$\|(A + E)^{-1}\|_p \leq \frac{\|A^{-1}\|_p}{1 - r}. \quad (2.40)$$

Da relação:

$$(A + E)^{-1} - A^{-1} = -A^{-1}E(A + E)^{-1} \quad (2.41)$$

e tomando a norma p , obtemos:

$$\|(A + E)^{-1} - A^{-1}\|_p \leq \|A^{-1}\|_p \|E\|_p \|(A + E)^{-1}\|_p \leq \frac{\|E\|_p \|A^{-1}\|_p^2}{1 - r}. \quad (2.42)$$

Exercícios Capítulo II

1 - Dada a matriz:

$$\mathbf{A} = \begin{bmatrix} 6 & 1 & 4 \\ -3 & 8 & -5 \\ 2 & -6 & 7 \end{bmatrix}$$

calcular e classificar a matriz $A - A^T = P$.

2 - Dada a matriz:

$$\mathbf{M} = \begin{bmatrix} \cos\theta & -\sin\theta & 0 \\ \sin\theta & \cos\theta & 0 \\ 0 & 0 & 1 \end{bmatrix}$$

calcular MM^T e classificar a matriz M .

3 - Seja a matriz A , invertível decomposta em matrizes blocos da forma:

$$\mathbf{A} = \begin{bmatrix} P & Q \\ R & S \end{bmatrix}$$

onde P e S são matrizes invertíveis de ordem p e s , respectivamente; Q e R são matrizes $p \times s$ e $s \times p$, respectivamente.

Escrevemos:

$$\mathbf{A}^{-1} = \begin{bmatrix} K & L \\ M & N \end{bmatrix}$$

onde K e N são matrizes invertíveis de ordem p e s , respectivamente; L e M são matrizes $p \times s$ e $s \times p$, respectivamente.

Desde que, $AA^{-1} = I$, onde I matriz identidade de ordem n , podemos escrever:

$$PK + QM = I_{pp} \quad (1)$$

$$PL + QN = \mathbf{0}_{ps} \quad (2)$$

$$RK + SM = \mathbf{0}_{sp} \quad (3)$$

$$RL + SN = I_{ss} \quad (4)$$

onde I_{pp} e $\mathbf{0}_{ps}$, são as matrizes identidade de ordem p e nula ($p \times s$), respectivamente. Idem para I_{ss} e $\mathbf{0}_{sp}$.

Mostre que:

$$\text{a) } K = (P - QS^{-1}R)^{-1} \text{ e } M = -S^{-1}RK;$$

$$\text{b) } N = (S - RP^{-1}Q)^{-1} \text{ e } L = -P^{-1}QN.$$

4 - Seja A uma matriz, $n \times n$.

a) Mostre que $(I - A)^{-1} = I + A + A^2 + A^3$, onde I é a matriz identidade, $n \times n$, e sendo $A^4 = \mathbf{0}$ (matriz nula);

b) Sejam as matrizes $C, D, n \times n$, e I é a matriz identidade, $n \times n$. Supondo que as matrizes inversas envolvidas existem, mostre que:

$$(C + DD^t)^{-1}D = C^{-1}D(I + D^tC^{-1}D)^{-1}.$$

Implementação dos Exercícios do Capítulo II em Matlab

```
1 %Exercicio 1 Capitulo 2
2 % clear
3 % A=[6 1 4; -3 8 -5; 2 -6 7]
4 % P=A-A'
```

Implementação de Exemplos do Capítulo II em Matlab

```
1 % Capitulo 2
2 % clear
3 % Matriz Transposta
4 % A=[3 2 2; 1 3 2; 1 1 3]
5 % B=[1 4 4; 5 1 4; 5 5 1]
6 % A'
7 % A''
8 % B'
9 % B''
10 % (A+B)'
11 % A'+B'
12 % (A*B)'
13 % B'*A'
14
15 %Matriz Inversa
16 % B=[3 5; 1 2]
17 % A=[2 -5; -1 3]
18 %
19 % A*B
20 % A^-1
21 % B^-1
22
23 %Propriedades
24
25 % A=[3 2 2; 1 3 2; 1 1 3]
26 % B=[1 4 4; 5 1 4; 5 5 1]
27 % A^-1
28 % B^-1
29 %
30 % (A*B)^-1-B^-1*A^-1
31 % clear
32 %
33 % A=[1 2 3; 2 5 3; 1 0 8]
34 % A^-1
35 % (A^-1)^-1
36 %
37 % A'*(A^-1)'
38
39 %Normas
40
41 % A=[3 2 2; 1 3 2; 1 1 3]
42
43 %Desigualdades
44
```

```

45 % %Propriedade1
46 % norm(A,2)
47 % norm(A,'fro')
48 % sqrt(3)*norm(A,2)
49 % %Propriedade3
50 % 1/(sqrt(3))*norm(A,inf)
51 % norm(A,2)
52 % sqrt(3)*norm(A,inf)
53
54 %Erros nas operacoes com matrizes
55 % clear
56 %
57 % A=[10 7 8 7; 7 5 6 5; 8 6 10 9; 7 5 9 10]
58 %
59 % cond(A,1)
60 % cond(A,2)

```

Capítulo 3

Resolução de Sistemas Lineares

3.1 Introdução

Existem diversos problemas de engenharia que envolvem álgebra linear. O problema central da álgebra linear consiste na resolução de sistemas de equações lineares e métodos de resolução dos mesmos, quando estas soluções existem. Por exemplo, seja calcular as tensões do circuito elétrico da figura 3.1:




Figura 3.1: *Circuito Elétrico*

Solução

Pela lei de Kirchoff, a soma das correntes que chegam a cada nó do circuito é nula. Pela lei de Ohm, a corrente elétrica que flui do nó j para o nó k de um circuito é:

$$I_{jk} = \frac{(V_j - V_k)}{R_{jk}}, \quad (3.1)$$

sendo V_j e V_k as tensões nos nós j e k , respectivamente, e R_{kj} a resistência na linha

jk . A corrente I_{jk} é expressa em ampéres e a resistência R_{jk} em **ohms**. As duas leis combinadas permitem o cálculo da tensão em cada ó do circuito. Por exemplo, no nó 1, pela lei de Kirchhoff, $I_{A1} + I_{21} + I_{31} + I_{41} = 0$. Utilizando a lei de Ohm, obtemos:

$$\frac{0 - V_1}{1} + \frac{V_2 - V_1}{1} + \frac{V_3 - V_1}{2} + \frac{V_4 - V_1}{2} = 0$$

ou seja,

$$-6V_1 + 2V_2 + V_3 + V_4 = 0$$

Fazendo o mesmo para os nós 2,3 e 4, obtemos um sistema de 4 equações lineares, a saber:

$$-6V_1 + 2V_2 + V_3 + V_4 = 0$$

$$3V_1 - 4V_2 + V_3 = 0$$

$$3V_1 + 2V_2 - 13V_3 + 6V_4 = -254$$

$$1V_1 + 2V_3 - 3V_4 = 0$$

As coordenadas do vetor solução $V = (25.80, 31.75, 49.61, 41.67)$ fornece a tensão em cada nó do circuito elétrico.

Iniciamos o estudo com o problemas básico de encontrar a solução de um sistema linear de n equações com n incógnitas. Um sistema linear com n equações e n incógnitas é escrito usualmente na forma:

$$a_{11}x_1 + a_{12}x_2 + \dots + a_{1n}x_n = b_1$$

$$a_{21}x_1 + a_{22}x_2 + \dots + a_{2n}x_n = b_2$$

$$\vdots \cdot \vdots$$

$$a_{n1}x_1 + a_{n2}x_2 + \dots + a_{nn}x_n = b_n$$

onde

$$a_{ij} : \text{coeficientes } 1 \leq i, j \leq n$$

$$x_j : \text{incógnitas } j = 1, 2, \dots, n$$

$$b_j : \text{constantes } j = 1, 2, \dots, n$$

A resolução de um sistema linear consiste em calcular os valores de $x_j, j = 1, 2, \dots, n$, caso eles existam, que satisfaçam as n equações simultâneas.

Usando notação matricial, escrevemos este sistema linear como:

$$Ax = b, \tag{3.2}$$

onde:

$$\mathbf{A} = \begin{bmatrix} a_{11} & a_{12} & \dots & a_{1n} \\ a_{21} & a_{22} & \dots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \dots & a_{nn} \end{bmatrix}$$

é a matriz, $n \times n$, dos coeficientes,

$$\mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix}$$

é o vetor das incógnitas e

$$\mathbf{b} = \begin{bmatrix} b_1 \\ b_2 \\ \vdots \\ b_n \end{bmatrix}$$

é o vetor constante.

Chamaremos de x^* o vetor solução do sistema linear $Ax = b$.

No caso geral em que o sistema linear envolve n equações com n incógnitas, apenas uma entre as situações abaixo irá ocorrer:

- i) o sistema linear tem única solução;
- ii) o sistema linear admite infinitas soluções(indeterminado);
- iii) o sistema linear não admite solução(impossível ou inconsistente).

Estaremos interessados em sistemas lineares $n \times n$ com uma única solução. A solução destes sistemas lineares é dada por: $x^* = A^{-1}b$. No entanto, calcular a matriz A^{-1} e em seguida efetuar o produto $A^{-1}b$ é desaconselhável, uma vez que o número de operações envolvidas é muito grande. Usaremos aqui o Método de Eliminação de Gauss para encontrar a solução destes sistemas lineares.

3.2 Método de Eliminação de Gauss

O Método de Eliminação de Gauss consiste em transformar o sistema linear original num sistema linear equivalente com matriz dos coeficientes triangular superior, pois a resolução torna-se imediata. Dizemos que dois sistemas lineares são equivalentes quando possuem a mesma solução. Descreveremos, a seguir, o Método de Eliminação de Gauss, aplicando uma sequência de operações elementares na matriz

A no processo de triangularização da mesma. Vamos supor que $\det(A) \neq 0$ (A invertível).

Triangularização da matriz A

O processo de triangularização consiste em eliminar a incógnita x_k na k -ésima etapa nas equações $k+1, k+2, k+3, \dots, n$. Usaremos a notação $a_{ij}^{(k)}$ para denotar o coeficiente da linha i e coluna j no final da k -ésima etapa, e $b_i^{(k)}$ para denotar a i -ésima componente do vetor constante no final da mesma etapa. Sendo $\det(A) \neq 0$ é sempre possível encontrar um elemento $a_{11} \neq 0$ na 1ª coluna. Caso $a_{11} = 0$ fazemos a troca de linhas. Escrevemos, inicialmente a matriz aumentada:

$$\mathbf{A}^{(0)}|\mathbf{b}^{(0)} = \left[\begin{array}{cccc|c} a_{11}^{(0)} & a_{12}^{(0)} & \dots & a_{1n}^{(0)} & b_1^{(0)} \\ a_{21}^{(0)} & a_{22}^{(0)} & \dots & a_{2n}^{(0)} & b_2^{(0)} \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ a_{n1}^{(0)} & a_{n2}^{(0)} & \dots & a_{nn}^{(0)} & b_n^{(0)} \end{array} \right]$$

onde $a_{ij}^{(0)} = a_{ij}$, $b_i^{(0)} = b_i$.

1ª etapa:

Para eliminar a incógnita x_1 das equações $i = 2, 3, \dots, n$ fazemos a seguinte operação: da equação i subtraímos a 1ª equação multiplicada por m_{i1} , onde

$$m_{i1} = \frac{a_{i1}^{(0)}}{a_{11}^{(0)}}, \quad i = 2, 3, \dots, n.$$

Os elementos $m_{i1}, i = 2, 3, \dots, n$ são os multiplicadores e o elemento $a_{11}^{(0)}$ é chamado de **pivô** desta etapa. No final desta etapa, obtemos a seguinte matriz aumentada:

$$\mathbf{A}^{(1)}|\mathbf{b}^{(1)} = \left[\begin{array}{cccc|c} a_{11}^{(0)} & a_{12}^{(0)} & \dots & a_{1n}^{(0)} & b_1^{(0)} \\ 0 & a_{22}^{(1)} & \dots & a_{2n}^{(1)} & b_2^{(1)} \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ 0 & a_{n2}^{(1)} & \dots & a_{nn}^{(1)} & b_n^{(1)} \end{array} \right]$$

onde $a_{ij}^{(1)} = a_{ij}^{(0)} - m_{i1}a_{1j}^{(0)}$, $i = 2, 3, \dots, n$ e $j = 1, 2, \dots, n$

$b_i^{(1)} = b_i^{(0)} - m_{i1}b_1^{(0)}$, $i = 2, 3, \dots, n$

2ª etapa:

Como $\det(A) \neq 0$, devemos encontrar pelo menos um elemento $a_{i2} \neq 0$ na 2ª coluna para $i = 2, 3, \dots, n$. Desta forma, tomamos o **pivô** $a_{22}^{(1)} \neq 0$ e temos os seguintes multiplicadores:

$$m_{i2} = \frac{a_{i2}^{(1)}}{a_{22}^{(1)}}, \quad i = 3, 4, \dots, n.$$

Eliminamos a incógnita x_2 nas equações $i = 3, \dots, n$ fazendo a seguinte operação: da equação i subtraímos a 2ª equação multiplicada por m_{i2} .

No final desta etapa obtemos a seguinte matriz aumentada:

$$\mathbf{A}^{(2)}|\mathbf{b}^{(2)} = \left[\begin{array}{cccc|c} a_{11}^{(0)} & a_{12}^{(0)} & \dots & \dots & a_{1n}^{(0)} & | & b_1^{(0)} \\ 0 & a_{22}^{(1)} & \dots & \dots & a_{2n}^{(1)} & | & b_2^{(1)} \\ 0 & 0 & a_{33}^{(2)} & \dots & a_{2n}^{(2)} & | & b_2^{(2)} \\ \vdots & \vdots & \vdots & \ddots & \vdots & | & \vdots \\ 0 & 0 & a_{n3}^{(2)} & \dots & a_{nn}^{(2)} & | & b_n^{(2)} \end{array} \right]$$

onde $a_{ij}^{(2)} = a_{ij}^{(1)} - m_{i2}a_{2j}^{(2)}$, $i = 3, 4, \dots, n$ e $j = 2, \dots, n$
 $b_i^{(2)} = b_i^{(1)} - m_{i2}b_2^{(1)}$, $i = 3, 4, \dots, n$

(n - 1)-ésima etapa:

No final desta última etapa, obtemos uma matriz triangular superior aumentada:

$$\mathbf{A}^{(n-1)}|\mathbf{b}^{(n-1)} = \left[\begin{array}{cccc|c} a_{11}^{(0)} & a_{12}^{(0)} & \dots & \dots & a_{1n}^{(0)} & | & b_1^{(0)} \\ 0 & a_{22}^{(1)} & \dots & \dots & a_{2n}^{(1)} & | & b_2^{(1)} \\ 0 & 0 & a_{33}^{(2)} & \dots & a_{2n}^{(2)} & | & b_2^{(2)} \\ \vdots & \vdots & \vdots & \ddots & \vdots & | & \vdots \\ 0 & 0 & 0 & \dots & a_{nn}^{(n-1)} & | & b_n^{(n-1)} \end{array} \right]$$

equivalente ao sistema linear inicial, onde $A^{(n-1)}$ é uma matriz triangular superior.

Resolução do sistema triangular

O sistema triangular é resolvido por resolução regressiva como segue:

Da última equação, obtemos:

$$x_n = \frac{b_n^{(n-1)}}{a_{nn}^{(n-1)}}$$

e da penúltima equação, obtemos:

$$x_{n-1} = \frac{(b_n^{(n-2)} - a_{n-1,n}^{(n-2)}x_n)}{a_{n-1,n-1}^{(n-2)}}$$

e assim sucessivamente obtemos $x_{n-2}, \dots, x_2$ e finalmente da 1ª equação, obtemos:

$$x_1 = \frac{(b_1^{(0)} - a_{12}^{(0)}x_2 - a_{13}^{(0)}x_3 - \dots - a_{1n}^{(0)}x_n)}{a_{11}^{(0)}}$$

Exemplo

Seja resolver o sistema linear abaixo pelo Método de Eliminação de Gauss.

$$2x_1 + x_2 + x_3 = 7$$

$$4x_1 + 4x_2 + 3x_3 = 21$$

$$6x_1 + 7x_2 + 4x_3 = 32$$

Triangularização da matriz $\mathbf{A}$

1ª etapa: Eliminação da incógnita x_1 .

Inicialmente, temos a seguinte matriz aumentada:

$$\mathbf{A}^{(0)}|\mathbf{b}^{(0)} = \left[\begin{array}{ccc|c} 2 & 1 & 1 & 7 \\ 4 & 4 & 3 & 21 \\ 6 & 7 & 4 & 32 \end{array} \right]$$

Calculamos $m_{21} = 4/2$ e $m_{31} = 6/2$ e substituímos a linha2 pela linha2 menos m_{21} vezes linha1 e também, a linha3 pela linha3 menos m_{31} vezes linha1. Obtendo, assim, a seguinte matriz aumentada:

$$\mathbf{A}^{(1)}|\mathbf{b}^{(1)} = \left[\begin{array}{ccc|c} 2 & 1 & 1 & 7 \\ 0 & 2 & 1 & 7 \\ 0 & 4 & 1 & 11 \end{array} \right]$$

2ª etapa: Eliminação da incógnita x_2 .

Calculamos $m_{32} = 4/2$ e substituímos a linha3 pela linha3 menos m_{32} vezes linha2, obtendo a seguinte matriz aumentada:

$$\mathbf{A}^{(2)}|\mathbf{b}^{(2)} = \left[\begin{array}{ccc|c} 2 & 1 & 1 & 7 \\ 0 & 2 & 1 & 7 \\ 0 & 0 & -1 & -3 \end{array} \right]$$

Resolução do sistema triangular

Agora, temos de resolver o seguinte sistema linear triangular:

$$\begin{array}{rrcr} 2x_1 & +x_2 & +x_3 & = & 7 \\ & 2x_2 & +x_3 & = & 7 \\ & & -x_3 & = & -3 \end{array}$$

Obtemos, por resolução regressiva:

$$x_3 = (-3)/(-1) = 3$$

$$x_2 = 7/2 - 3/2 = 2$$

$$x_1 = 7/2 - 2/2 - 3/2 = 1$$

3.3 Pivoteamento Parcial

No processo de escalonamento da matriz A pelo Método de Eliminação de Gauss devemos calcular os multiplicadores:

$$m_{ik} = a_{ik}^{(k-1)} / a_{kk}^{(k-1)}, i = k + 1, 3, \dots, n \quad (3.3)$$

em cada k -ésimo passo do processo.

Com o objetivo de eliminar possíveis **pivôs** nulos e diminuir os erros de arredondamento durante o processo, utilizamos a estratégia de pivoteamento parcial (ou total), que consiste no seguinte:

”No início do k -ésimo passo, escolhemos para **pivô** o elemento de maior módulo dentre os coeficientes $a_{ik}^{(k-1)}, i = k, k + 1, k + 2, \dots, n$ e trocamos as linhas k e i , caso necessário.”

Exemplo

Seja resolver o seguinte sistema linear pelo Método de Eliminação de Gauss com pivoteamento parcial:

$$3x_1 - 4x_2 + x_3 = 9$$

$$x_1 + 2x_2 + 2x_3 = 3$$

$$4x_1 - 3x_3 = -2$$

Temos a seguinte matriz aumentada do sistema linear inicial:

$$\mathbf{A}^{(0)}|\mathbf{b}^{(0)} = \left[\begin{array}{ccc|c} 3 & -4 & 1 & 9 \\ 1 & 2 & 2 & 3 \\ 4 & 0 & -3 & -2 \end{array} \right]$$

Triangularização da matriz A

1ª **etapa:** Eliminação da incógnita x_1 .

Antes de eliminar a incógnita x_1 , fazemos a troca dos coeficientes da coluna 1. Assim, temos a seguinte matriz aumentada:

$$\mathbf{A}^{(0)}|\mathbf{b}^{(0)} = \left[\begin{array}{ccc|c} 4 & 0 & -3 & -2 \\ 1 & 2 & 2 & 3 \\ 3 & -4 & 1 & 9 \end{array} \right]$$

Calculamos $m_{21} = 1/4$ e $m_{31} = 3/4$ e substituímos a linha 2 pela linha 2 - $m_{21} \times$ linha 1 e também, a linha 3 pela linha 3 - $m_{31} \times$ linha 1. Obtemos a seguinte matriz aumentada:

$$\mathbf{A}^{(1)}|\mathbf{b}^{(1)} = \left[\begin{array}{ccc|c} 4 & 0 & -3 & -2 \\ 0 & 2 & 2.75 & 3.5 \\ 0 & -4 & 3.25 & 10.5 \end{array} \right]$$

2ª etapa: Eliminação da incógnita x_2 .

Antes de calcularmos m_{32} , fazemos a troca da linha2 com a linha3, pois $|-4| > |2|$. Em seguida, calculamos $m_{32} = 2/(-4)$ e substituímos a linha3 pela linha3 - $m_{32} \times$ linha2, obtendo a seguinte matriz aumentada:

$$\mathbf{A}^{(2)}|\mathbf{b}^{(2)} = \left[\begin{array}{ccc|c} 4 & 0 & -3 & -2 \\ 0 & -4 & 3.25 & 10.5 \\ 0 & 0 & 4.375 & 8.75 \end{array} \right]$$

Resolução do sistema triangular

Agora, temos de resolver o seguinte sistema linear triangular:

$$\begin{array}{rclcl} 4x_1 & +0x_2 & -3x_3 & = & -2 \\ & -4x_2 & +3.25x_3 & = & 10.5 \\ & & 4.375x_3 & = & 8.75 \end{array}$$

Obtemos, por resolução regressiva:

$$x_3 = 8.75/4.375 = 2$$

$$x_2 = (10.5 - 3.25 \times 2)/(-4) = -1$$

$$x_1 = (-2 + 3 \times 2)/4 = 1$$

3.4 Decomposição LU

A decomposição da matriz A , $n \times n$, no produto de duas matrizes triangulares L e U é assegurada pelo seguinte teorema:

Teorema 3.1

Dada uma matriz A , $n \times n$, seja A_k a matriz constituída das primeiras k linhas e colunas da matriz A . Suponha que $\det(A_k) \neq 0$ para $k = 1, 2, \dots, (n-1)$. Então, existe uma única matriz triangular inferior $L = (m_{ij})$, com $m_{ii} = 1$, $i, j = 1, 2, \dots, n$ e uma única matriz triangular superior $U = (u_{ij})$ tais que $A = LU$. Ainda mais, $\det(A) = u_{11}u_{22}\dots u_{nn}$.

Prova

Seja o sistema linear $Ax = b$ que resolvemos pelo Método de Eliminação de Gauss. Na decomposição da matriz A no produto LU , temos:

$$A = LU \implies Ax = b \implies LUx = b$$

onde, L é uma matriz triangular inferior, $n \times n$, com coeficientes da diagonal principal iguais a 1,

U é uma matriz triangular superior, $n \times n$, encontrada pelo Método de Eliminação de Gauss.

Cálculo de L

Sejam

$$\mathbf{M}_1 = \begin{bmatrix} 1 & 0 & 0 & 0 & \dots & 0 \\ -m_{21} & 1 & 0 & 0 & \dots & 0 \\ -m_{31} & 0 & 1 & 0 & \dots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots & 0 \\ -m_{n1} & 0 & 0 & 0 & \dots & 1 \end{bmatrix}$$

$$\mathbf{M}_2 = \begin{bmatrix} 1 & 0 & 0 & 0 & \dots & 0 \\ 0 & 1 & 0 & 0 & \dots & 0 \\ 0 & -m_{32} & 1 & 0 & \dots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots & 0 \\ 0 & -m_{n2} & 0 & 0 & \dots & 1 \end{bmatrix}$$

e

$$\mathbf{M}_{n-1} = \begin{bmatrix} 1 & 0 & 0 & 0 & \dots & 0 \\ 0 & 1 & 0 & \dots & 0 & 0 \\ 0 & 0 & 1 & 0 & \dots & 0 \\ \vdots & \vdots & \vdots & \ddots & \vdots & \\ 0 & 0 & 0 & \dots & -m_{nn-1} & 1 \end{bmatrix}$$

Cálculo de U

No Método de Eliminação de Gauss transformamos o sistema linear $Ax = b$ no sistema equivalente $Ux = d$, onde U é uma matriz triangular superior.

O sistema linear obtido na 1ª etapa do Método de Eliminação de Gauss é $A^{(1)}x = b^{(1)}$ é equivalente a:

$$M_1Ax = M_1b \implies A^{(1)} = M_1A \text{ e } b^{(1)} = M_1b$$

O sistema linear obtido na 2ª etapa do Método de Eliminação de Gauss é $A^{(2)}x = b^{(2)}$ é equivalente a:

$$M_2A^{(1)}x = M_2b^{(1)} \implies M_2M_1Ax = M_2M_1b \implies A^{(2)} = M_2M_1A \text{ e } b^{(2)} = M_2M_1b$$

$$\implies A = M_1^{-1}M_2^{-1}A^{(2)}, \quad b = M_1^{-1}M_2^{-1}b^{(2)}$$

onde

$$\mathbf{M}_1^{-1} = \begin{bmatrix} 1 & 0 & 0 & 0 & \dots & 0 \\ m_{21} & 1 & 0 & 0 & \dots & 0 \\ m_{31} & 0 & 1 & 0 & \dots & 0 \\ \vdots & \vdots & \vdots & \vdots & \ddots & \vdots \\ m_{n1} & 0 & 0 & \dots & 0 & 1 \end{bmatrix}$$

e

$$\mathbf{M}_2^{-1} = \begin{bmatrix} 1 & 0 & 0 & 0 & \dots & 0 \\ 0 & 1 & 0 & 0 & \dots & 0 \\ 0 & m_{32} & 1 & 0 & \dots & 0 \\ \vdots & \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & m_{n2} & 0 & \dots & 0 & 1 \end{bmatrix}$$

O sistema linear obtido na $(n-1)^a$ etapa do Método de Eliminação de Gauss é $A^{(n-1)}x = b^{(n-1)}$ é equivalente a:

$$M_{n-1} \dots M_2 A^{(n-2)} x = M_{n-1} \dots M_2 b^{(n-2)} \implies M_{n-1} \dots M_2 M_1 A x = M_{n-1} \dots M_2 M_1 b \implies$$

$$A^{(n-1)} = M_{n-1} \dots M_2 M_1 A \text{ e } b^{(n-1)} = M_{n-1} \dots M_2 M_1 b \implies A = M_1^{-1} M_2^{-1} \dots M_{n-1}^{-1} A^{(n-1)}$$

, onde

$$\mathbf{M}_{n-1}^{-1} = \begin{bmatrix} 1 & 0 & 0 & 0 & \dots & 0 \\ 0 & 1 & 0 & 0 & \dots & 0 \\ 0 & 0 & 1 & 0 & \dots & 0 \\ \vdots & \vdots & \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \dots & m_{nn-1} & 1 \end{bmatrix}$$

Colocando $M_1^{-1} M_2^{-1} \dots M_{n-1}^{-1} = L$, $A^{(n-1)} = U$, obtemos $A = LU$.

Desta forma, fica assegurada a existência das matrizes L e U para a decomposição $A = LU$.

Para provar a unicidade, procedemos como segue:

Seja a matriz A , $n \times n$, decomposta nos seguintes produtos matriciais: $A = L_1 U_1$ e $A = L_2 U_2$, onde L_1, L_2 , U_1 e U_2 são as matrizes triangulares invertíveis da decomposição $A = LU$.

Temos que, $L_1 U_1 = L_2 U_2$ e assim, $L_2^{-1} L_1 = U_2 U_1^{-1}$.

Então, $L_2^{-1} L_1$ é uma matriz triangular inferior com 1's na diagonal e, consequentemente, $U_2 U_1^{-1}$ é uma matriz triangular superior com 1's na diagonal. A única matriz que tem esta propriedade é a matriz identidade. Portanto,

$$L_2^{-1} L_1 = I \text{ e } U_2 U_1^{-1} = I \implies L_1 = L_2 \text{ e } U_1 = U_2.$$

Para o cálculo de $\det(A)$, temos:

$$\det(A) = \det(LU) = \det(L)\det(U) = 1 \times \det(U) = u_{11}u_{22}u_{33} \dots u_{nn}.$$

Uma vez decomposta a matriz $A, n \times n$, no produto LU , temos de resolver os seguintes sistemas lineares:

- 1) $Ly = b$;
- 2) $Ux = y$, pois $Ax = b \implies LUx = b$, onde $Ux = y$

Exemplo

Seja resolver o sistema linear abaixo pela decomposição LU .

$$\begin{array}{rrcr} 2x_1 & +2x_2 & -x_3 & = & 1 \\ x_1 & +5x_2 & +3x_3 & = & 4 \\ 2x_1 & +x_2 & -5x_3 & = & -3 \end{array}$$

Obtemos as matrizes L e U , seguindo os cálculos propostos anteriormente:

$$\mathbf{L} = \begin{bmatrix} 1 & 0 & 0 \\ 0.5 & 1 & 0 \\ 1 & -0.25 & 1 \end{bmatrix}$$

e

$$\mathbf{U} = \begin{bmatrix} 2 & 2 & -1 \\ 0 & 4 & 3.5 \\ 0 & 0 & -3.125 \end{bmatrix}$$

Agora, podemos resolver o sistema linear acima só operando com o vetor b :

- 1) $Ly = b$

$$\begin{array}{rrcr} y_1 & & & = & 1 \\ 0.5y_1 & +y_2 & & = & 4 \\ y_1 & -0.25y_2 & +y_3 & = & -3 \end{array}$$

Dando $y_1 = 1, y_2 = 3.5, y_3 = -3.125$.

- 2) $Ux = y$

$$\begin{array}{rrcr} 2x_1 & +2x_2 & -x_3 & = & 1 \\ & 4x_2 & +3.5x_3 & = & 3.5 \\ & & -3.125x_3 & = & -3.125 \end{array}$$

Dando $x_3 = 1, x_2 = 0, x_1 = 1$.

3.5 Cálculo da Inversa da Matriz A

Da definição de inversa de uma matriz $A, n \times n$, sabe-se que:

$$AA^{-1} = A^{-1}A = I$$

Colocando $X = A^{-1}$, ou $AX_p = e_p, p = 1, 2, \dots, n$,

onde X_p é a p -ésima coluna da matriz X e e_p é a p -ésima coluna da matriz I , ou seja: o vetor da base canônica de $\mathbf{R}^p$.

Então, as colunas de A^{-1} são as soluções dos sistemas de equações lineares: $AX_p = e_p, p = 1, 2, \dots, n$.

O Método de Eliminação de Gauss pode ser empregado para a resolução destes sistemas lineares, porém os mesmos cálculos serão repetidos p vezes.

Uma outra maneira de calcular A^{-1} é usar a Decomposição LU. Uma vez sendo conhecida a Decomposição LU da matriz A , calcula-se A^{-1} como segue:

$$A^{-1} = (LU)^{-1} = U^{-1}L^{-1}, \quad (3.4)$$

onde L^{-1} é facilmente calculada.

Colocando $Y = L^{-1}$, as colunas Y_j de Y satisfazem:

$$LY_j = e_j, j = 1, 2, \dots, n \quad (3.5)$$

assim, os elementos de L^{-1} são determinados resolvendo-se os n sistemas triangulares que têm como solução:

$$y_{ij} = \frac{\delta_{ij} - \sum_{k=j}^{i-1} l_{ik}y_{kj}}{l_{ii}}, i = j, j+1, \dots, n \quad (3.6)$$

onde

$$\delta_{ij} = \begin{cases} 1 & \text{se } i = j \\ 0 & \text{se } i \neq j \end{cases}$$

Analogamente, $Z = U^{-1}$ é uma matriz triangular superior com os elementos calculados por meio de:

$$z_{ij} = \frac{\delta_{ij} - \sum_{k=i+1}^j u_{ik}z_{kj}}{u_{ii}}, i = j, j-1, \dots, 1 \quad (3.7)$$

Exemplo

Seja calcular a inversa da matriz

$$\mathbf{A} = \begin{bmatrix} 2 & 1 & 2 \\ 1 & 2 & 3 \\ 4 & 1 & 2 \end{bmatrix}$$

Usando a decomposição LU obtemos:

$$\mathbf{L} = \begin{bmatrix} 1 & & \\ 0.5 & 1 & \\ 2 & -0.67 & 1 \end{bmatrix}$$

e

$$\mathbf{U} = \begin{bmatrix} 2 & 1 & 2 \\ & 1.5 & 2 \\ & & -0.67 \end{bmatrix}$$

Aplicando as fórmulas anteriores para os cálculos de L^{-1} e U^{-1} , obtemos:

$$\mathbf{L}^{-1} = \begin{bmatrix} 1 & & & \\ -0.5 & 1 & & \\ -2 & 0.67 & 1 & \end{bmatrix}$$

e

$$\mathbf{U}^{-1} = \begin{bmatrix} 0.5 & -0.34 & 0.5 & \\ & 0.67 & 2 & \\ & & -1.5 & \end{bmatrix}$$

Em seguida, calculamos:

$$\mathbf{A}^{-1} = \mathbf{U}^{-1}\mathbf{L}^{-1} = \begin{bmatrix} -0.5 & 0 & 0.5 & \\ -5.02 & 2.01 & 2 & \\ 3.51 & -1 & -1.5 & \end{bmatrix}$$

Muitos autores utilizam o Método de Gauss-Jordan para o cálculo de A^{-1} , mas o método que acabamos de descrever é equivalente a este, onde são gastas n^3 operações em ambos os casos. O Método de Gauss-Jordan consiste em zerar também os coeficientes localizados acima da diagonal principal de U e em seguida, divide-se a diagonal da matriz resultante por seus coeficientes diagonais, obtendo-se assim a matriz identidade.

3.6 Decomposição para Tipos Especiais de Matrizes

Definimos, inicialmente, as matrizes estritamente diagonais dominantes, onde o Método de Eliminação de Gauss funciona eficazmente sem intercâmbio de linhas.

Definição 3.1

A matriz A , $n \times n$, é chamada estritamente diagonal dominante quando

$$|a_{ii}| > \sum_{\substack{j=1 \\ j \neq i}}^n |a_{ij}|, i = 1, 2, \dots, n \quad (3.8)$$

Exemplo

A matriz

$$\mathbf{A} = \begin{bmatrix} 7 & 2 & 0 \\ 3 & 5 & -1 \\ 0 & 5 & -6 \end{bmatrix}$$

é estritamente diagonal dominante, uma vez que:

$$|7| > |2| + |0|, |5| > |3| + |-1| \text{ e } |-6| > |0| + |5|$$

Damos, a seguir, o seguinte teorema:

Teorema 3.2

Uma matriz A , $n \times n$, estritamente diagonal dominante é não singular. Além do mais, a eliminação gaussiana pode ser executada em qualquer sistema linear da forma $Ax = b$ para obter sua única solução sem troca de colunas ou linhas, e não há propagação de erros de arredondamento durante o processo de eliminação.

Prova

Vamos mostrar por contradição que a matriz A é não singular.

Consideremos o sistema linear homogêneo $Ax = 0$, e suponhamos que exista uma solução não trivial $x = (x_i)$ para esse sistema. Seja k um índice para o qual

$$0 < |x_k| = \max_{1 \leq j \leq n} |x_j|$$

Como $\sum_{j=1}^n a_{ij}x_j = 0$ para cada $i = 1, 2, \dots, n$, temos que para $i = k$,

$$a_{kk}x_k = - \sum_{\substack{j=1 \\ j \neq k}}^n a_{kj}x_j$$

Daí temos,

$$|a_{kk}| |x_k| \leq \sum_{\substack{j=1 \\ j \neq k}}^n |a_{kj}| |x_j|$$

ou

$$|a_{kk}| \leq \sum_{\substack{j=1 \\ j \neq k}}^n |a_{kj}| \frac{|x_j|}{|x_k|} \leq \sum_{\substack{j=1 \\ j \neq k}}^n |a_{kj}|$$

Essa desigualdade contradiz a dominância da matriz A . Consequentemente, a única solução para o sistema homogêneo $Ax = 0$ é $x = 0$. Portanto, a matriz A é não singular.

Para provar que a eliminação de Gauss pode ser executada sem mudanças de linhas, basta mostrar que cada uma das matrizes $A^{(2)}, A^{(3)}, \dots, A^{(n)}$ geradas pelo processo de eliminação de Gauss é estritamente diagonal dominante. (Veja Burden e Faires Teorema 6.19 [5])

A demonstração de estabilidade do método pode ser encontrada em Wendroff [9].

Uma outra classe de matrizes, onde existe uma decomposição apropriada, é a matriz simétrica definida positiva.

Definição 3.2

A matriz A , $n \times n$, é chamada simétrica definida positiva(sdp) quando

$$x^t A x > 0 \quad \forall x \in \mathbf{R}^n, x \neq \mathbf{0} \quad (3.9)$$

Exemplo

A matriz

$$\mathbf{A} = \begin{bmatrix} 2 & -1 & 0 \\ -1 & 2 & -1 \\ 0 & -1 & 2 \end{bmatrix}$$

é simétrica positiva definida(sdp), uma vez que:

$$x^t A x = 2x_1^2 - 2x_1x_2 + 2x_2^2 - 2x_2x_3 + 2x_3^2 = x_1^2 + (x_1 - x_2)^2 + (x_2 - x_3)^2 + x_3^2 > 0$$

a menos que $x_1 = x_2 = x_3 = 0$.

Damos o seguinte teorema:

Teorema 3.3

Uma matriz A , $n \times n$, simétrica positiva definida(sdp) é não singular. Além do mais, a eliminação de Gauss pode ser executada em qualquer sistema linear da forma $Ax = b$ com todos os **pivôs** positivos para obter sua única solução sem troca de linhas, e não há propagação de erros de arredondamento durante o processo de eliminação.

Prova

Para a demonstração deste teorema veja os resultados encontrados em Burden e Faires [5] e também em Wendroff [9].

Agora, apresentamos dois corolários que fornecem a decomposição para as matrizes simétricas definidas positivas(sdp) (Veja Burden e Faires [5]).

Corolário 3.1

A matriz A , $n \times n$, é simétrica positiva definida(sdp) $\iff A$ pode ser fatorada na forma LDL^t , onde L é a matriz triangular inferior, $n \times n$, com coeficientes iguais a 1 em sua diagonal e D é uma matriz diagonal, $n \times n$, com coeficientes positivos.

Obs.1: Sendo a matriz A , $n \times n$, que pode ser fatorada de forma única como $A = LU$, de acordo com o **teorema 3.1**. Também, esta matriz pode ser fatorada de forma única com $A = LD\bar{U}$, onde:

L , $n \times n$, matriz triangular inferior com diagonal unitária;

D , $n \times n$, matriz diagonal;

$\bar{U}$, $n \times n$, matriz triangular superior com diagonal unitária.

No caso, sendo A , $n \times n$, matriz simétrica, temos que: $\bar{U} = L^t$. Portanto, a matriz A , $n \times n$, pode ser fatorada na forma $A = LDL^t$.

Temos que a matriz diagonal D é constituída dos coeficientes u_{ii} da matriz U , $n \times n$, e os coeficientes da matriz $\bar{U}$ serão $\bar{u}_{ij} = u_{ij}/u_{ii}$, $i = 1, 2, \dots, n, j = i, \dots, n$, onde para A , $n \times n$, matriz simétrica $\bar{U} = L^t$.

Corolário 3.2

A matriz A , $n \times n$, é simétrica positiva definida(sdp) $\iff A$ pode ser fatorada na forma LL^t , onde L é a matriz triangular inferior, $n \times n$, com coeficientes diagonais diferentes de zero.

Obs.2: No caso da matriz A , $n \times n$, simétrica positiva definida, temos que os coeficientes de D são tais que: $d_{ii} > 0, i = 1, 2, \dots, n$.

Fazendo $\bar{D} = D^{1/2}$, obtemos:

$$A = LDL^t = L\bar{D}\bar{D}L^t = (L\bar{D})(\bar{D}L^t) \quad (3.10)$$

Esta fatoração é conhecida como fatoração de Cholesky.

A decomposição apresentada no **corolário 3.1** pode ser aplicada às matrizes simétricas, mas não necessariamente positivas definidas. O resultado pode ser aplicado extensamente às matrizes simétricas, uma vez que estas são reconhecidas mais facilmente.

O **corolário 3.3**, a seguir, nos permite reconhecer a decomposição do **corolário 3.1**, relacionado-a com o Método de Eliminação de Gauss (Veja Burden e Faires [5]).

Corolário 3.3

Seja a matriz A , $n \times n$, simétrica para a qual a eliminação de Gauss poder ser aplicada sem a troca de linhas. Então, a matriz A pode ser fatorada na forma LDL^t , onde L é a matriz triangular inferior, $n \times n$, com coeficientes iguais a 1 em sua diagonal e D é uma matriz diagonal, $n \times n$, com coeficientes $a_{11}^{(0)}, a_{22}^{(1)}, \dots, a_{nn}^{(n-1)}$ obtidos na eliminação de Gauss.

Exemplo

Vimos que a matriz

$$\mathbf{A} = \begin{bmatrix} 2 & -1 & 0 \\ -1 & 2 & -1 \\ 0 & -1 & 2 \end{bmatrix}$$

é simétrica positiva definida(sdp). A fatoração LDL^t de A dada pelo **corolário 3.1**

é:

$$\mathbf{A} = \mathbf{LDL}^t = \begin{bmatrix} 1 & 0 & 0 \\ -0.5 & 1 & 0 \\ 0 & -0.6667 & 1 \end{bmatrix} \begin{bmatrix} 2 & 0 & 0 \\ 0 & 3/2 & 0 \\ 0 & 0 & 4/3 \end{bmatrix} \begin{bmatrix} 1 & -0.5 & 0 \\ 0 & 1 & -0.6667 \\ 0 & 0 & 1 \end{bmatrix}$$

e a fatoração de Cholesky LL^t de A dada pelo **corolário 3.2** é:

$$\mathbf{A} = \mathbf{LL}^t = \begin{bmatrix} 1.4142 & 0 & 0 \\ -0.7071 & 1.2247 & 0 \\ 0 & -0.8165 & 1.1547 \end{bmatrix} \begin{bmatrix} 1.4142 & -0.7071 & 0 \\ 0 & 1.2247 & -0.8165 \\ 0 & 0 & 1.1547 \end{bmatrix}$$

O resultado do teorema, a seguir, permite identificar quando uma matriz A , $n \times n$, simétrica com coeficientes reais é positiva definida.

Teorema 3.4

Seja a matriz A , $n \times n$, simétrica com coeficientes reais. Então, a matriz A é positiva definida $\iff A$ pode ser fatorada na forma LL^t , onde L é a matriz triangular inferior, $n \times n$, sendo os coeficientes de L números reais e com coeficientes diagonais diferentes de zero.

Prova

($\Leftarrow$) Se L tem coeficientes números reais, então:

$$x^t Ax = x^t L^t Lx = y^t y > 0,$$

pois $y = Lx$ é real, $\forall x \in \mathbf{R}^n, x \neq \mathbf{0}$

($\Rightarrow$)

Se a matriz A é positiva definida, então $\forall x \in \mathbf{R}^n, x \neq \mathbf{0}$

$$x^t Ax = x^t L^t Lx > 0,$$

donde Lx é real e, conseqüentemente, L é real.

Exemplo

A matriz

$$\mathbf{A} = \begin{bmatrix} 4 & 2 & 2 \\ 2 & 0 & -1 \\ 2 & -1 & 3 \end{bmatrix}$$

pode ser fatorada pela fatoração de Cholesky com números complexos, dando o seguinte resultado:

$$\mathbf{A} = \mathbf{LL}^t = \begin{bmatrix} 2 & 0 & 0 \\ 1 & i & 0 \\ 1 & 2i & 2.4495 \end{bmatrix} \begin{bmatrix} 2 & 1 & 1 \\ 0 & i & 2i \\ 0 & 0 & 2.4495 \end{bmatrix}$$

Como alguns coeficientes de L são números complexos, podemos concluir que a matriz A não é positiva definida.

Exercícios Capítulo III

1 - a) Se a matriz A é o produto:

$$\mathbf{A} = \begin{bmatrix} 1 & 0 & 0 \\ -1 & 1 & 0 \\ 0 & -1 & 1 \end{bmatrix} \begin{bmatrix} d_1 & 0 & 0 \\ 0 & d_2 & 0 \\ 0 & 0 & d_3 \end{bmatrix} \begin{bmatrix} 1 & -1 & 0 \\ 0 & 1 & -1 \\ 0 & 0 & 1 \end{bmatrix},$$

sob que condições A é não singular?

b) Resolva o sistema linear $Ax = b$ iniciando com $Lc = b$, onde:

$$\mathbf{c} = \begin{bmatrix} c_1 \\ c_2 \\ c_3 \end{bmatrix}, \quad \mathbf{b} = \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix} \quad \text{e} \quad \mathbf{L} = \begin{bmatrix} 1 & 0 & 0 \\ -1 & 1 & 0 \\ 0 & -1 & 1 \end{bmatrix}$$

2 - Para quais valores de a, b e c haverá mudança de linhas para que a decomposição de A em LU seja possível e para quais valores a matriz A é singular?

$$\mathbf{A} = \begin{bmatrix} 1 & 2 & 0 \\ a & 8 & 3 \\ 0 & b & 5 \end{bmatrix} \quad \text{e} \quad \mathbf{A} = \begin{bmatrix} c & 2 \\ 6 & 4 \end{bmatrix}$$

3 - Considere um sistema linear da forma:

$$-m_1x_1 + x_2 = b_1$$

$$-m_2x_1 + x_2 = b_2$$

onde m_1, m_2, b_1 e b_2 são constantes.

a) Mostre que o sistema linear tem uma solução se $m_1 \neq m_2$;

b) Se $m_1 = m_2$, mostre que o sistema linear é compatível se também $b_1 = b_2$;

c) Interprete geometricamente os itens a) e b).

4 - Obtenha a fatoração da forma $A = P^tLU$ para as seguintes matrizes, onde P é uma matriz de permutação:

$$\text{a) } \mathbf{A} = \begin{bmatrix} 0 & 2 & 3 \\ 1 & 1 & -1 \\ 0 & -1 & 1 \end{bmatrix} \quad \text{b) } \mathbf{A} = \begin{bmatrix} 1 & -2 & 3 & 0 \\ 1 & -2 & 3 & 1 \\ 1 & -2 & 2 & -2 \\ 2 & 1 & 3 & -1 \end{bmatrix}$$

5 - Encontre o valor de α de modo que a matriz:

$$\mathbf{A} = \begin{bmatrix} \alpha & 1 & -1 \\ 1 & 2 & 1 \\ -1 & 1 & 4 \end{bmatrix}$$

seja positiva definida.

6 - Encontre a fatoração LDL^t para as seguintes matrizes simétricas:

$$\text{a) } \mathbf{A} = \begin{bmatrix} 3 & -3 & 6 \\ -3 & 2 & -7 \\ 6 & -7 & 13 \end{bmatrix} \quad \text{b) } \mathbf{A} = \begin{bmatrix} 2 & -2 & 4 & -4 \\ -2 & 3 & -4 & 5 \\ 4 & -4 & 10 & -10 \\ -4 & 5 & -10 & 14 \end{bmatrix}$$

Quais são simétricas positivas definidas?

7 - Dado o sistema linear $Ax = b$, onde:

$$\mathbf{A} = \begin{bmatrix} 1/2 & 1/3 \\ 1/3 & 1/4 \end{bmatrix}, \quad \mathbf{x} = \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}, \quad \mathbf{b} = \begin{bmatrix} 1/63 \\ 1/168 \end{bmatrix}.$$

Considerando x a solução exata do mesmo dada por $x = (1/7, -1/6)^t$ e $\bar{x}$ a solução aproximada do mesmo com 3 casas decimais, calcule:

$$\|x - \bar{x}\|_\infty \text{ e } \|A\bar{x} - b\|_\infty.$$

8 - Resolva os dois sistemas lineares a seguir e compare suas soluções. As matrizes dos coeficientes são bem condicionadas? Mal condicionadas? Explique.

$$\text{a) } \begin{bmatrix} 1.0 & 2.0 \\ 2.0 & 3.9 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 1.12 \\ 2.16 \end{bmatrix} \quad \text{b) } \begin{bmatrix} 1.0 & 2.011 \\ 2.0 & 3.982 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 1.12 \\ 2.16 \end{bmatrix}$$

9 - Seja

$$\mathbf{A}_n = \begin{bmatrix} 1 & 1 \\ 1 & 1 - 1/n \end{bmatrix}$$

para cada inteiro positivo n .

Calcule:

a) A_n^{-1} ; **b)** $K(A_n)$, (norma ∞); **c)** $\lim_{n \rightarrow \infty} K(A_n)$, (norma ∞).

10 - As matrizes de Hilbert, H_n , onde: $h_{ij} = \frac{1}{i+j-1}$, $1 \leq i, j, \leq n$ são exemplos de matrizes mal condicionadas.

a) Use pacotes computacionais para calcular $K(A)$ e verificar que quanto maior for n mais mal condicionada é H_n ;

b) Use pacotes computacionais para calcular H_n^{-1} e em seguida, o produto $H_n^{-1} \times H_n$ para possíveis valores de n .

Implementação dos Exercícios do Capítulo III em Matlab

```
1 %Exercicios Capitulo 3
2
3 %Exercicio 4 letra a
4 % clear
5 % clc
6 % A=[0 2 3; 1 1 -1; 0 -1 1]
7 %
8 % P=[0 1 0; 1 0 0; 0 0 1]
9 %
10 % [L,U]=lu(A)
11 %
12 % [L,U]=lu(P^-1*A)
13
14 %Exercicio 4 letra b
15 % clear
16 % clc
17 % A=[1 -2 3 0; 1 -2 3 1; 1 -2 2 -2; 2 1 3 -1]
18 %
19 % P=[0 0 0 1; 0 1 0 0; 0 0 1 0; 1 0 0 0]
20 %
21 % [L,U]=lu(A)
22 %
23 % [L,U]=lu(P^-1*A)
24
25 %Exercicio 6 letra a
26 % clear
27 % clc
28 % A=[6 -7 13; -3 2 -7; 3 -3 6]
29 % [L,U]=lu(A)
30 % chol(A)
31
32
33 %Exercicio 6 letra a
34 % clear
35 % clc
36 % A=[4 -4 10 -10; -4 5 -10 14; 2 -2 4 -4; -2 3 -4 5]
37 % [L,U]=lu(A)
38 % chol(A)
39
40 %Exercicio 7
41 % clear
42 % clc
43 % x=[1/7 ; -1/6]
44 % X=[0.142; -0.166]
```



```

45 % A=[1/2 1/3; 1/3 1/4]
46 % b=[1/63; 1/168]
47 %
48 % norm((x-X),Inf)
49 %
50 % norm((A*X-b),Inf)
51
52 %Exercicio 8 letra a
53 % clear
54 % clc
55 % A=[1 2; 2 3.9]
56 % cond(A,1)
57
58 %Exercicio 8 letra b
59 % clear
60 % clc
61 % A=[1 2.011; 2 3.982]
62 % cond(A,1)
63
64
65 %Exercicio 10 letra a
66 % clear
67 % clc
68 % x=1:100;
69 % K(1:100)=0;
70 % for i=1:100
71 %     %K(i)=norm(hilb(i),1)*norm(invhilb(i),1);
72 %     K(i)=cond(hilb(i),1);
73 % end
74 % plot(x,log(K))
75 % title('Valores de K(A)')
76 % ylabel('log(K(A))')
77 % xlabel('n-dimensao da matriz de Hilbert')
78
79 %Fazendo o calculo para matriz de Hilbert para valores de n
    variando
80 %de 1 ate 100, e possivel perceber que o crescimento do valor de K(
    A)
81 %e exponencial (Eixo y na escala log na base 10), quanto maior o
    valor
82 %de n mais mal condicionada e a matriz.
83 %Obs: os testes com a funcao cond() nao apresentam o resultado
    esperado por
84 %limitacoes de arredondamento quando n fica muito grande.
85

```

```

86 %Exercicio 10 letra b
87 % clear
88 % clc
89 % j=1:100;
90 % N(1:100)=0;
91 % for i=1:100
92 %     N(i)= norm(invhilb(i)*hilb(i),1);
93 %     %N(i)=cond(hilb(i),1);
94 % end
95 % plot(j,log(N))
96 % title('Valores da Norma')
97 % ylabel('log(Norma)')
98 % xlabel('n-dimensÃ£o da matriz de Hilbert')
99
100 %O produto de  $H_{n-1} \times H_n$  deveria ser igual a matriz identidade de
    ordem n,
101 %porem quanto maior o valor de n maior e o erro de calculo e mais
102 %diferente da identidade fica o valor do produto. Uma forma de
    comparar
103 %o tamanho desse erro e calculando a norma da matriz resultante do
    produto
104 % $H_{n-1} \times H_n$ , se os calculos estivessem corretos e o resultado fosse a
    matriz
105 %identidade, o valor da norma seria 1 para qualquer valor de n.
106 %Com a ajuda do grafico acima e possÃvel perceber que o
    crescimento
107 %da norma e exponencial, evidenciando o erro dos calculos com o
    aumento
108 %de n.
109 %Obs: os testes com a funcao cond() nao apresentam o resultado
    esperado por
110 %limitacoes de arredondamento quando n fica muito grande.

```

Implementação de Exemplos do Capítulo III em Matlab

```
1 %Capítulo 3
2
3 % Decomposicao LU
4 % clear
5 % clc
6 % A=[2 2 -1; 2 1 -5; 1 5 3]
7 %
8 %
9 % [L,U]=lu(A)
10 % clear
11 % clc
12 % B=[2 1 2; 1 2 3; 4 1 2]
13 %
14 % [L,U]=lu(B)
15 %
16 % l=L^-1
17 % u=U^-1
18 %
19 % u*l
20 % B^-1
21
22 % Decomposicao para tipos especiais de matrizes
23 % clear
24 % clc
25 %
26 % A=[7 2 0
27 %      3 5 -1
28 %      0 5 -6]
29 %
30 % testeedd(A)
31
32 %Funcao para teste de Diagonal Dominante
33
34 % function[saida]=testeedd(A)
35 %
36 % %saida = 0 => Nao e Estritamente Diagonal Dominante
37 % %saida = 1 => E Estritamente Diagonal Dominante
38 %
39 %
40 % na=size(A);
41 % if na(1)~=na(2)
42 %     return
43 % end
44 %
```

```

45 % n=na(1);
46 % d(1:n)=0;
47 %
48 % for i=1:n
49 %     for j=1:n
50 %         if j~=i
51 %             d(i)=d(i)+abs(A(i,j));
52 %         end
53 %     end
54 %     if abs(A(i,i))<d(i)
55 %         saida=0;
56 %         return
57 %     end
58 % end
59 %     saida=1;
60 %
61 %
62 % end
63
64
65 %
66 % A^-1
67
68 %Fatoracao ldl e Cholesky
69 % clear
70 % clc
71 %
72 % A=[2 -1 0; -1 2 -1; 0 -1 2]
73 % [L,D]=ldl(A)
74 % C=chol(A)
75 %
76 % B=[4 2 2; 2 0 -1; 2 -1 3]
77 % chol(B)

```

Capítulo 4

Espaços Vetoriais

4.1 Introdução

No Capítulo 1 introduzimos o espaço vetorial das n -uplas em $\mathbf{R}^n$, onde vetores e operações vetoriais foram introduzidos de forma analítica com interpretação geométrica para $n \leq 3$. Daremos aqui a definição de espaço vetorial de forma axiomática, onde trabalharemos com elementos de um conjunto que satisfazem determinadas propriedades.

Definição 1

O conjunto V é chamado um espaço vetorial se satisfaz os dez axiomas a seguir, classificados em três grupos:

Axiomas do fecho

Axioma 1. (Fechamento da adição)

Para qualquer par de elementos $x, y \in V$, existe um único elemento em V , chamado soma de x e y , denotado por $x + y$;

Axioma 2. (Fechamento da multiplicação por escalar)

Para qualquer elemento $x \in V$ e para qualquer escalar $\alpha \in \mathbf{R}$, existe um único elemento em V , chamado produto de α por x , denotado αx ;

Axiomas da Adição

Axioma 3. (Comutatividade)

$$x + y = y + x, \forall x, y \in V;$$

Axioma 4. (Associatividade)

$$(x + y) + z = x + (y + z), \forall x, y, z \in V;$$

Axioma 5. (Existência do zero)

$$\exists \mathbf{0} \in V \text{ tal que } x + \mathbf{0} = x, \forall x \in V;$$

Axioma 6. (Existência do negativo)

$$\forall x \in V, \exists (-1)x \in V \text{ tal que } x + (-1)x = \mathbf{0};$$

Axiomas da Multiplicação por Escalar

Axioma 7. (Associatividade)

$$\alpha\beta(x) = \alpha(\beta x) \quad \forall \alpha, \beta \in \mathbf{R}, \forall x \in V;$$

Axioma 8. (Distributividade para adição em V)

$$\alpha(x + y) = \alpha x + \alpha y \quad \forall x, y \in V, \forall \alpha \in \mathbf{R};$$

Axioma 9. (Distributividade para adição em $\mathbf{R}$)

$$(\alpha + \beta)x = \alpha x + \beta x \quad \forall x \in V, \forall \alpha, \beta \in \mathbf{R};$$

Axioma 10. (Existência da identidade)

$$\forall x \in V, \text{ temos } 1x = x.$$

Obs.: Os escalares podem ser tomados no conjunto dos números complexos ($\mathbf{C}$) e o conjunto V será constituído de n -uplas também em $\mathbf{C}$. Desta forma, podemos definir o espaço vetorial complexo V

Exemplo 1 O conjunto $V = \mathbf{R}^n$, munido das operações da álgebra vetorial visto no Capítulo 1 é um espaço vetorial.

Exemplo 2 O conjunto $V = \mathbf{C}^n$, munido das operações da álgebra vetorial nos complexos, conforme a observação anterior, é um espaço vetorial.

Exemplo 3 O conjunto das matrizes retangulares, $m \times n$, com coeficientes complexos, denotado por $M(m, n)$, munido das operações de adição de matrizes e multiplicação por escalar em $\mathbf{C}$ é um espaço vetorial.

Exemplo 4 O conjunto dos polinômios com coeficientes reais de grau $\leq n$, denotado por P_n , munido das operações de adição de polinômios em P_n e multiplicação por escalar em $\mathbf{R}$ é um espaço vetorial.

O teorema a seguir, diz respeito sobre a unicidade dos elementos zero e simétricos, cuja prova baseia-se nos axiomas anteriores.

Teorema 4.1

- a) Em qualquer espaço vetorial V existe um e só um elemento zero;
- b) Em qualquer espaço vetorial V todo elemento x admite um e só um elemento y , tal que $x + y = \mathbf{0}$.

Prova

Prova do item a):

O **axioma 5** nos diz que existe pelo menos um elemento zero. Suponhamos que existam dois, digamos $\mathbf{0}_1$ e $\mathbf{0}_2$. Tomando $x = \mathbf{0}_1$ e $\mathbf{0} = \mathbf{0}_1$ no **axioma 5**, obtemos $\mathbf{0}_1 + \mathbf{0}_2 = \mathbf{0}_1$. Do mesmo modo, tomando $x = \mathbf{0}_2$ e $\mathbf{0} = \mathbf{0}_2$, encontramos $\mathbf{0}_2 + \mathbf{0}_1 = \mathbf{0}_1$. Mas, pelo **axioma 3**, $\mathbf{0}_1 + \mathbf{0}_2 = \mathbf{0}_2 + \mathbf{0}_1$. Logo, $\mathbf{0}_1 = \mathbf{0}_2$.

Prova do item b);

O **axioma 6** nos diz que existe pelo menos um elemento negativo, a saber $(-1)x$. Suponhamos que x tenham dois negativos, digamos y_1 e y_2 . Então $x + y_1 = \mathbf{0}$ e

$x + y_2 = \mathbf{0}$. Adicionando y_2 a ambos membros da primeira equação e usando os **axiomas 5,4,3**, obtemos $y_2 + (x + y_1) = y_2 + \mathbf{0} = y_2$ e, por outro lado, $y_2 + (x + y_1) = (y_2 + x) + y_1 = \mathbf{0} + y_1 = y_1 + \mathbf{0} = y_1$. Logo, $y_1 = y_2$, de modo que x tem exatamente um negativo.

As seguintes propriedades regem os cálculos algébricos elementares em um espaço vetorial.

Propriedades

Sejam x e y elementos quaisquer em um espaço vetorial V e α e β escalares quaisquer. Então verificam-se as seguintes propriedades:

- a) $0x = \mathbf{0}$;
- b) $\alpha\mathbf{0} = \mathbf{0}$;
- c) $(-\alpha)x = -(\alpha x) = \alpha(-x)$;
- d) Se $\alpha x = \mathbf{0}$, então ou $\alpha = 0$ ou $x = \mathbf{0}$;
- e) Se $\alpha x = \alpha y$ e $\alpha \neq 0$, então $x = y$;
- f) Se $\alpha x = \beta x$ e $x \neq \mathbf{0}$, então $\alpha = \beta$;
- g) $-(x + y) = (-x) + (-y) = -x - y$;
- h) $x + x = 2x, x + x + x = 3x$, em geral $\sum_{i=1}^n x = nx$.

Prova: (ver Apostol, Vol. II [3])

4.2 Subespaço Vetorial

Definição 2

Um subespaço vetorial de um espaço vetorial V é um subconjunto não vazio $W \subseteq V$ que satisfaz as seguintes propriedades:

- i) A adição de dois vetores quaisquer $w_1, w_2 \in W$ também está em W , isto é, se $w_1, w_2 \in W$, então $w_1 + w_2 \in W$;
- ii) A multiplicação de qualquer vetor $w \in W$ por um escalar qualquer α está em W , isto é, se $w \in W$ e α escalar, então $\alpha w \in W$.

Em outras palavras, um subespaço vetorial é um subconjunto W de um espaço vetorial V que é fechado em relação às operações de adição de vetores e multiplicação de escalar por vetor. Note que, em particular o vetor nulo pertence a todo subespaço vetorial. Isto é decorrente da propriedade ii) tomando $\alpha = 0$. O menor subespaço vetorial é o subespaço contendo somente o vetor nulo e o maior subespaço vetorial é o espaço vetorial V , chamados subespaços triviais. No caso do $\mathbf{R}^n$, o menor subespaço é o $\{\mathbf{0}\}$ e o maior subespaço é o próprio $\mathbf{R}^n$.

O seguinte teorema nos permite formular uma definição equivalente para subespaço vetorial.

Teorema 4.2

Seja um espaço vetorial V e um subconjunto não vazio $W \subseteq V$. Então, W é um subespaço vetorial de $V \iff (\alpha w_1 + \beta w_2) \in W \forall \alpha, \beta \in \mathbf{R} \text{ e } \forall w_1, w_2 \in W$.

Prova

Seja o subconjunto não vazio $W \subseteq V$. Sejam $w_1, w_2 \in W$ e $\alpha, \beta \in \mathbf{R}$, como por hipótese $(\alpha w_1 + \beta w_2) \in W$. Tomando $\alpha, \beta = 1$, temos que $w_1 + w_2 = 1w_1 + 1w_2 \in W$. Além do mais, tomando $\beta = 0$, temos que $\alpha w_1 = \alpha w_1 + 0w_2 \in W$. Logo, conforme a definição anterior, W é um subespaço vetorial de V .

Reciprocamente, se W é um subespaço vetorial de V , então obviamente

$$(\alpha w_1 + \beta w_2) \in W \forall \alpha, \beta \in \mathbf{R} \text{ e } \forall w_1, w_2 \in W.$$

Exemplo 1 Seja W o conjunto de todos os vetores em $\mathbf{R}^2$ tais que a 2a. componente é nula. W é um subespaço vetorial, constituído pelo *Eixo - x* do plano cartesiano, pois os axiomas i) e ii) são satisfeitos para W .

Exemplo 2 Seja $M(3, 3)$ o espaço vetorial das matrizes, 3×3 . Tomando neste espaço o subconjunto W formado pelas matrizes, 3×3 , triangulares superiores. Temos que são válidos os axiomas i) e ii) para W . Portanto, W é um subespaço vetorial de $M(3, 3)$. Note que a matriz nula, 3×3 , é o vetor nulo deste subespaço vetorial.

4.3 Independência linear, subespaço gerado, base e dimensão

O objetivo desta seção é introduzir e usar os seguintes conceitos:

- 1 - Subespaço vetorial gerado;
- 2 - Dependência e independência linear em um espaço vetorial V ;
- 3 - Base para um subespaço vetorial;
- 4 - Dimensão em um subespaço vetorial.

Definição 3

Seja W um subconjunto não vazio de um espaço vetorial V . Um elemento x de V da forma:

$$x = \sum_{i=1}^k \lambda_i v_i$$

onde $v_1, v_2, \dots, v_k \in W$ e $\lambda_1, \lambda_2, \dots, \lambda_k$ são escalares, diz-se uma combinação linear finita de elementos de W . O conjunto de todas as combinações lineares finitas de elementos de W verificam os axiomas de fecho e por conseguinte, é um subespaço vetorial de V . Chamamos este subespaço de subespaço gerado por W e o representamos por $L(W)$.

Exemplo 1 Tomamos no espaço vetorial $\mathbf{R}^2$ os seguintes conjuntos de vetores $\{\mathbf{i}, \mathbf{j}\}$, $\{\mathbf{0}, \mathbf{i} - \mathbf{j}, \mathbf{i} + \mathbf{j}\}$. Todos estes conjuntos geram o espaço vetorial $\mathbf{R}^2$, apesar de serem distintos.

Exemplo 2 O conjunto $\{w_1, w_2, w_3\}$ onde $w_1 = (1, 0, 0)$, $w_2 = (0, 1, 0)$ e $w_3 = (2, 0, 0)$ gera o plano xy em $\mathbf{R}^3$.

Vamos tratar agora das combinações lineares nulas.

Definição 4

Um conjunto W de elementos de um espaço vetorial V é chamado linearmente dependente se existe um conjunto finito de elementos distintos em W , digamos $v_1, v_2, \dots, v_k$, e escalares correspondentes $\lambda_1, \lambda_2, \dots, \lambda_k$, não todos nulos, tais que:

$$\sum_{i=1}^k \lambda_i v_i = 0$$

O conjunto W é chamado linearmente independente quando para quaisquer elementos $v_1, v_2, \dots, v_k$ em W e escalares correspondentes $\lambda_1, \lambda_2, \dots, \lambda_k$, tais que:

$$\sum_{i=1}^k \lambda_i v_i = 0$$

implica em $\lambda_1 = \lambda_2 = \dots = \lambda_k = 0$. Neste caso, também podemos dizer que os vetores $v_1, v_2, \dots, v_k$ são linearmente independentes.

Exemplo 1 Se em um conjunto W temos $v_1 = \mathbf{0}$, então podemos tomar a combinação linear $\lambda_1 v_1 + \lambda_2 v_2 + \dots + \lambda_k v_k = 0$, onde $\lambda_2 = \lambda_3 = \dots = \lambda_k = 0$ e temos $\lambda_1 v_1 = 0 \implies \lambda_1 \neq 0$. Portanto, $v_1, v_2, \dots, v_k$ são linearmente dependentes.

Obs.: O vetor nulo em um subespaço vetorial W é obtido pela combinação linear de vetores linearmente independentes em W .

Exemplo 2 Os vetores $v_1 = (2, 3)$, $v_2 = (4, 6) \in \mathbf{R}^2$ são linearmente dependentes, pois tomando a combinação linear $\lambda_1 v_1 + \lambda_2 v_2 = \mathbf{0}$ ou seja $\lambda_1(2, 3) + \lambda_2(4, 6) = (0, 0)$, obtemos: $2\lambda_1 + 4\lambda_2 = 0$ e $3\lambda_1 + 6\lambda_2 = 0$, ou seja: $\lambda_1 = -2\lambda_2$ que podem ser não nulos.

Definição 5

Uma base de um espaço vetorial V é um conjunto de vetores em V onde:

- i) gera o espaço vetorial V ;
- ii) e é linearmente independente.

Exemplo 1

O espaço vetorial $\mathbf{R}^n$ tem como base o conjunto dos vetores $e_1, e_2, \dots, e_n$, chamada de base canônica.

Exemplo 2 Seja $M(2, 2)$ o espaço vetorial das matrizes, 2×2 , que tem dimensão 4. Uma base para este espaço vetorial é conjunto formado pelas matrizes:

$$\mathbf{M}_1 = \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix}$$

$$\mathbf{M}_2 = \begin{bmatrix} 0 & 1 \\ 0 & 0 \end{bmatrix}$$

$$\mathbf{M}_3 = \begin{bmatrix} 0 & 0 \\ 1 & 0 \end{bmatrix}$$

$$\mathbf{M}_4 = \begin{bmatrix} 0 & 0 \\ 0 & 1 \end{bmatrix}$$

uma vez que qualquer matriz $\mathbf{M}$, 2×2 , onde

$$\mathbf{M} = \begin{bmatrix} a_{11} & a_{12} \\ a_{21} & a_{22} \end{bmatrix}$$

pode ser escrita como: $\mathbf{M} = a_{11}\mathbf{M}_1 + a_{12}\mathbf{M}_2 + a_{21}\mathbf{M}_3 + a_{22}\mathbf{M}_4$ e

$$\mathbf{M} = \begin{bmatrix} 0 & 0 \\ 0 & 0 \end{bmatrix}$$

somente quando $a_{11} = a_{12} = a_{21} = a_{22} = 0$.

Definição 6

Definimos dimensão de um espaço vetorial V o número de vetores da base de V , visto que qualquer base de V contem o mesmo número de vetores.

Exemplo 1

O espaço vetorial $\mathbf{R}^n$ tem dimensão n .

Exemplo 2 O espaço vetorial das matrizes $M(2, 2)$, 2×2 tem dimensão 4.

Seja V um espaço vetorial de dimensão n e consideremos uma base cujos elementos são dados na ordem $v_1, v_2, \dots, v_n$. Representamos esta base por um n sistema linear em $(v_1, v_2, \dots, v_n)$. Se $x \in V$, podemos expressar x como uma combinação linear destes elementos da base, de forma similar como fizemos no Capítulo 1 para vetores em $\mathbf{R}^n$:

$$x = \sum_{i=1}^n a_i v_i$$

Os coeficientes nesta igualdade formam um n sistema linear de números $(a_1, a_2, \dots, a_n)$ que ficam univocamente determinados para x . Estes coeficientes são chamados de componentes ou coordenadas da base ordenada.

4.4 Soma e Interseção de Subespaços

Definição 7

Sejam W_1 e W_2 subespaços vetoriais de um espaço vetorial V . Definimos soma e interseção de W_1 e W_2 , respectivamente, por:

$$1 - W_1 + W_2 = \{w_1 + w_2 \text{ tal que } w_1 \in W_1, w_2 \in W_2\}$$

$$2 - W_1 \cap W_2 = \{v \text{ tal que } v \in W_1 \text{ e } v \in W_2\}$$

Definição 8

Sejam W_1 e W_2 subespaços vetoriais de um espaço vetorial V . Definimos soma direta de W_1 e W_2 , notada por $W = W_1 \oplus W_2$, quando:

$$1 - W = W_1 + W_2;$$

$$2 - W_1 \cap W_2 = \mathbf{0}.$$

Os subespaços W_1 e W_2 são ditos complementares um do outro em W .

Teorema 4.3

Sejam W_1 e W_2 subespaços vetoriais de um espaço vetorial V , onde $V = W_1 \oplus W_2$. Então,

a) Todo vetor $v \in V$, pode ser escrito unicamente na forma $v = r + s$, onde $r \in W_1$ e $s \in W_2$;

$$b) \dim(V) = \dim(W_1) + \dim(W_2).$$

Prova

a) Suponha que um vetor qualquer $v \in V$ pode ser escrito como:

$$v = r_1 + s_1 = r_2 + s_2,$$

onde $r_1, r_2 \in W_1$ e $s_1, s_2 \in W_2$. Então, $r_1 - r_2 = s_2 - s_1$. Mas, $r_1 - r_2 \in W_1$ e $s_1 - s_2 \in W_2$. Desde que $W_1 \cap W_2 = \mathbf{0}$, devemos ter $r_1 = r_2$ e $s_1 = s_2$. O que prova a unicidade de r e s na forma $v = r + s$.

b) Para provar a segunda parte, basta usar o seguinte resultado válido para quaisquer subespaços W_1 e W_2 de V .

$$\dim(W_1 + W_2) = \dim(W_1) + \dim(W_2) - \dim(W_1 \cap W_2)$$

Como $\dim(W_1 \cap W_2) = 0$, segue-se que :

$$\dim(V) = \dim(W_1) + \dim(W_2)$$

Definição 9

Seja $\{v_1, v_2, \dots, v_k\}$ um conjunto ortogonal de vetores em $\mathbf{R}^n$, ou seja:

$$v_i^t v_j = 0 \quad \forall i, j, \quad i \neq j.$$

Dizemos que este conjunto é ortonormal quando:

$$v_i^t v_j = \delta_{ij},$$

onde

$$\delta_{ij} = \begin{cases} 1 & \text{se } i = j \\ 0 & \text{se } i \neq j \end{cases}$$

Definição 10

Seja W um subespaço vetorial de $\mathbf{R}^n$. O complemento ortogonal de W é definido por:

$$W^\perp = \{v \in \mathbf{R}^n \text{ tal que } v^t s = 0, \forall s \in W\}$$

Teorema 4.4

Seja W um subespaço de $\mathbf{R}^n$. Então,

- a) $W \oplus W^\perp = \mathbf{R}^n$;
- b) $(W^\perp)^\perp = W$.

Prova

Vamos provar a).

Seja $\{v_1, v_2, \dots, v_k\}$ uma base ortonormal de W e seja $x \in \mathbf{R}^n$ um vetor qualquer.

Sejam:

$$x_1 = \sum_{i=1}^k (x^t v_i) v_i$$

$$x_2 = x - x_1$$

Então, $x_1 \in W$ e, desde que

$$x_2^t v_j = x^t v_j - x_1^t v_j = x^t v_j - x^t v_j = 0, j = 1, 2, \dots, k$$

vemos que x_2 é ortogonal à $v_1, v_2, \dots, v_k$ e portanto à qualquer combinação linear destes vetores. Logo, x_2 é ortogonal a qualquer vetor de W . Assim, $W + W^\perp = \mathbf{R}^n$. Também, temos que $W \cap W^\perp = \mathbf{0}$, uma vez que o único vetor de $s \in W$ ortogonal à qualquer vetor de W é o $\mathbf{0}$.

Logo, $W \oplus W^\perp = \mathbf{R}^n$.

A prova de b) deixamos com exercício.

4.5 Espaços Linha e Coluna de A

Seja A uma matriz, $m \times n$, onde tomamos cada linha de A como uma n -upla de números reais, constituída de vetores em $\mathbf{R}^{1 \times n}$. De forma similar, tomamos cada coluna de A como uma m -upla de números reais, constituída de vetores em $\mathbf{R}^{m \times 1}$.

Estes vetores formam subespaços vetoriais que nos dão informações acerca do sistema linear $Ax = b$. Damos a seguinte definição:

Definição 11

Seja A uma matriz, $m \times n$, o subespaço de $\mathbf{R}^{1 \times n}$ gerado pelos vetores linha de A é chamado de espaço linha de A . Denotaremos este subespaço por $R(A)^t$. O subespaço de $\mathbf{R}^{m \times 1}$ gerado pelos vetores coluna de A é chamado de espaço coluna de A . Denotaremos este subespaço por $R(A)$.

Exemplo 1 Seja o sistema linear $Ax = b$:

$$\begin{bmatrix} 1 & 0 \\ 5 & 3 \\ 4 & 3 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} b_1 \\ b_2 \\ b_3 \end{bmatrix}$$

O espaço linha de A , $R(A)^t$, é o conjunto de todas combinações lineares da forma:

$$\alpha(1, 0) + \beta(5, 3) + \gamma(4, 3) = (\alpha + 5\beta + 4\gamma, 3\beta + 3\gamma).$$

O espaço coluna de A , $R(A)$, é o conjunto de todas combinações lineares da forma:

$$\alpha \begin{bmatrix} 1 \\ 5 \\ 4 \end{bmatrix} + \beta \begin{bmatrix} 0 \\ 3 \\ 3 \end{bmatrix} = \begin{bmatrix} \alpha \\ 5\alpha + 3\beta \\ 4\alpha + 3\beta \end{bmatrix}$$

Observe que para este exemplo, $m > n$, temos mais equações do que incógnitas. Este sistema linear será solúvel para somente certos termos independentes b 's que são subconjuntos de $\mathbf{R}^3$.

Antes de passarmos à discussão sobre a solubilidade de um sistema linear, vamos dar o seguinte teorema:

Teorema 4.5

Duas matrizes A e U , $m \times n$, equivalentes por linhas têm o mesmo espaço linha.

Prova

Se U é equivalente por linhas a A , então U pode ser formada por uma sequência finita de operações elementares sobre as linhas de A . Assim, as linhas de U são combinações lineares dos vetores linhas de A . Consequentemente, $R(U)^t$ tem que ser um subespaço de $R(A)^t$. Como A é equivalente por linhas a U , $R(A)^t$ tem que ser um subespaço de $R(U)^t$ pelo mesmo argumento.

Definição 12

Definimos o posto de uma matriz A , $m \times n$, a dimensão do seu espaço linha ($R(A)^t$).

Exemplo 2

Seja a matriz A , abaixo:

$$\mathbf{A} = \begin{bmatrix} 1 & 3 & 3 \\ 2 & 6 & 9 \\ -1 & -3 & 3 \end{bmatrix}$$

Reduzindo esta matriz A a sua forma equivalente triangular superior, obtemos:

$$\mathbf{U} = \begin{bmatrix} 1 & 3 & 3 \\ 0 & 0 & 3 \\ 0 & 0 & 0 \end{bmatrix}$$

Temos que os vetores

$$\begin{bmatrix} 1 & 3 & 3 \end{bmatrix}, \begin{bmatrix} 0 & 0 & 3 \end{bmatrix}$$

formam uma base para $R(U)^t$ e para $R(A)^t$, pois estas matrizes são equivalentes por linhas. Portanto, $\dim (R(A)^t) = \dim (R(U)^t)$.

Por outro lado, temos que os vetores

$$\begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}, \begin{bmatrix} 3 \\ 3 \\ 0 \end{bmatrix}$$

formam uma base para $R(U)$. Contudo, estes vetores não formam uma base para $R(A)$. Para encontrar os vetores da base de $R(A)$, buscamos os vetores colunas que correspondem à posição destes em U na matriz A , que são dados por:

$$\begin{bmatrix} 1 \\ 2 \\ -1 \end{bmatrix}, \begin{bmatrix} 3 \\ 9 \\ 3 \end{bmatrix}$$

Seja A uma matriz, $m \times n$, e $x = (x_1, x_2, \dots, x_n)$ e $b = (b_1, b_2, \dots, b_m)$ vetores em $\mathbf{R}^n$ e $\mathbf{R}^m$, respectivamente. Vamos agora, escrever o sistema linear $Ax = b$, na forma:

$$x_1 \begin{bmatrix} a_{11} \\ a_{21} \\ \vdots \\ a_{m1} \end{bmatrix} + x_2 \begin{bmatrix} a_{12} \\ a_{22} \\ \vdots \\ a_{m2} \end{bmatrix} + \dots + x_n \begin{bmatrix} a_{1n} \\ a_{2n} \\ \vdots \\ a_{mn} \end{bmatrix} = \begin{bmatrix} b_1 \\ b_2 \\ \vdots \\ b_n \end{bmatrix}$$

Segue-se desta representação que: "O sistema linear $Ax = b$ é solúvel $\iff$ o vetor b está no espaço coluna de A ($R(A)$)".

Substituindo o vetor b pelo vetor nulo $\mathbf{0}$, escrevemos:

$$x_1 a_1 + x_2 a_2 + \dots + x_n a_n = \mathbf{0},$$

onde $a_1, a_2, \dots, a_n$ são os vetores coluna da matriz A .

Desta forma, podemos dizer que o sistema linear homogêneo $Ax = \mathbf{0}$ tem apenas solução trivial $\iff$ os vetores coluna de A são linearmente independentes.

Vamos dar, agora, o seguinte teorema:

Teorema 4.6

Seja A uma matriz, $m \times n$. O sistema linear $Ax = b$ é solúvel para todo $b \in \mathbf{R}^m \iff$ os vetores coluna de A geram $\mathbf{R}^m$. O sistema $Ax = b$ tem no máximo uma solução para qualquer que seja o vetor $b \in \mathbf{R}^m \iff$ os vetores coluna de A são linearmente independentes.

Prova

Vimos que o sistema linear $Ax = b$ é solúvel $\iff$ o vetor $b \in R(A)$. Desta forma, o sistema linear $Ax = b$ é solúvel $\forall b \in \mathbf{R}^m \iff$ os vetores coluna de A geram $\mathbf{R}^m$.

Para a segunda afirmação, observamos que se $Ax = b$ tem no máximo uma solução para qualquer vetor $b \in \mathbf{R}^m$, então, particularizando temos que $Ax = \mathbf{0}$ tem apenas a solução trivial e, portanto os vetores coluna de A são linearmente independentes. Por outro lado, se os vetores coluna de A são linearmente independentes, o sistema linear homogêneo $Ax = \mathbf{0}$ tem apenas a solução trivial. Vamos supor que x_1 e x_2 sejam duas soluções de $Ax = b$. Temos que $x_1 - x_2$ é também uma solução do sistema linear homogêneo $Ax = \mathbf{0}$, e assim:

$$A(x_1 - x_2) = Ax_1 - Ax_2 = b - b = \mathbf{0}$$

Logo, $x_1 - x_2 = \mathbf{0} \implies x_1 = x_2$.

Seja A uma matriz, $m \times n$. Se os vetores coluna de A geram $\mathbf{R}^m$, então n tem que ser maior ou igual a m , já que um conjunto com menos que m vetores não pode gerar $\mathbf{R}^m$. Se as colunas de A são linearmente dependentes, então n tem que ser menor ou igual a m , já que qualquer conjunto com mais de m vetores em $\mathbf{R}^m$ é linearmente dependente. Portanto, se os vetores coluna de A formam uma base para $\mathbf{R}^m$, então $n = m$. Isto ocorre quando a matriz A , $n \times n$, é invertível.

Teorema 4.7

Seja A uma matriz, $m \times n$, de $\text{posto}(A) = r$. A dimensão do espaço linha de A (igual ao $\text{posto}(A)$) é igual a dimensão do espaço coluna.

Prova

Seja A uma matriz, $m \times n$, de $\text{posto}(A)$. Reduzindo esta matriz à sua forma escada U , temos que as r primeiras linhas destas têm primeiros coeficientes $\neq 0$, cujas colunas correspondentes são linearmente independentes. Retiramos da matriz U as colunas correspondentes às variáveis livres e fazemos o mesmo com as colunas correspondentes da matriz A . Chamando estas matrizes de U_l e A_l , respectivamente,

temos que estas são equivalentes por linhas. Assim, x é solução de $A_l x = \mathbf{0} \iff x$ é solução de $U_l x = \mathbf{0}$. Ou seja, as colunas de A_l também devem ser linearmente independentes. Assim, a dimensão do espaço coluna de A deve ser pelo menos igual à r , ou seja: $(\geq r)$. Aplicando este mesmo raciocínio à matriz A^t , concluímos que dimensão do espaço coluna de $A^t \geq$ dimensão do espaço linha de A^t . Portanto, $\dim(R(A)) = \dim(R(A^t)) = r$.

4.6 Espaço Nulo de A e Espaço nulo à esquerda de A

Uma segunda visão para interpretar a solução do sistema linear $Ax = b$ é a "dual" da primeira. Ela se concentra não em encontrar o vetor $b \in \mathbf{R}^m$, mas também no conjunto de soluções para obtê-lo. O lado direito $b = \mathbf{0}$ nos leva sempre em uma solução particular trivial $x = \mathbf{0}$, mas podem existir infinitas soluções diferentes da trivial (caso em que $n > m$).

Definição 13

Seja A uma matriz, $m \times n$, o subespaço de $\mathbf{R}^{1 \times n}$ gerado pelos vetores x tais que $Ax = \mathbf{0}$ é chamado de espaço nulo de A . Denotaremos este subespaço por $N(A)$, e chamaremos de nulidade de A a $\dim(N(A))$.

Exemplo 1

Seja o sistema linear $Ax = \mathbf{0}$:

$$\begin{bmatrix} 1 & 0 \\ 5 & 3 \\ 4 & 3 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}$$

cuja solução será somente a trivial $x_1 = x_2 = 0$.

Acrescentando uma coluna à matriz A deste sistema linear, sendo esta combinação linear das duas primeiras, obtemos, por exemplo, a matriz B , 3×3 :

$$\mathbf{B} = \begin{bmatrix} 1 & 0 & 1 \\ 5 & 3 & 8 \\ 4 & 3 & 7 \end{bmatrix}$$

Temos que, não alteramos o espaço coluna de A , uma vez que $\dim(R(A)) = \dim(R(B)) = 2$, mas o espaço nulo de B contém o vetor cujas componentes são 1, , 1, -1 e contém o múltiplo deste vetor, ou seja:

$$\begin{bmatrix} 1 & 0 & 1 \\ 5 & 3 & 8 \\ 4 & 3 & 7 \end{bmatrix} \begin{bmatrix} c \\ c \\ -c \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}$$

Assim,

$$N(B) = \{(x, y, z) \in \mathbf{R}^3 \text{ tal que } x = c, y = c, z = -c \text{ onde } c \in \mathbf{R}\}$$

que será uma reta em $\mathbf{R}^3$.

Também, podemos observar que os vetores de cada linha de B , ou seja, tomados em $R(B)^t$, são ortogonais aos vetores de $N(B)$. Além do mais, $\dim (R(B)^t) = 2$, $\dim (N(B)) = 1$ e $\dim (R(B)^t) + \dim (N(B)) = 3$.

Damos agora, o seguinte teorema:

Teorema 4.7

Seja A uma matriz, $m \times n$. A soma do posto(A) com nulidade de A é igual a n .

Prova

Seja U a forma escada reduzida por linhas de A . O sistema linear homogêneo $Ax = \mathbf{0}$ é equivalente ao sistema linear homogêneo $Ux = \mathbf{0}$. Se A tem posto r , então U tem r linhas não nulas e, portanto, o sistema linear homogêneo $Ux = \mathbf{0}$ tem r variáveis líderes correspondentes aos **pivôs** não nulos e $n - r$ variáveis livres. A dimensão de $N(A)$ é igual ao número de variáveis livres.

Definição 14

Seja A uma matriz, $m \times n$. O subespaço de $\mathbf{R}^{m \times 1}$ gerado pelos vetores y tais que $A^t y = \mathbf{0}$ é chamado de espaço nulo à esquerda de A . Este subespaço corresponde ao espaço nulo de A^t . Assim, denotaremos este subespaço por $N(A^t)$.

Para uma matriz A , $m \times n$, podemos ver os quatro subespaços, ditos fundamentais, em termos do número de componentes de seus vetores.

- O espaço nulo de A , ($N(A)$) e o espaço linha de A , ($R(A^t)$) são subespaços de $\mathbf{R}^n$;
- O espaço nulo à esquerda de A , ($N(A^t)$) e o espaço coluna de A , ($R(A)$) são subespaços de $\mathbf{R}^m$.

Aplicando o resultado do teorema anterior à matriz A^t , temos que:

$$r + \dim(N(A^t)) = m$$

Logo, o espaço nulo à esquerda de A , ($N(A^t)$) tem dimensão $m - r$.

Para encontrar $y \in N(A^t)$, ou seja $y \in \mathbf{R}^m$, tal que $y^t A = \mathbf{0}$, basta calcular o espaço nulo para a matriz A^t . Outra forma de calculá-lo, consiste em encontrar a decomposição $PA = LU$, onde P é uma matriz de permutação. Em seguida, calculamos $L^{-1}PA$. As últimas $m - r$ linhas de $L^{-1}P$ formarão a base do espaço nulo à esquerda de A , porque estas multiplicadas por A dão as linhas nulas em U . Contudo, o cálculo de L^{-1} não é tão imediato como fizemos para a decomposição de LU da matriz A , $n \times n$.

Exemplo 2

Seja a matriz A :

$$\mathbf{A} = \begin{bmatrix} 1 & 0 \\ 5 & 3 \\ 4 & 3 \end{bmatrix}$$

temos que a matriz A^t é dada por:

$$\mathbf{A}^t = \begin{bmatrix} 1 & 5 & 4 \\ 0 & 3 & 3 \end{bmatrix}$$

Como a matriz A^t já está na forma escalonada, basta resolver o sistema linear homogêneo $A^t y = \mathbf{0}$, ou seja:

$$\mathbf{A}^t \mathbf{y} = \begin{bmatrix} 1 & 5 & 4 \\ 0 & 3 & 3 \end{bmatrix} \begin{bmatrix} y_1 \\ y_2 \\ y_3 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

Obtendo como solução:

$$\begin{bmatrix} y_1 \\ y_2 \\ y_3 \end{bmatrix} = y_3 \begin{bmatrix} 1 \\ -1 \\ 1 \end{bmatrix}$$

Temos assim, que o espaço nulo à esquerda de A é gerado pelo vetor:

$$\begin{bmatrix} 1 \\ -1 \\ 1 \end{bmatrix}$$

Outra forma de obter este vetor y tal que $y^t A = \mathbf{0}$ consiste em calcular $L^{-1}P$. Ora, temos que:

$$\mathbf{L}^{-1} = \begin{bmatrix} 1 & 0 & 0 \\ -5 & 1 & 0 \\ 1 & -1 & 1 \end{bmatrix}$$

Como não houve permutação de linhas no processo da decomposição da matriz A , tomamos a última linha de L^{-1} na forma transposta.

Observe que este vetor é perpendicular aos vetores do espaço coluna de A , $R(A)$:

$$\begin{bmatrix} 1 \\ 5 \\ 4 \end{bmatrix}, \begin{bmatrix} 0 \\ 3 \\ 3 \end{bmatrix}$$

e temos que $\dim (R(A)) = 2$, $\dim (N(A^t)) = 1$ e $\dim (R(A)) + \dim (N(A^t)) = 3$.

4.7 Resolução do sistema linear de m equações com n incógnitas

Vamos retornar ao Método da Decomposição da matriz A , $n \times n$, na forma produto de matrizes LU . Durante o processo de escalonamento, consideramos o **pivô** sempre $\neq 0$, a menos de uma permutação nas linhas. Isto é possível, porque consideramos $\det(A) \neq 0$. Vamos estender o processo de escalonamento a uma matriz A , $m \times n$, usando o seguinte artifício:

- i) Escolhemos as primeiras linhas de modo a ter os primeiros coeficientes não nulos nestas linhas (estes coeficientes serão os **pivôs**) - caso necessário, trocamos as linhas;
- ii) Zeramos os coeficientes da coluna abaixo destes **pivôs**, por eliminação;
- iii) Cada **pivô** situa-se na coluna à direita da coluna **pivô** da linha acima; isto produz a forma escalonada.

Ilustrando, após o escalonamento, obtemos a seguinte matriz:

$$\mathbf{U} = \begin{bmatrix} * & * & * & * & \cdots & * & * \\ 0 & * & * & * & \cdots & * & * \\ 0 & 0 & 0 & * & \cdots & * & * \\ \vdots & \vdots & \vdots & \vdots & \ddots & \vdots & \vdots \\ 0 & 0 & 0 & 0 & \cdots & 0 & * \\ 0 & 0 & 0 & 0 & 0 & 0 & 0 \end{bmatrix}$$

Exemplo 1

Seja a matriz A , 3×4 :

$$\mathbf{A} = \begin{bmatrix} 1 & 3 & 3 & 2 \\ 2 & 6 & 9 & 5 \\ -1 & -3 & 3 & 0 \end{bmatrix}$$

Procedendo o escalonamento da matriz A , obtemos a seguinte matriz U , 3×4 :

$$\mathbf{U} = \begin{bmatrix} 1 & 3 & 3 & 2 \\ 0 & 0 & 3 & 1 \\ 0 & 0 & 0 & 0 \end{bmatrix}$$

e L , será uma matriz, 3×3 , obtida de forma similar à decomposição LU , e também inversível. Assim, obtemos:

$$\mathbf{L} = \begin{bmatrix} 1 & 0 & 0 \\ 2 & 1 & 0 \\ -1 & 2 & 1 \end{bmatrix}$$

Observe que nenhuma operação de troca de linhas foi necessária neste exemplo. Mas, caso haja necessidade, usaremos uma matriz de permutação P para a troca de linhas. Damos o seguinte teorema:

Teorema 4.8

Para qualquer matriz A , $m \times n$, existem uma matriz de permutação P , $m \times m$, uma matriz triangular inferior L , $m \times m$, com diagonal unitária e uma matriz na forma escada U , $m \times n$, correspondentes, tais que $PA = LU$.

Prova

Aplicamos sucessivamente matrizes de permutações $P_1, P_2, P_3, \dots, P_k$, $m \times m$, no sistema linear $Ax = b$ de tal forma que assegure que nenhum intercâmbio de linhas seja necessário para resolver o sistema linear por meio da eliminação de Gauss. Desta forma, colocando a matriz de permutação P , $m \times m$, como:

$$P = P_k P_{k-1} P_{k-2} \dots P_2 P_1,$$

o sistema linear

$$PAx = Pb$$

pode ser resolvido sem intercâmbio de linhas. Mas, essa matriz PA pode ser fatorada em

$$PA = LU,$$

onde L é a matriz triangular inferior, $m \times m$, e U é a matriz na forma escada, $m \times n$. Como $P^{-1} = P^t$, temos a fatoração

$$A = P^{-1}LU = (P^t L)U.$$

Note que a matriz $P^t L$ não é triangular inferior, a menos que $P = I$.

Vamos agora analisar os dois casos de sistemas lineares: homogêneo e não homogêneo.

Caso homogêneo

Vamos considerar agora, a solução do sistema linear $Ux = \mathbf{0}$. Temos:

$$\mathbf{U}\mathbf{x} = \begin{bmatrix} 1 & 3 & 3 & 2 \\ 0 & 0 & 3 & 1 \\ 0 & 0 & 0 & 0 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ 0 \end{bmatrix}$$

Separamos as incógnitas x_1, x_2, x_3 e x_4 em dois grupos:

1o. grupo: Variáveis básicas Correspondentes às colunas **pivôs**. No caso, x_1 e x_3 ;

2o. grupo: Variáveis livres Correspondentes às colunas sem **pivôs**. No caso, x_2 e x_4 ;

Em seguida, escrevemos a solução geral como uma combinação das variáveis livres x_2 e x_4 , ou seja:

$$\mathbf{x} = \begin{bmatrix} -3x_2 - x_4 \\ x_2 \\ -1/3x_4 \\ x_4 \end{bmatrix} = x_2 \begin{bmatrix} -3 \\ 1 \\ 0 \\ 0 \end{bmatrix} + x_4 \begin{bmatrix} -1 \\ 0 \\ -1/3 \\ 1 \end{bmatrix}$$

Observe que o vetor

$$\begin{bmatrix} -3 \\ 1 \\ 0 \\ 0 \end{bmatrix}$$

dá a solução do sistema linear homogêneo $Ax = \mathbf{0}$ para as variáveis livres $x_2 = 1$ e $x_4 = 0$ e o vetor

$$\begin{bmatrix} -1 \\ 0 \\ -1/3 \\ 1 \end{bmatrix}$$

dá a solução do sistema linear homogêneo $Ax = \mathbf{0}$ para as variáveis livres $x_2 = 0$ e $x_4 = 1$. Todas as soluções do sistema linear homogêneo são combinações lineares destas duas. Temos que o espaço nulo de A ($N(A)$) é gerado por estes dois vetores.

Enunciamos o seguinte teorema:

Teorema 4.9

Seja A uma matriz, $m \times n$. Se o sistema linear homogêneo $Ax = \mathbf{0}$ tem mais incógnitas do que equações ($n > m$), ele tem solução diferente da solução trivial.

Prova

Desde que a matriz A tem mais colunas do que linhas, $n > m$, existirá no máximo m **pivôs**, daí existirá pelo menos $n - m$ variáveis livres. Existirá sempre mais variáveis livres se algumas linhas de U reduzem à zero, não mais do que isso, pelo menos uma variável deverá ser livre. Atribuindo um valor a esta variável, obtemos uma solução não trivial x . Na verdade, múltiplas soluções cx satisfazendo $A(cx) = 0$.

Observe que o espaço nulo é um subespaço de $\mathbf{R}^4$, com a dimensão igual ao número de variáveis livres. Trataremos a dimensão deste subespaço posteriormente.

Caso não homogêneo

No caso não homogêneo, o sistema original fica $Ax = b$, onde $b \neq \mathbf{0}$. Voltando ao exemplo anterior, obtemos após o escalonamento o sistema linear equivalente $Ux = c$:

$$\mathbf{U}\mathbf{x} = \begin{bmatrix} 1 & 3 & 3 & 2 \\ 0 & 0 & 3 & 1 \\ 0 & 0 & 0 & 0 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \end{bmatrix} = \begin{bmatrix} b_1 \\ b_2 - 2b_1 \\ b_3 - 2b_2 + 5b_1 \end{bmatrix}$$

onde o vetor c do lado direito desta equação é obtido através da operação: L^{-1} .

O sistema linear $Ux = c$ será inconsistente a menos que $b_3 - 2b_2 + 5b_1 = 0$.

Outra forma de interpretar a solução do sistema linear não homogêneo consiste em tomar o espaço coluna ($R(A)$). Este espaço é gerado pelos vetores coluna:

$$\begin{bmatrix} 1 \\ 2 \\ -1 \end{bmatrix}, \begin{bmatrix} 3 \\ 9 \\ 3 \end{bmatrix}$$

sendo que estes vetores coluna em A correspondem aos vetores coluna da matriz U com **pivôs**. Estes vetores geram um plano em $\mathbf{R}^3$, que consiste no conjunto dos pontos $(b_1, b_2, b_3) \in \mathbf{R}^3$ tais que $b_3 - 2b_2 + 5b_1 = 0$, condição imposta para o sistema linear ser solúvel, forçando o valor do vetor $b \in \mathbf{R}^3$. Geometricamente, dizemos que o vetor $(5, -2, 1)$ é perpendicular a cada coluna de A .

Assim, tomando como termo independente o vetor $(1, 5, 5)$ que é perpendicular ao vetor $(5, -2, 1)$, obtemos o seguinte sistema linear solúvel:

$$\mathbf{A}\mathbf{x} = \begin{bmatrix} 1 & 3 & 3 & 2 \\ 2 & 6 & 9 & 5 \\ -1 & -3 & 3 & 0 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \end{bmatrix} = \begin{bmatrix} 1 \\ 5 \\ 5 \end{bmatrix}$$

Após o escalonamento, obtemos:

$$\mathbf{U}\mathbf{x} = \begin{bmatrix} 1 & 3 & 3 & 2 \\ 0 & 0 & 3 & 1 \\ 0 & 0 & 0 & 0 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \\ x_4 \end{bmatrix} = \begin{bmatrix} 1 \\ 3 \\ 0 \end{bmatrix}$$

Observe que obtemos a última linha nula e as outras duas equações nos dão a solução: $x_3 = 1 - 1/3 x_4$ e $x_1 = -2 - 3x_2 - x_4$, onde x_2 e x_4 são variáveis livres.

Colocando a solução geral x_{geral} na forma:

$$\mathbf{x}_{\text{geral}} = \begin{bmatrix} -2 \\ 0 \\ 1 \\ 0 \end{bmatrix} + x_2 \begin{bmatrix} -3 \\ 1 \\ 0 \\ 0 \end{bmatrix} + x_4 \begin{bmatrix} -1 \\ 0 \\ -1/3 \\ 1 \end{bmatrix}$$

onde temos: $x_{\text{geral}} = x_{\text{particular}} + x_{\text{homogeneo}}$, sendo que o primeiro vetor coluna corresponde a solução particular para o sistema linear não homogêneo e as duas últimas parcelas fornecem a solução para o sistema linear homogêneo $Ax = \mathbf{0}$, bastando atribuir valores $x_2 = 1, x_4 = 0$ e $x_2 = 0, x_4 = 1$, respectivamente.

Geometricamente, a solução geral está em uma superfície bidimensional, mas que não é um subespaço vetorial por não conter a origem. Esta superfície é paralela ao espaço nulo anterior, mas deslocado pela solução particular.

Assim, os cálculos para a solução não homogênea incluem um novo passo:

- 1) Reduz-se $Ax = b$ à forma escalonada $Ux = c$;
- 2) Tome todas as variáveis livres iguais à zero e encontre a solução particular;
- 3) Faça o lado direito da equação $Ux = c$ igual a zero e para cada variável livre igual à 1 e com as outras nulas, encontre as soluções homogêneas.

A eliminação por escalonamento nos dá o número de **pivôs** e o número de variáveis livres. Se existem r **pivôs**, existem r variáveis básicas e $n - r$ variáveis livres.

4.8 Inversa à Direita e à Esquerda de Matriz

Definição 15

Seja a matriz $A, m \times n$. Dizemos que a matriz $B, n \times m$, é a inversa à esquerda da matriz A , quando esta existe e $BA = I_n$, onde I_n é a matriz identidade de ordem n . Dizemos que a matriz $C, n \times m$, é a inversa à direita da matriz A , quando esta existe e $AC = I_m$, onde I_m é a matriz identidade de ordem m .

Temos que para matrizes $A, n \times n$, quando estas inversas existem, elas são iguais.

De fato:

$$B = BI_m = B(AC) = (BA)C = I_n C = C,$$

sendo que neste caso $m = n$.

Teorema 4.10(Existência e Unicidade de Solução para $Ax = b$)

Existência O sistema linear $Ax = b$ tem pelo menos uma solução para qualquer vetor $b \in \mathbf{R}^m \iff$ as colunas de A geram $\mathbf{R}^m$, ($\text{posto}(A) = r = m$). Neste caso, existe uma inversa à direita $C, n \times m$, tal que $AC = I_m$, onde I_m é a matriz identidade de ordem m . Isto é possível somente quando $m \leq n$.

Unicidade O sistema linear $Ax = b$ tem no máximo uma solução para qualquer vetor $b \in \mathbf{R}^m \iff$ as colunas de A são linearmente independentes, ($\text{posto}(A) = r = n$). Neste caso, existe uma inversa à esquerda $B, n \times m$, tal que $BA = I_n$, onde I_n é a matriz identidade de ordem n . Isto é possível somente quando $m \geq n$.

Prova

Este teorema é similar ao teorema da seção 4.5, formulado agora com matrizes inversa à direita e à esquerda.

No primeiro caso, uma solução possível será $x = Cb$, uma vez que:

$$Ax = ACb = I_m b = b.$$

Mas, existem outras soluções se existem outras inversas à direita.

No segundo caso, se existe uma solução para $Ax = b$, esta tem de ser:

$$x = I_n x = BAx = Bb.$$

Existem fórmulas simples para inversas à esquerda e à direita, se elas existem:

$$B = (A^t A)^{-1} A^t \text{ e } C = A^t (A A^t)^{-1}$$

mas, para a existência das mesmas, as matrizes $A^t A, n \times n$, e $A A^t, m \times m$, deverão ser invertíveis e neste caso, $BA = I_n$ e $AC = I_m$.

Veremos no capítulo sobre ortogonalidade que:

- $A^t A, n \times n$, tem inversa quando ($\text{posto}(A^t A) = r = n$), e

- $A A^t, m \times m$, tem inversa quando ($\text{posto}(A A^t) = r = m$).

Assim, estas fórmulas têm sentido quando o posto é o maior possível.

Exemplo 1

Vamos considerar a matriz $A, 2 \times 3$, de posto = 2, abaixo:

$$\mathbf{A} = \begin{bmatrix} 4 & 0 & 0 \\ 0 & 5 & 0 \end{bmatrix}$$

Desde que $r = m = n$, o teorema anterior garante a existência de uma inversa à direita C :

$$\mathbf{AC} = \begin{bmatrix} 4 & 0 & 0 \\ 0 & 5 & 0 \end{bmatrix} \begin{bmatrix} 1/4 & 0 \\ 0 & 1/5 \\ c_{31} & c_{32} \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$$

Como c_{31} e c_{32} são arbitrários, existem diversas inversas à direita. Quando $c_{31} = c_{32} = 0$, obtemos a matriz "pseudoinversa".

A matriz A não tem inversa à esquerda, uma vez que BA tem a terceira coluna nula.

Neste exemplo, a fórmula $C = A^t(AA^t)^{-1}$ nos dá a escolha específica para a inversa à direita de A , a "pseudoinversa":

$$\mathbf{C} = \begin{bmatrix} 4 & 0 \\ 0 & 5 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} 1/16 & 0 \\ 0 & 1/25 \end{bmatrix} = \begin{bmatrix} 1/4 & 0 \\ 0 & 1/5 \\ 0 & 0 \end{bmatrix}$$

A matriz A^t neste exemplo, em contrapartida, pode ter infinitas inversas à esquerda:

$$\mathbf{BA}^t = \begin{bmatrix} 1/4 & 0 & b_{13} \\ 0 & 1/5 & b_{23} \end{bmatrix} \begin{bmatrix} 4 & 0 \\ 0 & 5 \\ 0 & 0 \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$$

Agora, a última coluna da inversa à esquerda de A^t é arbitrária.

Considerando o sistema linear:

$$\begin{bmatrix} 4 & 0 \\ 0 & 5 \\ 0 & 0 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} b_1 \\ b_2 \\ b_3 \end{bmatrix}$$

é solúvel somente quando $b_3 = 0$, tendo única solução $x_1 = 1/4$ e $x_2 = 1/5$. Neste caso, as colunas de A^t são linearmente independentes ($\text{posto}(A^t) = 2$), não existindo variáveis livres.

Para uma matriz A , $m \times n$, não é possível haver ambos, existência e unicidade. Se $m \neq n$, não podemos ter ($\text{posto}(A) = n$) e ($\text{posto}(A) = m$). Em contrapartida, uma matriz A , $n \times n$, tem inversa à esquerda $\iff$ ela tem inversa à direita. Neste caso, a inversa da matriz existe e é única: $B = C = A^{-1}$.

Exercícios Capítulo IV

1 - Dados os vetores coluna abaixo:

$$\mathbf{v}_1 = \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}, \mathbf{v}_2 = \begin{bmatrix} 1 \\ 1 \\ 0 \end{bmatrix}, \mathbf{v}_3 = \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix} \text{ e } \mathbf{v}_4 = \begin{bmatrix} 2 \\ 3 \\ 4 \end{bmatrix}.$$

Mostre que:

- a) os vetores v_1, v_2 e v_3 são linearmente independentes;
- b) os vetores v_1, v_2, v_3 e v_4 são linearmente dependentes.

2 - Dada a matriz:

$$\mathbf{A} = \begin{bmatrix} 1 & 2 & 2 & 3 & 1 & 4 \\ 2 & 4 & 5 & 5 & 4 & 9 \\ 3 & 6 & 7 & 8 & 5 & 9 \end{bmatrix}$$

- a) Encontre uma base para o espaço linha de A ;
- b) Encontre uma base para o espaço coluna de A ;
- c) Encontre uma base para o espaço nulo de A ;
- d) Qual o $\text{posto}(A)$?

3 - Em cada um dos sistemas lineares a seguir, encontre uma condição para os valores de b_1, b_2 e b_3 , para que esses sistemas lineares sejam solúveis:

a)

$$\begin{bmatrix} 1 & 4 & 2 \\ 2 & 8 & 4 \\ -1 & -4 & -2 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} b_1 \\ b_2 \\ b_3 \end{bmatrix}$$

b)

$$\begin{bmatrix} 1 & 4 \\ 2 & 9 \\ -1 & -4 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} b_1 \\ b_2 \\ b_3 \end{bmatrix}$$

4 - Encontre, quando existirem, uma inversa à esquerda e/ou uma inversa à direita para as matrizes a seguir:

a)

$$\mathbf{A} = \begin{bmatrix} 1 & 2 & 0 \\ 0 & 2 & 1 \end{bmatrix}$$

b)

$$\mathbf{B} = \begin{bmatrix} 1 & 0 \\ 2 & 2 \\ 0 & 1 \end{bmatrix}$$

5 - Para uma matriz A , $m \times n$, pode ser provado que existe uma única matriz $A^\sharp$, $m \times n$, tal que $AA^\sharp A = A$ e $A^\sharp AA^\sharp = A^\sharp$, com ambas $AA^\sharp$ e $A^\sharp A$ simétricas. A matriz $A^\sharp$ é chamada inversa de **Moore-Penrose** de A .

- a) Se a matriz A é quadrada e inversível, mostre que $A^\sharp = A^{-1}$;
- b) Se $(\text{posto}(A) = r = m)$, mostre que $A^\sharp = A^t(AA^t)^{-1}$;
- c) Se $(\text{posto}(A) = r = n)$, mostre que $A^\sharp = (A^t A)^{-1} A^t$.

Implementação dos Exercícios do Capítulo IV em Matlab

```
1 %
   %%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%
2 % Exercicio 1
3 %
   %%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%

4 clear;
5 clc;
6
7 A = [1,0,0;
8 1,1,0;
9 1,1,1];
10
11 isLDorLI(A)
12
13 A= [1,0,0;
14 1,1,0;
15 1,1,1;
16 2,3,4];
17
18 isLDorLI(A)
19
20 %
   %%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%

21 % Exercicio 2
22 %
   %%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%

23 A=[1,2,2,3,1,4;
24 2,4,5,5,4,9;
25 3,6,7,7,5,9];
26
27 % A) e B)
28 bases(A);
29
30 % C)
31 null(A);
32
33 % D)
34 rank(A);
35
36 %
```

%%

37 % *Exercicio 4*

38 %

%%

39

40 % *A)*

41 $A = [1, 2, 0;$

42 $0, 2, 0];$

43

44 $A' * A;$

45 `display('Singular, nao inversivel a esquerda');`

46

47 $A' * \text{inv}(A * A');$ % *ou simplesmente pinv(A);*

48

49 `display('Inversivel a direita');`

50

51 % *B)*

52 $A = [0, 1;$

53 $2, 2;$

54 $0, 1]$

55 `pinv(A);`

56 `display('Inversivel a esquerda');`

Implementação de Exemplos do Capítulo IV em Matlab

```

1 function []=isLDorLI(M)
2 mxn=size(M); % tamanho da matriz
3 m=mxn(1); % numero de linha
4 n=mxn(2); %numero de colunas
5 posto=rank(M); %posto da matriz M
6
7 if(m > n )
8     display('E LD');
9     return;
10 else
11     if(posto == m)
12         display('E LI');
13     else
14         display('E LD');
15     end
16 end
17
18 end
19
20 % exemplo 1
21 A = [1,0,0;
22      1,1,0;
23      1,1,1];
24
25 isLDorLI(A)
26
27 A= [1,0,0;
28     1,1,0;
29     1,1,1;
30     2,3,4];
31
32 isLDorLI(A)
33
34 %exemplo 2
35 A = [1      2      2      3      1      4
36      2      4      5      5      4      9
37      3      6      7      8      5      9];
38
39 % Para espaco linha:
40 Colspace(A)
41
42 %Para espaco Coluna:
43 A=A';
44 B=colspace(A);

```

```

45 B=B'; % (espaco Coluna )
46
47 display(B);
48
49 %exemplo3
50 %Espacos nulos Ax=0
51 null(A)
52
53 %Espaco nulo a esquerda
54 null(A')
55
56 %Posto
57 rank(A)
58
59 %exemplo 4
60 A= sym([ 1 3 3 2; 2 6 9 7; -1 -3 3 4]);
61 B=[1 5 5 ]';
62 N=null(A);
63 C=linsolve(A,B);
64
65 %O N da os vetores da base do espaco nulo
66 display(N)
67 %O C da a solucao particular.
68 display(C)
69
70
71 %exemplo 5
72 %inversa a direita
73 A =[4,0,0;
74     0,5,0];
75
76 pinv(A) % ou A'*(A*A')^-1
77
78 %inversa a esquerda
79 ((A'*A)^-1)*A';

```

Capítulo 5

Transformações Lineares

5.1 Introdução

Trataremos aqui das funções cujos domínios e contradomínios são espaços vetoriais. Chamamos tais funções de transformações, aplicações ou operadores. Seguimos as notações de Apostol, Vol. II [3])

Sejam V e W , dois espaços arbitrários. Usaremos a notação:

$$T : V \longrightarrow W$$

para indicar que T é uma função cujo domínio é V e contradomínio W . Para qualquer valor x em V , o elemento $T(x) \in W$ é chamado de imagem de x por T , e dizemos que T aplica x em $T(x)$.

Vamos assumir que V e W são espaços vetoriais no mesmo corpo de escalares e definimos uma transformação linear como segue:

Definição 1

Se V e W são espaços vetoriais, uma função $T : V \longrightarrow W$ é chamada uma transformação (ou operador) linear de V em W se tem as seguintes propriedades:

- a) $T(x + y) = T(x) + T(y) \quad \forall x, y \in V$;
- b) $T(\alpha x) = \alpha T(x) \quad \forall x \in V$ e todo escalar α .

Neste caso, dizemos que uma transformação linear T preserva a adição e a multiplicação por escalar. Estas duas propriedades podem ser combinadas na fórmula:

$$T(\alpha x + \beta y) = \alpha T(x) + \beta T(y) \quad \forall x, y \in V \text{ e todo escalar } \alpha \text{ e } \beta.$$

De fórmula mais geral, escrevemos a relação:

$$T\left(\sum_{i=1}^n a_i x_i\right) = \sum_{i=1}^n a_i T(x_i)$$

para quaisquer n elementos $x_1, x_2, \dots, x_n \in V$ e quaisquer n escalares $a_1, a_2, \dots, a_n \in K$.

Exemplo 1

A transformação identidade $T : V \longrightarrow V$, onde $T(x) = x, \forall x \in V$, que é representada por I .

Exemplo 2

A transformação nula $T : V \longrightarrow V$, onde $T(x) = 0x = \mathbf{0}, \forall x \in V$, que aplica cada elemento $x \in V$ em $\mathbf{0}$.

Exemplo 3

A transformação multiplicação por escalar fixo c tal que $T : V \longrightarrow V$, onde $T(x) = cx, \forall x \in V$.

Exemplo 4

A transformação dada por equações lineares onde definimos $T : \mathbf{R}^n \longrightarrow \mathbf{R}^m$, que aplica cada vetor $x = (x_1, x_2, \dots, x_n) \in \mathbf{R}^n$ no vetor $y = (y_1, y_2, \dots, y_m) \in \mathbf{R}^m$ pelas equações:

$$y_i = \sum_{k=1}^n a_{ik}x_k, \quad i = 1, 2, \dots, m$$

Exemplo 5

Seja V um espaço vetorial Euclidiano e seja z um vetor fixo em V . Definimos:

$$T : V \longrightarrow \mathbf{R} \text{ tal que } T(x) = \langle x, z \rangle, \quad \forall x \in V.$$

Exemplo 6

Seja $p = p(x) = c_0 + c_1x + \dots + c_nx^n$ um polinômio em P_n , conjunto de polinômios de grau $\leq n$, e definimos a função:

$$T : P_n \longrightarrow P_{n+1} \text{ tal que } T(p) = T(p(x)) = xp(x)$$

A função T é uma transformação linear, pois temos:

$$\text{i) } T(p_1 + p_2) = T(p_1(x) + p_2(x)) = x(p_1(x) + p_2(x)) = xp_1(x) + xp_2(x) = T(p_1) + T(p_2), \quad \forall p_1, p_2 \in P_n;$$

$$\text{ii) } T(kp_1) = T(kp_1(x)) = x(kp_1(x)) = k(xp_1(x)) = kT(p_1), \quad \forall p_1 \in P_n, \quad \forall k \in \mathbf{R}.$$

Exemplo 7

Seja $\mathbf{C}^1(a, b)$ o espaço vetorial de todas as funções reais deriváveis em um intervalo aberto (a, b) . A transformação que aplica cada função f de $\mathbf{C}^1(a, b)$ na sua derivada f' chama-se operador de derivação e é representado por D . Temos que:

$$D : \mathbf{C}^1(a, b) \longrightarrow \mathbf{C}^1(a, b) \text{ tal que } D(f) = f', \quad \forall f \in \mathbf{C}^1(a, b).$$

Esta transformação é linear e chama-se operador de derivação.

Exemplo 8

Seja $\mathbf{C}^o [a, b]$ o espaço vetorial de todas as funções reais contínuas em um intervalo fechado $[a, b]$. Se $f \in \mathbf{C}^o [a, b]$, definimos $g = T(f)$ como sendo a função de $f \in \mathbf{C}^o [a, b]$ definida por:

$$g(x) = \int_a^x f(t)dt, \quad a \leq x \leq b.$$

Esta transformação é linear e chama-se operador de integração.

5.2 Espaço Nulo e Imagem

Definição 2

Seja a transformação linear $T : V \longrightarrow W$. O conjunto dos vetores $w \in W$ tais que é imagem de algum vetor $v \in V$, chama-se imagem de T . Denotamos por: $Im(T) \subseteq W$ (imagem de T contida em W).

$$Im(T) = \{w \in W \text{ tal que } \exists v \in V, T(v) = w\},$$

Exemplo 1

Seja $T : \mathbf{R}^3 \longrightarrow \mathbf{R}^3$ dada por: $T(x, y, z) = (0, y, z)$.

$$Im(T) = \{(x, y, z) \in \mathbf{R}^3 \text{ tal que } x = 0\}$$

Vamos dar o seguinte teorema:

Teorema 5.1

O conjunto $T(V)$ (Imagem de V por T) é um subespaço vetorial de W . Além do mais, T aplica o elemento zero de V no elemento zero de W .

Prova

Para demonstrar que $T(V)$ é um subespaço vetorial de W , basta verificar os axiomas do fecho.

i) Sejam $T(x)$ e $T(y)$ elementos de $T(V)$. Temos que $T(x) + T(y) = T(x + y)$ e assim, $T(x) + T(y) \in T(V)$;

ii) Para qualquer escalar α temos que $\alpha T(x) = T(\alpha x)$ e assim, $\alpha T(x) \in T(V)$.

Agora, tomando $\alpha = 0$ em ii), concluímos que $T(\mathbf{0}) = \mathbf{0}$.

Portanto, $T(V)$ é um subespaço vetorial de W .

Teorema 5.2

Seja a transformação linear $T : V \longrightarrow W$. Se $\{v_1, v_2, \dots, v_n\}$ gera V , então $\{T(v_1), T(v_2), \dots, T(v_n)\}$ gera $Im(T)$.

Prova

Seja $w \in Im(T)$. Temos que, $\exists v \in V$ tal que $T(v) = w$.

Por outro lado, v pode ser escrito como:

$$v = a_1v_1 + a_2v_2 + \dots + a_nv_n, \text{ com escalares } a_i, \ i = 1, 2, \dots, n.$$

Assim,

$$\begin{aligned} w = T(v) &= T(a_1v_1 + a_2v_2 + \dots + a_nv_n) = T(a_1v_1) + T(a_2v_2) + \dots + T(a_nv_n) = \\ &= a_1T(v_1) + a_2T(v_2) + \dots + a_nT(v_n). \end{aligned}$$

Ou seja,

$$\{T(v_1), T(v_2), \dots, T(v_n)\} \text{ gera } \text{Im}(T).$$

Definição 3

O conjunto de todos os elementos de V tal que T aplica em $\mathbf{0} \in W$ chama-se o espaço nulo de T e representa-se por $N(T)$. Assim, escrevemos:

$$N(T) = \{x \in V \text{ tal que } T(x) = \mathbf{0}\},$$

também chamado núcleo de T .

Teorema 5.3

O espaço nulo de T é um subespaço vetorial de V .

Prova

Sejam $x, y \in N(T)$ e α escalar. Temos que $x + y$ e $\alpha x \in N(T)$, pois:

i) $T(x + y) = T(x) + T(y) = \mathbf{0} + \mathbf{0} = \mathbf{0}$;

ii) $T(\alpha x) = \alpha T(x) = \alpha \mathbf{0} = \mathbf{0}$.

Além do mais, $T(\mathbf{0}) = \mathbf{0}$.

Portanto, $N(T)$ é um subespaço vetorial de V .

Exemplo 1

Para a transformação identidade I em V , o espaço nulo consiste apenas $\mathbf{0}$ em V .

Exemplo 2

Para a transformação nula 0 de V em W , o espaço nulo consiste de todos os elementos de V .

Exemplo 3

Seja a transformação linear: $T : \mathbf{R}^3 \longrightarrow \mathbf{R}^2$ dada por:

$$T(x, y, z) = (x - y + z, 2x + y + z)$$

Temos que:

$$N(T) = \{(x, y, z) \in \mathbf{R}^3 \text{ tal que } T(x, y, z) = (0, 0)\},$$

Para isto, basta resolver o sistema linear homogêneo:

$$\begin{cases} x - y + z = 0 \\ 2x + y + z = 0 \end{cases} \implies \begin{cases} y = \frac{-x}{2} \\ z = \frac{-3x}{2} \end{cases}$$

Assim, temos:

$$N(T) = \left\{ \left(x, \frac{-x}{2}, \frac{-3x}{2} \right) \in \mathbf{R}^3 \right\},$$

que corresponde ao subespaço vetorial gerado pelo vetor $(1, \frac{-1}{2}, \frac{-3}{2})$.

Exemplo 4

Seja a transformação linear: $T : \mathbf{R}^3 \longrightarrow \mathbf{R}^3$ dada por:

$$T(x, y, z) = (x + y + z, x + y - z, x + y - z)$$

Para encontrar o conjunto $N(T)$, resolvemos o sistema linear homogêneo:

$$\begin{cases} x + y + z = 0 \\ x + y - z = 0 \\ x + y - z = 0 \end{cases} \implies \begin{cases} x = -y \\ z = 0 \end{cases}$$

Assim, temos:

$$N(T) = \{(-y, y, 0) \in \mathbf{R}^3\},$$

que corresponde ao subespaço vetorial gerado pelo vetor $(-1, 1, 0)$.

Para encontrar o conjunto $Im(T)$, resolvemos o sistema linear não homogêneo:

$$\begin{cases} x + y + z = a \\ x + y - z = b \\ x + y - z = c \end{cases}$$

Este sistema linear é compatível para $b - c = 0$ e sendo a qualquer, tomando $a, b, c \in \mathbf{R}$. Assim, obtemos:

$$Im(T) = \{(a, b, b) \in \mathbf{R}^3\}.$$

Teorema 5.4

Uma transformação linear $T : V \longrightarrow W$ é injetiva $\iff N(T) = \{\mathbf{0}\}$.

Prova

Obs. T é injetiva quando:

$$T(v_1) = T(v_2), \quad v_1, v_2 \in V \implies v_1 = v_2;$$

ou ainda: $v_1 \neq v_2, \quad v_1, v_2 \in V \implies T(v_1) \neq T(v_2)$. ($\implies$) Se $v \in N(T)$, então $T(v) = \mathbf{0}$. Como $T(\mathbf{0}) = \mathbf{0} \implies T(v) = \mathbf{0}$. Por hipótese, T sendo injetora, $v = \mathbf{0}$. Portanto, $N(T) = \{\mathbf{0}\}$.

($\Leftarrow$) Seja, $v_1, v_2 \in V$, tais que $T(v_1) = T(v_2)$. Ou seja, $T(v_1) - T(v_2) = \mathbf{0}$ e como T é linear: $T(v_1 - v_2) = \mathbf{0} \Rightarrow v_1 - v_2 \in N(T)$. Como, por hipótese $N(T) = \{\mathbf{0}\} \Rightarrow v_1 - v_2 = \mathbf{0} \Rightarrow v_1 = v_2$. Portanto, T é injetora.

Teorema 5.5: (Dimensão: núcleo e imagem)

Seja V um espaço vetorial de dimensão finita, onde $\dim(V) = n$. Tem-se que $T(V)$ também é de dimensão finita e além do mais,

$$\dim N(T) + \dim T(V) = \dim(V) \quad (I)$$

Prova

Sejam $n = \dim(V)$ e $\{v_1, v_2, \dots, v_k\}$ uma base para $N(T)$, onde $k = \dim N(T) \leq n$. Pelo teorema da complementação da base, este conjunto de vetores formam parte de uma certa base de V , por exemplo, a base:

$$\{v_1, v_2, \dots, v_k, v_{k+1}, \dots, v_{k+r}\} \quad (II)$$

com $k + r \leq n$. Vamos mostrar que o conjunto de r vetores,

$$\{T(v_{k+1}), \dots, T(v_{k+r})\} \quad (III)$$

formam uma base para $T(V)$, o que prova $\dim T(V) = r$. Uma vez que, $k + r = n$, isto também prova (I).

Inicialmente, vamos provar que os r vetores em (III) geram $T(V)$.

Se $y \in T(V)$, temos $y = T(x)$ para algum $x \in V$, e podemos escrever:

$$x = c_1 v_1 + c_2 v_2 + \dots + c_k v_k + c_{k+1} v_{k+1} + \dots + c_{k+r} v_{k+r}$$

Daí, temos:

$$y = T(x) = \sum_{i=1}^{k+r} c_i T(v_i) = \sum_{i=1}^k c_i T(v_i) + \sum_{i=k+1}^{k+r} c_i T(v_i) = \sum_{i=k+1}^{k+r} c_i T(v_i)$$

uma vez que $T(v_1) = T(v_2) = \dots = T(v_r) = \mathbf{0}$.

Portanto, $\{T(v_{k+1}), T(v_{k+2}), \dots, T(v_r)\}$ gera $T(V)$.

Além do mais, este conjunto é linearmente independente.

De fato:

Vamos supor que existam escalares $c_{k+1}, c_{k+2}, \dots, c_{k+r}$ tais que:

$$\sum_{i=k+1}^{k+r} c_i T(v_i) = \mathbf{0}$$

Então,

$$T\left(\sum_{i=k+1}^{k+r} c_i(v_i)\right) = \mathbf{0},$$

e assim,

$$\sum_{i=k+1}^{k+r} c_i(v_i) \in N(T), \text{ ou ainda: } x - x = c_1v_1 + c_2v_2 + \dots + c_kv_k.$$

Assim, escrevemos:

$$x - x = \sum_{i=1}^k c_i v_i - \sum_{i=k+1}^{k+r} c_i v_i = \mathbf{0}.$$

Como os vetores em (II) são linearmente independentes, temos que $c_i = 0 \forall i = 1, 2, \dots, k+r$.

Consequentemente, $\{T(v_{k+1}), T(v_{k+2}), \dots, T(v_r)\}$ é linearmente independente.

5.3 Operações Algébricas em Transformações Lineares

Definição 4

Sejam $S : V \longrightarrow W$ e $T : V \longrightarrow W$ duas transformações lineares pertencentes ao $\mathcal{L}(V, W)$ (conjunto das aplicações lineares de V em W). Se c é qualquer escalar em K , definimos a soma $S + T$ e o produto por escalar cT pelas igualdades:

- i) $(S + T)(x) = S(x) + T(x)$ e,
- ii) $(cT)(x) = cT(x), \forall x \in V$.

Obs. $\mathcal{L}(V, W)$ é um espaço vetorial com as operações definidas acima.

Definição 5:(Composição de aplicações)

Sejam $T : U \longrightarrow V$ e $S : V \longrightarrow W$ duas aplicações, onde U, V e W são conjuntos. A composição ST é a aplicação $ST : U \longrightarrow W$ definida por:

$$(ST)(x) = S(T(x)), \forall x \in U.$$

Exemplo 1

Sejam as aplicações $S, T : \mathbf{R} \longrightarrow \mathbf{R}$ definidas por $S(x) = x$ e $T(x) = x + 1$. Temos:

$$(ST)(x) = S(T(x)) = S(x + 1) = x + 1$$

e

$$(TS)(x) = T(S(x)) = T(x) = x + 1$$

Exemplo 2

Sejam as aplicações $S, T : \mathbf{R} \longrightarrow \mathbf{R}$ definidas por $S(x) = 2x$ e $T(x) = x + 1$. Temos:

$$(ST)(x) = S(T(x)) = S(x + 1) = 2x + 2$$

e

$$(TS)(x) = T(S(x)) = T(2x) = 2x + 1$$

Note que $(ST) \neq (TS)$.

Definição 6

Sejam $T : V \longrightarrow V$ uma transformação linear (operador linear). Definimos as potências inteiras de T , por indução, do seguinte modo:

$$T^0 = I, T^n = TT^{n-1} \text{ (para } n \geq 1)$$

onde, I é o operador identidade.

Teorema 5.6

Se U, V e W são espaços vetoriais com os mesmos escalares e se $T : U \longrightarrow V$ e $S : V \longrightarrow W$ são transformações lineares, então a composição $ST : U \longrightarrow W$ é linear.

Prova

De fato, sejam $x, y \in U$ e a, b escalares quaisquer. Temos:

$$(ST)(ax + by) = S(T(ax + by)) = S(aT(x) + bT(y)) = a(ST)(x) + b(ST)(y)$$

A partir deste teorema, enunciamos o seguinte teorema:

Teorema 5.7

Sejam U, V e W espaços vetoriais com os mesmos escalares e sejam as transformações lineares $S, T \in \mathcal{L}(V, W)$ e seja c um escalar qualquer.

a) Para qualquer transformação linear $R : U \longrightarrow V$ temos:

$$(S + T)R = SR + TR$$

e

$$(cS)R = c(SR);$$

b) Para qualquer transformação linear $R : W \longrightarrow U$ temos:

$$R(S + T) = RS + RT$$

e

$$R(cS) = c(RS).$$

Prova (ver Apostol, Vol. II [3])

5.4 Transformações Inversa à Direita e Inversa à Esquerda

Dada uma transformação linear T , queremos encontrar uma transformação linear S , cuja composição com T seja a transformação linear idêntica. Como $ST \neq TS$, vamos introduzir dois tipos de transformações inversas.

Definição 7

Uma transformação linear $R : T(V) \longrightarrow V$ chama-se uma inversa à direita da transformação linear $T : V \longrightarrow W$ quando se tem $T \circ R = I_{T(V)}$, ou seja, quando:

$$T(R(y)) = y, \quad \forall y \in T(V)$$

Exemplo 1

Seja a transformação linear:

$$T : \mathbf{R}^3 \longrightarrow \mathbf{R}^2, \text{ tal que } (x, y, z) \longrightarrow (x, y)$$

A transformação linear:

$$R : \mathbf{R}^2 \longrightarrow \mathbf{R}^3, \text{ tal que } (x, y) \longrightarrow (x, y, ax + by), \quad a, b \in \mathbf{R}$$

é uma inversa à direita para T . Variando os valores de a e $b \in \mathbf{R}$, obtemos diversas transformações inversas à direita para T .

Obs.: Veja **Exemplo 4** da **Seção 5.6**

Definição 8

Uma transformação linear $S : T(V) \longrightarrow V$ chama-se uma inversa à esquerda da transformação linear $T : V \longrightarrow W$ quando se tem $S \circ T = I_V$, ou seja, quando:

$$S(T(x)) = x, \quad \forall x \in V$$

Exemplo 2

Seja a transformação linear:

$$T : \mathbf{R}^2 \longrightarrow \mathbf{R}^3, \text{ tal que } (x, y) \longrightarrow (x + 2y, 2x + 3y, 3x + 4y)$$

A transformação linear:

$$S : \mathbf{R}^3 \longrightarrow \mathbf{R}^2, \text{ tal que } (x, y, z) \longrightarrow (-3x + 2y, 2x - y)$$

é uma inversa à esquerda para T , uma vez que:

$$S(T(x, y)) = S(x + 2y, 2x + 3y, 3x + 4y) =$$

$$= (-3(x + 2y) + 2(2x + 3y), 2(2x + 3y) - (2x + 3y)) = (x, y), \forall (x, y) \in \mathbf{R}^2$$

Portanto, S é a inversa à esquerda de T .

Obs.: Veja **Exemplo 5** da **Seção 5.6**

Teorema 5.8

Uma transformação $T : V \longrightarrow W$ pode ter, quanto muito uma inversa à esquerda. Se a transformação T tem uma inversa à esquerda S , então S também é a inversa à direita.

Prova

Seja $T : V \longrightarrow W$ com duas inversas à esquerda, $S : T(V) \longrightarrow V$ e $S' : T(V) \longrightarrow V$. Seja $y \in T(V)$. Como $y = T(x)$ para algum $x \in V$, temos:

$$S(T(x)) = x \text{ e } S'(T(x)) = x \implies S(y) = S'(y), \forall y \in T(V)$$

Portanto, $S = S'$, ou seja, a inversa à esquerda é única.

Vamos mostrar, agora, que S é também inversa à direita, caso ela exista.

Seja $y \in T(V)$. Vamos mostrar que $T(S(y)) = y$.

Como $y = T(x)$, temos que $y = T(x)$ para algum $x \in V$. Como S é a inversa à esquerda de T temos:

$$x = S(T(x)) = S(y)$$

Aplicando T a ambos os lados desta igualdade, obtemos:

$$T(x) = T(S(y)) \text{ ou ainda } y = T(S(y)), \text{ pois } y = T(x).$$

Portanto, S também é uma inversa à direita.

Teorema 5.9:(Caracterização das transformações inversas)

Uma transformação $T : V \longrightarrow W$ tem uma inversa à esquerda $\iff T$ aplica elementos distintos de V em elementos distintos de W , isto é:

$$\forall x, y \in V, x \neq y \implies T(x) \neq T(y) \text{ (T é injetiva)}$$

ou, de forma equivalente:

$$\forall x, y \in V, T(x) = T(y) \implies x = y$$

Prova

" $\implies$ " Assumindo que T tenha uma inversa à esquerda S , e assumindo que $T(x) = T(y)$, queremos provar que $x = y$.

Aplicando S , a igualdade anterior, obtemos: $S(T(x)) = S(T(y))$, ou seja, $x = y$, uma vez que $S(T(x)) = x$ e $S(T(y)) = y$.

” $\Leftarrow$ ”Vamos assumir agora, que T é injetiva em V . Temos de encontrar uma transformação $S : T(V) \rightarrow V$, inversa à esquerda de T .

Se $y \in T(V)$, então $y = T(x)$ para algum $x \in V$. Mas, por hipótese, existe um único x tal que $y = T(x)$. Colocando $S(y) = x$, podemos definir S em $T(V)$ como segue:

$$S(y) = x \text{ significa que } T(x) = y.$$

Portanto, temos $S(T(x)) = x$ para $x \in V$, de modo que $ST = I_V$, ou seja, S é a inversa à esquerda de T .

Definição 9

Seja $T : V \rightarrow W$ injetiva e sobrejetiva, ou seja, T é bijetiva. A única inversa à esquerda de T (que é também inversa à direita de T) representa-se por T^{-1} . Neste caso, diz-se que T é invertível e chama-se T^{-1} a inversa de T .

Exemplo 1

Seja a transformação linear: Seja $T : \mathbf{R}^3 \rightarrow \mathbf{R}^2$ tal que $(x, y, z) \rightarrow (x, y)$.

Temos que, T não é injetiva. De fato, tomando, por exemplo, $(1, 3, 3) \neq (1, 3, -2)$, temos que $T(1, 3, 3) = (1, 3) = T(1, 3, -2)$.

Por outro lado, T é sobrejetiva. De fato, tomando o vetor $(y_1, y_2) \in \mathbf{R}^2$, vamos procurar o vetor $(x_1, x_2, x_3) \in \mathbf{R}^3$ tal que $T(x_1, x_2, x_3) = (y_1, y_2)$. Como $T(x_1, x_2, x_3) = (x_1, x_2)$, basta tomar $x_1 = y_1$ e $x_2 = y_2$.

5.5 Transformações Lineares Inversas

Vamos generalisar o estudo de transformação linear inversa para o caso $T : V \rightarrow W$ injetiva, onde V e W são espaços vetoriais quaisquer. A linearidade de T nos permite expressar a propriedade injetiva de diversas formas equivalentes.

Teorema 5.10

Seja a transformação linear $T : V \rightarrow W$. Então, as afirmações seguintes são equivalentes:

- a) T é injetiva em V ;
- b) T é invertível e sua inversa $T^{-1} : T(V) \rightarrow V$ é linear;
- c) $\forall x \in V, T(x) = \mathbf{0} \iff x = \mathbf{0}$. Isto é, o espaço nulo $N(T)$ contém somente o vetor nulo em V .

Prova

Vamos provar que a) implica b), b) implica c) e c) implica a).

a) $\implies$ b) Se T é injetiva em V , então T tem uma inversa, de acordo com o Teorema 9. Vamos mostrar agora que T^{-1} é linear. Para isto, tomamos dois vetores

u e $v \in T(V)$. Então, $u = T(x)$ e $v = T(y)$ para algum x e algum y em V . Para quaisquer escalares α e β , temos:

$$\alpha u + \beta v = \alpha T(x) + \beta T(y) = T(\alpha x + \beta y),$$

uma vez que T é linear. Portanto, aplicando T^{-1} a ambos os membros desta igualdade, obtemos:

$$T^{-1}(\alpha u + \beta v) = \alpha x + \beta y = \alpha T^{-1}(u) + \beta T^{-1}(v),$$

ou seja, T^{-1} é linear.

$b) \implies c)$ Vamos assumir que vale $b)$. Vamos tomar um vetor x qualquer em V tal que $T(x) = \mathbf{0}$. Aplicando T^{-1} , obtemos: $x = T^{-1}\mathbf{0} = \mathbf{0}$, uma vez que T^{-1} é linear. Logo, $b) \implies c)$.

$c) \implies a)$ Vamos assumir que vale $c)$. Sejam u e v quaisquer em V tal que $T(u) = T(v)$. Como T é linear, temos que: $T(u - v) = T(u) - T(v) = \mathbf{0}$, e usando a hipótese em $c)$ temos que $u - v = \mathbf{0}$. Logo, T é injetiva, e a prova do teorema é completa.

Exemplo 1

Seja $T : \mathbf{R}^2 \longrightarrow \mathbf{R}^2$ o operador de rotação do vetor $(x_1, y_1) \in \mathbf{R}^2$ de um ângulo θ , conforme mostra Figura 5.1.




Figura 5.1: Rotação de um vetor no plano

Temos que o operador T leva o vetor $(x_1, y_1) = (r \cos \alpha, r \sin \alpha)$ no vetor $(x_2, y_2) = (r \cos(\alpha + \theta), r \sin(\alpha + \theta))$. Daí, obtemos:

$$x_2 = r(\cos \alpha \cos \theta - \sin \alpha \sin \theta) = x_1 \cos \theta - y_1 \sin \theta$$

e

$$y_2 = r(\sin \alpha \cos \theta + \cos \alpha \sin \theta) = y_1 \cos \theta + x_1 \sin \theta$$

O operador de rotação inverso, gira o vetor imagem (x_2, y_2) de volta de um ângulo $-\theta$.

Daremos, na próxima seção, a representação matricial deste operador.

Exemplo 2

Seja $T : P_n \longrightarrow P_{n+1}$ a transformação linear $T(p) = T(p(x)) = xp(x)$. Temos que, se

$$p = p(x) = c_0 + c_1x + c_2x^2 + \dots + c_nx^n \text{ e } q = q(x) = d_0 + d_1x + d_2x^2 + \dots + d_nx^n$$

são polinômios distintos em P_n , então:

$$T(p) = T(p(x)) = c_0x + c_1x^2 + \dots + c_nx^{n+1} \text{ e } T(q) = T(q(x)) = d_0x + d_1x^2 + \dots + d_nx^{n+1}$$

diferem entre si em pelo menos um coeficiente.

Portanto, $T(p) \neq T(q)$. Logo, T é injetiva e assim, T tem uma inversa.

Obs. Aqui a imagem de T não é todo o espaço P_{n+1} , pois $Im(T)$ consiste nos polinômios de grau $\leq (n+1)$ com o termo constante nulo.

Como, $T(p) = T(p(x)) = c_0x + c_1x^2 + \dots + c_nx^{n+1}$, segue-se que,

$$T^{-1} : P_{n+1} \longrightarrow P_n$$

é dada por:

$$T^{-1}(c_0x + c_1x^2 + \dots + c_nx^{n+1}) = c_0 + c_1x + c_2x^2 + \dots + c_nx^n$$

Desta forma, dada uma transformação linear $T : V \longrightarrow W$ que seja injetiva, podemos definir uma transformação linear inversa T^{-1} , tal que $T^{-1} : Im(T) \longrightarrow V$, onde cada $T^{-1}(w) = v$, $\forall w \in Im(T)$, sendo $v \in V$.

Temos que:

$$T^{-1}(T(v)) = T^{-1}(w) = v \text{ e } T(T^{-1}(w)) = T(v) = w$$

Obs. No caso em que $T : V \longrightarrow V$ é um operador injetor, sendo V um espaço vetorial de dimensão finita, temos que $Im(T) = V$, ou seja, o domínio de T^{-1} é todo o espaço V .

Quando o espaço vetorial V tem dimensão finita, a propriedade da transformação linear ser injetiva pode ser formulada em termos de independência linear e dimensionalidade, conforme o teorema a seguir:

Teorema 5.11

Se $T : V \longrightarrow W$ é uma transformação linear e V tem dimensão finita, $\dim(V) = n$, são equivalentes as afirmações:

- a) T é injetiva;
- b) Se os vetores $e_1, e_2, \dots, e_p$ são linearmente independentes em V , então os vetores $T(e_1), T(e_2), \dots, T(e_p)$ são linearmente independentes em $T(V)$;
- c) $\dim(V) = n$;
- d) Se $\{e_1, e_2, \dots, e_p\}$ é uma base em V , então $\{T(e_1), T(e_2), \dots, T(e_p)\}$ é uma base em $T(V)$.

Prova

a) $\implies$ b) Assumamos que T é injetiva. Sejam os vetores $e_1, e_2, \dots, e_p$ linearmente independentes em V e consideremos os vetores $T(e_1), T(e_2), \dots, T(e_p)$ em $T(V)$. Suponhamos que:

$$\sum_{i=1}^p c_i T(e_i) = \mathbf{0}$$

para certos escalares $c_1, c_2, \dots, c_p$. Por linearidade, obtemos:

$$T\left(\sum_{i=1}^p c_i e_i\right) = \mathbf{0}, \text{ e portanto, } \sum_{i=1}^p c_i e_i = \mathbf{0},$$

uma vez que T é injetiva. Como $e_1, e_2, \dots, e_p$ são linearmente independentes em V , então $c_1 = c_2 = \dots = c_p = 0$. Logo, os vetores $T(e_1), T(e_2), \dots, T(e_p)$ são linearmente independentes em $T(V)$.

b) $\implies$ c) Assumamos b) válido. Seja $\{e_1, e_2, \dots, e_p\}$ base de V . Por b), os n vetores $T(e_1), T(e_2), \dots, T(e_p)$ são linearmente independentes em $T(V)$. Portanto, $\dim T(V) \geq n$. Mas, pelo Teorema 3, temos que $\dim T(V) \leq n$. Portanto, $\dim T(V) = n$.

c) $\implies$ d) Assumamos agora que c) vale e seja $\{e_1, e_2, \dots, e_n\}$ uma base de V . Tomando qualquer vetor y em $T(V)$, temos que $y = T(x)$ para algum $x \in V$, e assim temos:

$$x = \sum_{i=1}^n c_i e_i, \text{ e portanto, } y = T(x) = \sum_{i=1}^n c_i T(e_i)$$

Logo, $\{T(e_1), T(e_2), \dots, T(e_n)\}$ gera $T(V)$. Como, por hipótese $\dim T(V) = n$, então $\{T(e_1), T(e_2), \dots, T(e_n)\}$ é uma base de $T(V)$.

d) $\implies$ a) Finalmente, assumamos que c) vale. Vamos provar que $T(x) = \mathbf{0}$ implica em $x = \mathbf{0}$.

Seja $\{e_1, e_2, \dots, e_n\}$ é uma base de V . Se $x \in V$, então temos:

$$x = \sum_{i=1}^n c_i e_i, \text{ e portanto, } T(x) = \sum_{i=1}^n c_i T(e_i).$$

Se $T(x) = \mathbf{0}$, então $c_1 = c_2 = \dots = c_n = 0$, uma vez que os vetores $T(e_1), T(e_2), \dots, T(e_n)$ são linearmente independentes. Portanto, $x = \mathbf{0}$. Logo, T é injetiva e desta forma, a prova fica completa.

Podemos sempre sonstruir uma transformação linear $T : V \longrightarrow W$ com valores determinados para vetores de uma base de V , conforme teorema:

Teorema 5.12

Se $\{e_1, e_2, \dots, e_n\}$ é uma base em V , sendo $\dim(V) = n$, e $u_1, u_2, \dots, u_n$ são vetores arbitrários de um espaço vetorial W , então existe uma única transformação linear $T : V \longrightarrow W$ tal que:

$$T(e_k) = u_k, \quad k = 1, 2, \dots, n \quad (*)$$

Esta transformação T aplica um vetor arbitrário $x \in V$ do seguinte modo:

$$x = \sum_{k=1}^n x_k e_k \implies T(x) = \sum_{k=1}^n x_k u_k$$

Prova

Qualquer vetor $x \in V$ pode ser expresso unicamente como uma combinação linear dos vetores $e_1, e_2, \dots, e_n$, sendo $x_1, x_2, \dots, x_n$ as componentes do vetor x em relação à base ordenada $\{e_1, e_2, \dots, e_n\}$. A transformação T definida acima é linear. Se $x = e_k$ para algum k , então todas as componentes de x são nulas exceto a k -ésima, que é igual a 1, de modo que $T(e_k) = u_k$, como requerido em $(*)$.

Para provar que a transformação linear é única, tomamos outra transformação linear T' e calculamos $T'(x)$. Temos que:

$$T'(x) = T'\left(\sum_{k=1}^n x_k e_k\right) = \sum_{k=1}^n x_k T'(e_k) = \sum_{k=1}^n x_k u_k = T(x)$$

Desde que, $T'(x) = T(x)$, $\forall x \in V$, temos que $T' = T$.

Exemplo 1

Seja encontrar a transformação linear $T : \mathbf{R}^2 \longrightarrow \mathbf{R}^2$ tal que $T(i) = i + j$ e $T(j) = 2i - j$, onde i, j são os vetores da base canônica de $\mathbf{R}^2$.

Seja $x = x_1 i + x_2 j$ um vetor qualquer de $\mathbf{R}^2$. Temos que:

$$T(x) = x_1 T(i) + x_2 T(j) = x_1(i + j) + x_2(2i - j) = (x_1 + 2x_2)i + (x_1 - x_2)j$$

Desta forma, podemos escrever:

$$\begin{bmatrix} u_1 \\ u_2 \end{bmatrix} = \begin{bmatrix} T \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 1 & 2 \\ 1 & -1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$$

5.6 Representação Matricial das Transformações Lineares

Seja a transformação linear $T : V \longrightarrow W$, onde $\dim(V) = n$ e $\dim(W) = m$, e sendo dadas bases de V e W , respectivamente, pretendemos encontrar uma representação matricial para a transformação linear T em relação a estas bases. Enunciamos o seguinte teorema:

Teorema 5.13

Seja a transformação linear $T : V \longrightarrow W$, onde $\dim(V) = n$ e $\dim(W) = m$, sendo $\{e_1, e_2, \dots, e_n\}$ base ordenada de V e $\{w_1, w_2, \dots, w_m\}$ base ordenada de W . Seja uma matriz $[t_{ij}]$, $m \times n$, cujos coeficientes são representados por:

$$T(e_k) = \sum_{i=1}^n t_{ik} w_i, \quad k = 1, 2, \dots, n$$

Então, um vetor arbitrário $x \in V$, onde

$$x = \sum_{k=1}^n x_k e_k (*)$$

é aplicado por $T \in W$, onde

$$T(x) = \sum_{k=1}^n x_k u_k (**)$$

As componentes $y_1, y_2, \dots, y_m$ estão relacionadas às componentes $x_1, x_2, \dots, x_n$ por:

$$y_i = \sum_{k=1}^n t_{ik} x_k, \quad i = 1, 2, \dots, m \quad (***)$$

Prova

Desde que T tem valores em W , cada elemento $T(e_k)$ pode ser expresso unicamente como combinação dos vetores $w_1, w_2, \dots, w_m$ da base de W , a saber:

$$T(e_k) = \sum_{i=1}^m t_{ik} w_i$$

onde $t_{1k}, t_{2k}, \dots, t_{mk}$ são as componentes de $T(e_k)$ em relação à base $\{w_1, w_2, \dots, w_m\}$. Podemos colocar a m -upla $(t_{1k}, t_{2k}, \dots, t_{mk})$ como o vetor coluna:

$$\begin{bmatrix} t_{1k} \\ t_{2k} \\ \vdots \\ t_{mk} \end{bmatrix}$$

Em seguida, podemos dispor cada vetor coluna para os n vetores $T(e_1), T(e_2), \dots, T(e_n)$ na matriz $[T]$ como segue:

$$[\mathbf{T}] = \begin{bmatrix} t_{11} & t_{12} & \dots & t_{1n} \\ t_{21} & t_{22} & \dots & t_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ t_{m1} & t_{m2} & \dots & t_{mn} \end{bmatrix}$$

Aplicando a matriz $[T]$ em cada membro da equação $(**)$ e usando a relação $(*)$, obtemos:

$$T(x) = \sum_{k=1}^n x_k T(e_k) = \sum_{k=1}^n x_k \sum_{i=1}^m t_{ik} w_i = \sum_{i=1}^m \left(\sum_{k=1}^n t_{ik} x_k \right) w_i = \sum_{i=1}^m y_i w_i,$$

onde cada componente y_i é dada por $(***)$.

Exemplo 1

Seja a transformação linear $T : \mathbf{R}^3 \longrightarrow \mathbf{R}^2$ dada por $T(x) = (x_1 + x_2, x_2 + x_3)$ para cada $x = (x_1, x_2, x_3) \in \mathbf{R}^3$. Temos que:

$$\mathbf{T}(\mathbf{e}_1) = \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \quad \mathbf{T}(\mathbf{e}_2) = \begin{bmatrix} 1 \\ 1 \end{bmatrix}, \quad \mathbf{T}(\mathbf{e}_3) = \begin{bmatrix} 0 \\ 1 \end{bmatrix}$$

Desta forma, obtemos a matriz $[T]$, 2×3 , seguinte:

$$[\mathbf{T}] = \begin{bmatrix} 1 & 1 & 0 \\ 0 & 1 & 1 \end{bmatrix}$$

Exemplo 2

Seja $T : \mathbf{R}^2 \longrightarrow \mathbf{R}^2$ o operador de rotação do vetor $(x_1, y_1) \in \mathbf{R}^2$ de um ângulo θ . Temos que a matriz $[T]$ deste operador é dada por:

$$[\mathbf{T}] = \begin{bmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{bmatrix}$$

que é invertível, pois $\det[T] = \cos^2 \theta + \sin^2 \theta = 1 \neq 0$.

Temos que:

$$[\mathbf{T}^{-1}] = [\mathbf{T}]^{-1} = \begin{bmatrix} \cos(-\theta) & -\sin(-\theta) \\ \sin(-\theta) & \cos(-\theta) \end{bmatrix} = \begin{bmatrix} \cos \theta & \sin \theta \\ -\sin \theta & \cos \theta \end{bmatrix}$$

Definição 10

Dada a transformação linear $T : \mathbf{R}^n \longrightarrow \mathbf{R}^m$, onde $B = \{u_1, u_2, \dots, u_n\}$ base de $\mathbf{R}^n$ e $B' = \{w_1, w_2, \dots, w_m\}$ base de $\mathbf{R}^m$. A matriz canônica $A = [T]$ desta transformação é chamada a matriz de T em relação às bases B e B'. Notamos por:

$$A[x]_B = [T(x)]_{B'} \quad (1)$$

onde $[x]_B$ e $[T(x)]_{B'}$ são os vetores colunas em $\mathbf{R}^n$ e $\mathbf{R}^m$, respectivamente.

Temos que, em particular, para os vetores da base B , $u_1, u_2, \dots, u_n$:

$$A[u_1]_B = [T(u_1)]_{B'}, A[u_2]_B = [T(u_2)]_{B'}, \dots, A[u_n]_B = [T(u_n)]_{B'} \quad (2)$$

Como

$$[\mathbf{u}_1]_B = \begin{bmatrix} 1 \\ 0 \\ \vdots \\ 0 \end{bmatrix}, [\mathbf{u}_2]_B = \begin{bmatrix} 0 \\ 1 \\ \vdots \\ 0 \end{bmatrix}, \dots, [\mathbf{u}_n]_B = \begin{bmatrix} 0 \\ 0 \\ \vdots \\ 1 \end{bmatrix}$$

obtemos:

$$\mathbf{A}[\mathbf{u}_1]_B = \begin{bmatrix} t_{11} \\ t_{12} \\ \vdots \\ t_{m1} \end{bmatrix}, \mathbf{A}[\mathbf{u}_2]_B = \begin{bmatrix} t_{12} \\ t_{22} \\ \vdots \\ t_{m2} \end{bmatrix}, \dots, \mathbf{A}[\mathbf{u}_n]_B = \begin{bmatrix} t_{1n} \\ t_{2n} \\ \vdots \\ t_{mn} \end{bmatrix}$$

Substituindo estes resultados em (2), obtemos:

$$[\mathbf{T}(\mathbf{u}_1)]_{B'} = \begin{bmatrix} t_{11} \\ t_{12} \\ \vdots \\ t_{m1} \end{bmatrix}, [\mathbf{T}(\mathbf{u}_2)]_{B'} = \begin{bmatrix} t_{12} \\ t_{22} \\ \vdots \\ t_{m2} \end{bmatrix}, \dots, [\mathbf{T}(\mathbf{u}_n)]_{B'} = \begin{bmatrix} t_{1n} \\ t_{2n} \\ \vdots \\ t_{mn} \end{bmatrix}$$

Assim, escrevemos:

$$A = [[T(u_1)]_{B'} \ [T(u_2)]_{B'} \ \dots \ [T(u_n)]_{B'}] \quad (3)$$

Denotamos esta matriz também pelo símbolo:

$$[T]_{B',B} \quad (4)$$

Voltando em (1), vemos que esta matriz tem a seguinte propriedade:

$$[T]_{B',B} [x]_B = [T(x)]_{B'} \quad (5)$$

Observe o cancelamento ocorrido na fórmula (5), pelo fato do subscrito B ocorrer duas vezes no lado esquerdo da mesma.

No caso especial de operadores lineares em que $V = W$, a matriz resultante é chamada a matriz de T em relação à base B . Neste caso, uma vez que $B = B'$, simplesmente escrevemos:

$$[T]_{B',B} = [T]_B \quad (6)$$

e

$$[T]_B [x]_B = [T(x)]_B \quad (7)$$

ou seja, a matriz de coordenada de $T(x)$ é matriz de T vezes a matriz de coordenadas de x .

Exemplo 3

Dada a transformação linear $T : \mathbf{R}^2 \longrightarrow \mathbf{R}^2$, dada por

$$\mathbf{T} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} x_1 + x_2 \\ -2x_1 + 4x_2 \end{bmatrix}.$$

Tomando a base $B = \{u_1, u_2\}$ de $\mathbf{R}^2$ onde,

$$\mathbf{u}_1 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}, \quad \mathbf{u}_2 = \begin{bmatrix} 1 \\ 2 \end{bmatrix},$$

obtemos:

$$[\mathbf{T}(\mathbf{u}_1)] = \begin{bmatrix} 1 + 1 \\ -2 \times 1 + 4 \times 1 \end{bmatrix} = \begin{bmatrix} 2 \\ 2 \end{bmatrix} = 2\mathbf{u}_1$$

e

$$[\mathbf{T}(\mathbf{u}_2)] = \begin{bmatrix} 1 + 2 \\ -2 \times 1 + 4 \times 2 \end{bmatrix} = \begin{bmatrix} 3 \\ 6 \end{bmatrix} = 3\mathbf{u}_2$$

Portanto,

$$[\mathbf{T}]_B = \begin{bmatrix} [T(u_1)]_B & [T(u_2)]_B \end{bmatrix} = \begin{bmatrix} 2 & 0 \\ 0 & 3 \end{bmatrix}$$

Exemplo 4

Vamos retornar ao **Exemplo 1** da **Seção 5.4**.

Seja a transformação linear:

$$T : \mathbf{R}^3 \longrightarrow \mathbf{R}^2, \text{ tal que } (x, y, z) \longrightarrow (x, y)$$

A transformação linear:

$$R : \mathbf{R}^2 \longrightarrow \mathbf{R}^3, \text{ tal que } (x, y) \longrightarrow (x, y, ax + by), \quad a, b \in \mathbf{R}$$

é uma inversa à direita para T . Variando os valores de a e $b \in \mathbf{R}$, obtemos diversas transformações inversas à direita para T .

De fato:

A matriz da transformação T é tal que:

$$[\mathbf{T}(\mathbf{e}_1)] \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \quad [\mathbf{T}(\mathbf{e}_2)] = \begin{bmatrix} 0 \\ 1 \end{bmatrix}, \quad [\mathbf{T}(\mathbf{e}_3)] = \begin{bmatrix} 0 \\ 0 \end{bmatrix}$$

Assim, a matriz de T fica:

$$[\mathbf{T}] = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \end{bmatrix}$$

A transformação da inversa à direita para T é dada por:

$R : \mathbf{R}^2 \longrightarrow \mathbf{R}^3$, tal que $(x, y) \longrightarrow (x, y, z)$, e $T(R(x, y)) = (x, y)$ para cada $(x, y) \in \mathbf{R}^2$

Escrevendo $[T] \circ [R] = [I_{T(V)}]$, devemos encontrar a matriz de R :

$$[\mathbf{R}] = \begin{bmatrix} y_1 & z_1 \\ y_2 & z_2 \\ y_3 & z_3 \end{bmatrix}$$

tal que

$$[\mathbf{T}] \circ [\mathbf{R}] = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$$

Daí, calculamos:

$$\begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \end{bmatrix} \begin{bmatrix} y_1 & z_1 \\ y_2 & z_2 \\ y_3 & z_3 \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$$

onde obtemos os resultados $y_1 = 1, y_2 = 0, z_1 = 0, z_2 = 1$ e y_3, z_3 variáveis livres.

Colocando $y_3 = a$ e $z_3 = b$, obtemos a inversa à direita:

$$[\mathbf{R}] = \begin{bmatrix} 1 & 0 \\ 0 & 1 \\ a & b \end{bmatrix}$$

Finalmente, calculamos:

$$[\mathbf{R}] \begin{bmatrix} x \\ y \end{bmatrix} = \begin{bmatrix} x \\ y \\ ax + by \end{bmatrix}$$

Exemplo 5

Vamos retornar ao **Exemplo 2** da **Seção 5.4**.

Seja a transformação linear:

$$T : \mathbf{R}^2 \longrightarrow \mathbf{R}^3, \text{ tal que } (x, y) \longrightarrow (x + 2y, 2x + 3y, 3x + 4y)$$

A transformação linear:

$$S : \mathbf{R}^3 \longrightarrow \mathbf{R}^2, \text{ tal que } (x, y, z) \longrightarrow (-3x + 2y, 2x - y)$$

é uma inversa à esquerda para T , uma vez que:

$$\begin{aligned} S(T(x, y)) &= S(x + 2y, 2x + 3y, 3x + 4y) = \\ &= (-3(x + 2y) + 2(2x + 3y), 2(2x + 3y) - (2x + 3y)) = (x, y), \quad \forall (x, y) \in \mathbf{R}^2 \end{aligned}$$

De fato:

A matriz da transformação T é tal que:

$$[\mathbf{T}(\mathbf{e}_1)] \begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix}, \quad [\mathbf{T}(\mathbf{e}_2)] = \begin{bmatrix} 2 \\ 3 \\ 4 \end{bmatrix}$$

Assim, a matriz de T fica:

$$[\mathbf{T}] = \begin{bmatrix} 1 & 2 \\ 2 & 3 \\ 3 & 4 \end{bmatrix}$$

A transformação da inversa à esquerda de T é dada por:

$$S : \mathbf{R}^3 \longrightarrow \mathbf{R}^2, \text{ tal que } (x, y, z) \longrightarrow (x, y), \text{ e } S(T(x, y, z)) = I_V \text{ (} I_V \text{ identidade em } V \text{)}$$

Escrevendo $[S] \circ [T] = [I_V]$, devemos encontrar a matriz de S :

$$[\mathbf{S}] = \begin{bmatrix} x_1 & x_2 & x_3 \\ y_1 & y_2 & y_3 \end{bmatrix}$$

tal que

$$[\mathbf{S}] \circ [\mathbf{T}] = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$$

Daí, calculamos:

$$\begin{bmatrix} x_1 & x_2 & x_3 \\ y_1 & y_2 & y_3 \end{bmatrix} \begin{bmatrix} 1 & 2 \\ 2 & 3 \\ 3 & 4 \end{bmatrix} = \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix}$$

obtendo os resultados $x_1 = -3, x_2 = 2, y_1 = 2, y_2 = -1$, onde tomamos $x_3 = y_3 = 0$ para as variáveis livres. Portanto, a inversa à esquerda fica:

$$[\mathbf{S}] = \begin{bmatrix} -3 & 2 & 0 \\ 2 & -1 & 0 \end{bmatrix}$$

Finalmente, calculamos:

$$[\mathbf{S}] \begin{bmatrix} x \\ y \\ z \end{bmatrix} = \begin{bmatrix} -3x + 2y \\ 2x - y \end{bmatrix}$$

Exemplo 6

Seja o operador linear $D : P_2 \longrightarrow P_1$, onde P_k ($k = 1, 2$) é o espaço vetorial dos polinômios de grau $\leq k$, dada por $D(p) = p'$ para cada $p \in P_2$. Tomando as bases ordenadas $B = \{1, x, x^2\}$ e $B' = \{1, x\}$ em P_2 e P_1 , respectivamente, obtemos:

$$D(1) = 0, \quad D(x) = 1, \quad D(x^2) = 2x$$

onde dispomos as componentes de $D(1), D(x)$ e $D(x^2)$ em relação à base $B' = \{1, x, x^2\}$ na forma dos vetores colunas, seguintes:

$$[\mathbf{D}(1)]_{\mathbf{B}'} = \begin{bmatrix} 0 \\ 0 \end{bmatrix}, \quad [\mathbf{D}(x)]_{\mathbf{B}'} = \begin{bmatrix} 1 \\ 0 \end{bmatrix}, \quad [\mathbf{D}(x^2)]_{\mathbf{B}'} = \begin{bmatrix} 0 \\ 2 \end{bmatrix}$$

Obtendo, assim, a matriz $\mathbf{D}_{\mathbf{B}', \mathbf{B}}$ correspondente a esta transformação:

$$\mathbf{D}_{\mathbf{B}', \mathbf{B}} = \begin{bmatrix} 0 & 1 & 0 \\ 0 & 0 & 2 \end{bmatrix}$$

Se $p(x) = a_0 + a_1x + a_2x^2$, o vetor de coordenadas de p em relação à base ordenada de P_2 é:

$$[\mathbf{p}(\mathbf{x})]_{\mathbf{B}} = \begin{bmatrix} a_0 \\ a_1 \\ a_2 \end{bmatrix}$$

Para encontrar o vetor de coordenadas de $D(p)$ em relação à base ordenada de P_1 , basta multiplicar:

$$\begin{bmatrix} 0 & 1 & 0 \\ 0 & 0 & 2 \end{bmatrix} \begin{bmatrix} a_0 \\ a_1 \\ a_2 \end{bmatrix} = \begin{bmatrix} a_1 \\ 2a_2 \end{bmatrix}$$

5.7 Mudança de Base em Transformações Lineares

Até o presente momento, fixamos uma base B no espaço vetorial V , onde definimos a transformação linear. Vamos tratar nesta seção da mudança de base no espaço vetorial V e como fica definida a transformação linear usando esta nova base B' .

Definição 11

Sejam $B = \{u_1, u_2, \dots, u_n\}$ uma base do espaço vetorial V e $B' = \{v_1, v_2, \dots, v_n\}$ uma nova base de V . Suponhamos que:

$$v_i = a_{i1}u_1 + a_{i2}u_2 + \dots + a_{in}u_n, \quad i = 1, 2, \dots, n,$$

onde a_{ik} , $k = 1, 2, \dots, n$ são os vetores coluna da k -ésima coluna. Assim, na forma matricial, escrevemos:

$$\begin{bmatrix} v_1 \\ v_2 \\ \vdots \\ v_n \end{bmatrix} = \begin{bmatrix} a_{11} & a_{12} & \dots & a_{1n} \\ a_{21} & a_{22} & \dots & a_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ a_{n1} & a_{n2} & \dots & a_{nn} \end{bmatrix} \begin{bmatrix} u_1 \\ u_2 \\ \vdots \\ u_n \end{bmatrix}$$

ou seja,

$$v = Au,$$

onde $v = [v_1 v_2 \dots v_n]^t$ e $u = [u_1 u_2 \dots u_n]^t$, e A , a matriz $n \times n$ acima.

A matriz $P = A^t$ é chamada matriz de transição da base "velha" B para a base "nova" B' .

Propriedade

1 - A matriz de transição de base P é invertível, e sua inversa P^{-1} é a matriz de transição da base B' para a base B ;

2 - Seja P , a matriz de transição da base canônica $E \in \mathbf{R}^n$ para outra base B . Então, P é a matriz cujas colunas são precisamente os vetores colunas $u_1, u_2, \dots, u_n$;

2 - Seja P , a matriz de transição de uma base B para outra base B' em V . Então, para qualquer $v \in V$, temos:

$$P[v]_{B'} = [v]_B$$

e daí, temos:

$$P^{-1}[v]_B = [v]_{B'}$$

Damos, o seguinte teorema:

Teorema 5.14

Seja P a matriz de transição de uma base B para uma outra base B' em um espaço vetorial V . Então, para qualquer transformação linear $T : V \longrightarrow V$,

$$[T]_{B'} = P^{-1}[T]P$$

Ou seja, se A é matriz que representa a transformação linear T na base B de V , então $C = P^{-1}AP$ é a matriz que representa T em uma nova base B' , onde P é a matriz de transição da base B para a base B' .

Prova

Seja um vetor $v \in V$ qualquer. Então, pela propriedade **2)** anterior temos:

$$P[v]_{B'} = [v]_B$$

Portanto,

$$P^{-1}[T]_B P[v]_{B'} = P^{-1}[T]_B [v]_B = P^{-1}[T(v)]_B = [T(v)]_{B'}.$$

Mas, $[T]_{B'}[v]_{B'} = [T(v)]_{B'}$.

Como na aplicação $v \longrightarrow [v]_B$ é sobre $\mathbf{R}^n$, temos:

$$(P^{-1}[T]_B P)[x] = [T]_{B'}[x], \quad \forall x \in \mathbf{R}^n.$$

Assim,

$$(P^{-1}[T]_B P) = [T]_{B'}.$$

Exemplo 1

Consideremos as seguintes bases em $\mathbf{R}^2$:

$$E = \{e_1 = (1, 0), e_2 = (0, 1)\} \text{ e } B = \{u_1 = (1, -2), u_2 = (2, -5)\}.$$

Como os vetores E é formado pela base canônica, escrevemos P como os vetores coluna de B , ou seja:

$$\mathbf{P} = \begin{bmatrix} 1 & 2 \\ -2 & -5 \end{bmatrix}$$

Seja o operador linear $T : \mathbf{R}^2 \longrightarrow \mathbf{R}^2$, dado por:

$$\mathbf{T} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 2x_1 - 3x_2 \\ 4x_1 + x_2 \end{bmatrix}.$$

Temos que:

$$[\mathbf{T}(\mathbf{e}_1)] = \begin{bmatrix} 2 \\ 4 \end{bmatrix}$$

e

$$[\mathbf{T}(\mathbf{e}_2)] = \begin{bmatrix} -3 \\ 1 \end{bmatrix}$$

e assim, a representação usual de T na base canônica E fica:

$$\mathbf{A} = \begin{bmatrix} 2 & -3 \\ 4 & 1 \end{bmatrix}$$

Desta forma, a representação matricial de T em relação à base B , fica:

$$\mathbf{C} = \mathbf{P}^{-1}\mathbf{A}\mathbf{P} = \begin{bmatrix} 5 & 2 \\ -2 & -1 \end{bmatrix} \begin{bmatrix} 2 & -3 \\ 4 & 1 \end{bmatrix} \begin{bmatrix} 1 & 2 \\ -2 & -5 \end{bmatrix} = \begin{bmatrix} 44 & 101 \\ -18 & -41 \end{bmatrix}$$

Exemplo 2

Seja o operador linear $T : P_1 \longrightarrow P_2$, onde P_k ($k = 1, 2$) é o espaço vetorial dos polinômios de grau $\leq k$, dada por $T(p(x)) = xp(x)$ para cada $p \in P_2$. Tomando as bases ordenadas $E = \{1, x\}$ e $E' = \{1, x, x^2\}$ em P_1 e P_2 , respectivamente, obtemos:

$$T(1) = x, \quad T(x) = x^2$$

onde dispomos as componentes de $T(1)$ e $T(x)$ em relação à base $E' = \{1, x, x^2\}$ na forma do vetores colunas, seguintes:

$$[\mathbf{T}(\mathbf{1})]_{\mathbf{E}'} = \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}, \quad [\mathbf{T}(\mathbf{x})]_{\mathbf{E}'} = \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix}$$

Obtendo, assim, a matriz $\mathbf{T}_{\mathbf{E}', \mathbf{E}}$ correspondente a este operador:

$$\mathbf{T}_{\mathbf{E}', \mathbf{E}} = \begin{bmatrix} 0 & 0 \\ 1 & 0 \\ 0 & 1 \end{bmatrix}$$

Seja a base $B' = \{1, 1+x, x+x^2\}$ de P_2 . Vamos escrever $[T]_{B', E}$.

Temos que:

$$\mathbf{P} = \begin{bmatrix} 1 & 1 & 0 \\ 0 & 1 & 1 \\ 0 & 0 & 1 \end{bmatrix}$$

é a matriz de mudança (transição) da base B' para a base canônica E' ($P[v]_{E'} = [v]_{B'}$).

Calculando P^{-1} , obtemos:

$$\mathbf{P}^{-1} = \begin{bmatrix} 1 & -1 & 1 \\ 0 & 1 & -1 \\ 0 & 0 & 1 \end{bmatrix},$$

que é a matriz de mudança da base E' para a base B' de P_2 .

Daí, obtemos:

$$[\mathbf{T}]_{B',E} = \mathbf{P}^{-1}[\mathbf{T}]_{E',E} = \begin{bmatrix} 1 & -1 & 1 \\ 0 & 1 & -1 \\ 0 & 0 & 1 \end{bmatrix} \begin{bmatrix} 0 & 0 \\ 1 & 0 \\ 0 & 1 \end{bmatrix} = \begin{bmatrix} -1 & 1 \\ 1 & -1 \\ 0 & 1 \end{bmatrix}$$

Observe, neste exemplo, que só houve mudança de base na imagem do operador linear.

5.8 Isomorfismo entre Transformações Lineares

Vimos na **seção 5.5** para que a transformação linear T ser invertível é necessário e suficiente que ela seja injetiva e sobrejetiva, ou seja, bijetiva.

Definição 13 Uma transformação $T : V \longrightarrow W$ é um isomorfismo, ou ainda, os espaços V e W são isomorfos quando a transformação T é uma bijeção linear entre V e W .

Além do mais, se $T : V \longrightarrow W$ e $S : W \longrightarrow Z$ são isomorfismos, então $T^{-1} : W \longrightarrow V$ e $ST : V \longrightarrow Z$ são isomorfismos. Assim, tem-se $(ST)^{-1} = T^{-1}S^{-1}$ e, para $\alpha \neq 0$, $(\alpha T)^{-1} = \frac{1}{\alpha}T^{-1}$.

Um isomorfismo $T : V \longrightarrow W$ transforma toda base de V numa base de W . Reciprocamente, se uma transformação linear $T : V \longrightarrow W$ leva alguma base de V numa base de W , então a transformação T é um isomorfismo.

Teorema 5.15

Sejam V e W dois espaços vetoriais de dimensão finita. V e W têm a mesma dimensão $\iff$ existe um isomorfismo entre eles.

Prova

$\implies$ Seja V um espaço vetorial de dimensão finita n . Fixando uma base $\{v_1, v_2, \dots, v_n\} \subset V$, podemos definir uma transformação linear $T : \mathbf{R}^n \longrightarrow V$ colocando para $v = (\alpha_1, \alpha_2, \dots, \alpha_n) \in \mathbf{R}^n$, $T(v) = \alpha_1 v_1 + \alpha_2 v_2 + \dots + \alpha_n v_n$. Temos que: $T(e_1) = \alpha_1 v_1$, $T(e_2) = \alpha_2 v_2$, $\dots$, $T(e_n) = \alpha_n v_n$. Assim, T transforma a base canônica $\{e_1, e_2, \dots, e_n\} \subset \mathbf{R}^n$ na base $\{v_1, v_2, \dots, v_n\} \subset V$. Portanto, T é um isomorfismo entre $\mathbf{R}^n$ e V . Ou seja, todo espaço vetorial de dimensão finita n é isomorfo à $\mathbf{R}^n$.

$\Leftarrow$ Sejam os isomorfismos $T : \mathbf{R}^n \longrightarrow V$ e $S : \mathbf{R}^n \longrightarrow W$. Como o inverso $T^{-1} : V \longrightarrow \mathbf{R}^n$ e o produto $ST^{-1} : V \longrightarrow W$ são isomorfismos, temos que V e W têm a mesma dimensão n .

Exemplo 1

O espaço P_n , dos polinômios de grau $\leq n$ tem dimensão $n + 1$. Portanto, P_n é isomorfo à $\mathbf{R}^{n+1}$.

Exemplo 2

O espaço $M(m \times p)$, das matrizes retangulares $m \times p$, é isomorfo à $\mathbf{R}^{mp}$. Por exemplo, o espaço das matrizes quadradas $M(2 \times 2)$ é isomorfo à $\mathbf{R}^4$. Mais precisamente, podemos definir uma transformação linear bijetiva $T : M(2 \times 2) \longrightarrow \mathbf{R}^4$, levando a base ordenada de $M(2 \times 2)$:

$$\left\{ \begin{bmatrix} 1 & 0 \\ 0 & 0 \end{bmatrix}, \begin{bmatrix} 0 & 1 \\ 0 & 0 \end{bmatrix}, \begin{bmatrix} 0 & 0 \\ 1 & 0 \end{bmatrix}, \begin{bmatrix} 0 & 0 \\ 0 & 1 \end{bmatrix} \right\}$$

na base canônica ordenada de $\mathbf{R}^4$: $\{e_1, e_2, e_3, e_4\}$.

Exercícios Capítulo V

1 - Em cada item a seguir, use a matriz canônica da transformação T para encontrar $T(x)$. Em seguida, confira o resultado calculando $T(x)$ diretamente.

a) $T(x_1, x_2) = (-x_1 + x_2, x_2)$, onde $x = (-1, 4)$;

b) $T(x_1, x_2, x_3) = (2x_1 - x_2, x_2 + x_3, 0)$, onde $x = (2, 1, -3)$.

2 - Use multiplicação matricial para encontrar a reflexão do vetor $(-1, 2)$,

a) no eixo $-x$;

b) no eixo $-y$;

c) na reta $y = x$.

3 - Use multiplicação matricial para encontrar a reflexão do vetor $(2, -5, 3)$,

a) no plano $-xy$;

b) no plano $-xz$;

c) no plano $-yz$.

4 - Use multiplicação matricial para encontrar a projeção ortogonal do vetor $(2, -5)$,

a) sobre o eixo $-x$;

b) sobre o eixo $-y$.

5 - Use multiplicação matricial para encontrar a projeção ortogonal do vetor $(-2, 1, 3)$,

a) sobre o plano $-xy$;

b) sobre o plano $-xz$;

c) sobre o plano $-yz$.

6 - Use multiplicação matricial para encontrar a imagem do vetor $(3, -4)$ quando este for rotacionado de um ângulo de:

a) $\theta = 30^\circ$; b) $\theta = -60^\circ$;

c) $\theta = 45^\circ$; d) $\theta = 90^\circ$.

7 - Use multiplicação matricial para encontrar a imagem do vetor $(-2, 1, 2)$ quando este for rotacionado de um ângulo de:

a) $\theta = 30^\circ$ em torno do eixo $-x$;

b) $\theta = 45^\circ$ em torno do eixo $-y$;

c) $\theta = 90^\circ$ em torno do eixo $-z$.

8 - Encontre a matriz canônica do operador que efetua a rotação de um vetor em $\mathbf{R}^3$ por um ângulo de $\theta = -60^\circ$

a) em torno do eixo $-x$;

b) em torno do eixo $-y$;

c) em torno do eixo $-z$.

9 - Use multiplicação matricial para encontrar a imagem do vetor $(-2, 1, 2)$ quando este for rotacionado de um ângulo de:

a) $\theta = -30^\circ$ em torno do *eixo* $-x$;

b) $\theta = -45^\circ$ em torno do *eixo* $-y$;

c) $\theta = -90^\circ$ em torno do *eixo* $-z$;

d) sobre o *plano* $-xz$;

10 - Sejam $B = \{u_1, u_2, u_3\}$ uma base para o espaço vetorial $\mathbf{R}^3$ e $T : \mathbf{R}^3 \longrightarrow \mathbf{R}^3$ um operador linear tal que:

$$[\mathbf{T}]_{\mathbf{B}} = \begin{bmatrix} -3 & 4 & 7 \\ 1 & 0 & -2 \\ 0 & 1 & 0 \end{bmatrix}$$

Encontre $[T]_{B'}$, sendo $B' = \{v_1, v_2, v_3\}$ a base de $\mathbf{R}^3$ definida por $v_1 = u_1, v_2 = u_1 + u_2$ e $v_3 = u_1 + u_2 + u_3$.

Implementação dos Exercícios do Capítulo V em Matlab

```

1 clear;
2 disp ( 'Lista 5');
3 disp ( ' ');
4 disp ( 'Exercicio 1a');
5 disp ( 'Usar a matriz canonica T para achar T(x).');
6 disp ( 'a) T(x1,x2) = (-x1+x2, x2), onde x =(-1,4)');
7 % montando o sistema do item a)
8 %
9 T=[-1,1;0,1];
10 T
11 X=[-1;4];
12 X
13 C=T*X;
14 disp ( ' Resultado do item a) para T(x) = T . X');
15 C
16 disp ( ' ')
17
18 disp ( '
    -----,
    )
19 disp ( 'Exercicio 1b');
20 disp ( 'Usar a matriz canonica T para achar T(x).');
21 disp ( 'a) T(x1,x2,x3) = (2x1-x2, x2+x3,0), onde x =(2,1,-3)');
22 % montando o sistema do item b)
23 %
24 T=[2,-1,0;0,1,1;0,0,0];
25 T
26 X=[2;1;-3];
27 X
28 C=T*X;
29 disp ( ' Resultado do item b) para T(x) = T . X');
30 C
31 disp ( ' ')
32
33 disp ( '
    -----,
    )
34 disp ( 'Exercicio 2a');
35 disp ( 'Usar a multiplicacao matricial para encontrar a reflexao do
    vetor (-1,2) no eixo X. ');
36 V=[-1;2];
37 V
38 RotX=[-1,0;0,1];
39 RotX

```

```

40 RefX=RotX*V;
41 RefX
42 disp ( '      ')
43
44 disp ( '
      -----,
      )
45 disp ( 'Exercicio 2b');
46 disp ('Usar a multiplicacao matricial para encontrar a reflexao do
      vetor (-1,2) no eixo Y. ');
47 V=[-1;2];
48 V
49 RotY=[1,0;0,-1];
50 RotY
51 RefY=RotY*V;
52 RefY
53 disp ( '      ')
54
55 disp ( '
      -----,
      )
56 disp ( 'Exercicio 2c');
57 disp ('Usar a multiplicacao matricial para encontrar a reflexao do
      vetor (-1,2) nA RETA Y=X');
58 V=[-1;2];
59 V
60 RotYX=[0,1;1,0];
61 RotYX
62 RefYX=RotYX*V;
63 RefYX
64 disp ( '      ')
65
66 disp ( '
      -----,
      )
67 disp ( 'Exercicio 3a');
68 disp ('Usar a multiplicacao matricial para encontrar a reflexao do
      vetor (2,-5,3) no plano XY');
69 V=[2;-5;3];
70 V
71 RotXY=[1,0,0;0,1,0;0,0,-1];
72 RotXY
73 PlanXY=RotXY*V;
74 PlanXY
75 disp ( '      ')

```

```

76
77 disp ( '
    -----,
    )
78 disp ( 'Exercicio 3b');
79 disp ( 'Usar a multiplicacao matricial para encontrar a reflexao do
    vetor (2,-5,3) no plano XZ');
80 V=[2;-5;3];
81 V
82 RotXZ=[1,0,0;0,-1,0;0,0,1];
83 RotXZ
84 PlanXZ=RotXZ*V;
85 PlanXZ
86 disp ( '      ')
87
88 disp ( '
    -----,
    )
89 disp ( 'Exercicio 3c');
90 disp ( 'Usar a multiplicacao matricial para encontrar a reflexao do
    vetor (2,-5,3) no plano YZ');
91 V=[2;-5;3];
92 V
93 RotYZ=[-1,0,0;0,1,0;0,0,1];
94 RotYZ
95 PlanYZ=RotYZ*V;
96 PlanYZ
97 disp ( '      ')
98
99 disp ( '
    -----,
    )
100 disp ( 'Exercicio 4a');
101 disp ( 'Usar a multiplicacao matricial para encontrar a projecao
    ortogonal do vetor (2,-5) sobre o eixo X');
102 V=[2;-5];
103 V
104 EixoX=[1,0;0,0];
105 EixoX
106 ProjX=EixoX*V;
107 ProjX
108 disp ( '      ')
109
110 disp ( '
    -----,

```

```

    )
111 disp ( 'Exercicio 4b');
112 disp ('Usar a multiplicacao matricial para encontrar a projecao
        ortogonal do vetor (2,-5) sobre o eixo Y');
113 V=[2;-5];
114 V
115 EixoY=[0,0;0,1];
116 EixoY
117 ProjY=EixoY*V;
118 ProjY
119 disp ( '      ')
120
121 disp ( '
        -----,
    )
122 disp ( 'Exercicio 5a');
123 disp ('Usar a multiplicacao matricial para encontrar a projecao
        ortogonal do vetor (-2,1,3) sobre o plano XY');
124 V=[-2;1;3];
125 V
126 PlanoXY=[1,0,0;0,1,0;0,0,0];
127 PlanoXY
128 ProjXY=PlanoXY*V;
129 ProjXY
130 disp ( '      ')
131
132 disp ( '
        -----,
    )
133 disp ( 'Exercicio 5b');
134 disp ('Usar a multiplicacao matricial para encontrar a projecao
        ortogonal do vetor (-2,1,3) sobre o plano XZ');
135 V=[-2;1;3];
136 V
137 PlanoXZ=[1,0,0;0,0,0;0,0,1];
138 PlanoXZ
139 ProjXZ=PlanoXZ*V;
140 ProjXZ
141 disp ( '      ')
142
143 disp ( '
        -----,
    )
144 disp ( 'Exercício 5c');
145 disp ('Usar a multiplicacao matricial para encontrar a projecao

```



```

        ortogonal do vetor (-2,1,3) sobre o plano YZ');
146 V=[-2;1;3];
147 V
148 PlanoYZ=[0,0,0;0,1,0;0,0,1];
149 PlanoYZ
150 ProjYZ=PlanoYZ*V;
151 ProjYZ
152 disp ('      ')
153
154 disp ('
        -----,
    )
155 disp ( 'Exercicio 6a');
156 disp ('Usar a multiplicacao matricial para encontrar a IMAGEM do
        vetor (3,-4) QUANDO ROTACIONADO DE 30°');
157 V=[3;-4];
158 V
159 Rot30=[cos(pi/6),-sin(pi/6);sin(pi/6),cos(pi/6)];
160 Rot30
161 Imagem30=Rot30*V;
162 Imagem30
163 disp ('      ')
164
165 disp ('
        -----,
    )
166 disp ( 'Exercicio 6b');
167 disp ('Usar a multiplicacao matricial para encontrar a IMAGEM do
        vetor (3,-4) QUANDO ROTACIONADO DE -60°');
168 V=[3;-4];
169 V
170 RotN60=[cos(-pi/3),-sin(-pi/3);sin(-pi/3),cos(-pi/3)];
171 RotN60
172 Imagem=RotN60*V;
173 Imagem
174 disp ('      ')
175
176 disp ('
        -----,
    )
177 disp ( 'Exercicio 6c');
178 disp ('Usar a multiplicacao matricial para encontrar a IMAGEM do
        vetor (3,-4) QUANDO ROTACIONADO DE 45°');
179 V=[3;-4];
180 V

```

```

181 Rot45=[cos(pi/4),-sin(pi/4);sin(pi/4),cos(pi/4)];
182 Rot45
183 Imagem=Rot45*V;
184 Imagem
185 disp ( '      ')
186
187 disp ( '
      -----,
      )
188 disp ( 'Exercicio 6d');
189 disp ( 'Usar a multiplicacao matricial para encontrar a IMAGEM do
      vetor (3,-4) QUANDO ROTACIONADO DE 90Â°');
190 V=[3;-4];
191 V
192 Rot90=[cos(pi/2),-sin(pi/2);sin(pi/2),cos(pi/2)];
193 Rot90
194 Imagem=Rot90*V;
195 Imagem
196 disp ( '      ')
197
198 disp ( '
      -----,
      )
199 disp ( 'Exercicio 7a');
200 disp ( 'Usar a multiplicacao matricial para encontrar a IMAGEM do
      vetor (-2,1,2) QUANDO ROTACIONADO DE 30Â° em torno do eixo X');
201 V=[-2;1;2];
202 V
203 PlanoYZ=[1,0,0;0,cos(pi/6),-sin(pi/6);0,sin(pi/6),cos(pi/6)];
204 PlanoYZ
205 Imagem=PlanoYZ*V;
206 Imagem
207 disp ( '      ')
208
209 disp ( '
      -----,
      )
210 disp ( 'Exercicio 7b');
211 disp ( 'Usar a multiplicacao matricial para encontrar a IMAGEM do
      vetor (-2,1,2) QUANDO ROTACIONADO DE 45Â° em torno do eixo Y');
212 V=[-2;1;2];
213 V
214 PlanoXZ=[cos(pi/4),0,-sin(pi/4);0,1,0;sin(pi/4),0,cos(pi/4)];
215 PlanoXZ
216 Imagem=PlanoXZ*V;

```

```

217 Imagem
218 disp ( '      ')
219
220 disp ( '
-----,
    )
221 disp ( 'Exercicio 7c');
222 disp ( 'Usar a multiplicacao matricial para encontrar a IMAGEM do
    vetor (-2,1,2) QUANDO ROTACIONADO DE 90° em torno do eixo Z');
223 V=[-2;1;2];
224 V
225 PlanoXY=[cos(pi/2),-sin(pi/2),0;sin(pi/2),cos(pi/2),0;0,0,1];
226 PlanoXY
227 Imagem=PlanoXY*V;
228 Imagem
229 disp ( '      ')
230
231 disp ( '
-----,
    )
232 disp ( 'Exercicio 8a');
233 disp ( 'Encontrar uma matriz canonica do operador  que efetua a
    rotacao de um vetor V em R3 por um angulo de -60° em torno do
    eixo X');
234 V=[1;1;1];
235 V
236 PlanoYZ=[1,0,0;0,cos(-pi/3),-sin(-pi/3);0,sin(-pi/3),cos(-pi/3)];
237 disp ( 'Matriz canonica do plano YZ para um angulo de -60°')
238 PlanoYZ
239 Imagem=PlanoYZ*V;
240 Imagem
241 disp ( '      ')
242
243 disp ( '
-----,
    )
244 disp ( 'Exercicio 8b');
245 disp ( 'Encontrar uma matriz canonica do operador  que efetua a
    rotacao de um vetor V em R3 por um angulo de -60° em torno do
    eixo Y');
246 V=[1;1;1];
247 V
248 PlanoXZ=[cos(-pi/3),0,-sin(-pi/3);0,1,0;sin(-pi/3),0,cos(-pi/3)];
249 disp ( 'Matriz canonica do plano XZ para um angulo de -60°')
250 PlanoXZ

```

```

251 Imagem=PlanoXZ*V;
252 Imagem
253 disp ( '      ')
254
255 disp ( '
      -----,
      )
256 disp ( 'Exercicio 8c');
257 disp ('Encontrar uma matriz canonica do operador  que efetua a
      rotacao de um vetor V em R3 por um angulo de -60° em torno do
      eixo Z');
258 V=[1;1;1];
259 V
260 PlanoXY=[cos(-pi/3),-sin(-pi/3),0;sin(-pi/3),cos(-pi/3),0;0,0,1];
261 disp ('Matriz canonica do plano XY para um angulo de -60°')
262 PlanoXY
263 Imagem=PlanoXY*V;
264 Imagem
265 disp ( '      ')
266
267 disp ( '
      -----,
      )
268 disp ( 'Exercicio 9a');
269 disp ('Usar a multiplicacao matricial para encontrar a IMAGEM do
      vetor (-2,1,2) QUANDO ROTACIONADO DE -30° em torno do eixo X');
270 V=[-2;1;2];
271 V
272 PlanoYZ=[1,0,0;0,cos(-pi/6),-sin(-pi/6);0,sin(-pi/6),cos(-pi/6)];
273 PlanoYZ
274 Imagem=PlanoYZ*V;
275 Imagem
276 disp ( '      ')
277
278 disp ( '
      -----,
      )
279 disp ( 'Exercicio 9b');
280 disp ('Usar a multiplicacao matricial para encontrar a IMAGEM do
      vetor (-2,1,2) QUANDO ROTACIONADO DE -45° em torno do eixo Y');
281 V=[-2;1;2];
282 V
283 PlanoXZ=[cos(-pi/4),0,-sin(-pi/4);0,1,0;sin(-pi/4),0,cos(-pi/4)];
284 PlanoXZ
285 Imagem=PlanoXZ*V;

```

```

286 Imagem
287 disp ( '      ')
288
289 disp ( '
      -----,
      )
290 disp ( 'Exercicio 9c');
291 disp ( 'Usar a multiplicacao matricial para encontrar a IMAGEM do
      vetor (-2,1,2) QUANDO ROTACIONADO DE -90° em torno do eixo Z');
292 V=[-2;1;2];
293 V
294 PlanoXY=[cos(-pi/2),-sin(-pi/2),0;sin(-pi/2),cos(-pi/2),0;0,0,1];
295 PlanoXY
296 Imagem=PlanoXY*V;
297 Imagem
298 disp ( '      ')
299
300 disp ( '
      -----,
      )
301 disp ( 'Exercicio 9d');
302 disp ( 'Usar a multiplicacao matricial para encontrar a IMAGEM do
      vetor (-2,1,2) sobre o plano XZ');
303 V=[-2;1;2];
304 V
305 PlanoXZ=[1,0,0;0,0,0;0,0,1];
306 PlanoXZ
307 Imagem=PlanoXZ*V;
308 Imagem
309 disp ( '      ')
310
311 disp ( '
      -----,
      )
312 disp ( 'Exercicio 10');
313 disp ( 'Encontrar um operador [T]B tal que C = P(-1)*[T]B*P');
314 TB=[-3,4,7;1,0,-2;;0,1,0];
315 TB
316 P=[1,0,0;1,1,0;1,1,1];
317 P
318 C=inv(P)*TB*P;
319 disp ( 'C = P(-1)*[T]B*P');
320 C

```

Implementação de Exemplos do Capítulo V em Matlab

```

1 clear;
2 disp ( 'Cap 5 - Secao 5.4');
3 disp ( ' ');
4 disp ( 'Exemplo 2');
5
6 disp ( 'T(x,y)=(x+2y,2x+3y,3x+4y)');
7 disp ( 'S(x,y,z)=(-3x+2y,2x-y)');
8 disp ( '');
9 % Carregando as Matrizes)
10 %
11 T=[1 2;2 3;3 4];
12 T
13 S=[-3 2 0;2 -1 0;0 0 0];
14 S
15 disp ( ' Calculo de S*T');
16 S*T
17
18 clear;
19 disp ( '
    -----,
    )
20 disp ( 'Cap 5 - Secao 5.2');
21 disp ( ' ');
22 disp ( 'Exemplo 3');
23
24 disp ( 'Se T(x,y,z)=(x-y+z,2x+y+z), achar N(T).');
25 disp ( '');
26 % Carregando a Matriz)
27 %
28 T=[1 -1 1;2 1 1];
29 disp ( ' Calculo de N(T):');
30 null(T,'r')
31
32 clear;
33 disp ( '
    -----,
    );
34 disp ( 'Cap 5 - Secao 5.2');
35 disp ( ' ');
36 disp ( 'Exemplo 4');
37 disp ( ' ');
38
39 disp ( 'Se T(x,y,z)=(x+y+z,x+y-z,x+y-z), achar N(T).');
40 disp ( '');

```

```
41 % Carregando a Matriz)
42 %
43 T=[1 1 1;1 1 -1;1 1 -1];
44 disp (' Calculo de N(T):');
45 null(T,'r')
```

Capítulo 6

Subespaços Ortogonais. Projeções em subespaços ortogonais. Aplicações

6.1 Introdução

No Capítulo 3 definimos ortogonalidade de vetores em $\mathbf{R}^n$. Vamos utilizar este conceito de ortogonalidade nos quatro subespaços fundamentais ($R(A), R(A^t), N(A)$ e $N(A^t)$) (ver Strang [8]). Antes porém, vamos estabelecer a ligação da ortogonalidade com a independência linear entre vetores ortogonais.

Teorema 6.1

Se os vetores $v_1, v_2, \dots, v_k \in \mathbf{R}^n$ são mutuamente ortogonais, então eles são linearmente independentes.

Prova

Vamos tomar a combinação linear nula $c_1 v_1 + c_2 v_2 + \dots + c_k v_k = \mathbf{0}$. Vamos mostrar que $c_i = 0, \forall i = 1, 2, \dots, k$, tomando como hipótese que $v_1, v_2, \dots, v_k \in \mathbf{R}^n$ são mutuamente ortogonais.

Para mostrar que $c_1 = 0$, fazemos o produto interno:

$$v_1^t \cdot (c_1 v_1 + c_2 v_2 + \dots + c_k v_k) = v_1^t \mathbf{0} = 0$$

Desta forma, $c_1 v_1^t v_1 = 0$, pois $v_1^t v_i = 0 \forall i \neq 1$ e como $v_1^t v_1 \neq 0$, tem-se: $c_1 = 0$.

Fazemos o mesmo para cada $c_i, i = 2, 3, \dots, k$, ou seja:

$$v_i^t \cdot (c_1 v_1 + c_2 v_2 + \dots + c_k v_k) = v_i^t \mathbf{0} = 0$$

Assim, $c_i v_i^t v_i = 0 \forall i \neq k$ e como $v_i^t v_i \neq 0$, tem-se: $c_i = 0 \forall i = 2, 3, \dots, k$.

Logo, os vetores $v_1, v_2, \dots, v_k \in \mathbf{R}^n$ são linearmente independentes.

6.2 Subespaços Ortogonais

Vamos iniciar esta seção enunciando o teorema sobre a ortogonalidade entre os subespaços fundamentais para uma matriz A , $m \times n$.

Teorema 6.2

O espaço linha de A , $(R(A^t))$ de uma matriz retangular A , $m \times n$, é ortogonal ao espaço nulo de A , $(N(A))$ (em $\mathbf{R}^n$). O espaço coluna de A , $(R(A))$ de uma matriz retangular A , $m \times n$, é ortogonal ao espaço nulo à esquerda de A , $(N(A^t))$ (em $\mathbf{R}^m$).

Prova

Suponha que $x \in N(A)$, $x \in \mathbf{R}^n$ e $v \in R(A^t)$. Então, $Ax = \mathbf{0}$ e $v = A^t z$ para algum vetor $z \in \mathbf{R}^m$, onde v é a combinação linear das linhas de A . Devemos mostrar que $v^t x = 0$.

De fato:

$$v^t x = (A^t z)^t x = z^t A x = z^t \mathbf{0} = 0.$$

De forma similar, suponha que $y \in N(A^t)$, $y \in \mathbf{R}^m$ e $v \in R(A)$. Então, $A^t y = \mathbf{0}$ ou $y^t A = \mathbf{0}$ e $v = Az$ para algum vetor $z \in \mathbf{R}^n$, onde v é a combinação linear das colunas de A . Devemos mostrar que $v^t y = 0$.

De fato:

$$v^t y = (Az)^t y = z^t A^t y = z^t \mathbf{0} = 0.$$

Ilustração

$$\mathbf{A}\mathbf{x} = \begin{bmatrix} \text{linha } 1 \\ \text{linha } 2 \\ \vdots \\ \text{linha } m \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ \vdots \\ x_n \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ \vdots \\ 0 \end{bmatrix}$$

$$\mathbf{y}^t \mathbf{A} = \begin{bmatrix} y_1 & y_2 & \cdots & y_m \end{bmatrix} \begin{bmatrix} \text{coluna } 1 & \text{coluna } 2 & \cdots & \text{coluna } n \end{bmatrix} = \begin{bmatrix} 0 \\ 0 \\ \vdots \\ 0 \end{bmatrix}$$

Exemplo

Seja a matriz A , 3×2 , cujo posto(A) = 1, abaixo:

$$\mathbf{A} = \begin{bmatrix} 1 & 3 \\ 2 & 6 \\ 3 & 9 \end{bmatrix}$$

As linhas da matriz A são múltiplas do vetor $(1, 3)$ e são ortogonais ao vetor $(-3, 1) \in N(A)$.

De fato:

$$\begin{bmatrix} 1 & 3 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = 0, \begin{bmatrix} 2 & 6 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = 0, \begin{bmatrix} 3 & 9 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = 0$$

Observe que $R(A^t)$ e $N(A)$ são retas em $\mathbf{R}^2$. Em contraste, $R(A)$ é uma reta com vetor direção

$$\begin{bmatrix} 1 \\ 2 \\ 3 \end{bmatrix}$$

e $N(A^t)$ é o plano de equação $1y_1 + 2y_2 + 3y_3 = 0$, uma vez que $y^t A = \mathbf{0}$.

Podemos estabelecer agora, o seguinte corolário:

Corolário 1

O espaço nulo de A , $(N(A))$ é o complemento ortogonal do espaço linha de A , $(R(A^t))$ em $\mathbf{R}^n$, ou seja, $N(A)^t = R(A^t)$. O espaço nulo à esquerda de A , $(N(A^t))$ é o complemento ortogonal ao espaço coluna de A , $(R(A))$ em $\mathbf{R}^m$, ou seja, $N(A^t)^t = R(A)$.

Prova

A prova se baseia nos resultados do teorema anterior e na definição de complemento ortogonal.

Queremos saber quando a equação linear $Ax = b$ é solúvel sob a ótica dos subespaços fundamentais. Assim, damos o seguinte teorema:

Teorema 6.3

A equação linear $Ax = b$ é solúvel $\iff b^t y = 0$ sempre que $A^t y = \mathbf{0}$.

Prova

A prova é decorrente dos resultados anteriores.

Como resultado direto temos que: "o vetor b deve ser combinação linear das colunas de A ". E como resultado indireto temos que: "o vetor b deve ser ortogonal a todo vetor que é ortogonal às colunas de A ".

Exemplo

Seja o seguinte sistema linear:

$$\begin{aligned} x_1 - x_2 &= b_1 \\ x_2 - x_3 &= b_2 \\ x_3 - x_1 &= b_3 \end{aligned}$$

que na forma matricial se escreve:

$$\begin{bmatrix} 1 & -1 & 0 \\ 0 & 1 & -1 \\ -1 & 0 & 1 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \begin{bmatrix} b_1 \\ b_2 \\ b_3 \end{bmatrix}$$

Somando todas as equações, temos que o sistema linear é solúvel para $b_1 + b_2 + b_3 = 0$, ou seja, quando o vetor

$$\mathbf{b} = \begin{bmatrix} b_1 \\ b_2 \\ b_3 \end{bmatrix} \text{ é ortogonal ao vetor } \mathbf{y} = \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix}$$

Isto torna mais fácil que checar com todas as colunas.

6.3 A matriz A e Subespaços Fundamentais

Quando o espaço vetorial $\mathbf{R}^n$ é decomposto em dois subespaços ortogonais todo vetor $x \in \mathbf{R}^n$ se escreve como $x = v \oplus w$, $v \in V$, $w \in W$, onde V e W são subespaços ortogonais em $\mathbf{R}^n$. O vetor v é a projeção do vetor x em V e o vetor w é a projeção ortogonal do vetor x em W , onde $W = V^\perp$. (Figura 6.1)




Figura 6.1: *Projeção Ortogonal*

Vamos definir uma aplicação do espaço linha de A , $R(A^t)$ no espaço coluna de A , $R(A)$. Temos que os subespaço $R(A^t)$ e $N(A)$ são complementos ortogonais em $\mathbf{R}^n$ e os subespaços $R(A)$ e $N(A^t)$ são complementos ortogonais em $\mathbf{R}^m$. O espaço nulo de A , $N(A)$ é levado no vetor nulo em $\mathbf{R}^m$ e por outro lado, nada é levado no espaço nulo à esquerda de A , $N(A^t)$. (Veja Figura 6.2) Para analisar a ação do espaço linha de $A, R(A^T)$ e o espaço nulo de $A, N(A)$, tomamos um vetor $x \in \mathbf{R}^n$ escrito nas componentes x_{linha} e x_{nulo} destes espaços, respectivamente, como $x = x_{linha} + x_{nulo}$. Aplicando a matriz A neste vetor x , obtemos:

$$Ax = Ax_{linha} + Ax_{nulo} = Ax_{linha} + \mathbf{0} = Ax_{linha}$$

Damos o seguinte teorema:




Figura 6.2: Ação de $Ax = A(x_{linha} + x_{nulo})$ onde A , matriz $m \times n$

Teorema 6.4

A aplicação do espaço linha no espaço coluna é invertível. Todo vetor $b \in \mathbf{R}^m$ no espaço coluna é imagem de um único vetor $x_{linha} \in \mathbf{R}^n$, no espaço linha.

Prova

Se o vetor b está no espaço coluna, ele é uma combinação linear Ax das colunas de A . Com efeito, ele é Ax_{linha} , com x_{linha} no espaço linha, uma vez que as componentes do espaço nulo de A dão $Ax_{nulo} = \mathbf{0}$. Seja um outro vetor y_{linha} no espaço linha dando $Ay_{linha} = b$, assim obtemos $A(x_{linha} - y_{linha}) = b - b = \mathbf{0}$. Daí, temos que $x_{linha} - y_{linha}$ pertence ao espaço nulo de A e espaço linha de A , e como estes são complementares temos que $x_{linha} - y_{linha} = \mathbf{0}$, ou seja: $x_{linha} = y_{linha}$.

Logo, um único vetor do espaço linha de A é levado no vetor $b \in \mathbf{R}^m$.

Conclusão

”Toda matriz A , $m \times n$, transforma seu espaço linha no seu espaço coluna.”

Nestes espaços r - dimensionais, a matriz A é invertível quando o seu espaço nulo é zero. Quando vamos na direção oposta, ou seja, quando aplicamos A^t de $R(A)$ para $R(A^t)$, ela não define a aplicação inversa. A^t move os espaços corretamente, mas esta aplicação não é biunívoca. Temos que A^{-1} existe $\iff$ posto(A) = $r = m = n$.

Quando falha a existência de A^{-1} , procuramos sua substituta natural. Ela é chamada pseudoinversa, e a denotamos por A^+ . Ela inverte a matriz A quando é possível: $A^+Ax = x$ para $x \in R(A^t)$. No espaço nulo à esquerda nada pode ser feito: $A^+y = \mathbf{0}$.

6.4 Projeção em Subespaços

Suponhamos que dado um ponto $b \in \mathbf{R}^n$ queremos encontrar sua distância a uma reta com vetor direção $a \in \mathbf{R}^n$. Queremos encontrar nesta reta um ponto p , o mais próximo de b . Geometricamente, temos em $\mathbf{R}^3$, a reta que liga o ponto b ao ponto p é perpendicular ao vetor a . (Veja Figura 6.3)




Figura 6.3: *Projeção em Subespaços*

A situação é a mesma quando, ao invés de uma reta na direção do vetor a , temos um plano em uma dada direção - ou mais geralmente, qualquer subespaço S de $\mathbf{R}^n$. Neste caso, o problema consiste em encontrar o ponto p no subespaço S que é mais próximo de b . Este ponto p é a projeção de b neste subespaço S . Quando projetamos b em S , p é um ponto onde a perpendicular encontra o subespaço S .

Uma das aplicações desta projeção consiste exatamente no problema da solução pelo método dos mínimos quadrados para um sistema sobredeterminado. Neste problema, o vetor b representa os dados, por exemplo, coletados de um experimento, e estes dados contêm alguns erros neste subespaço. Quando queremos escrever o vetor b como uma combinação linear dos vetores da base neste subespaço, isto não pode ser feito, pois as equações são inconsistentes e não têm solução. O método dos mínimos quadrados seleciona o ponto p como uma melhor escolha possível.

Retornando ao Capítulo 1, dados dois vetores a e $b \in \mathbf{R}^n$, com $a \neq 0$ podemos definir o vetor ta , onde $t = a^t b / a^t a$, como a projeção do vetor b ao longo do vetor a . Assim, a projeção p deve ser um múltiplo do vetor a , que aqui escrevemos como: $p = \bar{x}a$, onde queremos encontrar $\bar{x}$. Usando a interpretação geométrica em $\mathbf{R}^3$,

temos que o segmento de reta que vai de b à $p = \bar{x}a$ é perpendicular ao vetor a :

$$(b - a) \perp a \iff a^t(b - \bar{x}a) = 0 \iff \bar{x} = a^tb/a^ta$$

Assim, definimos:

Definição 1

Definimos a projeção b na reta que passa pela origem $\mathbf{0}$ e direção a como:

$$p = \bar{x}a = \frac{a^tb}{a^ta}a$$

Em $\mathbf{R}^3$, temos a seguinte interpretação correta para p . (Figura abaixo)

Temos que $\|b - p\|^2$ não pode ser negativa, assim:

$$\|b - \frac{a^tb}{a^ta}a\|^2 = b^tb - 2\frac{(a^tb)^2}{a^ta} + (\frac{a^tb}{a^ta})^2a^ta = \frac{(b^tb)(a^ta) - (a^tb)^2}{a^ta} \geq 0$$

O numerador $(b^tb)(a^ta) - (a^tb)^2$ nunca é negativo, assim, podemos extrair a raiz quadrada na expressão $(b^tb)(a^ta) \geq (a^tb)^2$, encontrando a desigualdade de Cauchy Schwarz:

$$|a^tb| \leq \|a\| \|b\|$$

Vimos que esta igualdade é válida quando o vetor b é múltiplo do vetor a . O ângulo θ entre a e b é $+1$ e -1 . Neste caso, b é identificado com sua projeção p e a distância entre b e a reta de direção a é zero.

Projeções de posto 1

A projeção do vetor b na reta que passa pela origem $\mathbf{0}$ e direção do vetor a pode ser escrita como:

$$p = a \frac{a^tb}{a^ta}.$$

Nesta fórmula, colocamos propositalmente o número

$$\bar{x} = \frac{a^tb}{a^ta}$$

após o vetor a . Procedendo desta forma, escrevemos:

$$p = Pb$$

onde

$$P = \frac{aa^t}{a^ta}$$

P é definida como a matriz de projeção que multiplicada pelo vetor b produz a projeção p .

Observe que o produto de um vetor coluna por um vetor linha dá uma matriz quadrada, que em seguida, é dividida pelo número a^ta .

Exemplo 1

A matriz P que projeta na reta de direção de $a = (1, 1, 1)$ é:

$$P = \frac{aa^t}{a^t a} = \frac{1}{3} \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix} \begin{bmatrix} 1 & 1 & 1 \end{bmatrix} = \begin{bmatrix} 1/3 & 1/3 & 1/3 \\ 1/3 & 1/3 & 1/3 \\ 1/3 & 1/3 & 1/3 \end{bmatrix}$$

Esta matriz tem duas propriedades básicas da matriz de projeção:

- i) P é uma matriz quadrada;
- ii) e $P^2 = P$.

Também, neste exemplo, conforme quatro subespaços fundamentais vemos que:

- i) $\text{posto}(P) = 1$;
- ii) O espaço coluna ($R(P)$) consiste da reta na direção do vetor $a = (1, 1, 1)$;
- iii) O espaço nulo $N(P)$ consiste do plano perpendicular à a .

Toda coluna é um múltiplo do vetor a , de modo que Pb está na reta de direção a .

Estes vetores que projetam em $p = \mathbf{0}$ são especialmente importantes. Eles satisfazem a relação $a^t b = 0$, isto é, eles são perpendiculares ao vetor a e suas componentes ao longo da reta são nulas. Eles pertencem ao plano perpendicular, que é o espaço nulo de P .

Por outro lado como a matriz P é simétrica, o espaço linha é igual ao espaço coluna.

Exemplo 2

Vamos tomar a projeção no plano- xy na direção do ângulo θ . A reta tem direção $a = (\cos \theta, \sin \theta)$ e a matriz de projeção é:

$$P = \frac{aa^t}{a^t a} = \frac{\begin{bmatrix} c \\ s \end{bmatrix} \begin{bmatrix} c & s \end{bmatrix}}{\begin{bmatrix} c & s \end{bmatrix} \begin{bmatrix} c \\ s \end{bmatrix}} = \begin{bmatrix} c^2 & cs \\ cs & s^2 \end{bmatrix}$$

onde $c = \cos \theta$, $s = \sin \theta$ e $c^2 + s^2 = 1$.

Vimos esta matriz de projeção em transformações lineares.

6.5 Projeções e Aproximação pelos Mínimos Quadrados

Vimos que o sistema linear $Ax = b$ tem ou não solução. Se o vetor b não está no espaço coluna, ($R(A)$), o sistema linear é inconsistente e não temos como resolver

o sistema linear. Contudo, existem situações práticas em que erros em algumas das equações provocam inconsistência do sistema linear. Um exemplo clássico disso é quando temos diversas medidas de valores (x, y) no plano e queremos encontrar a reta que passa por estes pontos. Geralmente, procuramos o valor do vetor $x \in \mathbf{R}^n$ que minimiza a média do erro nas m equações dadas. Como existem diversas maneiras de calcular esta média, é mais conveniente tomar a soma dos quadrados dos erros.

Caso 1: Regressão linear simples

Vamos descrever o Método da Regressão Linear usando o seguinte exemplo:

Exemplo

Seja o sistema linear a uma variável:

$$2x = b_1$$

$$3x = b_2$$

$$4x = b_3$$

A solução x deste problema existe somente quando o vetor $b = (b_1, b_2, b_3)$ está na mesma direção da reta de direção $a = (2, 3, 4)$. Apesar da insolubilidade do sistema linear, equações inconsistentes aparecem na prática e o problema deve ser resolvido. Assim, apelamos pelo Método de Aproximação pelo Mínimos Quadrados que consiste em encontrar um valor de x que minimiza a média dos erros nas m equações ($m = 3$, no exemplo dado). Existem diversas maneiras de se definir tal média, mas a mais conveniente é a soma dos quadrados.

$$E^2 = (2x - b_1)^2 + (3x - b_2)^2 + (4x - b_3)^2$$

Quando a solução existe, o erro mínimo é $E = 0$. Caso não exista, o mínimo será dado pelo valor de x quando a derivada primeira da função parábola E^2 é igual a zero, ou seja, quando:

$$\frac{dE^2}{dx} = 2((2x - b_1)2 + (3x - b_2)3 + (4x - b_3)4) = 0$$

Resolvendo esta equação em x , obtemos a solução pelos mínimos quadrados do sistema linear $ax = b$:

$$\bar{x} = \frac{2b_1 + 3b_2 + 4b_3}{2^2 + 3^2 + 4^2}$$

Identificamos, nesta equação, o valor $a^t b$ no numerador e o valor $a^t a$ no denominador.

No caso geral para m equações, pretendemos resolver o sistema linear $ax = b$ minimizando a função:

$$E^2 = (a_1x - b_1)^2 + (a_2x - b_2)^2 + \cdots + (a_mx - b_m)^2$$

Igualando a derivada de E^2 à zero, obtemos:

$$\frac{dE^2}{dx} = 2((a_1x - b_1)a_1 + (a_2x - b_2)a_2 + \cdots + (a_mx - b_m)a_m) = 0$$

e assim, escrevemos:

”A solução pelos Método dos Mínimos Quadrados é dada por:

$$\bar{x} = \frac{a^tb}{a^ta}.”$$

A interpretação geométrica para o Método dos Mínimos Quadrados nos indica que a reta que liga b ao ponto p na reta de direção do vetor a deve ser perpendicular à a , ou seja:

$$a^t(b - \bar{x}a) = a^tb - \frac{a^tb}{a^ta}a^ta = 0.$$

Caso 2: Método dos Mínimos Quadrados Multivariável

Vamos considerar o problema similar ao anterior, onde agora $x \in \mathbf{R}^n, b \in \mathbf{R}^m$. Neste caso, temos de considerar o sistema linear

$$Ax = b$$

onde, A é uma matriz, $m \times n$, e esperamos que o sistema linear seja inconsistente.

Vamos considerar o erro:

$$E = \| Ax - b \|$$

que é exatamente a distância do vetor b ao ponto Ax no espaço coluna da matriz A . Queremos encontrar a solução $\bar{x}$ pelo Método dos Mínimos Quadrados que minimiza a função E^2 . Esta solução localiza-se no ponto $p = A\bar{x}$ o mais próximo de b do que qualquer ponto do espaço coluna da matriz A .

Usando o apelo geométrico em $\mathbf{R}^3$ para calcular $\bar{x}$, temos que: ” p deve ser a projeção de b no espaço coluna da matriz A ”. O vetor erro $b - A\bar{x}$ deve ser perpendicular a este espaço coluna de A .

O cálculo de $\bar{x}$ e a projeção $p = A\bar{x}$ é feito em duas etapas:

1 - Os vetores ortogonais ao espaço coluna estão no espaço nulo à esquerda de A . Assim, o vetor erro $b - A\bar{x}$ deve estar no espaço nulo de A^t :

$$A^t(b - A\bar{x}) = \mathbf{0} \text{ ou } A^tA\bar{x} = A^tb;$$

2 - O vetor erro $b - A\bar{x}$ deve ser ortogonal a cada vetor coluna de A :

$$\begin{aligned} a_1^t(b - A\bar{x}) &= 0 \\ a_2^t(b - A\bar{x}) &= 0 \\ &\vdots \\ a_n^t(b - A\bar{x}) &= 0 \end{aligned}$$

ou na forma matricial:

$$\begin{bmatrix} a_1^t \\ a_2^t \\ \vdots \\ a_n^t \end{bmatrix} \begin{bmatrix} b - A\bar{x} \end{bmatrix} = \mathbf{0}$$

Esta é a equação $A^t(b - A\bar{x}) = \mathbf{0}$ ou $A^tA\bar{x} = A^tb$, chamada de Equação Normal.

Assim, escrevemos o seguinte resultado:

”A solução pelo Método dos Mínimos Quadrados de um sistema linear inconsistente $Ax = b$, com m equações e n incógnitas satisfaz:

$$A^tA\bar{x} = A^tb$$

Se as colunas da matriz A são linearmente independentes, então A^tA é invertível e

$$\bar{x} = (A^tA)^{-1}A^tb.$$

A projeção do vetor b no espaço coluna de A é portanto:

$$p = A\bar{x} = A(A^tA)^{-1}A^tb.$$

Exemplo

Seja encontrar a solução pelo Método dos Mínimos Quadrados do sistema linear:

$$\begin{aligned} x_1 - x_2 &= 4 \\ 3x_1 + 2x_2 &= 1 \\ -2x_1 + 4x_2 &= 3 \end{aligned}$$

e seja encontrar a projeção ortogonal do vetor b no espaço coluna da matriz A .

Solução:

Temos que:

$$\mathbf{A} = \begin{bmatrix} 1 & -1 \\ 3 & 2 \\ -2 & 4 \end{bmatrix} \text{ e } \mathbf{b} = \begin{bmatrix} 4 \\ 1 \\ 3 \end{bmatrix}$$

Observe que as colunas da matriz A são linearmente independentes, portanto existe uma única solução pelo Método dos Mínimos Quadrados. Temos que:

$$\mathbf{A}^t\mathbf{A} = \begin{bmatrix} 1 & 3 & -2 \\ -1 & 2 & 4 \end{bmatrix} \begin{bmatrix} 1 & -1 \\ 3 & 2 \\ -2 & 4 \end{bmatrix} = \begin{bmatrix} 14 & -3 \\ -3 & 21 \end{bmatrix}$$

e

$$\mathbf{A}^t\mathbf{b} = \begin{bmatrix} 1 & 3 & -2 \\ -1 & 2 & 4 \end{bmatrix} \begin{bmatrix} 4 \\ 1 \\ 3 \end{bmatrix} = \begin{bmatrix} 1 \\ 10 \end{bmatrix}$$

e portanto, o Sistema Normal $A^t Ax = A^t b$, neste caso, fica:

$$\begin{bmatrix} 14 & -3 \\ -3 & 21 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \begin{bmatrix} 1 \\ 10 \end{bmatrix}$$

cuja solução é:

$$x_1 = \frac{17}{95}, x_2 = \frac{143}{285}.$$

A projeção ortogonal do vetor b no espaço coluna da matriz A é:

$$\mathbf{p} = \mathbf{A}\bar{\mathbf{x}} = \begin{bmatrix} 1 & -1 \\ 3 & 2 \\ -2 & 4 \end{bmatrix} \begin{bmatrix} \frac{17}{95} \\ \frac{143}{285} \end{bmatrix} = \begin{bmatrix} \frac{-92}{285} \\ \frac{439}{285} \\ \frac{94}{57} \end{bmatrix}$$

ou seja:

$$\begin{aligned} x_1 - x_2 &= -0.3228 \\ 3x_1 + 2x_2 &= 1.5404 \\ -2x_1 + 4x_2 &= 1.6491 \end{aligned}$$

Observe que:

$$\begin{aligned} \mathbf{a}_1^t(\mathbf{b} - \mathbf{A}\bar{\mathbf{x}}) &= \begin{bmatrix} 1 & 3 & -2 \end{bmatrix} \begin{bmatrix} 4.3228 \\ -0.5404 \\ 1.3509 \end{bmatrix} = 0 \\ \mathbf{a}_2^t(\mathbf{b} - \mathbf{A}\bar{\mathbf{x}}) &= \begin{bmatrix} -1 & 2 & 4 \end{bmatrix} \begin{bmatrix} 4.3228 \\ -0.5404 \\ 1.3509 \end{bmatrix} = 0 \end{aligned}$$

onde o vetor erro $E = (4.3228, -0.5404, 1.3509)$.

6.6 Matrizes Ortogonais e ortogonalização de Gram-Schmidt

Nesta seção trataremos dos seguinte tópicos:

- 1 - Definição e propriedades de matrizes ortogonais (Q);
- 2 - A solução de $Qx = b$, ordinária e pelo Método dos Mínimos Quadrados;
- 3 - O processo de ortogonalização de Gram-Schmidt e sua interpretação como uma nova fatorização $A = QR$.

1 - Matrizes Ortogonais

Definição 2

Uma matriz ortogonal Q é simplesmente uma matriz quadrada, $n \times n$, com vetores colunas ortonormais, isto é, as colunas da matriz Q é constituída dos vetores $q_1, q_2, \dots, q_n$ tais que:

$$q_i^t q_j = \delta_{ij},$$

onde

$$\delta_{ij} = \begin{cases} 1 & \text{se } i = j \\ 0 & \text{se } i \neq j \end{cases}$$

Propriedades

1 - Se as colunas da matriz Q , $n \times n$, são ortonormais então:

$$Q^t Q = \begin{bmatrix} q_1^t \\ q_2^t \\ \vdots \\ q_n^t \end{bmatrix} \begin{bmatrix} q_1 & q_2 & \dots & q_n \end{bmatrix} = \begin{bmatrix} 1 & 0 & \dots & 0 \\ 0 & 1 & \dots & 0 \\ \vdots & \vdots & \ddots & 0 \\ 0 & 0 & \dots & 1 \end{bmatrix}$$

Portanto, $Q^t Q = I \iff Q^t = Q^{-1}$.

Exemplo 1

Seja a matriz de rotação dada no capítulo anterior:

$$Q = \begin{bmatrix} \cos \theta & -\sin \theta \\ \sin \theta & \cos \theta \end{bmatrix}$$

Temos que:

$$Q^t = Q^{-1} = \begin{bmatrix} \cos \theta & \sin \theta \\ -\sin \theta & \cos \theta \end{bmatrix}$$

Vimos que a transformação dada por esta matriz Q gira todo vetor em $\mathbf{R}^2$ de um ângulo θ e Q^t gira este vetor de volta de um ângulo $-\theta$.

Exemplo 2

Toda matriz de permutação P é uma matriz ortogonal.

De fato, a posição do coeficiente 1 na k -ésima coluna de P corresponderá à posição deste mesmo coeficiente na k -ésima linha de P^t . Por exemplo, se

$$P = \begin{bmatrix} 0 & 1 & 0 \\ 0 & 0 & 1 \\ 1 & 0 & 0 \end{bmatrix},$$

temos que:

$$P^t = P^{-1} = \begin{bmatrix} 0 & 0 & 1 \\ 1 & 0 & 0 \\ 0 & 1 & 0 \end{bmatrix}$$

2 - A multiplicação de uma matriz ortogonal Q , $n \times n$, por um vetor $x \in \mathbf{R}^n$ preserva seu comprimento, ou seja:

$$\| Qx \| = \| x \| \quad \forall x \in \mathbf{R}^n$$

A matriz ortogonal Q , também preserva produtos internos e ângulos, uma vez que:

$$(Qx)^t(Qy) = x^t Q^t Q y = x^t y$$

A preservação do comprimento do vetor x decorre diretamente de $Q^t Q = I$

De fato,

$$\| Qx \|^2 = \| x \|^2 \quad \forall x \in \mathbf{R}^n$$

pois,

$$(Qx)^t(Qx) = x^t Q^t Q x = x^t x.$$

Assim, quando no espaço um vetor é rotacionado e refletido, o produto interno e o comprimento do vetor é preservado. Isto corresponde uma interpretação geométrica para a matriz ortogonal Q .

2.1 - Cálculo de $Qx = b$, Q matriz quadrada

Iniciamos os cálculos usando a propriedade **1** : $Q^t = Q^{-1}$.

Dada uma base, qualquer vetor $b \in \mathbf{R}^n$ é uma combinação linear de vetores nesta base, e assim, o problema será encontrar os coeficientes nesta combinação linear:

$$b = x_1 q_1 + x_2 q_2 + \dots + x_n q_n (*)$$

Multiplicando ambos os termos desta equação por q_i^t , $i = 1, 2, \dots, n$, obtemos:

$$q_i^t b = x_i q_i^t q_i, \quad i = 1, 2, \dots, n$$

e como $q_i^t q_i = 1$, chegamos à:

$$x_i = q_i^t b, \quad i = 1, 2, \dots, n$$

Portanto,

$$b = (q_1^t b) q_1 + (q_2^t b) q_2 + \dots + (q_n^t b) q_n (**).$$

Desta forma, podemos reescrever (*) na forma matricial,

$$Qx = b$$

cujas solução é dada por:

$$x = Q^{-1} b$$

Como $Q^{-1} = Q^t$ a solução se escreve:

$$\mathbf{x} = \mathbf{Q}^t \mathbf{b} = \begin{bmatrix} q_1^t \\ q_2^t \\ \vdots \\ q_n^t \end{bmatrix} \begin{bmatrix} b \end{bmatrix} = \begin{bmatrix} q_1^t b \\ q_2^t b \\ \vdots \\ q_n^t b \end{bmatrix}$$

Obs.1:

A interpretação para o vetor b na fórmula (**) em termos de projeções é a seguinte: "Todo vetor b é a soma de suas projeções unidimensionais nas retas de direções q_i , $i = 1, 2, \dots, n$."

Uma vez que as projeções são ortogonais, podemos usar a relação de Pitágoras em $\mathbf{R}^n$:

$$\| b \|^2 = (q_1^t b)^2 + (q_2^t b)^2 + \dots + (q_n^t b)^2.$$

ou seja:

$$\| b \|^2 = \| Q^t b \|^2$$

como mostramos na propriedade **2**.

Obs.2:

Desde que $Q^t = Q^{-1}$, temos que $QQ^t = I$ (produto interno das linhas de Q). Onde podemos dizer: "As linhas de uma matriz quadrada são ortonormais sempre que as colunas o forem".

Exemplo

A matriz Q , 3×3 , abaixo, tem esta propriedade.

$$\mathbf{Q} = \begin{bmatrix} \frac{-1}{\sqrt{2}} & \frac{1}{\sqrt{6}} & \frac{1}{\sqrt{3}} \\ 0 & \frac{-2}{\sqrt{6}} & \frac{1}{\sqrt{3}} \\ \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{6}} & \frac{1}{\sqrt{3}} \end{bmatrix}$$

2.2 - Cálculo de $Qx = b$, Q matriz retangular

Vamos considerar agora, $Qx = b$, onde a matriz Q , $m \times n$, tem mais linhas do que colunas ($m > n$). Neste caso, esperamos não resolver $Qx = b$ exatamente. Assim, vamos usar o Método dos Mínimos Quadrados.

Mesmo Q sendo uma matriz retangular ainda temos $Q^t Q = I$, onde I é uma matriz identidade, $n \times n$. Na forma matricial, temos:

$$\begin{bmatrix} q_1^t \\ q_2^t \\ \vdots \\ q_n^t \end{bmatrix} \begin{bmatrix} q_1 & q_2 & \vdots & q_n \end{bmatrix} = \begin{bmatrix} 1 & 0 & \dots & 0 \\ 0 & 1 & \dots & 0 \\ \vdots & \vdots & \ddots & 0 \\ 0 & 0 & \dots & 1 \end{bmatrix}$$

onde Q^t é a inversa à esquerda de Q .

Se as colunas da matriz Q são ortonormais, então o problema dos mínimos quadrados torna-se fácil. Assim fazemos:

$Qx = b$ (sistema retangular insolúvel);

$Q^t Q \bar{x} = Q^t b$ (equação normal para $\bar{x}$, na qual $Q^t Q = I$)

$\bar{x} = Q^t b$ ($\bar{x}_i = q_i^t b$)

$p = Q \bar{x}$ (projeção do vetor b nas colunas é: $(q_1^t b)q_1 + (q_2^t b)q_2 + \dots + (q_n^t b)q_n$)

$p = QQ^t b$ (de modo que a matriz de projeção é $P = QQ^t$).

As fórmulas são do tipo $p = A\bar{x}$ e $P = A(A^t A)^{-1} A^t$, para matriz A retangular. No caso, como Q é uma matriz ortogonal, $Q^t Q = I$, e a parte pesada do Método dos Mínimos Quadrados desaparece. As projeções nos eixos são acopladas e p é a soma das projeções unidimensionais. (Veja figura 3.10)

Vale a pena ressaltar que $Q^t Q$ é a matriz identidade I , $n \times n$, enquanto que QQ^t é uma matriz de projeção P , $m \times m$.

Exemplo

Suponhamos que queremos projetar o ponto $b = (x, y, z)$ do espaço no plano- xy . Sua projeção é $p = (x, y, 0)$ onde pode ser visto como a soma das projeções nos eixos x e y , como segue:

$$\mathbf{q}_1 = \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix} \text{ e } (\mathbf{q}_1^t \mathbf{b}) \mathbf{q}_1 = \begin{bmatrix} x \\ 0 \\ 0 \end{bmatrix}$$

$$\mathbf{q}_2 = \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix} \text{ e } (\mathbf{q}_2^t \mathbf{b}) \mathbf{q}_2 = \begin{bmatrix} 0 \\ y \\ 0 \end{bmatrix}$$

A matriz de projeção será:

$$\mathbf{P} = \mathbf{q}_1 \mathbf{q}_1^t + \mathbf{q}_2 \mathbf{q}_2^t = \begin{bmatrix} 1 & 0 & 0 \\ 0 & 1 & 0 \\ 0 & 0 & 0 \end{bmatrix}$$

e

$$\mathbf{P} \begin{bmatrix} x \\ y \\ z \end{bmatrix} = \begin{bmatrix} x \\ y \\ 0 \end{bmatrix}$$

3 - Processo de Ortogonalização de Gram-Schmidt

O processo de Ortogonalização de Gram-Schmidt consiste em (no caso particular de $\mathbf{R}^3$), dados três vetores $a, b, c \in \mathbf{R}^3$, encontrar os vetores q_1, q_2 e q_3 a partir destes vetores iniciais de tal forma que os vetores q_1, q_2 e q_3 sejam ortonormais.

Inicialmente, calculamos:

$$q_1 = \frac{a}{\|a\|}$$

e, em seguida, calculamos:

$$\tilde{b} = b - (q_1^t b)q_1$$

que normalizado fica:

$$q_2 = \frac{\tilde{b}}{\|\tilde{b}\|}$$

Finalmente, calculamos:

$$\tilde{c} = c - (q_1^t c)q_1 - (q_2^t c)q_2$$

que normalizado fica:

$$q_3 = \frac{\tilde{c}}{\|\tilde{c}\|}$$

Exemplo

Dados os três vetores linearmente independentes:

$$a = \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix}, \quad b = \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix}, \quad c = \begin{bmatrix} 2 \\ 1 \\ 0 \end{bmatrix}$$

Na 1a. etapa, obtemos:

$$q_1 = \frac{a}{\|a\|} = \begin{bmatrix} \sqrt{2}/2 \\ 0 \\ \sqrt{2}/2 \end{bmatrix}$$

Na 2a. etapa, obtemos:

$$\tilde{b} = b - (q_1^t b)q_1 = \begin{bmatrix} 1 \\ 0 \\ 0 \end{bmatrix} - \frac{\sqrt{2}}{2} \begin{bmatrix} \sqrt{2}/2 \\ 0 \\ \sqrt{2}/2 \end{bmatrix} = \begin{bmatrix} 1/2 \\ 0 \\ -1/2 \end{bmatrix}$$

$$q_2 = \frac{\tilde{b}}{\|\tilde{b}\|} = \begin{bmatrix} \sqrt{2}/2 \\ 0 \\ -\sqrt{2}/2 \end{bmatrix}$$

Na 3a. etapa, obtemos:

$$\tilde{c} = c - (q_1^t c)q_1 - (q_2^t c)q_2 = \begin{bmatrix} 2 \\ 1 \\ 0 \end{bmatrix} - \sqrt{2} \begin{bmatrix} \sqrt{2}/2 \\ 0 \\ \sqrt{2}/2 \end{bmatrix} - \sqrt{2} \begin{bmatrix} \sqrt{2}/2 \\ 0 \\ -\sqrt{2}/2 \end{bmatrix} = \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}$$

$$q_3 = \frac{\tilde{c}}{\|\tilde{c}\|} = \begin{bmatrix} 0 \\ 1 \\ 0 \end{bmatrix}$$

Portanto, a matriz ortogonal fica:

$$\mathbf{Q} = \begin{bmatrix} \sqrt{2}/2 & \sqrt{2}/2 & 0 \\ 0 & 0 & 1 \\ \sqrt{2}/2 & -\sqrt{2}/2 & 0 \end{bmatrix}$$

Generalizando, o processo de ortogonalização de Gram-Schmidt inicia com vetores $a_1, a_2, \dots, a_n$ linearmente independentes e finaliza com vetores $q_1, q_2, \dots, q_n$, ortonormais. No j -ésimo passo, subtraímos de a_j as componentes nas direções que já foram previamente calculadas pelo processo, a saber:

$$\tilde{a}_j = a_j - (q_1^t a_j)q_1 - \dots - (q_{j-1}^t a_j)q_{j-1}$$

Em seguida, normalizamos $\tilde{a}_j$, obtendo:

$$q_j = \frac{\tilde{a}_j}{\|\tilde{a}_j\|}$$

6.7 Fatoração QR

Vamos considerar a matriz A , $m \times n$, com vetores coluna linearmente independentes. Pretendemos decompor a matriz A no produto das matrizes Q , $m \times n$, e R , $n \times n$, onde Q é uma matriz ortogonal e R é uma matriz triangular superior. Assim, seja a matriz A , com os vetores colunas $a, b, c \in \mathbf{R}^m$:

$$\mathbf{A} = \begin{bmatrix} \vdots & \vdots & \vdots \\ a & b & c \\ \vdots & \vdots & \vdots \end{bmatrix}$$

para iniciarmos o processo. Vamos finalizar com a matriz Q seguinte:

$$\mathbf{Q} = \begin{bmatrix} \vdots & \vdots & \vdots \\ q_1 & q_2 & q_3 \\ \vdots & \vdots & \vdots \end{bmatrix}$$

onde os vetores coluna $q_1, q_2, q_3 \in \mathbf{R}^m$ são vetores ortonormais obtidos pelo processo de ortogonalização de Gram-Schmidt e com a matriz R , triangular superior, de modo que $A = QR$

Usando o processo de ortogonalização de Gram-Schmidt escrevemos os vetores a, b e c como combinação linear dos vetores q_1, q_2 e q_3 . No caso, teremos:

$$a = (q_1^t a)q_1$$

$$b = (q_1^t b)q_1 + (q_2^t b)q_2$$

$$c = (q_1^t c)q_1 + (q_2^t c)q_2 + (q_3^t c)q_3$$

Expressando a matriz A , nesta forma, obtemos a fatoração $A = QR$:

$$\begin{bmatrix} \vdots & \vdots & \vdots \\ a & b & c \\ \vdots & \vdots & \vdots \end{bmatrix} = \begin{bmatrix} \vdots & \vdots & \vdots \\ q_1 & q_2 & q_3 \\ \vdots & \vdots & \vdots \end{bmatrix} \begin{bmatrix} q_1^t a & q_1^t b & q_1^t c \\ 0 & q_2^t b & q_2^t c \\ 0 & 0 & q_3^t c \end{bmatrix}$$

Exemplo

Vamos tomar a matriz A , 3×3 , seguinte:

$$\mathbf{A} = \begin{bmatrix} 1 & 1 & 2 \\ 0 & 0 & 1 \\ 1 & 0 & 0 \end{bmatrix}$$

Usando o processo de ortogonalização de Gram-Schmidt obtemos a matriz Q seguinte:

$$\mathbf{Q} = \begin{bmatrix} \frac{1}{\sqrt{2}} & \frac{1}{\sqrt{2}} & 0 \\ 0 & 0 & 1 \\ \frac{1}{\sqrt{2}} & -\frac{1}{\sqrt{2}} & 0 \end{bmatrix}$$

e de acordo com a fórmula para a matriz R , obtemos:

$$\mathbf{R} = \begin{bmatrix} \sqrt{2} & \frac{1}{\sqrt{2}} & \sqrt{2} \\ 0 & \frac{1}{\sqrt{2}} & \sqrt{2} \\ 0 & 0 & 1 \end{bmatrix}$$

Observe que esta fatoração é similar a fatoração $A = LU$, exceto que agora a matriz Q tem colunas ortogonais. Os coeficientes diagonais na matriz R são os comprimentos de $\tilde{a}, \tilde{b}$ e $\tilde{c}$, respectivamente. Os coeficientes extradiagonais superiores na matriz R são $q_1^t b, q_1^t c$ e $q_2^t c$ e os coeficientes extradiagonais inferiores são nulos decorrente da forma construtiva do método de ortogonalização de Gram-Schmidt.

”Toda matriz A , $n \times n$, com colunas linearmente independentes pode ser fatorada em $A = QR$. As colunas da matriz Q , $m \times n$, são ortonormais, e a matriz R , $n \times n$, é triangular superior e invertível. Quando $m = n$, todas as matrizes são quadradas.”

A importância principal da ortogonalização reside no fato que ela simplifica o Problema dos Mínimos Quadrados $Ax = b$. No caso, temos:

$$A^t A = R^t Q^t Q R = R^t R$$

Portanto, a equação fundamental $A^t A \bar{x} = A^t b$ simplifica em:

$$R^t R \bar{x} = R^t Q^t b \text{ ou } R \bar{x} = Q^t b$$

onde a resolução desta última equação é simples, uma vez que R é uma matriz triangular superior. O custo real do método é de mn^2 operações, decorrente das operações na obtenção da matriz Q e da matriz R usando o processo de ortogonalização de Gram-Schmidt.

Exercícios Capítulo VI

1 - Considerando que S é um plano gerado pelos vetores $(x_1, x_2, x_3, x_4) \in \mathbf{R}^4$ que satisfaz

$$x_1 + x_2 + x_3 + x_4 = 0,$$

escreva uma base para $S^\perp$. Crie uma matriz P que tenha S como seu espaço nulo.

2 - Encontre a matriz de projeção P no espaço gerado pelos vetores coluna

$$\mathbf{a}_1 = \begin{bmatrix} 1 \\ 0 \\ 1 \end{bmatrix}, \mathbf{a}_2 = \begin{bmatrix} 1 \\ 1 \\ -1 \end{bmatrix}.$$

3 - O sistema linear baixo não tem solução:

$$\mathbf{A}\mathbf{x} = \begin{bmatrix} 1 & -1 \\ 1 & 0 \\ 1 & 1 \end{bmatrix} \begin{bmatrix} C \\ D \end{bmatrix} = \begin{bmatrix} 4 \\ 5 \\ 9 \end{bmatrix} = \mathbf{b}.$$

a) Esboce e encontre uma reta que leva à minimização da soma dos quadrados $(C - D - 4)^2 + (C - 5)^2 + (C + D - 9)^2$;

b) Qual a projeção de b no espaço coluna de A ?

4 - Aplique o processo de Gram-Schmidt nos vetores

$$\mathbf{a} = \begin{bmatrix} 0 \\ 0 \\ 1 \end{bmatrix}, \mathbf{b} = \begin{bmatrix} 0 \\ 1 \\ 1 \end{bmatrix}, \mathbf{c} = \begin{bmatrix} 1 \\ 1 \\ 1 \end{bmatrix}.$$

Escreva o resultado na forma $A = QR$.

5 - Suponha que o espaço vetorial $\mathbf{R}^3$ tenha o produto interno $\langle u, v \rangle = u_1v_1 + 2u_2v_2 + 3u_3v_3$, onde $u = (u_1, u_2, u_3)$, $v = (v_1, v_2, v_3) \in \mathbf{R}^3$. Aplique o processo de Gram-Schmidt para transformar $u_1 = (1, 1, 1)$, $u_2 = (1, 1, 0)$, $u_3 = (1, 0, 0)$ numa base ortonormal.

Implementação dos Exercícios do Capítulo VI em Matlab

```
1 disp ('
    -----,
    )
2
3 disp ('Exercicios Propostos');
4
5 disp ('Exercicio 01')
6
7
8 % O exercicio pede para encontrar a matriz de projecao P para os
   vetores %
9 % O calculo sera feito utilizando a formula  $P = AA' / A'A$  %
10
11 % Vetor a1 %
12
13
14 a1 = [1;0;1]; %vetor%
15
16 a1t = a1'; %vetor transposto%
17
18 prod_num1 = a1*a1t; %produto numerador%
19 prod_den1 = a1t*a1; %produto denominador%
20
21 P1 = prod_num1/prod_den1; %matriz de projecao%
22
23
24 % Vetor a2 %
25
26
27 a2 = [1;1;-1]; %vetor%
28
29 a2t = a2'; %vetor transposto%
30
31 prod_num2 = a2*a2t; %produto numerador%
32 prod_den2 = a2t*a2; %produto denominador%
33
34 P2 = prod_num2/prod_den2 %matriz de projecao%
35
36
37
38 disp ('
    -----,
    )
39
```

```

40 disp ('Exercicios Propostos');
41
42 disp ('Exercicio 02')
43
44
45 syms c d;
46 %definindo as matrizes
47 A = [1 -1; 1 0; 1 1];
48 x = [c; d];
49 b = [4; 5; 9];
50
51 %para desenvolver o metodo dos minimos quadrados buscaremos um
    sistema
52 %normal na forma  $AtAx = Atb$ 
53
54 At = A'; %vetor transposto
55 AtA = At * A;
56 Atb = At * b;
57
58 %resolvendo o sistema
59 'Solucao das incognitas C e D do sistema'
60 x_ = linsolve(AtA,Atb)
61
62
63 'Grafico da reta e erros de aproximacao'
64 Px = [-1 0 1];
65 Py = [4 5 9];
66 Py_ = [3.5 6 8.5];
67
68 plot(Px,Py,'x',Px,Py_);
69 axis([-2 2 3 10]);
70 %projecao
71 'Projeção'
72 projecao = A*x_
73
74 'Vetor Erro'
75 error = (b - A*x_)
76
77
78
79 disp ('
    -----,
    )
80
81 disp ('Exercicios Propostos');

```

```

82
83 disp ('Exercicio 03')
84
85 % Neste programa utilizaremos uma forma rapida de determinar as
    matrizes Q
86 % e R
87
88 % definindo os vetores %
89 a = [0;0;1];
90 b = [0;1;1];
91 c = [1;1;1];
92
93 % matriz A
94
95 A = [a b c];
96
97 % as matrizes Q e R serao determinadas usando a funcao qr(matriz)
98
99 [Q,R] = qr(A);
100
101 A_prova2 = Q * R;
102
103
104 disp ('
    -----,
    )
105
106 disp ('Exercicios Propostos');
107
108 disp ('Exercicio 04')
109
110
111 %-----
112 %      Fatoração QR - Processo de Gram-Schmidt Classico
113 %-----
114      function [Q,R] = gram_schmid(A)
115
116      [m,n] = size(A);
117 %
118 %-----
119 %      Processo de Ortogonalizacao de Gram-Schmidt
120 %-----
121      for j = 1:n
122          Q(:,j) = A(:,j);
123          for i = 1:(j - 1)

```

```

124             R(i,j) = dot(A(:,j),Q(:,i));
125             Q(:,j) = Q(:,j) - R(i,j)*Q(:,i);
126         end
127     R(j,j) = sqrt(dot(Q(:,j),Q(:,j)));
128     Q(:,j) = Q(:,j) / R(j,j);
129 end

```


Implementação dos Exemplos do Capítulo VI em Matlab

```
1
2 disp ('Subespacos Ortogonais. Projeco es em subespacos ortogonais.
    Aplicacoes');
3
4 disp ('Projecao em Subespacos');
5
6 disp ('Exemplo 01')
7 % Calculo da matriz de projecao P para um vetor
8
9 a = [1; 1; 1]; %vetor
10 % a funçao round arredonda para inteiro
11
12 at = a'; %vetor transposto
13
14 % P e calculado pelo produto entre o vetor * vetor_transposto /
15 % vetor_transposto * vetor
16
17 P = (a*at) / (at*a)
18
19
20 disp ('
    -----,
    )
21
22 disp ('Subespacos Ortogonais. Projeco es em subespacos ortogonais.
    Aplicacoes');
23
24 disp ('Projecao em Subespacos');
25
26 disp ('Exemplo 02')
27
28 % Calculo da matriz de projecao P para um vetor
29
30 syms c s;
31
32 a = [c ; s]; %vetor
33
34 at = a.'; %vetor transposto
35
36 % P e calculado pelo produto entre o vetor * vetor_transposto /
37 % vetor_transposto * vetor
38
39 P = (a*at) / (at*a)
40
```

```

41
42 disp ( '
    -----
    )
43
44 disp ( 'Projecoes e Aproximacao pelos minimos quadrados');
45
46 disp ( 'Exemplo 01')
47
48
49 syms x z1 z2 z3 ; % declara as variaveis
50
51 x = [x]; % vetor x
52
53 b = [z1;z2;z3]; % vetor b
54
55 a = [2; 3; 4]; % vetor a
56
57 ax_b = a*x-b; % produto vetores a_x e subtrai vetor b
58
59 e2 = (ax_b(1))^2 + (ax_b(2))^2 + (ax_b(3))^2; % soma dos quadrados
60
61 d_e2 = diff(e2); % derivada da soma dos quadrados
62
63 x_ = solve('d_e2 = 0','d_e2 = 0'); % igualando a derivada a zero e
    resolvendo o
64                % sistema em funcao de x
65
66 atb = a'*b; % produto transposta de a pelo vetor b
67
68 ata = a'*a % produto transposta de a pelo vetor a
69
70
71
72 disp ( '
    -----
    )
73
74 disp ( 'Projecoes e Aproximacao pelos minimos quadrados');
75
76 disp ( 'Exemplo 02')
77
78
79 A = [1 -1; 3 2; -2 4];
80

```

```

81 b = [4;1;3];
82
83 AtA = A'*A; % produto da transposta pela matriz
84
85 Atb = A'*b; % produto da transposta pela matriz b
86
87 x_ = linsolve(AtA,Atb); % resolve o sistema Ax = b
88
89 p = A*x_; % calculo da projecao ortogonal
90
91 a1t = (A(:,1))'*(b-p)
92
93 a2t = (A(:,2))'*(b-p)
94
95 E = b-p % vetor erro
96
97
98
99 disp ('
    -----,
    )
100
101 disp ('Matrizes Ortogonais e Ortogonalizacao de Gram-Schmit');
102
103 disp ('Exemplo 01')
104
105 % Mostra que a matriz transposta e igual a sua inversa
106
107 syms cos sin; % declara as incognitas
108
109 Q = [cos -sin;sin cos]; %vetor
110
111 Qt = Q.'; % matriz transposta
112
113 Qi = inv(Q) % matriz inversa
114
115
116
117 disp ('
    -----,
    )
118
119 disp ('Matrizes Ortogonais e Ortogonalizacao de Gram-Schmit');
120
121 disp ('Exemplo 02')

```

```

122
123
124 % Mostra que toda matriz de permutacao P e ortogonal
125
126 P = [0 1 0; 0 0 1; 1 0 0]; % matriz de permutacao P
127
128 Pt = P'; % matriz transposta
129
130 Pi = inv(P) % matriz inversa
131
132
133
134 disp ('
    -----,
    )
135
136 disp ('Matrizes Ortogonais e Ortogonalizacao de Gram-Schmit');
137
138 disp ('Exemplo 03')
139
140
141 syms x y z; % declaracao das incognitas
142
143 b = [x;y;z]; % vetor b
144 p = [x;y;0]; % projecão
145
146 q1 = [1;0;0];
147
148 q1tbq1 = (q1'*b)*q1;
149
150 q2 = [0;1;0];
151
152 q2tbq2 = (q2'*b)*q2;
153
154 P = q1*q1' + q2*q2';
155
156 Pb = P*b % produto da matriz P pelo vetor b e igual a projecao p
157
158
159
160 disp ('
    -----,
    )
161
162 disp ('Matrizes Ortogonais e Ortogonalizacao de Gram-Schmit');

```

```

163
164 disp ('Exemplo 04')
165
166 % Calculo da matriz ortogonal Q
167
168 % definindo os vetores
169 a = [1;0;1];
170 b = [1;0;0];
171 c = [2;1;0];
172
173
174 % a partir dos vetores a, b e c, encontraremos os vetores q1, q2 e
    q3 tal
175 % que estes seja ortonormais
176
177 % calculo q1
178 q1 = a / norm(a);
179
180 % calculo q2
181 b_ = b - (q1'*b)*q1;
182 q2 = b_ / norm(b_);
183
184 % calculo q3
185 c_ = c - (q1'*c)*q1 - (q2'*c)*q2;
186 q3 = c_ / norm(c_);
187
188 % matriz Q
189 Q = [q1 q2 q3]
190
191
192
193 disp ('
    -----
    ')
194
195 disp ('Fatoracao QR');
196
197 disp ('Exemplo 01')
198
199
200 % Aplicacao de Gram-Schmidt e escrever os resultados na forma A=QR
201
202 % matriz
203 A = [1 1 2; 0 0 1; 1 0 0];
204

```

```

205 % definindo os vetores %
206 a = A(:,1);
207 b = A(:,2);
208 c = A(:,3);
209
210 % a partir dos vetores a, b e c, encontraremos os vetores q1, q2 e
    q3 tal %
211 % que estes seja ortonormais %
212
213 % calculo q1 %
214 q1 = a / norm(a);
215
216 % calculo q2 %
217 b_ = b - (q1'*b)*q1;
218 q2 = b_ / norm(b_);
219
220 % calculo q3 %
221 c_ = c - (q1'*c)*q1 - (q2'*c)*q2;
222 q3 = c_ / norm(c_);
223
224
225 % matriz R %
226 % primeiramente calcularemos as 3 colunas da matriz R e depois a
    juntaremos
227 % formando a matriz triangular superior R %
228
229 %coluna 1%
230 r1 = [q1'*a; 0; 0];
231
232 %coluna 2%
233 r2 = [q1'*b; q2'*b; 0];
234
235 %coluna 3%
236 r3 = [q1'*c; q2'*c; q3'*c];
237
238 % as matrizes Q e R
239
240 Q = [q1 q2 q3]
241 R = [r1 r2 r3]
242
243
244 %-----
245 %          Fatoracao QR - Processo de Gram-Schmidt Classico
246 %-----
247          function [Q,R] = gram_schmid(A)

```

```

248
249 %Exemplo: A = [0 0 1; 0 1 1; 1 1 1]
250
251 [m,n] = size(A);
252 %
253 %-----
254 % Processo de Ortogonalizacao de Gram-Schmidt
255 %-----
256 for j = 1:n
257     Q(:,j) = A(:,j);
258     for i = 1:(j - 1)
259         R(i,j) = dot(A(:,j),Q(:,i));
260         Q(:,j) = Q(:,j) - R(i,j)*Q(:,i);
261     end
262     R(j,j) = sqrt(dot(Q(:,j),Q(:,j)));
263     Q(:,j) = Q(:,j) / R(j,j);
264 end

```

Implementação de Exemplos do Capítulo VI em Matlab

```
1
2 disp ('Subespacos Ortogonais. Projeco es em subespacos ortogonais.
      Aplicacoes');
3
4 disp ('Projecao em Subespacos');
5
6 disp ('Exemplo 01')
7 % Calculo da matriz de projecao P para um vetor
8
9 a = [1; 1; 1]; %vetor
10 % a funçao round arredonda para inteiro
11
12 at = a'; %vetor transposto
13
14 % P e calculado pelo produto entre o vetor * vetor_transposto /
15 % vetor_transposto * vetor
16
17 P = (a*at) / (at*a)
18
19
20 disp ('
      -----,
      )
21
22 disp ('Subespacos Ortogonais. Projeco es em subespacos ortogonais.
      Aplicacoes');
23
24 disp ('Projecao em Subespacos');
25
26 disp ('Exemplo 02')
27
28 % Calculo da matriz de projecao P para um vetor
29
30 syms c s;
31
32 a = [c ; s]; %vetor
33
34 at = a.'; %vetor transposto
35
36 % P e calculado pelo produto entre o vetor * vetor_transposto /
37 % vetor_transposto * vetor
38
39 P = (a*at) / (at*a)
40
```



```

41
42 disp ( '
    -----
    )
43
44 disp ( 'Projecoes e Aproximacao pelos minimos quadrados');
45
46 disp ( 'Exemplo 01')
47
48
49 syms x z1 z2 z3 ; % declara as variaveis
50
51 x = [x]; % vetor x
52
53 b = [z1;z2;z3]; % vetor b
54
55 a = [2; 3; 4]; % vetor a
56
57 ax_b = a*x-b; % produto vetores a_x e subtrai vetor b
58
59 e2 = (ax_b(1))^2 + (ax_b(2))^2 + (ax_b(3))^2; % soma dos quadrados
60
61 d_e2 = diff(e2); % derivada da soma dos quadrados
62
63 x_ = solve('d_e2 = 0','d_e2 = 0'); % igualando a derivada a zero e
    resolvendo o
64                % sistema em funcao de x
65
66 atb = a'*b; % produto transposta de a pelo vetor b
67
68 ata = a'*a % produto transposta de a pelo vetor a
69
70
71
72 disp ( '
    -----
    )
73
74 disp ( 'Projecoes e Aproximacao pelos minimos quadrados');
75
76 disp ( 'Exemplo 02')
77
78
79 A = [1 -1; 3 2; -2 4];
80

```

```

81 b = [4;1;3];
82
83 AtA = A'*A; % produto da transposta pela matriz
84
85 Atb = A'*b; % produto da transposta pela matriz b
86
87 x_ = linsolve(AtA,Atb); % resolve o sistema Ax = b
88
89 p = A*x_; % calculo da projecao ortogonal
90
91 a1t = (A(:,1))'*(b-p)
92
93 a2t = (A(:,2))'*(b-p)
94
95 E = b-p % vetor erro
96
97
98
99 disp ('
    -----,
    )
100
101 disp ('Matrizes Ortogonais e Ortogonalizacao de Gram-Schmit');
102
103 disp ('Exemplo 01')
104
105 % Mostra que a matriz transposta e igual a sua inversa
106
107 syms cos sin; % declara as incognitas
108
109 Q = [cos -sin;sin cos]; %vetor
110
111 Qt = Q.'; % matriz transposta
112
113 Qi = inv(Q) % matriz inversa
114
115
116
117 disp ('
    -----,
    )
118
119 disp ('Matrizes Ortogonais e Ortogonalizacao de Gram-Schmit');
120
121 disp ('Exemplo 02')

```

```

122
123
124 % Mostra que toda matriz de permutacao P e ortogonal
125
126 P = [0 1 0; 0 0 1; 1 0 0]; % matriz de permutacao P
127
128 Pt = P'; % matriz transposta
129
130 Pi = inv(P) % matriz inversa
131
132
133
134 disp ('
    -----,
    )
135
136 disp ('Matrizes Ortogonais e Ortogonalizacao de Gram-Schmit');
137
138 disp ('Exemplo 03')
139
140
141 syms x y z; % declaracao das incognitas
142
143 b = [x;y;z]; % vetor b
144 p = [x;y;0]; % projecção
145
146 q1 = [1;0;0];
147
148 q1tbq1 = (q1'*b)*q1;
149
150 q2 = [0;1;0];
151
152 q2tbq2 = (q2'*b)*q2;
153
154 P = q1*q1' + q2*q2';
155
156 Pb = P*b % produto da matriz P pelo vetor b e igual a projecao p
157
158
159
160 disp ('
    -----,
    )
161
162 disp ('Matrizes Ortogonais e Ortogonalizacao de Gram-Schmit');

```

```

163
164 disp ('Exemplo 04')
165
166 % Calculo da matriz ortogonal Q
167
168 % definindo os vetores
169 a = [1;0;1];
170 b = [1;0;0];
171 c = [2;1;0];
172
173
174 % a partir dos vetores a, b e c, encontraremos os vetores q1, q2 e
    q3 tal
175 % que estes seja ortonormais
176
177 % calculo q1
178 q1 = a / norm(a);
179
180 % calculo q2
181 b_ = b - (q1'*b)*q1;
182 q2 = b_ / norm(b_);
183
184 % calculo q3
185 c_ = c - (q1'*c)*q1 - (q2'*c)*q2;
186 q3 = c_ / norm(c_);
187
188 % matriz Q
189 Q = [q1 q2 q3]
190
191
192
193 disp ('
    -----,
    )
194
195 disp ('Fatoracao QR');
196
197 disp ('Exemplo 01')
198
199
200 % Aplicacao de Gram-Schmidt e escrever os resultados na forma A=QR
201
202 % matriz
203 A = [1 1 2; 0 0 1; 1 0 0];
204

```

```

205 % definindo os vetores %
206 a = A(:,1);
207 b = A(:,2);
208 c = A(:,3);
209
210 % a partir dos vetores a, b e c, encontraremos os vetores q1, q2 e
    q3 tal %
211 % que estes seja ortonormais %
212
213 % calculo q1 %
214 q1 = a / norm(a);
215
216 % calculo q2 %
217 b_ = b - (q1'*b)*q1;
218 q2 = b_ / norm(b_);
219
220 % calculo q3 %
221 c_ = c - (q1'*c)*q1 - (q2'*c)*q2;
222 q3 = c_ / norm(c_);
223
224
225 % matriz R %
226 % primeiramente calcularemos as 3 colunas da matriz R e depois a
    juntaremos
227 % formando a matriz triangular superior R %
228
229 %coluna 1%
230 r1 = [q1'*a; 0; 0];
231
232 %coluna 2%
233 r2 = [q1'*b; q2'*b; 0];
234
235 %coluna 3%
236 r3 = [q1'*c; q2'*c; q3'*c];
237
238 % as matrizes Q e R
239
240 Q = [q1 q2 q3]
241 R = [r1 r2 r3]
242
243
244 %-----
245 %          Fatoracao QR - Processo de Gram-Schmidt Classico
246 %-----
247          function [Q,R] = gram_schmid(A)

```

```

248
249 %Exemplo:  A = [0 0 1; 0 1 1; 1 1 1]
250
251         [m,n] = size(A);
252 %
253 %-----
254 %         Processo de Ortogonalizacao de Gram-Schmidt
255 %-----
256         for j = 1:n
257             Q(:,j) = A(:,j);
258             for i = 1:(j - 1)
259                 R(i,j) = dot(A(:,j),Q(:,i));
260                 Q(:,j) = Q(:,j) - R(i,j)*Q(:,i);
261             end
262             R(j,j) = sqrt(dot(Q(:,j),Q(:,j)));
263             Q(:,j) = Q(:,j) / R(j,j);
264         end

```

Capítulo 7

Determinantes

7.1 Função Determinante

Um determinante é um certo tipo de função que associa um número real a uma matriz quadrada.

Antes de definir a função determinate, vamos dar as seguintes definições:

Definição 1

Uma permutação do conjunto de inteiros $\{1, 2, 3, \dots, n\}$ é um rearranjo destes inteiros em alguma ordem sem omissões ou repetições.

Notação: Permutação arbitrária no conjunto $S_n =$ conjunto das permutações em $1, 2, 3, \dots, n$ é dada por: $\sigma = j_1 j_2 \dots j_n$, onde $j_i = \sigma(i)$.

Definição 2

Uma permutação é chamada par se o número total de inversões é um inteiro par e é chamada ímpar se o número total de inversões é ímpar.

Obs.: Ocorre uma inversão numa permutação sempre que um inteiro maior precede um menor.

Exemplo

$$S_3 = \{1, 2, 3\}$$

Permutação	No. inversões	Classificação
(1, 2, 3)	0	par
(1, 3, 2)	1	ímpar
(2, 1, 3)	1	ímpar
(2, 3, 1)	2	par
(3, 1, 2)	2	par
(3, 2, 1)	3	ímpar

Definição 3

Definimos o sinal da permutação σ por:

$$sn(\sigma) = \begin{cases} 1 & \text{se } \sigma \text{ é par} \\ -1 & \text{se } \sigma \text{ é ímpar} \end{cases}$$

Definição 4

Definimos a função **det** para uma matriz $A, n \times n$, por:

$$\mathbf{det}(\mathbf{A}) = \sum_{\sigma} sn(\sigma) a_{1j_1} a_{2j_2} \dots a_{nj_n}$$

ou ainda, como a soma de todos os produtos elementares de A com sinal, onde um produto elementar da matriz A é o produto de n entradas de A , tais que não há duas de mesma linha ou coluna de A .

Exemplo 1

Seja a seguinte matriz $A, 3 \times 3$:

$$\mathbf{A} = \begin{bmatrix} a_{11} & a_{12} & a_{13} \\ a_{21} & a_{22} & a_{23} \\ a_{31} & a_{32} & a_{33} \end{bmatrix}$$

Temos que:

$$\mathbf{det}(\mathbf{A}) = a_{11}a_{22}a_{33} - a_{11}a_{23}a_{32} - a_{12}a_{21}a_{33} + a_{12}a_{23}a_{31} + a_{13}a_{21}a_{32} - a_{13}a_{22}a_{31}$$

7.2 Cálculo de Determinantes-Redução por Linhas

Propriedades Básicas

Teorema 7.1

Seja A uma matriz quadrada $n \times n$. Se a matriz A tem uma linha ou uma coluna de zeros, então $\mathbf{det}(\mathbf{A}) = 0$.

Prova

De fato, cada produto elementar terá um zero como fator. Assim, o somatório dos produtos elementares será igual à zero.

Teorema 7.2

Se a matriz $A, n \times n$ é triangular superior (inferior ou diagonal), então $\mathbf{det}(\mathbf{A})$ é o produto das entradas na diagonal principal da matriz, ou seja, $\mathbf{det}(\mathbf{A}) = a_{11}a_{22} \dots a_{nn}$.

Prova

De fato, cada produto elementar terá um fator não nulo da diagonal, sendo os outros fatores nulos. Assim, o somatório dos produtos elementares será igual à zero.

Exemplo 2

Seja a matriz $A, 4 \times 4$, triangular inferior:

$$\mathbf{A} = \begin{bmatrix} a_{11} & 0 & 0 & 0 \\ a_{21} & a_{22} & 0 & 0 \\ a_{31} & a_{32} & a_{33} & 0 \\ a_{41} & a_{42} & a_{43} & a_{44} \end{bmatrix}$$

Vamos considerar o produto elementar $a_{1j_1}a_{2j_2}a_{3j_3}a_{4j_4}$ típico. Como $a_{12} = a_{13} = a_{14} = 0$, precisamos de $j_1 = 1$, então $j_2 \neq 1$. Assim, $j_2 = 2, 3, 4$. Como $a_{23} = a_{24} = 0$, para ter um produto elementar não nulo devemos ter $j_2 = 2$. Continuando deste modo, obtemos: $\det(\mathbf{A}) = a_{11}a_{22}a_{33}a_{44}$.

Teorema 7.3

Seja A uma matriz quadrada $n \times n$. Temos que: $\det(\mathbf{A}) = \det(\mathbf{A}^t)$.

Prova

Se $A = (a_{ij}), n \times n$, então $A^t = (b_{ij})$, onde $b_{ij} = a_{ji}, i = 1, 2, \dots, n, j = 1, 2, \dots, n$.

Logo,

$$\det(\mathbf{A}^t) = \sum_{\sigma} sn(\sigma) b_{1\sigma(1)} b_{2\sigma(2)} \dots b_{n\sigma(n)} = \sum_{\sigma} sn(\sigma) a_{\sigma(1)1} a_{\sigma(2)2} \dots a_{\sigma(n)n}$$

Seja $\tau = \sigma^{-1}$, permutação inversa ($\sigma^{-1}(j) = k \Leftrightarrow \sigma(k) = j$).

Temos que $sn(\tau) = sn(\sigma)$ e $a_{\sigma(1)1} a_{\sigma(2)2} \dots a_{\sigma(n)n} = a_{1\tau(1)} a_{2\tau(2)} \dots a_{n\tau(n)}$.

Portanto,

$$\det(\mathbf{A}^t) = \sum_{\tau} sn(\sigma) a_{1\tau(1)} a_{2\tau(2)} \dots a_{n\tau(n)}.$$

Definição 5

Uma matriz $E, n \times n$, que pode ser obtida da matriz identidade $I_n, n \times n$, executando uma única operação elementar sobre linhas é chamada uma matriz elementar.

Teorema 7.4

Seja A uma matriz quadrada $n \times n$.

a) Se B é a matriz, $n \times n$, que resulta da multiplicação de uma única linha ou uma única coluna de A por um escalar k , então: $\det(\mathbf{B}) = k \det(\mathbf{A})$;

b) Se B é a matriz, $n \times n$, que resulta da permutação de duas linhas ou duas colunas de A , então: $\det(\mathbf{B}) = -\det(\mathbf{A})$;

c) Se B é a matriz, $n \times n$, que resulta quando um múltiplo de uma linha de A é somado a outra linha de A ou quando um múltiplo de uma coluna de A é somado a outra coluna de A , então: $\det(\mathbf{B}) = \det(\mathbf{A})$.

Prova (ver Apostol, Vol II [3])

Corolário 1

Seja E uma matriz elementar $n \times n$.

a) Se E resulta da multiplicação de uma única linha ou uma única coluna de I_n por um escalar k , então: $\det(\mathbf{E}) = k$;

b) Se E resulta da permutação de duas linhas ou duas colunas de I_n , então: $\det(\mathbf{E}) = -1$;

c) Se E resulta quando um múltiplo de uma linha de I_n é somado a outra linha de I_n ou quando um múltiplo de uma coluna de I_n é somado a outra coluna de I_n , então: $\det(\mathbf{E}) = 1$.

Prova

Consequência imediata do teorema anterior.

Teorema 7.5

Se A uma matriz $n \times n$, com duas linhas proporcionais ou duas colunas proporcionais, então: $\det(\mathbf{A}) = 0$.

Prova

Basta fazer a redução da matriz A introduzindo uma linha de zeros.

Exemplo 3

Seja calcular $\det(\mathbf{A})$, onde:

$$\mathbf{A} = \begin{bmatrix} 0 & 1 & 5 \\ 3 & -6 & 9 \\ 2 & 6 & 1 \end{bmatrix}$$

Vamos reduzir esta matriz à forma escalonada e aplicar o teorema 2.

$$\begin{aligned} \det(\mathbf{A}) &= \begin{vmatrix} 0 & 1 & 5 \\ 3 & -6 & 9 \\ 2 & 6 & 1 \end{vmatrix} = - \begin{vmatrix} 3 & -6 & 9 \\ 0 & 1 & 5 \\ 2 & 6 & 1 \end{vmatrix} = -3 \begin{vmatrix} 1 & -2 & 3 \\ 0 & 1 & 5 \\ 2 & 6 & 1 \end{vmatrix} = \\ &= -3 \begin{vmatrix} 1 & -2 & 3 \\ 0 & 1 & 5 \\ 0 & 10 & -5 \end{vmatrix} = -3 \begin{vmatrix} 1 & -2 & 3 \\ 0 & 1 & 5 \\ 0 & 0 & -55 \end{vmatrix} = -3 \times 1 \times (-55) = 165 \end{aligned}$$

Teorema 7.6

Sejam A e B matrizes, $n \times n$, e seja k um escalar qualquer. Temos que:

a) $\det(k \mathbf{A}) = k^n \det(\mathbf{A})$;

b) Na maioria dos casos, $\det(\mathbf{A} + \mathbf{B}) \neq \det(\mathbf{A}) + \det(\mathbf{B})$;

c) $\det(\mathbf{AB}) = \det(\mathbf{A}) \det(\mathbf{B})$;

d) Uma matriz quadrada A , $n \times n$, é invertível $\iff \det(\mathbf{A}) \neq 0$;

e) $\det(\mathbf{A}^{-1}) = \frac{1}{\det(\mathbf{A})}$.

Prova(ver Apostol, Vol II [3])

7.3 Cálculo de Determinantes - Expansão em Cofatores

Definição 6

Seja a matriz $A, n \times n$. O determinante menor da entrada a_{ij} , ou simplesmente, o menor de a_{ij} é denotado por M_{ij} e é definido como o determinante da submatriz por supressão da i -ésima linha e da j -ésima coluna da matriz A . O número $(-1)^{(i+j)} M_{ij}$ é denotado por C_{ij} e é chamado o cofator do coeficiente a_{ij} .

Exemplo 4

Dada a matriz $A, 3 \times 3$:

$$\mathbf{A} = \begin{bmatrix} 3 & 1 & -4 \\ 2 & 5 & 6 \\ 1 & 4 & 8 \end{bmatrix}$$

O cofator de $a_{11} = 3$ é:

$$\mathbf{C}_{11} = (-1)^{1+1} \begin{vmatrix} 5 & 6 \\ 4 & 8 \end{vmatrix} = 16$$

O cofator de $a_{12} = 1$ é:

$$\mathbf{C}_{12} = (-1)^{1+2} \begin{vmatrix} 2 & 6 \\ 1 & 8 \end{vmatrix} = -10$$

Cálculo do determinante da matriz $\mathbf{A}$ usando Cofatores

Teorema 7.7

O determinante da matriz $A = (a_{ij})$ é igual a soma dos produtos obtidos pela multiplicação dos elementos de qualquer linha(ou coluna) de A por seus respectivos cofatores, ou seja:

$$\det(A) = \sum_{j=1}^n a_{kj} C_{kj} = a_{k1} C_{k1} + a_{k2} C_{k2} + \dots + a_{kn} C_{kn}$$

ou,

$$\det(A) = \sum_{i=1}^n a_{ik} C_{ik} = a_{1k} C_{1k} + a_{2k} C_{2k} + \dots + a_{nk} C_{nk}$$

Prova(ver Apostol, Vol II [3])

Exemplo 4

Dada a matriz $A, 3 \times 3$:

$$\mathbf{A} = \begin{bmatrix} 0 & 2 & 3 \\ 4 & 5 & 1 \\ 2 & -1 & 3 \end{bmatrix}$$

Temos que:

$$\begin{aligned}\det(\mathbf{A}) &= 0 \times (-1)^{1+1} \begin{vmatrix} 5 & 1 \\ -1 & 3 \end{vmatrix} + 2 \times (-1)^{1+2} \begin{vmatrix} 4 & 1 \\ 2 & 3 \end{vmatrix} + 3 \times (-1)^{1+3} \begin{vmatrix} 4 & 5 \\ 2 & -1 \end{vmatrix} = \\ &= 0 - 2 \times 10 + 3 \times (-14) = -62.\end{aligned}$$

7.4 Cálculo da inversa da matriz $\mathbf{A}$ usando Ad-junta Clássica

Definição 7

Seja a matriz $A, n \times n$. Definimos a matriz dos cofatores de A , denotada por C , a matriz $n \times n$, cujos coeficientes são os cofatores da matriz A , ou seja:

$$\mathbf{C} = \begin{bmatrix} C_{11} & C_{12} & \dots & C_{1n} \\ C_{21} & C_{22} & \dots & C_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ C_{n1} & C_{n2} & \dots & C_{nn} \end{bmatrix}$$

Definimos, a adjunta clássica de A , denotada por $\text{Adj}(A)$, a transposta da matriz dos cofatores de A , ou seja:

$$\text{Adj}(\mathbf{A}) = \begin{bmatrix} C_{11} & C_{21} & \dots & C_{n1} \\ C_{12} & C_{22} & \dots & C_{n2} \\ \vdots & \vdots & \ddots & \vdots \\ C_{1n} & C_{2n} & \dots & C_{nn} \end{bmatrix}$$

Teorema 7.8

Se A é uma matriz, $n \times n$, invertível, então:

$$A^{-1} = \frac{1}{\det(A)} \text{Adj}(A)$$

Prova(ver Apostol, Vol II [3])

Exemplo

Seja calcular a inversa da matriz A do exemplo anterior, onde $\det(A) = -62$ ($\det(A) \neq 0, A$ é invertível).

$$\mathbf{A} = \begin{bmatrix} 0 & 2 & 3 \\ 4 & 5 & 1 \\ 2 & -1 & 3 \end{bmatrix}$$

Cálculo de $\text{Adj}(A)$

Temos que:

$$\mathbf{C}_{11} = \begin{vmatrix} 5 & 1 \\ -1 & 3 \end{vmatrix} = 16, \quad \mathbf{C}_{12} = \begin{vmatrix} 4 & 1 \\ 2 & 3 \end{vmatrix} = 10, \quad \mathbf{C}_{13} = \begin{vmatrix} 4 & 5 \\ 2 & -1 \end{vmatrix} = -14,$$

$$\mathbf{C}_{21} = \begin{vmatrix} 2 & 3 \\ -1 & 3 \end{vmatrix} = 9, \quad \mathbf{C}_{22} = \begin{vmatrix} 0 & 3 \\ 2 & 3 \end{vmatrix} = -6, \quad \mathbf{C}_{23} = \begin{vmatrix} 0 & 2 \\ 2 & -1 \end{vmatrix} = -4,$$

$$\mathbf{C}_{31} = \begin{vmatrix} 2 & 3 \\ 5 & 1 \end{vmatrix} = -13, \quad \mathbf{C}_{32} = \begin{vmatrix} 0 & 3 \\ 4 & 1 \end{vmatrix} = -12, \quad \mathbf{C}_{33} = \begin{vmatrix} 0 & 2 \\ 4 & 5 \end{vmatrix} = -8,$$

$$\mathbf{Adj}(\mathbf{A}) = \begin{bmatrix} 16 & 9 & -13 \\ 10 & -6 & -12 \\ -14 & -4 & -8 \end{bmatrix}$$

Cálculo de A^{-1}

Usando a fórmula do **teorema 7.8**, obtemos:

$$\mathbf{A}^{-1} = \frac{1}{(-62)} \begin{bmatrix} 16 & 9 & -13 \\ 10 & -6 & -12 \\ -14 & -4 & -8 \end{bmatrix}$$

7.5 Produto Vetorial de Vetores

Daremos aqui um método para se obter um vetor perpendicular a cada dois vetores $A, B \in \mathbf{R}^3$, A, B linearmente independentes.

Definição 8

Sejam $A = (a_1, a_2, a_3)$ e $B = (b_1, b_2, b_3)$ dois vetores em $\mathbf{R}^3$. O produto vetorial $A \times B$, nesta ordem, é definido pelo vetor C , perpendicular aos vetores A e B , cujas componentes são determinantes de ordem dois, dado por:

$$\mathbf{C} = \mathbf{A} \times \mathbf{B} = \left(\begin{vmatrix} a_2 & a_3 \\ b_2 & b_3 \end{vmatrix}, \begin{vmatrix} a_3 & a_1 \\ b_3 & b_1 \end{vmatrix}, \begin{vmatrix} a_1 & a_2 \\ b_1 & b_2 \end{vmatrix} \right)$$

que pode também ser expresso utilizando os vetores coordenados unitários $\mathbf{i}, \mathbf{j}$ e $\mathbf{k}$:

$$\mathbf{C} = \mathbf{A} \times \mathbf{B} = \begin{vmatrix} a_2 & a_3 \\ b_2 & b_3 \end{vmatrix} \mathbf{i} + \begin{vmatrix} a_3 & a_1 \\ b_3 & b_1 \end{vmatrix} \mathbf{j} + \begin{vmatrix} a_1 & a_2 \\ b_1 & b_2 \end{vmatrix} \mathbf{k}$$

ou melhor:

$$\mathbf{C} = \mathbf{A} \times \mathbf{B} = \begin{vmatrix} i & j & k \\ a_1 & a_2 & a_3 \\ b_1 & b_2 & b_3 \end{vmatrix}$$

Exemplo

Qual o produto vetorial dos vetores $A = -i + 2k$ e $B = 2i + j - k$?

Solução

$$\begin{aligned} \mathbf{C} = \mathbf{A} \times \mathbf{B} &= \begin{vmatrix} i & j & k \\ -1 & 0 & 2 \\ 2 & 1 & -1 \end{vmatrix} = \\ &= \begin{vmatrix} 0 & 2 \\ 1 & -1 \end{vmatrix} \mathbf{i} - \begin{vmatrix} -1 & 2 \\ 2 & -1 \end{vmatrix} \mathbf{j} + \begin{vmatrix} -1 & 0 \\ 2 & 1 \end{vmatrix} \mathbf{k} = -2i + 3j - k. \end{aligned}$$

Observe que:

$$C \perp A \text{ e } C \perp B$$

De fato:

$$A \cdot C = (-1, 0, 2) \cdot (-2, 3, -1) = 2 - 2 = 0 \text{ e } B \cdot C = (2, 1, -1) \cdot (-2, 3, -1) = -4 + 3 + 1 = 0.$$

Interpretação geométrica do Produto Vetorial

Sejam A e B dois vetores não nulos em $\mathbf{R}^3$ fazendo um ângulo θ entre eles, onde $0 \leq \theta \leq \pi$. Podemos escrever:

$$A \cdot B = \|A\| \|B\| \cos \theta$$

Pela identidade de Lagrange, temos:

$$\begin{aligned} \|A \times B\|^2 &= \|A\|^2 \|B\|^2 - (A \cdot B)^2 = \\ &= \|A\|^2 \|B\|^2 - (\|A\| \|B\| \cos^2 \theta) = \\ &= \|A\|^2 \|B\|^2 (1 - \cos^2 \theta) = \\ &= \|A\|^2 \|B\|^2 \sin^2 \theta \end{aligned}$$

Portanto,

$$\|A \times B\| = \|A\| \|B\| \sin \theta.$$

Desta forma, podemos concluir que $\|A \times B\|$ é igual a área do paralelogramo de lados $\|A\|$ e $\|B\|$, conforme mostra Figura 7.1.




Figura 7.1: *Área do Paralelogramo*

Exercícios Capítulo VII

1 - Seja a matriz A , 4×4 ,

$$\mathbf{A} = \begin{bmatrix} a & b & 0 & 0 \\ c & d & 0 & 0 \\ e & f & g & h \\ x & y & z & w \end{bmatrix}$$

Mostre que:

$$\det(\mathbf{A}) = \det \begin{bmatrix} a & b \\ c & d \end{bmatrix} \det \begin{bmatrix} g & h \\ z & w \end{bmatrix}$$

2 - Seja uma matriz A , $n \times n$, invertível. Mostre que, se a matriz A é ortogonal ($A^t = A^{-1}$), então $\det(A) = \pm 1$.

3 - Dada a matriz A , 4×4 ,

$$\mathbf{A} = \begin{bmatrix} 1 & 3 & 0 & 1 \\ 2 & 1 & -1 & 4 \\ -3 & 0 & 2 & -1 \\ 1 & -4 & 0 & 1 \end{bmatrix}$$

e o vetor coluna b ,

$$\mathbf{b} = \begin{bmatrix} 2 \\ 1 \\ -1 \\ 1 \end{bmatrix}$$

Utilizando o método de inversão de matrizes por determinante e matriz adjunta:

a) mostre que a matriz A é invertível;

b) resolva o sistema linear $Ax = b$.

4 - Dada a matriz A , 3×3 ,

$$\mathbf{A} = \begin{bmatrix} a+b & ab & 0 \\ 1 & a+b & ab \\ 0 & 1 & a+b \end{bmatrix}$$

onde a e b são números reais com $a \neq b$. Mostre que $\det(A) = (a^4 - b^4)/(a - b)$.

Implementação dos Exercícios do Capítulo VII em Matlab

```
1 clear
2 disp('Exercicio 3');
3 A=[1 3 0 1; 2 1 -1 4; -3 0 2 -1; 1 -4 0 1];
4 det(A)
5 cofator(A)
6 inversa=det(A)^-1*cofator(A)
7 b=[2; 1; -1; 1]
8 x=inversa*b
```

Implementação de Exemplos do Capítulo VII em Matlab

```

1 % clear
2 % disp('Calculo Determinante');
3 % disp('Exemplo 3');
4 % A=[0 1 5; 3 -6 9; 2 6 1]
5 % det(A)
6
7 %=====
8 % clear
9 % disp('Calculo Matriz Cofatores');
10 % disp('Exemplo 4');
11 % A=[3 1 -4; 2 5 6; 1 4 8];
12 % cof=cofator(A)
13
14 %=====
15 % clear
16 % disp('Calculo da Matriz Adjunta');
17 % disp('Exemplo 5');
18 % A=[0 2 3; 4 5 1; 2 -1 3];
19 % adj=cofator(A)'
20 % inversa=det(A)^-1*adj
21 % A^-1
22
23
24 %Funcao para calculo da Matriz dos Cofatores
25
26 % function[saida]=cofator(A)
27 % na=size(A);
28 % if na(1)~=na(2)
29 %     return
30 % %     teste para verificar se a matriz e quadrada
31 % end
32 % n=na(1);
33 % saida(1:n,1:n)=0;
34 % for p=1:n
35 %     for q=1:n
36 %         aux=A;
37 %         aux(p,:)=[]; %elimina a linha p da matriz aux
38 %         aux(:,q)=[]; %elimina a coluna q da matriz aux
39 %         saida(p,q)=(-1)^(p+q)*det(aux);
40 %     end
41 % end
42 % end
43
44 %=====

```

```

45 % clear
46 % disp('Calculo Produto Vetorial ');
47 % disp('Exemplo 6');
48 % A=[-1 0 2];
49 % B=[2 1 -1];
50 % C=cross(A,B)
51
52 %=====

```

Capítulo 8

Autovalores e Autovetores

8.1 Introdução

No Capítulo 2 vimos o Método de Eliminação de Gauss para obtenção da solução do Sistema Linear $Ax = b$, onde A é uma matriz $n \times n$ e x e b são vetores em $\mathbf{R}^n$. Agora, estamos interessados em resolver o problema $Ax = \lambda x$, onde A é uma matriz $n \times n$, x é um vetor em $\mathbf{R}^n$ e λ é um número em $\mathbf{R}$ (podemos estender o estudo ao caso complexo). A resolução de ambos os problemas pode ser obtida via determinante, sendo que no primeiro problema usamos a regra de Cramer para a obtenção da solução $x = A^{-1}b$, quando esta é única e no segundo problema encontramos as raízes do polinômio $\det(A - \lambda I)$, que serão os autovalores da matriz A .

O segundo problema aparece em muitas aplicações. Podemos introduzi-lo via solução de equações diferenciais.

Exemplo

Seja o par de equações:

$$\begin{aligned}\frac{dv}{dt} &= 4v - 5w, \quad v = 8 \text{ em } t = 0 \\ \frac{dw}{dt} &= 2v - 3w, \quad w = 5 \text{ em } t = 0\end{aligned}$$

Na forma matricial, escrevemos:

$$\frac{du}{dt} = Au, \quad u = u_0 \text{ em } t = 0$$

onde

$$\mathbf{u}(t) = \begin{bmatrix} v(t) \\ w(t) \end{bmatrix}, \quad \mathbf{u}_0 = \begin{bmatrix} 8 \\ 5 \end{bmatrix} \text{ em } t = 0 \text{ e } \mathbf{A} = \begin{bmatrix} 4 & -5 \\ 2 & -3 \end{bmatrix}$$

Procuramos por soluções da forma:

$$v(t) = e^{\lambda t} y$$

$$w(t) = e^{\lambda t} z$$

ou na forma vetorial:

$$u(t) = e^{\lambda t} x$$

Calculando $\frac{du}{dt}$ e substituindo no problema na forma matricial, obtemos:

$$\lambda e^{\lambda t} y = 4e^{\lambda t} y - 5e^{\lambda t} z$$

$$\lambda e^{\lambda t} z = 2e^{\lambda t} y - 3e^{\lambda t} z$$

Cancelando o termo comum $e^{\lambda t}$, obtemos:

$$4y - 5z = \lambda y$$

$$2y - 3z = \lambda z$$

O vetor x associado à λ , soluções da equação $Ax = \lambda x$, nos dá a solução $u(t) = e^{\lambda t} x$, onde vemos que o número $e^{\lambda t}$ cresce ou decresce vezes um vetor fixo x .

8.2 Autovalores e Autovetores

Definição 1

Um escalar λ é um autovalor (valor próprio) da matriz $A, n \times n$, se existir um vetor $x \neq \mathbf{0}, x \in \mathbf{R}^n$, tal que:

$$Ax = \lambda x$$

Este vetor x , associado ao autovalor λ , diz-se autovetor (vetor próprio) de A .

Solução de $Ax = \lambda x$

A solução de $Ax = \lambda x$ é dada por:

$$(A - \lambda I)x = \mathbf{0},$$

ou seja, o vetor x pertence ao espaço nulo da matriz $A - \lambda I$. Assim, o número λ é escolhido de modo que $A - \lambda I$ tenha um espaço nulo. Como $x \neq \mathbf{0}$, devemos ter $A - \lambda I$ singular. Daí, podemos enunciar o seguinte resultado:

Teorema 8.1

O número λ é autovalor da matriz $A, n \times n \iff \det(A - \lambda I) = 0$.

Prova(ver Apostol, Vol II [3])

Definição 2

A equação $\det(A - \lambda I) = 0$ pode ser escrita na forma $f(\lambda) = \lambda^n + c_1 \lambda^{n-1} + \dots + c_{n-1} \lambda + c_n$, chamado de polinômio característico.

Para cada raiz λ do polinômio característico $f(\lambda)$ corresponde um autovetor x , solução do sistema linear homogêneo:

$$(A - \lambda I)x = \mathbf{0}.$$

Exemplo 1

Seja a matriz:

$$\mathbf{A} = \begin{bmatrix} 2 & 1 & 1 \\ 2 & 3 & 4 \\ -1 & -1 & -2 \end{bmatrix},$$

cujos polinômio característico é:

$$\det(\mathbf{A} - \lambda \mathbf{I}) = \det \begin{bmatrix} \lambda - 2 & -1 & -1 \\ -2 & \lambda - 3 & -4 \\ 1 & 1 & \lambda + 2 \end{bmatrix} = \lambda^3 - 3\lambda^2 - \lambda + 3 = (\lambda - 1)(\lambda + 1)(\lambda - 3)$$

Solução

Autovalores: $\lambda_1 = 1, \lambda_2 = -1, \lambda_3 = 3$.

Autovetores Associados: Basta resolver os sistemas lineares $Ax = \lambda_i x$, $i = 1, 2, 3$, obtendo:

Para $\lambda_1 = 1, x = t(1, -1, 0)$, $t \in \mathbf{R}, t \neq 0$;

Para $\lambda_2 = -1, x = t(0, 1, -1)$, $t \in \mathbf{R}, t \neq 0$;

Para $\lambda_3 = 3, x = t(2, 3, -1)$, $t \in \mathbf{R}, t \neq 0$.

Definição 3 Definimos o subespaço invariante o subespaço gerado pelos autovetores associados ao autovalor λ e o notamos por: $E(\lambda)$.

Para o exemplo anterior temos:

$$E(1) = \{(1, -1, 0)\}, E(-1) = \{(0, 1, -1)\}, E(3) = \{(2, 3, -1)\}$$

Observe que, correspondendo aos autovalores distintos, obtemos os autovetores linearmente independentes.

Para autovalores múltiplos a dimensão do subespaço invariante será importante na verificação da diagonalização da matriz A .

Exemplo 2

Seja a seguinte matriz de projeção:

$$\mathbf{P} = \begin{bmatrix} 1/2 & 1/2 \\ 1/2 & 1/2 \end{bmatrix}$$

Esta matriz tem como autovalor $\lambda_1 = 1$ com correspondente autovetor:

$$\mathbf{x}_1 = \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

e autovalor $\lambda_2 = 0$ com correspondente autovetor:

$$\mathbf{x}_2 = \begin{bmatrix} 1 \\ -1 \end{bmatrix}$$

Os autovalores de uma projeção são 1 ou 0. Quando $\lambda_1 = 1$ o vetor é projetado em si mesmo e quando $\lambda_2 = 0$ o vetor é projetado no vetor nulo. O espaço coluna de P é formado pelos autovetores correspondentes à $\lambda_1 = 1$ e o espaço nulo é formado pelos autovetores correspondentes à $\lambda_2 = 0$. Nestes espaços, temos $\dim R(P) = r$, onde $\lambda_1 = 1$ é repetido r vezes e $\dim N(P) = n - r$, onde $\lambda_2 = 0$ é repetido $n - r$ vezes.

8.3 Traço de uma matriz

Seja $f(\lambda)$ o polinômio característico da matriz $A, n \times n$. Sendo $\lambda_1, \lambda_2, \dots, \lambda_n$ distintos, escrevemos:

$$f(\lambda) = (\lambda - \lambda_1)(\lambda - \lambda_2) \dots (\lambda - \lambda_n)$$

ou ainda:

$$f(\lambda) = \lambda^n + c_1 \lambda^{n-1} + \dots + c_{n-1} \lambda + c_n$$

onde o termo constante c_n e o coeficiente c_1 do termo λ^{n-1} são dados pelas fórmulas:

$$c_n = (-1)^n \lambda_1 \lambda_2 \dots \lambda_n$$

e

$$c_1 = -(\lambda_1 + \lambda_2 + \dots + \lambda_n)$$

e ainda:

$$c_n = (-1)^n \det(A) \implies \lambda_1 \lambda_2 \dots \lambda_n = \det(A).$$

Definição 4

Chama-se traço de A a soma das raízes do polinômio característico $f(\lambda)$ e é denotado por $tr(A)$. Escrevemos:

$$tr(A) = \sum_{i=1}^n \lambda_i = -c_1$$

Desenvolvendo o determinante de $A - \lambda I$, também encontramos:

$$c_1 = -(a_{11} + a_{22} + \dots + a_{nn})$$

Desta forma, também definimos:

$$tr(A) = \sum_{i=1}^n a_{ii}$$

Propriedades de $\text{tr}(A)$

Sejam A e B matrizes, $n \times n$. Temos que:

- i) $\text{tr}(A + B) = \text{tr}(A) + \text{tr}(B)$;
- ii) $\text{tr}(cA) = c \text{tr}(A)$, c escalar;
- iii) $\text{tr}(AB) = \text{tr}(BA)$;
- iv) $\text{tr}(A^t) = \text{tr}(A)$.

Prova

Basta usar as propriedades da função determinante.

8.4 Diagonalização de uma Matriz

Vamos desenvolver o estudo de dois problemas diferentes, porém equivalentes:

- O problema de autovetores: Dada uma matriz $A, n \times n$, existe uma base de $\mathbf{R}^{n \times n}$ consistindo de autovetores de A ?

- O problema de diagonalização: Dada uma matriz $A, n \times n$, existe uma matriz invertível $S, n \times n$, tal que $S^{-1}AS$ é uma matriz diagonal?

Damos a seguinte definição:

Definição 5

Uma matriz $A, n \times n$, é dita diagonalizável se existir uma matriz invertível S tal que $S^{-1}AS$ é uma matriz diagonal, neste caso, dizemos que S diagonaliza a matriz A .

Teorema 8.2

Se A é uma matriz, $n \times n$, então são equivalentes as seguintes afirmações:

- i) A matriz A é diagonalizável;
- ii) A matriz A tem n autovetores linearmente independentes.

Prova

$i) \implies ii)$

Se a matriz A é diagonalizável, então existe uma matriz S invertível, que notamos:

$$S = \begin{bmatrix} s_{11} & s_{12} & \dots & s_{1n} \\ s_{21} & s_{22} & \dots & s_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ s_{n1} & s_{n2} & \dots & s_{nn} \end{bmatrix},$$

tal que $S^{-1}AS$ é uma matriz diagonal. Escrevemos: $S^{-1}AS = \Lambda$, onde:

$$\Lambda = \begin{bmatrix} \lambda_1 & 0 & \dots & 0 \\ 0 & \lambda_2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \lambda_n \end{bmatrix},$$

Daí, segue-se que $AS = S\Lambda$, ou seja:

$$AS = \begin{bmatrix} s_{11} & s_{12} & \dots & s_{1n} \\ s_{21} & s_{22} & \dots & s_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ s_{n1} & s_{n2} & \dots & s_{nn} \end{bmatrix} \begin{bmatrix} \lambda_1 & 0 & \dots & 0 \\ 0 & \lambda_2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \lambda_n \end{bmatrix} = \begin{bmatrix} \lambda_1 s_{11} & \lambda_2 s_{12} & \dots & \lambda_n s_{1n} \\ \lambda_1 s_{21} & \lambda_2 s_{22} & \dots & \lambda_n s_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ \lambda_1 s_{n1} & \lambda_2 s_{n2} & \dots & \lambda_n s_{nn} \end{bmatrix}$$

Denotando os vetores coluna de S por $s_1, s_2, \dots, s_n$ temos que os vetores coluna de AS são sucessivamente $\lambda_1 s_1, \lambda_2 s_2, \dots, \lambda_n s_n$. Por outro lado, temos que as sucessivas colunas de AS são:

$$As_1, As_2, \dots, As_n$$

Assim, devemos ter:

$$As_1 = \lambda_1 s_1, As_2 = \lambda_2 s_2, \dots, As_n = \lambda_n s_n$$

Como S é invertível, estes vetores coluna são todos não nulos. Desta forma, $\lambda_1, \lambda_2, \dots, \lambda_n$ são autovalores de A com $s_1, s_2, \dots, s_n$ autovetores associados. Além do mais, como S é invertível, concluímos que $s_1, s_2, \dots, s_n$ são linearmente independentes.

ii) $\implies i$)

Vamos supor que a matriz A tem n autovetores $s_1, s_2, \dots, s_n$ linearmente independentes correspondentes aos autovalores $\lambda_1, \lambda_2, \dots, \lambda_n$ e seja:

$$S = \begin{bmatrix} s_{11} & s_{12} & \dots & s_{1n} \\ s_{21} & s_{22} & \dots & s_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ s_{n1} & s_{n2} & \dots & s_{nn} \end{bmatrix}$$

onde $s_1, s_2, \dots, s_n$ são os vetores coluna de S .

Os vetores coluna de AS são:

$$As_1, As_2, \dots, As_n$$

onde

$$As_1 = \lambda_1 s_1, As_2 = \lambda_2 s_2, \dots, As_n = \lambda_n s_n$$

Assim,

$$\mathbf{AS} = \begin{bmatrix} \lambda_1 s_{11} & \lambda_2 s_{12} & \dots & \lambda_n s_{1n} \\ \lambda_1 s_{21} & \lambda_2 s_{22} & \dots & \lambda_n s_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ \lambda_1 s_{n1} & \lambda_2 s_{n2} & \dots & \lambda_n s_{nn} \end{bmatrix} = \begin{bmatrix} s_{11} & s_{12} & \dots & s_{1n} \\ s_{21} & s_{22} & \dots & s_{2n} \\ \vdots & \vdots & \ddots & \vdots \\ s_{n1} & s_{n2} & \dots & s_{nn} \end{bmatrix} \begin{bmatrix} \lambda_1 & 0 & \dots & 0 \\ 0 & \lambda_2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & \dots & \lambda_n \end{bmatrix} = \mathbf{S}\mathbf{\Lambda}$$

onde $\mathbf{\Lambda}$ é uma matriz diagonal com os autovalores $\lambda_1, \lambda_2, \dots, \lambda_n$ de A . Como, por hipótese, os autovetores de A são linearmente independentes, concluímos que os vetores coluna de S são linearmente independentes e daí a matriz S invertível. Desta forma, reescrevemos a igualdade anterior como $S^{-1}AS = \mathbf{\Lambda}$, ou seja: a matriz A é diagonalizável.

Obs.: As matrizes A e $\mathbf{\Lambda}$ têm o mesmo polinômio característico e portanto os mesmos autovetores (A e $\mathbf{\Lambda}$ são semelhantes).

Exemplo 3

Seja a matriz $A, n \times n$:

$$\mathbf{A} = \begin{bmatrix} 5 & -6 & -6 \\ -1 & 4 & 2 \\ 3 & -6 & -4 \end{bmatrix}$$

Temos que a equação característica de A é:

$$(\lambda - 2)^2(\lambda - 1) = 0$$

Os autovalores associados à $\lambda_1 = 2$ são dados pela solução de $Ax = 2x$, dada por: $x = (x_1, x_2, x_3)$ tal que $x_1 = 2x_2 + 2x_3$. Assim, a base para o subespaço invariante gerado pelos autovetores associados à $\lambda_1 = 2$ é:

$$E(2) = \{(2, 1, 0), (2, 0, 1)\}$$

Os autovalores associados à $\lambda_2 = 1$ são dados pela solução de $Ax = x$, dada por: $x = (x_1, x_2, x_3)$ tal que $x_1 = x_3 = -3x_2$. Assim, a base para o subespaço invariante gerado pelos autovetores associados à $\lambda_2 = 1$ é:

$$E(1) = \{(3, -1, 3)\}$$

Como existem três autovetores linearmente independentes, tomamos como colunas da matriz S os vetores coluna:

$$\mathbf{s}_1 = \begin{bmatrix} 2 \\ 1 \\ 0 \end{bmatrix}, \mathbf{s}_2 = \begin{bmatrix} 2 \\ 0 \\ 1 \end{bmatrix}, \mathbf{s}_3 = \begin{bmatrix} 3 \\ -1 \\ 3 \end{bmatrix}$$

Desta forma, podemos concluir que a matriz A é diagonalizável, pois ela tem três autovetores linearmente independentes. Assim, escrevemos:

$$\mathbf{S} = \begin{bmatrix} 2 & 2 & 3 \\ 1 & 0 & -1 \\ 0 & 1 & 3 \end{bmatrix}$$

Vamos dar um teorema importante sobre a diagonalização de uma matriz $A, n \times n$. Porém, antes vamos dar a seguinte definição:

Definição 6

Seja λ_k é um autovalor de uma matriz $A, n \times n$. A dimensão do subespaço invariante $E(\lambda_k)$ é chamado de multiplicidade geométrica de λ_k e o número de vezes que $\lambda - \lambda_k$ aparece como fator do polinômio característico de A é chamado de multiplicidade algébrica de λ_k .

Teorema 8.3

Se A é uma matriz quadrada $n \times n$, então:

- i) Para cada autovalor de A , a multiplicidade geométrica é menor ou igual a multiplicidade algébrica;
- ii) A é diagonalizável $\iff$ para cada autovalor, a multiplicidade geométrica é igual à multiplicidade algébrica.

Prova(ver Apostol, Vol II [3])

Obs.:

Quando a diagonalização da matriz A não for possível, recorreremos à forma canônica de Jordan, tornando $S^{-1}AS$ "mais próximo da matriz diagonal".

Pelo teorema anterior, vemos que dada uma matriz $A, n \times n$, é sempre possível encontrar uma matriz não singular S , tal que a matriz $D = S^{-1}AS$ é diagonal, e esta matriz S não é única. Contudo, se a matriz S é constituída de vetores ortonormais, ou seja, quando S é ortogonal, esta será única para seus autovalores ordenados.

Temos que as matrizes D e A são semelhantes e têm o mesmo polinômio característico.

De fato:

$$\det(D - \lambda I) = \det(S^{-1}AS - \lambda I) = \det(S^{-1}(A - \lambda I)S) = \det(S^{-1})\det(A - \lambda I)\det(S) = \det(A - \lambda I)$$

Teorema 8.4

Seja A é uma matriz quadrada $n \times n$. Sejam $\lambda_1, \lambda_2, \dots, \lambda_k$ os autovalores distintos de A e seja $W_i = E(\lambda_i)$. São equivalentes as seguintes afirmações:

- i) A matriz A é diagonalizável;

ii) O polinômio característico de A é:

$$f(\lambda) = (\lambda - \lambda_1)^{d_1} (\lambda - \lambda_2)^{d_2} \dots (\lambda - \lambda_k)^{d_k}$$

e

$$\dim(W_i) = d_i, i = 1, 2, \dots, k.$$

ii)

$$\dim(W_1) + \dim(W_2) + \dots + \dim(W_k) = n$$

Prova(ver Apostol, Vol II [3])

8.5 Polinômios e Matrizes

Vamos considerar um polinômio $f(t)$ com escalares $a_i, i = 0, 1, \dots, n$ em K ($\mathbf{R}$ ou $\mathbf{C}$):

$$f(t) = a_n t^n + a_{n-1} t^{n-1} + \dots + a_1 t + a_0$$

Definição 7

Tomando uma matriz $A, n \times n$ com coeficientes em K , podemos definir:

$$f(A) = a_n A^n + a_{n-1} A^{n-1} + \dots + a_1 A + a_0 I,$$

onde I é a matriz identidade, também $n \times n$.

Dizemos que a matriz A é uma raiz de $f(t)$, quando $f(A) = \mathbf{0}$.

Exemplo 4

Sejam

$$\mathbf{A} = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}$$

e

$$f(t) = 2t^2 - 3t + 7, \quad g(t) = t^2 - 5t - 2.$$

Temos:

$$\mathbf{f}(\mathbf{A}) = 2 \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}^2 - 3 \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix} + 7 \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} = \begin{bmatrix} 18 & 14 \\ 21 & 39 \end{bmatrix}$$

e

$$\mathbf{g}(\mathbf{A}) = \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix}^2 - 5 \begin{bmatrix} 1 & 2 \\ 3 & 4 \end{bmatrix} - 2 \begin{bmatrix} 1 & 0 \\ 0 & 1 \end{bmatrix} = \begin{bmatrix} 0 & 0 \\ 0 & 0 \end{bmatrix}$$

Logo, a matriz A é uma raiz de $g(t)$.

Propriedades

Sejam f e g polinômios com coeficientes em K ($\mathbf{R}$ ou $\mathbf{C}$), A uma matriz, $n \times n$, com coeficientes em K . Então:

- i) $(f + g)(A) = f(A) + g(A)$;
- ii) $(fg)(A) = f(A)g(A)$;
- iii) $(kf)(A) = kf(A)$, $\forall k \in K$.

Prova

(Basta usar as operações com polinômios)

Teorema 8.5(Cayley Hamilton)

Toda matriz $A, n \times n$, é um zero de seu polinômio característico.

Prova

Seja A uma matriz $n \times n$, onde

$$f(t) = \det(A - tI) = t^n + a_{n-1}t^{n-1} + \dots + a_1t + a_0$$

Denotamos por $B(t)$ a adjunta clássica de $A - tI$. Os elementos de $B(t)$ são cofatores de matriz $A - tI$, ou seja, são polinômios em t de grau $\leq n - 1$. Assim:

$$B(t) = B_{n-1}t^{n-1} + B_{n-2}t^{n-2} + \dots + B_1t + B_0$$

onde B_i são matrizes $k \times k$, $k \leq n - 1$, com coeficientes independentes de t .

Pela propriedade da adjunta clássica, temos que:

$$(A - tI)B(t) = \det(A - tI)I,$$

ou seja,

$$(A - tI)B_{n-1}t^{n-1} + B_{n-2}t^{n-2} + \dots + B_1t + B_0 = (t^n + a_{n-1}t^{n-1} + \dots + a_1t + a_0)I$$

Efetuando as operações algébricas em ambos os lados desta equação, obtemos para $k = n, n - 1, \dots, 0$:

$$\begin{aligned} B_{n-1} &= I \\ B_{n-2} - AB_{n-1} &= a_{n-1}I \\ B_{n-3} - AB_{n-2} &= a_{n-2}I \\ &\dots\dots\dots \\ B_0 - AB_1 &= a_1I \\ -AB_0 &= a_0I \end{aligned}$$

Multiplicando estas equações por $A^n, A^{n-1}, \dots, A, I$, respectivamente, obtemos:

$$\begin{aligned} A^n B_{n-1} &= A^n \\ A^{n-1} B_{n-2} - A^n B_{n-1} &= a_{n-1} A^{n-1} \\ A^{n-2} B_{n-3} - A^{n-1} B_{n-2} &= a_{n-2} A^{n-2} \\ &\dots\dots\dots \\ AB_0 - A^2 B_1 &= a_1 A \\ -AB_0 &= a_0 I \end{aligned}$$

Somando membro a membro os lados destas igualdades, obtemos:

$$\mathbf{0} = A^n + a_{n-1} A^{n-1} + \dots + a_1 A + a_0$$

Logo, a matriz A é um zero de seu polinômio característico.

8.6 Potências de matrizes

Definição 8

Seja uma matriz $A, n \times n$, multiplicada por si mesmo um certo número de vezes. Neste caso, sendo k um número inteiro positivo, definimos a potência k -ésima de A por: $A^k = AA \dots A$ (k vezes).

Suponhamos que a matriz $A, n \times n$, possa ser diagonalizada na forma $S^{-1}AS = D$, onde D é uma matriz diagonal. Então, a matriz A admite a fatoração diagonal, extremamente útil:

$$A = SDS^{-1}$$

Utilizando-se esta fatoração, a potência de A é facilmente calculada, como segue:

”Seja $D = \text{diag}(k_1, k_2, \dots, k_n)$. Então:

$$A^m = (SDS^{-1})^m = SD^m S^{-1} = S \text{diag}(k_1^m, k_2^m, \dots, k_n^m) S^{-1}$$

e, mais geralmente, para qualquer polinômio $f(t)$,

$$f(A) = f(SDS^{-1}) = Sf(D)S^{-1} = S \text{diag}(f(k_1), f(k_2), \dots, f(k_n)) S^{-1}$$

Exemplo

Seja a matriz:

$$\mathbf{A} = \begin{bmatrix} 4 & 2 \\ 3 & -1 \end{bmatrix}$$

Temos que o polinômio característico de A é:

$$f(t) = t^2 - 3t - 10$$

cujas raízes são os autovalores: $\lambda_1 = 5$ e $\lambda_2 = -2$. Calculando os autovetores correspondentes, obtemos: $s_1 = (2, 1)$ e $s_2 = (-1, 3)$.

Desta forma, obtemos a matriz S cujas colunas são os autovetores acima:

$$\mathbf{S} = \begin{bmatrix} 2 & -1 \\ 1 & 3 \end{bmatrix}$$

e obtemos:

$$\mathbf{S}^{-1} = \begin{bmatrix} 3/7 & 1/7 \\ -1/7 & 2/7 \end{bmatrix}$$

$D = S^{-1}AS$ é a matriz diagonal cujos coeficientes diagonais são os respectivos autovalores:

$$\mathbf{D} = \begin{bmatrix} 5 & 0 \\ 0 & -2 \end{bmatrix}$$

Consequentemente, a matriz A admite a fatoração diagonal:

$$\mathbf{A} = \mathbf{S}\mathbf{D}\mathbf{S}^{-1} = \begin{bmatrix} 2 & -1 \\ 1 & 3 \end{bmatrix} \begin{bmatrix} 5 & 0 \\ 0 & -2 \end{bmatrix} \begin{bmatrix} 3/7 & 1/7 \\ -1/7 & 2/7 \end{bmatrix}$$

Por exemplo, para o polinômio $f(t) = t^4 - 4t^3 - 3t^2 + 5$ podemos calcular:

$$\mathbf{f}(\mathbf{A}) = \mathbf{S}\mathbf{f}(\mathbf{D})\mathbf{S}^{-1} = \begin{bmatrix} 2 & -1 \\ 1 & 3 \end{bmatrix} \begin{bmatrix} 55 & 0 \\ 0 & 41 \end{bmatrix} \begin{bmatrix} 3/7 & 1/7 \\ -1/7 & 2/7 \end{bmatrix} = \begin{bmatrix} 53 & 4 \\ 6 & 43 \end{bmatrix}$$

Exercícios Capítulo VIII

1 - a) Seja a matriz simétrica, 2×2 ,

$$\mathbf{A} = \begin{bmatrix} p & a \\ a & q \end{bmatrix}$$

mostre que o polinômio característico de A tem apenas raízes reais.

b) Sejam λ_1 e λ_2 autovalores distintos de uma matriz simétrica A , $n \times n$, correspondendo aos autovetores v_1 e v_2 , respectivamente. Sabendo-se que vale a seguinte propriedade:

$$Av_1 \cdot v_2 = v_1 \cdot Av_2,$$

mostre que v_1 é ortogonal à v_2 .

2 - Seja a matriz

$$\mathbf{A} = \begin{bmatrix} a_1 & b_1 & d_1 \\ b_1 & a_2 & b_2 \\ d_1 & b_2 & a_3 \end{bmatrix}$$

a) Expresse $\det(A - \lambda I)$ como um polinômio $f(\lambda) = \lambda^3 + c_1\lambda^2 + c_2\lambda + c_3$;

b) Expresse os coeficientes c_1 e c_3 em termos de determinantes e traços.

3 - Dada a matriz

$$\mathbf{A} = \begin{bmatrix} 2 & 1 & 0 \\ 0 & 1 & -1 \\ 0 & 2 & 4 \end{bmatrix}$$

a) Encontre os autovalores de A ;

b) Para a cada autovalor λ_k de A , encontre a dimensão do subespaço invariante $E(\lambda_k)$;

c) A matriz A é diagonalizável? Justifique sua conclusão.

4 - Dada a matriz

$$\mathbf{A} = \begin{bmatrix} -1 & 4 & -2 \\ -3 & 4 & 0 \\ -3 & 1 & 3 \end{bmatrix}$$

a) Encontre os autovalores de A ;

b) Para a cada autovalor λ_k de A , encontre os autovetores correspondentes;

c) Caso a matriz A seja diagonalizável, encontre a matriz invertível P tal que $P^{-1}AP$ é uma matriz diagonal.

Implementação dos Exercícios do Capítulo VIII em Matlab

```
1 %Exercicio 3:
2 %Definindo a matriz A
3 A=[2 1 0;0 1 -1;0 2 4]
4 %Calculo dos autovalores
5 lambda=eig(A)
6 %Calculo dos autovalores e autovetores
7 [V,D]=eig(A)
8 %subespaco invariante do autovalor 2
9 E2=V(:,1:2)
10 %Verificando se os autovetores referentes ao autovalor 2 sao
    linearmente
11 %independentes
12 rank(E2)
13 %subespaco invariante do autovalor 3
14 E3=V(:,3)
15 %Exercicio 4
16 %Definindo a matriz A
17 A=[-1 4 -2;-3 4 0;-3 1 3]
18 %Calculo dos autovalores e autovetores
19 [P,D]=eig(A)
20 %Verifivando se P diagonaliza A
21 inv(V)*A*V
```

Implementação de Exemplos do Capítulo VIII em Matlab

```

1 %Exemplo 1
2 % Autovalores e autovetores
3 %Definindo a matriz A
4 A=[2 1 1;2 3 4;-1 -1 -2];
5 %Calculo dos autovalores e autovetores
6 [V,D]=eig(A)
7 % ObservaÃ§Ã£o 1: A ordem dos autovalores na diagonal corresponde
   a ordem das
8 % colunas dos autovetores.
9 % ObservaÃ§Ã£o 2: A matriz dos autovetores esta normalizada. Para
   obter a
10 % amtriz do exemplo da apostila e necessario dividir pelo modulo
   da menor
11 % componente do autovetor.
12 %
   %%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%
13 %Exemplo 2
14 %Projecao
15 %Definindo a matriz P
16 P=[1/2 1/2;1/2 1/2]
17 %Calculo do posto de P
18 rank(P)
19 P*P
20 %Calculo dos autovalores e autovetores
21 [Vp,Dp]=eig(P)
22 P*V(:,2)
23 $%
   %%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%
24 %Traco de uma matriz
25 %Definindo a matriz A
26 A=[2 1 1;2 3 4;-1 -1 -2]
27 %Calculo do traco de A
28 trA= trace(A)
29 %Calculo dos autovalores e autovetores
30 [V,D]=eig(A)
31 %Calculo do traco de D
32 trD=trace(D)
33 %
   %%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%
34 %Exemplo 3
35 % Diagonalizacao de uma matriz

```

```

36 %Definindo a matriz A
37 A=[5 -6 -6;-1 4 2;3 -6 -4]
38 %Calculo dos autovalores e autovetores
39 [S,D]=eig(A)
40 Diag=inv(S)*A*S
41 %
    %%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%
42 %Exemplo 4
43 %Polinomios e matrizes
44 %Definindo a matriz A
45 A=[1 2;3 4]
46 %Calculo de f(A)
47 f=2*mpower(A,2)-3*A+7*eye(2)
48 %Calculo de g(A)
49 g=mpower(A,2)-5*A-2*eye(2)
50 %
    %%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%%
51 %Exemplo 5
52 %Potencia de matrizes
53 A=[4 2;3 -1]
54 %Calculo de f(A)
55 f=mpower(A,4)-4*mpower(A,3)-3*mpower(A,2)+5*eye(2)
56 [S,D]=eig(A)
57 %Calculo de f(D)
58 F=mpower(D,4)-4*mpower(D,3)-3*mpower(D,2)+5*eye(2)
59 %Calculo f(A)
60 S*F*inv(S)

```

Capítulo 9

Decomposição em Valores Singulares - SVD

9.1 Introdução

A Decomposição em Valores Singulares(SVD) de uma matriz A , $m \times n$, é uma decomposição que pode ser utilizada em muitas aplicações, a saber: processamento digital de imagens, posto "efetivo", decomposição polar, filtragem de sinais, etc.

(ver Leon [7])

Vamos supor, em toda seção, que A é uma matriz $m \times n$ com $m \geq n$. Vamos apresentar um método para determinar quão próxima A está de uma matriz de posto menor. O método envolve a fatoração da matriz A em um produto $U \Sigma V^t$, onde U é uma matriz ortogonal $m \times m$, V é uma matriz ortogonal $n \times n$ e Σ é uma matriz extritamente diagonal cujos coeficientes diagonais satisfazem $\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r \geq 0$, ou seja:

$$\Sigma = \begin{bmatrix} \sigma_1 & 0 & 0 & \dots & 0 & 0 \\ 0 & \sigma_2 & 0 & \dots & 0 & 0 \\ \vdots & \vdots & \ddots & \vdots & \vdots & \\ 0 & 0 & 0 & 0 & \sigma_r & 0 \\ 0 & 0 & 0 & 0 & 0 & 0 \end{bmatrix}$$

Os σ_i determinados por essa fatoração são únicos e são chamados valores singulares da matriz A . A fatoração $U \Sigma V^t$ é chamada de Decomposição em Valores Singulares(SVD). As colunas da matriz U , $m \times m$, são os autovetores da matriz AA^t e as colunas da matriz V , $n \times n$, são os autovetores da matriz A^tA . Os r valores singulares da diagonal da matriz Σ , $m \times n$, são raízes quadradas dos autovalores não nulos de ambas as matrizes AA^t e A^tA .

9.2 Desenvolvimento do cálculo da SVD

Damos o seguinte teorema garantindo a SVD de uma matriz A , $m \times n$.

Teorema 9.1

Se A é uma matriz $m \times n$, então a matriz A tem uma Decomposição em Valores Singulares(SVD).

Prova

Temos que $A^t A$ é uma matriz simétrica. Daí, todos os seu autovalores são reais e não negativos. Além do mais, ela pode ser diagonalizada ortogonalmente pela matriz V .

Seja λ um autovalor de $A^t A$ e seja x o autovetor associado. Então,

$$\|Ax\|^2 = x^t A^t A x = \lambda x^t x = \lambda \|x\|^2 \implies \lambda = \frac{\|Ax\|^2}{\|x\|^2} \geq 0.$$

Vamos supor que as colunas da matriz V são ordenadas de modo que os autovalores correspondentes a estas colunas satisfazem:

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_n \geq 0$$

Os valores singulares da matriz A são dados por:

$$\sigma_j = \sqrt{\lambda_j}, \quad j = 1, 2, \dots, n$$

Vamos denotar por r o posto da matriz A . A matriz $A^t A$ também tem posto r . Como $A^t A$ é simétrica, temos que seu posto é igual ao número de autovalores não nulos. Logo,

$$\lambda_1 \geq \lambda_2 \geq \dots \geq \lambda_r \geq 0 \text{ e } \lambda_{r+1} = \lambda_{r+2} = \dots = \lambda_n = 0$$

e o mesmo vale para os valores singulares:

$$\sigma_1 \geq \sigma_2 \geq \dots \geq \sigma_r \geq 0 \text{ e } \sigma_{r+1} = \sigma_{r+2} = \dots = \sigma_n = 0$$

Sejam as matrizes:

$$\mathbf{V}_1 = \begin{bmatrix} v_1 & v_2 & \dots & v_n \end{bmatrix}, \quad \mathbf{V}_2 = \begin{bmatrix} v_{r+1} & v_{r+2} & \dots & v_n \end{bmatrix} \text{ e } \mathbf{\Sigma}_1 = \begin{bmatrix} \sigma_1 & 0 & \dots & 0 \\ 0 & \sigma_2 & \dots & 0 \\ \vdots & \vdots & \ddots & \vdots \\ 0 & 0 & 0 & \sigma_r \end{bmatrix}$$

Assim, escrevemos:

$$\mathbf{\Sigma} = \begin{bmatrix} \mathbf{\Sigma}_1 & \mathbf{0} \\ \mathbf{0} & \mathbf{0} \end{bmatrix} \quad (1)$$

e

$$\mathbf{V} = \begin{bmatrix} V_1 & V_2 \end{bmatrix} \quad (2)$$

Os vetores coluna de V_2 são os autovetores de $A^t A$ associados $\tilde{\lambda} = 0$. Logo,

$$A^t A v_j = \mathbf{0}, \quad j = r+1, r+2, \dots, n$$

e portanto, as colunas de V_2 formam uma base ortonormal para $N(A^t A) = N(A)$.

Daí, escrevemos:

$$A V_2 = \mathbf{0}$$

e como V é uma matriz ortogonal temos:

$$I = V V^t = V_1 V_1^t + V_2 V_2^t$$

Multiplicando esta igualdade pela matriz A , obtemos:

$$A = A I = V_1 V_1^t + V_2 V_2^t = A V_1 V_1^t \quad (3)$$

Até aqui, construímos as matrizes Σ e V dadas por (1) e (2). Vamos mostrar, agora, como construir uma matriz ortogonal U , $m \times m$, tal que:

$$A = U \Sigma V^t, \text{ ou } A V = U \Sigma \quad (4)$$

Comparando as r primeiras colunas de cada lado de (4), vemos que:

$$A v_j = \sigma_j u_j, \quad j = 1, 2, \dots, r$$

Definindo,

$$u_j = \frac{1}{\sigma_j} A v_j, \quad j = 1, 2, \dots, r \quad (5)$$

e

$$\mathbf{U}_1 = \begin{bmatrix} u_1 & u_2 & \dots & u_r \end{bmatrix},$$

segue-se que:

$$A V_1 = U_1 \Sigma_1 \quad (6)$$

As colunas de U_1 formam um conjunto ortonormal, já que:

$$\begin{aligned} u_i^t u_j &= \left(\frac{1}{\sigma_i} v_i^t A^t \right) \left(\frac{1}{\sigma_j} A v_j \right), \quad i, j = 1, 2, \dots, r \\ &= \frac{1}{\sigma_i \sigma_j} v_i^t (A^t A v_j) = \frac{1}{\sigma_i \sigma_j} v_i^t (\sigma_j^2 v_j) \\ &= \frac{\sigma_j}{\sigma_i} v_i^t v_j = \delta_{ij}. \end{aligned}$$

Segue de (5) que cada u_j , $1 \leq j \leq r$, está no espaço coluna de A ($\dim R(A) = r$) $\implies u_1, u_2, \dots, u_r$ forma uma base ortonormal de $R(A)$. Como $m = \dim R(A) + \dim N(A^t)$, temos que o espaço vetorial $N(A^t)$ tem dimensão $m - r$.

Seja $\{u_{r+1}, u_{r+2}, \dots, u_m\}$ uma base para $N(A^t)$ e definimos:

$$\mathbf{U}_2 = \begin{bmatrix} u_{r+1} & u_{r+2} & \dots & u_m \end{bmatrix} \text{ e } \mathbf{U} = \begin{bmatrix} U_1 & U_2 \end{bmatrix}$$

Desta forma, os vetores $u_1, u_2, \dots, u_m$ formam uma base ortonormal para $\mathbf{R}^m$. Logo, U é uma matriz ortogonal. Além do mais, $A = U\Sigma V^t$.

De fato:

De (6) e (3) temos:

$$\mathbf{U}\Sigma\mathbf{V}^t = \begin{bmatrix} U_1 & U_2 \end{bmatrix} \begin{bmatrix} \Sigma_1 & \mathbf{0} \\ \mathbf{0} & \mathbf{0} \end{bmatrix} \begin{bmatrix} V_1^t \\ V_2^t \end{bmatrix} = \mathbf{U}_1\Sigma_1\mathbf{V}_1^t = \mathbf{A}\mathbf{V}_1\mathbf{V}_1^t = \mathbf{A}$$

Observações:

Obs.1: As colunas de U e V fornecem bases ortonormais para os quatro subespaços fundamentais, a saber:

- r primeiras colunas de U : $R(A)$;
- $m - r$ últimas colunas de U : $N(A^t)$;
- r primeiras colunas de V : $R(A^t)$;
- $n - r$ últimas colunas de V : $N(A)$.

Obs.2: A SVD fornece estas bases de uma forma bem especial. Além de ortonormais, tem-se: "a matriz A multiplicada por uma coluna da matriz V produz um múltiplo de uma coluna da matriz U ". Isto decorre diretamente de $AV = U\Sigma$, olhando coluna por coluna.

Obs.3: As conexões com AA^t e A^tA devem valer se a fórmula $U\Sigma V^t$ está correta. Isto pode ser visto facilmente de:

$$AA^t = (U\Sigma V^t)(V\Sigma^t U^t) = U\Sigma\Sigma^t U^t$$

e

$$A^tA = (V\Sigma^t U^t)(U\Sigma V^t) = V\Sigma^t\Sigma V^t$$

Da primeira igualdade, U deve ser a matriz dos autovalores de AA^t . A matriz dos autovalores no meio do produto matricial é $\Sigma\Sigma^t$ que é uma matriz $m \times m$ com $\sigma_1^2, \sigma_2^2, \dots, \sigma_r^2$ na diagonal. Da segunda igualdade, V deve ser a matriz dos autovalores de A^tA . A matriz dos autovalores no meio do produto matricial é $\Sigma^t\Sigma$ tem os mesmos coeficientes $\sigma_1^2, \sigma_2^2, \dots, \sigma_r^2$ na diagonal, mas é uma matriz $n \times n$.

Exemplo 1

Seja a matriz:

$$\mathbf{A} = \begin{bmatrix} 3 & 1 & 1 \\ -1 & 3 & 1 \end{bmatrix} \quad (1)$$

Procedemos como segue:

1) - Determinação da matriz U

Temos que:

$$\mathbf{A}\mathbf{A}^t = \begin{bmatrix} 3 & 1 & 1 \\ -1 & 3 & 1 \end{bmatrix} \begin{bmatrix} 3 & -1 \\ 1 & 3 \\ 1 & 1 \end{bmatrix} = \begin{bmatrix} 11 & 1 \\ 1 & 11 \end{bmatrix}$$

cujos autovalores são dados por:

$$\begin{bmatrix} 11 & 1 \\ 1 & 11 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \end{bmatrix} = \lambda \begin{bmatrix} x_1 \\ x_2 \end{bmatrix}$$

Onde obtemos, $\lambda_1 = 10$ e $\lambda_2 = 12$, cujos autovetores correspondentes são:

$$\begin{bmatrix} 1 \\ -1 \end{bmatrix} \text{ e } \begin{bmatrix} 1 \\ 1 \end{bmatrix}$$

Segundo a ordenação dos autovalores, obtemos a matriz:

$$\begin{bmatrix} 1 & 1 \\ 1 & -1 \end{bmatrix}$$

Nomeando por v_1 e v_2 os vetores coluna desta matriz e aplicando o processo de ortogonalização de Gram-Schmidt, obtemos:

$$\mathbf{u}_1 = \frac{\mathbf{v}_1}{\|\mathbf{v}_1\|} = \begin{bmatrix} 1/\sqrt{2} \\ 1/\sqrt{2} \end{bmatrix}$$

$$\mathbf{w}_2 = \mathbf{v}_2 - (\mathbf{u}_1 \cdot \mathbf{v}_2)\mathbf{u}_1 = \begin{bmatrix} 1 \\ -1 \end{bmatrix}$$

e normalizando, obtemos:

$$\mathbf{u}_2 = \frac{\mathbf{w}_2}{\|\mathbf{w}_2\|} = \begin{bmatrix} 1/\sqrt{2} \\ -1/\sqrt{2} \end{bmatrix}$$

Dando, finalmente, a matriz:

$$\mathbf{U} = \begin{bmatrix} 1/\sqrt{2} & 1/\sqrt{2} \\ 1/\sqrt{2} & -1/\sqrt{2} \end{bmatrix}$$

2) - Determinação da matriz V

é feita de forma similar à obtenção da matriz U.

Neste caso, calculamos:

$$\mathbf{A}^t \mathbf{A} = \begin{bmatrix} 3 & -1 \\ 1 & 3 \\ 1 & 1 \end{bmatrix} \begin{bmatrix} 3 & 1 & 1 \\ -1 & 3 & 1 \end{bmatrix} = \begin{bmatrix} 10 & 0 & 2 \\ 0 & 10 & 4 \\ 2 & 4 & 2 \end{bmatrix}$$

cujos autovalores são dados por:

$$\begin{bmatrix} 10 & 0 & 2 \\ 0 & 10 & 4 \\ 2 & 4 & 2 \end{bmatrix} \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix} = \lambda \begin{bmatrix} x_1 \\ x_2 \\ x_3 \end{bmatrix}$$

Onde obtemos, $\lambda_1 = 0$, $\lambda_2 = 10$ e $\lambda_3 = 12$ cujos autovetores correspondentes são:

$$\begin{bmatrix} 1 \\ 2 \\ -5 \end{bmatrix}, \begin{bmatrix} 2 \\ -1 \\ 0 \end{bmatrix} \text{ e } \begin{bmatrix} 1 \\ 2 \\ 1 \end{bmatrix}$$

Segundo a ordenação dos autovalores, obtemos a matriz:

$$\begin{bmatrix} 1 & 2 & 1 \\ 2 & -1 & 2 \\ 1 & 0 & -5 \end{bmatrix}$$

Nomeando por y_1, y_2 e y_3 os vetores coluna desta matriz e aplicando o processo de ortogonalização de Gram-Schmidt, obtemos:

$$\mathbf{v}_1 = \frac{\mathbf{y}_1}{\|\mathbf{y}_1\|} = \begin{bmatrix} 1/\sqrt{6} \\ 2/\sqrt{6} \\ 1/\sqrt{6} \end{bmatrix}$$

$$\mathbf{w}_2 = \mathbf{y}_2 - (\mathbf{v}_1 \cdot \mathbf{y}_2) \mathbf{v}_1 = \begin{bmatrix} 2 \\ -1 \\ 0 \end{bmatrix}$$

e normalizando, obtemos:

$$\mathbf{v}_2 = \frac{\mathbf{w}_2}{\|\mathbf{w}_2\|} = \begin{bmatrix} 2/\sqrt{5} \\ -1/\sqrt{5} \\ 0 \end{bmatrix}$$

$$\mathbf{w}_3 = \mathbf{y}_3 - (\mathbf{v}_1 \cdot \mathbf{y}_3) \mathbf{v}_1 - (\mathbf{v}_2 \cdot \mathbf{y}_3) \mathbf{v}_2 = \begin{bmatrix} -2/3 \\ -4/3 \\ 10/3 \end{bmatrix}$$

e normalizando, obtemos:

$$\mathbf{v}_3 = \frac{\mathbf{w}_3}{\|\mathbf{w}_3\|} = \begin{bmatrix} 1/\sqrt{30} \\ 2/\sqrt{30} \\ -5/\sqrt{30} \end{bmatrix}$$

Dando, finalmente, a matriz:

$$\mathbf{V} = \begin{bmatrix} 1/\sqrt{6} & 2/\sqrt{5} & 1/\sqrt{30} \\ 2/\sqrt{6} & -1/\sqrt{5} & 2/\sqrt{30} \\ 1/\sqrt{6} & 0 & -5/\sqrt{30} \end{bmatrix}$$

Para a matriz S , tomamos a raiz quadrada dos maiores autovalores ordenados na diagonal, obtendo:

$$\mathbf{S} = \begin{bmatrix} \sqrt{12} & 0 & 0 \\ 0 & \sqrt{10} & 0 \end{bmatrix}$$

Observe que os maiores autovalores de U e V são os mesmos e o autovetor nulo de V é descartado.

Se A é uma matriz, $m \times n$, onde $\text{posto}(A) = r$ e $0 < k < r$, podemos usar a decomposição em valores singulares para encontrar uma matriz em $\mathbf{R}^{m \times n}$ de posto k o mais próximo possível de A em relação à norma de Frobenius. Seja $\mathcal{M}$ o conjunto de todas as matrizes $m \times n$ de posto menor ou igual a k . Pode-se mostrar que existe uma matriz $X \in \mathcal{M}$ tal que:

$$\|A - X\|_F = \min_{S \in \mathcal{M}} \|A - S\|_F$$

Supondo que este mínimo possa ser atingido, vamos dar alguns resultados propostos por Leon [7] para obtenção de tal matriz X . Inicialmente, damos o seguinte lema:

Lema 9.1

Se A é uma matriz, $m \times n$, e Q é uma matriz, $m \times n$ ortogonal, então

$$\|QA\|_F = \|A\|_F$$

Prova

$$\begin{aligned} \|QA\|_F^2 &= \|(Qa_1, Qa_2, \dots, Qa_n)\|_F^2 = \sum_{i=1}^n \|Qa_i\|_2^2 = \\ &= \sum_{i=1}^n \|a_i\|_2^2 = \|A\|_F^2 \end{aligned}$$

Pelo lema, se a matriz A tem uma decomposição em valores singulares $U\Sigma V^t$, então

$$\|A\|_F = \|\Sigma V^t\|_F$$

Como

$$\|\Sigma V^t\|_F = \|(\Sigma V^t)^t\|_F = \|V\Sigma^t\|_F = \|\Sigma^t\|_F$$

segue que

$$\|A\|_F = (\sigma_1^2 + \sigma_2^2 + \dots + \sigma_n^2)^{1/2}$$

Damos agora, o seguinte teorema:

Teorema 9.2

Sejam $A = U\Sigma V^t$ uma matriz, $m \times n$ e $\mathcal{M}$ o conjunto de todas as matrizes $m \times n$ de posto menor ou igual a k , onde $0 < k < \text{posto}(A)$. Se X é uma matriz em $\mathcal{M}$ satisfazendo

$$\|A - X\|_F = \min_{S \in \mathcal{M}} \|A - S\|_F$$

então,

$$\|A - X\|_F = (\sigma_{k+1}^2 + \sigma_{k+2}^2 + \dots + \sigma_n^2)^{1/2}$$

Em particular, se $A' = U\Sigma'V^t$, onde

$$\Sigma' = \begin{bmatrix} \sigma_1 & 0 & \dots & \cdot & & \\ 0 & \sigma_2 & \dots & \cdot & & \mathbf{0} \\ \vdots & \vdots & \ddots & \vdots & & \\ \cdot & \cdot & \cdot & \sigma_k & & \\ & \mathbf{0} & & & & \mathbf{0} \end{bmatrix} = \begin{bmatrix} \Sigma_1 & \mathbf{0} \\ \mathbf{0} & \mathbf{0} \end{bmatrix} \quad (1)$$

então,

$$\|A - A'\|_F = (\sigma_{k+1}^2 + \sigma_{k+2}^2 + \dots + \sigma_n^2)^{1/2} = \min_{S \in \mathcal{M}} \|A - S\|_F$$

Prova

(ver Leon [7])

Se a matriz A tem posto n , então

$$A' = U \begin{bmatrix} \sigma_1 & 0 & \dots & 0 & 0 \\ 0 & \sigma_2 & \dots & 0 & 0 \\ \vdots & \vdots & \ddots & \vdots & \vdots \\ 0 & 0 & \cdot & \sigma_{n-1} & 0 \\ 0 & 0 & \dots & 0 & 0 \end{bmatrix} V^t = \sigma_1 \mathbf{E}_1 + \dots + \sigma_{n-1} \mathbf{E}_{n-1}$$

vai ser uma matriz de posto $n - 1$ mais próximo possível de A em relação à norma de Frobenius. Do mesmo modo, $A'' = \sigma_1 E_1 + \dots + \sigma_{n-2} E_{n-2}$ vai ser a matriz

mais próxima de posto $n - 2$, e assim por diante. Em particular, se A é uma matriz invertível $n \times n$, então A' é singular e $\|A - A'\|_F = \sigma_n$. Logo, σ_n pode ser considerado como uma medida de quão próximo uma matriz está de ser singular.

Vimos na seção 2 que o número de condição de uma matriz A é dado por $\text{cond}_2(A) = \|A\|_2 \|A^{-1}\|_2$, e quando este número é muito grande, a matriz A é dita mal condicionada.

Os seguintes resultados nos permite calcular o número de condição de uma matriz A .

Teorema 9.3

Se A é uma matriz $m \times n$ com decomposição em valores singulares $U\Sigma V^t$, então

$$\|A\|_2 = \sigma_1$$

Prova

(ver Leon [7])

Corolário 9.1

Se a matriz A , $n \times n$, é invertível e com decomposição em valores singulares $U\Sigma V^t$, então

$$\text{cond}_2(A) = \sigma_1 / \sigma_n$$

Prova

(ver Leon [7])

9.3 Aplicação da SVD no Método dos Mínimos Quadrados

Vimos, anteriormente, que a solução de um sistema linear inconsistente $Ax = b$ com m equações e n incógnitas satisfaz:

$$A^t A \bar{x} = A^t b$$

Se as colunas da matriz A são linearmente independentes, então a matriz $A^t A$ é invertível e

$$\bar{x} = (A^t A)^{-1} A^t b$$

Vamos analisar as seguintes dificuldades encontradas no sistema linear $Ax = b$:

- 1) As linhas da matriz A podem ser linearmente dependentes;
- 2) As colunas da matriz A podem ser linearmente dependentes.

No primeiro caso, as equações podem não ter solução, pois o vetor b não está no espaço coluna da matriz A . Para contornar o problema, projetamos o vetor b no

espaço coluna da matriz A . Ao invés de resolver o sistema linear $Ax = b$, resolvemos o sistema linear $A\bar{x} = p$ onde $p = A(A^t A)^{-1} A^t b$ que pertence ao espaço coluna de b . Para o segundo caso, escolhemos uma solução particular $A\bar{x} = p$, dada pela seguinte regra:

”A solução ótima de $A\bar{x} = p$ é aquela que apresenta comprimento mínimo.”

A solução ótima em ambos os casos será chamada de x^+ , dada pela pseudoinversa.

Exercícios Capítulo IX

1 - Calcule os valores singulares e a decomposição em valores singulares das seguintes matrizes:

a)

$$\mathbf{A} = \begin{bmatrix} 3 & 12 & -10 \\ 1 & -1 & 5 \\ -2 & -8 & 5 \end{bmatrix}$$

b)

$$\mathbf{B} = \begin{bmatrix} 1 & 5 & 9 \\ 2 & 6 & 10 \\ 3 & 7 & 11 \\ 4 & 8 & 12 \end{bmatrix}$$

2 - Diz-se que uma matriz A , $m \times n$, tem **posto completo** se $\text{posto}(A) = \min\{m, n\}$. A decomposição em valores singulares nos permite medir o quão próximo a matriz A está do posto completo. Se $s_{\min}$ é o menor valor singular de A e $s_{\min} \neq 0$, então a distância de A ao conjunto de matrizes com posto $r = \min\{m, n\} - 1$ é $s_{\min}$. Determine a distância de cada uma das matrizes dadas para as matrizes do mesmo tamanho cujo posto é $r = \min\{m, n\} - 1$:

a)

$$\mathbf{A} = \begin{bmatrix} 1 & 3 & 2 \\ 4 & 1 & 0 \\ 2 & -5 & -4 \\ 1 & 2 & 1 \end{bmatrix}$$

b)

$$\mathbf{A} = \begin{bmatrix} 1 & 0 & 0 & -1 & 0 \\ -1 & 1 & 1 & 0 & 0 \\ 0 & 0 & 1 & -2 & -1 \\ 0 & 1 & 0 & 1 & 1 \end{bmatrix}$$

3 - Encontre a norma $\|\cdot\|_2$ para as matrizes do exercício **1** usando a decomposição em valor singular.

4 - Encontre o número de condição (cond_2) para a matriz A , $n \times n$, a seguir,

usando a decomposição em valor singular de A :

$$\mathbf{A} = \begin{bmatrix} 1 & -1 & -1 & \dots & -1 & -1 \\ 0 & 1 & -1 & \dots & -1 & -1 \\ 0 & 0 & 1 & \dots & -1 & -1 \\ \vdots & \vdots & \vdots & \ddots & -1 & -1 \\ 0 & 0 & 0 & \dots & 1 & -1 \\ 0 & 0 & 0 & \dots & 0 & 1 \end{bmatrix}$$

Obs. Tome $n = 100$.

Implementação dos Exercícios do Capítulo IX em Matlab

```
1 clear;
2
3 disp ( 'Lista 9');
4 disp ( ' ');
5
6 disp ( 'Exercicio 1a');
7 disp ('Achar os valores singulares e a decomposicao em valores
    singulares da matriz:');
8 %
9 A=[3 12 -10;1 -1 5;-2 -8 5];
10 A
11 disp ( ' Deconposicao SVD de A');
12 [U,S,V]=svd(A)
13
14 disp ( ' ')
15 disp ( '
    -----,
    )
16 disp ( ' ');
17
18 disp ( 'Exercicio 1b');
19 disp ('Achar os valores singulares e a decomposicao em valores
    singulares da matriz:');
20 %
21 B=[1 5 9;2 6 10;3 7 11;4 8 12];
22 B
23 disp ( ' Deconposicao SVD de B');
24 [U,S,V]=svd(B)
25
26 disp ( ' ')
27 disp ( '
    -----,
    )
28 disp ( ' ');
29
30 disp ( 'Exercicio 2a');
31 disp ('Determinar a distancia D da matriz A para as matrizes do
    mesmo tamanho cujo posto e  $r=\min\{m,n\}-1$  ');
32
33 A=[1 3 2;4 1 0;2 -5 -4;1 2 1];
34 A
35 disp ('0 posto de A e:');
36 rank(A)
37
```



```

38 disp (' Deconposicao SVD de A');
39 [U,S,V]=svd(A)
40
41 disp ('A distancia e:')
42 S(rank(A),rank(A))
43
44 disp ('      ')
45 disp ('
-----,
      )
46 disp ('      ');
47
48 disp ('Exercicio 2b');
49 disp ('Determinar a distancia D da matriz A para as matrizes do
      mesmo tamanho cujo posto e r=min{m,n}-1')
50
51 A=[1 0 0 -1 0;-1 1 1 0 0;0 0 1 -2 -1;0 1 0 1 1];
52 A
53 disp (' O posto de A e:')
54 rank(A)
55
56 disp (' Deconposicao SVD de A');
57 [U,S,V]=svd(A)
58
59 disp ('A distancia e:')
60 S(rank(A),rank(A))
61
62 disp ('      ')
63 disp ('
-----,
      )
64 disp ('      ');
65
66 disp ('Exercicio 3a');
67 disp ('Encontre a norma ||.||2 para a matriz A do exercicio 1
      usando a decomposicao em valor singular')
68 A=[3 12 -10;1 -1 5;-2 8 5];
69 A
70 disp (' Deconposicao SVD de A');
71 [U,S,V]=svd(A)
72 disp('||A||2=sigma1(A)');
73 S(1,1)
74 disp('Usando norm(A)');
75 norm(A)
76

```

```

77 disp ( '      ')
78 disp ( '
-----,
    )
79 disp ( '      ');
80
81 disp ( 'Exercicio 3a');
82 disp ( 'Encontre a norma ||.||2 para a matriz B do exercicio 1
    usando a decomposicao em valor sigular')
83
84 B=[1 5 9;2 6 10;3 7 11;4 8 12]
85 B
86 disp ( ' Deconposicao SVD de B');
87 [U,S,V]=svd(B)
88 disp('||B||2=signma1(B)');
89 S(1,1)
90 disp('Usando norm(B)');
91 norm(B)
92
93 disp ( '      ')
94 disp ( '
-----,
    )
95 disp ( '      ');
96
97
98 disp ( 'Exercicio 4');
99 disp ( 'Encontre o numero de condicao (cond2) para a matriz A, n x n
    usando a decomposicao singular de A para n=100')
100 disp('Como n e muito grande, sera feito um loop com n=10, 30, 40,
    50 e 100, para que seja observada a variaÃ§Ã£o do numero de
    condicao.')
101 disp('Tambem foi suprimida a impressao da matriz devido a seu
    tamanho')
102
103 Valores=[10 30 40 50 100];
104
105 for N=Valores
106     N
107     A(1:N,1:N)=0;
108     for i=1:N
109         for j=1:N
110             if i==j
111                 A(i,j)=1;
112                 end

```

```

113         if i<j
114             A(i,j)=-1;
115         end
116     end
117 end
118
119 disp('Calculando por SVD')
120 disp(' ')
121
122 [U,S,V]=svd(A);
123
124 disp('S(1,1)')
125 S(1,1)
126 disp('S(N,N)')
127 S(N,N)
128
129 disp('Cond2 = S(1,1)*S(N,N)')
130 Cond2=S(1,1)/S(N,N)
131
132 disp(' ')
133 disp('Calculando da forma tradicional')
134 disp(' ')
135
136 disp('Cond2 = norm(A,2)*norm(inv(A),2)');
137 cond=norm(A,2)*norm(inv(A),2)
138 end

```

Bibliografia

- [1] Albrecht, P. - Análise Numérica -um curso moderno, *LTC Ed.*, 240 p., 1973.
- [2] Apostol, T. - Cálculo com Funções de uma Variável, *Reverté Ed.*, 771 p., 2006.
- [3] Apostol, T. - Cálculo com Funções de Várias Variáveis e álgebra Linear, *Reverté Ed.*, 752 p., 2008.
- [4] Anton, H. e Rorres, C. - Álgebra Linear com Aplicações, *Bookman Ed.*, 572 p., 2008.
- [5] Burden, R. e Faires, D. - Análise Numérica, *Thomson Ed.*, 740 p., 2003.
- [6] Golub, G. and Van Loan, C. - Matrix Computations, *Johns Hopkins Univ. Press*, 694 p., 1996.
- [7] Leon, S.J. - Álgebra Linear com Aplicações, *LTC Ed.*, 390 p., 2008.
- [8] Strang, G. - Álgebra Linear e suas Aplicações, *Cengage Learning Ed.*, 456 p., 2010.
- [9] Wendroff, B. - Theoretical numerical analysis, *Academic Press Ed.*, New York, 1966.